



软件导刊

Software Guide

ISSN 1672-7800,CN 42-1671/TP

《软件导刊》网络首发论文

题目：传统到深度学习：图像去噪算法综述
作者：王潇旖，仲彦军，资政
网络首发日期：2025-09-29
引用格式：王潇旖，仲彦军，资政. 传统到深度学习：图像去噪算法综述[J/OL]. 软件导刊. <https://link.cnki.net/urlid/42.1671.TP.20250928.1705.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基金项目：自治区创新环境(人才、基地)建设专项-自然科学基金计划基金项目(2021D01A125); 新疆维吾尔自治区高校科研计划基金项目(XJEDU2020Y027); 中央支持地方高校改革发展专项资金项目(新疆师范大学)

作者简介：王潇漪(2000-), 女, CCF学生会员, 新疆师范大学数学科学学院硕士研究生, 研究方向为数字图像处理、模式识别等; 仲彦军(1981-), 男, 博士, 新疆师范大学数学科学学院副教授, 研究方向为计算机图形学和数据可视化方向; 资政(2001-), 男, 新疆师范大学数学科学学院硕士研究生, 研究方向为数字图像处理、计算机图形学。本文通讯作者: 仲彦军。

DOI: 10.11907/rjcdk.251288

传统到深度学习：图像去噪算法综述

王潇漪^{1,2}, 仲彦军^{1,2}, 资政^{1,2}

(1. 新疆师范大学 数学科学学院;

(2. 新疆师范大学 CAD&CG实验室, 新疆 乌鲁木齐 830000)

摘要：图像去噪是数字图像处理的基础步骤，对图像质量的提高和后续处理起着关键性的作用。受限于拍摄设备精度以及传输环境干扰等因素的影响，图像在成像过程中产生的各种混合噪声导致图片模糊、细节不清晰以及色度失真，将不断影响着人们的生活和工作，人们对获取更准确和更清晰的图片需求日益强烈，因此图像去噪显得尤为重要。根据去噪算法的类型，将算法分为滤波法、低秩优化法、稀疏优化法、深度学习等方法，从处理速度、抗噪能力、边缘保持等方面进行分析，并通过PSNR等评价指标进行比较。评估了各种方法针对不同图片的去噪效果以及优缺点，探讨了各方法的试用场景以及发展方向，并对动态图像的实时去噪、参数自适应调整以及不依赖大规模数据集的去噪方法进行展望。

关键词：图像去噪、数字图像处理、边缘保持、深度学习、实时去噪

From Traditional to Deep Learning: A Survey of Image Denoising Methods

WANG Xiaoyi^{1,2}, ZHONG Yanjun^{1,2}, ZI Zheng^{1,2}

(1. School of Mathematical Sciences, Xinjiang Normal University;

(2. CAD&CG Laboratory, Xinjiang Normal University, Urumqi 830000, China)

Abstract: Image denoising is a fundamental step in digital image processing and plays a crucial role in improving image quality and enabling subsequent processing. Constrained by factors including the precision limitations of imaging devices and transmission environment interference, various mixed noise artifacts generated during the imaging process lead to image blurring, compromised detail resolution, and chromatic distortion. These degradations persistently affect both daily life and professional activities, while the growing demand for acquiring higher-precision and clearer images makes image denoising particularly crucial. Based on denoising algorithm typology, these methods are categorized into filtering-based approaches, low-rank optimization, sparse optimization, and deep learning-based frameworks. Their performance is systematically analyzed in terms of processing speed, noise suppression capability, and edge preservation characteristics, with comparative evaluations conducted through quantitative metrics such as PSNR. A comprehensive evaluation of denoising performance across methodologies is conducted for diverse image types, systematically benchmarking their strengths and limitations. The analysis further delineates applicable scenarios and development trajectories for each approach, with particular emphasis on emerging frontiers including real-time denoising for dynamic imagery, parameter self-adaptation mechanisms, and data-efficient paradigms that circumvent reliance on large-scale training datasets.

Keywords: image denoising; digital image processing; edge preservation; deep learning; real-time denoising

0 引言

图像在实际应用中可能存在各种各样的噪声，这些噪声可能来源于成像系统的光电转换噪声、传输信道中的带宽限制、存储介质的物理损伤以及环境中的电磁干扰等多重因素。噪声的存在不仅导致图像视觉保真度的多维度劣化，包括边缘轮廓模糊化、高频细节衰减、色度信息失真以及信噪比显著下降，更会直接影响后续计算机视觉任务的精度，如图像分割的边界定位误差、目标检测的误报率上升以及特征匹配的可靠性降低等关键性能指标。所以，对图像

进行去噪是至关重要的。它不仅能提升图像的视觉质量，还能显著改善后续计算机视觉任务的精度和可靠性。

图像去噪作为数字图像处理的关键领域,其本质在于建立噪声分布与图像本征结构的解耦机制,通过数学建模与算法设计实现噪声抑制与特征保真的双重优化目标去噪算法的性能由噪声先验建模精度与特征重构能力的协同作用所决定,直接影响重建图像的峰值信噪比(PSNR)和结构相似性(SSIM)等客观指标。根据Liu等^[1-3]的研究综述,我们可以清晰地看到图像去噪方法的发展脉络。过去的传统图像去噪方法主要依赖于一些基于数学模型和信号处理的算法,例如小波变换、滤波器等。传统的去噪方法虽然在一定程度上能够去除图像中的噪声,但也有一定的局限性,比如对复杂噪声的处理不够完善,和对真实图像的泛化能力较弱。为了提升去噪模型对不同类型噪声和图像的去噪效果,深度学习方法应运而生。深度学习去噪方法能够根据神经网络自动提取和学习图像特征,并对不同噪声水平的噪声实现自适应去噪,从而达到将干净的图像从噪声图像中还原的目的。和传统去噪方法不同的是,基于深度学习的图像去噪方法具有更强的适应性和鲁棒性,能够更好地处理各种类型的噪声,同时在保持图像边缘方面也表现出了显著的优势。

本文主要对从传统到深度的去噪方法进行总结,主要分为四部分:(1)主要介绍图像去噪面临的挑战;(2)对于图像去噪方法的介绍,传统方法主要分为空间域滤波、变换域滤波、统计模型、稀疏表示、聚类低秩等,而深度学习方法主要分为基于卷积神经网络(CNN)、基于生成对抗网络(GAN)、基于图神经网络(GNN)等;(3)对比实验;(4)总结及未来展望。

1 噪声模型及面临的挑战

通常,图像去噪的建模过程为:

$$X = Y + N \quad (1)$$

其中, X 表示观测到的噪声图像, Y 表示未知的干净噪声图像, N 表示各种类型的噪声,主要包括高斯噪声、椒盐噪声、泊松噪声等。

随着人们对干净图像质量的需求越来越高,图像去噪技术也在不断更新。传统去噪方法有较为成熟的应用时,基于神经网络结构和训练的深度学习方法也在不断崛起。传统方法和基于深度学习方法的碰撞,使得图像去噪技术不断提升,日益完善。然而,在这不断发展的进程中,图像去噪仍面临着诸多亟待攻克挑战:

(1) 噪声类型复杂: 图像噪声类型多样,且实际场景中多为混合噪声,其类型和强度未知,增加了去噪难度。

(2) 数据获取困难: 深度学习方法需要大量高质量的训练数据,但获取和标注这些数据耗时且成本高。

(3) 模型泛化能力不足: 大多数去噪模型在特定数据集上表现良好,但对未知噪声类型或新场景的适应性差。

(4) 去噪与细节平衡: 在去除噪声的同时,需要尽可能保留图像的细节信息。

(5) 计算复杂度高: 深度学习模型的训练和推理需要大量计算资源,难以在实时应用或资源受限的设备上高效运行。

2 传统去噪

2.1 空间滤波

传统图像去噪方法以空间域滤波为核心,通过邻域像素操作实现噪声抑制与细节恢复。Tukey等^[2-3]提出来的均值和中值滤波,通过邻域像素的平均值或中值替换当前像素值,可快速消除孤立噪声,但易导致边缘模糊。Kumar等^[4-5]提出来的采用高斯核加权平均滤波,在降噪同时保留部分边缘信息,但高噪声场景下仍存在过度平滑问题。Tomasi等人^[5-7]提出来的双边滤波,通过像素相似性保持边缘,但计算复杂度较高且对高频噪声敏感。

针对前面滤波方法的局限性,非局部均值(NLM)算法^[8]通过充分挖掘图像的自相似性,实现更优的细节保持效果:

$$G(x) = \frac{1}{C(x)} \sum_{y \in \Omega} w(x, y) \cdot I(y) \quad (2)$$

其中, $G(x)$ 是滤波后的图像在位置 x 的像素值, Ω 是搜索窗口的大小, $w(x, y)$ 表示权重函数, $I(x)$ 是输入图像在位置 x 的像素值, $C(x)$ 表示归一化因子。

尽管NLM显著提升去噪质量,但其全图相似性计算会导致时间复杂度高,过度平滑风险。为了减少去噪时间和提高计算效率,Wang等人^[9-17]通过快速搜索、旋转不变性设计等方法降低时间复杂度,以及Brun等人^[18-24]引入自适应参数和块匹配优化等策略提升细节保留能力。

2.2 变换域滤波

变换域滤波的核心思想是通过频域特征分离实现去噪,根据基函数的不同,主要方法可分为:基于全局频谱分析,适合周期性噪声去除的傅里叶变换滤波^[25-26]。通过多尺度分解实现局部特征保留,对非平稳噪声有效的小波变换滤波^[27-28]和利用能量压缩特性,在分块处理中平衡去噪与细节保留的离散余弦变换滤波。

由Dabov等人提出来的BM3D^[29]是最经典的变换域滤波方法,其主要思想是通过块匹配实现分组,得到一个三维的组合,再对其进行协同变换和滤波,最后对滤波结果进行整合,从而得到最后的降噪图像。

BM3D算法^[29]通过三维变换域收缩实现高效噪声分离,但对除高斯白噪声以外的其他噪声适应性有限。针对彩色图像特性,Dabov等人在BM3D算法的基础上进一步提出CBM3D^[30],将RGB转换为YUV空间,利用亮度分量Y主导块匹配过程,并在色度通道UV上采用轻量化滤波,但在保持色彩一致性的同时,可能损失高饱和度区域的色度细节。

为了进一步提高去噪效果,Maggioni等人提出了块匹配和四维滤波的BM4D算法^[31],该算法主要利用立方体的体素堆叠成组合,并进行四维变换,进行变换后的组合通过系数的收缩可以有效地分离原始图像和噪声,进而达到去噪目的,BM4D算法主要在三维图像去噪方面应用广泛。

2.3 统计模型

基于统计模型的去噪方法通过建立图像与噪声的联合概率分布,利用统计推断理论实现噪声分离。其通用框架可表示为:

$$\hat{x} = \arg \max_x P(x|y) = \arg \max_x \frac{P(y|x)P(x)}{P(y)} \quad (3)$$

其中, $P(y|x)$ 为噪声似然项, $P(x)$ 为图像先验项。

在基于统计模型的去噪方法中,最大后验概率模型(MAP)^[32]凭借其贝叶斯框架的理论优势取得显著去噪效果,但其性能受限于先验假设的合理性约束。马尔可夫随机场(MRF)^[33]通过空间相关性建模在结构完整性恢复方面表现突出,但存在迭代收敛速度较慢的缺陷。相比之下,高斯混合模型(GMM)^[34]无需依赖外部数据就能完成去噪,但在处理复杂场景时易受模型复杂度制约。由LEBaum等人提出的隐马尔可夫模型(HMM)^[35]虽然具备时序特征建模的独特优势,却面临训练过程收敛困难的技术挑战。

近年来,统计模型与深度学习的融合逐渐成为研究热点。深度学习在图像去噪中展现出强大的能力,但对训练数据依赖较大,且难以处理未见过的噪声类型。统计建模方法具有较强的理论基础和对噪声的适应性,将二者结合,通过构建合适的网络来学习统计理论,可以更好地捕捉图像的先验信息和噪声属性,从而提高去噪效果。

2.4 稀疏表示

稀疏表示方法要求提取噪声图像块中的稀疏成分,并利用这些稀疏成分进行线性组合,以此达到降噪的目的。许多现有的图像去噪技术都利用了自然图像的稀疏性知识,作为一种

字典学习方法,稀疏表示模型可以从数据集中学习,也可以通过K奇异值分解(K-SVD)算法从图像本身学习。

K-SVD去噪算法^[36]是由Aharon等人提出来的,其主要主要通过字典更新来实现去噪,即从有噪声的图像 Y 中学习字典 D :

$$\min_{D,X} \|Y - DX\|_F^2 + \lambda \|x_i\|_1 \quad (4)$$

其中, Y 表示观测到的图像矩阵, D 表示字典矩阵, X 表示稀疏编码矩阵, λ 是一个正则化参数, $\|x_i\|_1$ 是向量 x_i 的 L_1 范数。

尽管K-SVD算法的去噪效果比较好,但在计算时可能会陷入局部最小值,这就导致最终学习到的字典不是全局最优的。Dong等人在2012年提出来的NCSR去噪模型^[37-38]结合了非局部自相似性(NSS)和稀疏表示来提高图像非局部之间的相关性,以此来找到全局最优解:

$$\alpha^* = \arg \min \|Y - D\alpha\|_F^2 + \lambda \|\alpha_i - \beta_i\|_1 \quad (5)$$

其中, Y 表示观测到的图像矩阵, D 是字典矩阵, α 表示系数矩阵, λ 是一个正则化参数, 用于两项之间的权衡控制, $\|\alpha_i - \beta_i\|_1$ 表示向量 $\alpha_i - \beta_i$ 的 L_1 范数。

NCSR模型将非局部自相似性(NSS)^[39]自然地融入稀疏表示框架中,使得在恢复图像细节和纹理区域非常有效,能够降低NCSR模型的复杂度,特别是能够快速处理复杂图像。




Fig.1 Comparison of different deep learning denoising methods on the Set12 dataset when $\sigma=25$

图1 $\sigma=25$ 时不同传统去噪方法在Set12 数据集上的去噪对比

从图1中可以看出,WNNM 算法对图像的去噪效果优于其它传统算法,其优越性不仅在峰值信噪比 (PSNR)指标上体现出来,同时也在图像细节恢复和边缘保持方面有所体现,与协同滤波算法(BM3D)相比,WNNM算法在降噪和边缘保护方面具有巨大的潜力。

2.5 聚类低秩

图像通常具有低秩结构,通过低秩分解可以将噪声与图像信息分离,从而实现去噪。低秩模型在图像去噪模型方面取得了良好的效果,通过低秩分解可以将图像中的噪声与有用信息进行分离,从而达到去噪目的。

基于低秩矩阵分解的方法在图像处理中具有广泛的应用,其核心思想是将图像矩阵分解为一个低秩矩阵和一个噪声矩阵,从而实现去噪。例如,Dong等人提出了一种基于SVD的低秩方法^[41],该方法主要通过对奇异值迭代收缩来去除噪声,但过度依赖奇异值的截断可能会影响去噪效果。为了减少对奇异值的依赖,Cao等人在2015年提出了LRMF算法^[42-44],该算法的去噪过程可以表示为一个优化问题,用核范数最小化来近似低秩函数,将问题转化为一个凸优化问题:

$$\min_{L,S} \|Y - L - S\|_F^2 + \lambda_1 \|L\|_* + \lambda_2 \|S\|_1 \quad (6)$$

其中, Y 表示观测到的矩阵, L 为低秩矩阵代表图像的主要成分, S 代表噪声, λ_1 、 λ_2 为正则化参数, $\|L\|_*$ 是矩阵 L 的核范数, $\|S\|_1$ 是矩阵 S 的 L_1 范数。

LRMF算法^[42]是经典的低秩去噪算法,不仅在去噪效果方面有很大的优势,还在重建平滑和纹理区域方面表现优异,但在去噪过程中,需要合理选择参数以平衡去噪效果

和图像质量。为了进一步提升去噪效果,核范数最小化(NNM)^[45]通过最小化噪声图像和原始图像之间的范数来实现去噪,其目标函数为:

$$X_i = \arg \min_{X_i} \|Y_i - X_i\|_F^2 + \lambda \|X_i\|_* \quad (7)$$

其中, λ 是一个正数, Y_i 表示为噪声块矩, X_i 表示为降噪后的矩阵, $\|X_i\|_*$ 是矩阵 X_i 的核范数。

在NNM算法中,对所有的奇异值进行软阈值收缩可能会使得图像的信息主要集中在数值较大的地方,因而会导致去噪效果不好且图像细节恢复不够完善。为了提高去噪效果,Gu等人在NNM算法的基础上诞生了WNNM算法^[40],对不同的奇异值进行不同的软阈值收缩,使得在去噪的基础上更好地完善图像边缘细节,但其迭代成本较以往的去噪方法来说也在不断提高。

3 深度学习去噪

传统的图像去噪算法在处理噪声时高速且有效,但对于复杂的噪声模式和图像细节方面仍然存在局限性。近几年基于深度学习的图像去噪算法在图像处理方面获得了极大的进展,与传统图像去噪算法不同,深度学习的去噪模型具有更高的灵活性和适应性,能够处理各种复杂的噪声类型和不同的应用场景。基于深度学习的图像去噪方法主要分为基于卷积神经网络(CNN)、基于生成对抗网络(GAN)、基于图神经网络(GNN)、基于Transformer、基于扩散模型以及基于BSN等。

3.1 基于卷积神经网络(CNN)

3.1.1 自监督学习

目前,基于卷积神经网络(CNN)的图像去噪方法主要分为自监督学习和监督学习两大类。自监督学习N2N^[89]、N2V^[90]、N2S^[91]、S2S^[92]等是利用噪声图像自身进行训练,不需要依赖成对的噪声图像和干净图像。图2表示的是N2V论文中的网络结构图,其去噪流程用公式(8)和(9)来表示:




Fig. 2 The structure diagram of the N2V network

图2 N2V 网络结构图

训练阶段: 对于输入像素 i , 使用其感受野内的图像块作为输入, 通过参数 θ 来预测目标像素 $\hat{S}_i$ 的值:

$$\hat{S}_i = f(x_{RF(i)}; \theta) \quad (8)$$

其中, f 表示CNN模型, $x_{RF(i)}$ 表示以像素 i 为中心的感受野内的图像块。

测试阶段: 主要通过调整参数 θ 来最小化所有像素预测值与实际值之间的损失:

$$\theta^* = \arg \min_{\theta} \sum_i \sum_j L(f(x_{RF(i)}^j; \theta), S_i^j) \quad (9)$$

其中, θ^* 表示最优参数, L 是损失函数, 用于衡量预测值 $f(x_{RF(i)}^j; \theta)$ 与真实值 S_i^j 之间的差异。

自监督学习对于不同类型的噪声和图像内容适应性有限, 且对于参数的调整缺乏灵活性, 通常需要更多的计算资源和训练时间来达到理想的去噪效果。

3.1.2 监督学习

监督学习的核心是通过大量的噪声图像和对应的干净图像来训练一个模型, 使模型能够从噪声图像中恢复出干净的图像。具体来说, 给定噪声图像 I_n 和对应干净图像 I_c , 监督学习的目标是学习一个函数 f , 使得

$$I_c = f(I_n) \quad (10)$$

由 Vincent 等提出的多层感知器 MLP^[46] 和 Chen 等提出的 TNRD^[47] 前馈深度网络是最基本的深度学习网络结构, 这类方法在训练集足够时可以达到图像去噪的最优水平, 但需要复杂的前期处理且无法适应不同水平的噪声。

为了避免对图像的复杂前期进行预处理, 将噪声直接从噪声图像中分离出来, Zhang 等人在 2017 年提出去噪卷积神经网络 DnCNN^[48], 该模型主要通过隐藏层中的操作隐式地去除潜在的干净图像, 其去噪模型为:

$$\hat{x} = F(y, M; \Theta_\sigma) \quad (11)$$

其中, $\hat{x}$ 表示模型输出结果, y 表示观测到的图像, M 表示噪声等级图, 参数 Θ_σ 是固定的。

DnCNN 模型^[48] 的主要特点在于引入了残差学习和批量归一化, 两者的融合可以有效地提升训练速度和去噪性能, 以便改善去噪结果。但该判别去噪方法灵活有限, 其学习模型只针对特定的噪声水平定制, 训练后的模型 Θ_σ 很难直接应用于其他噪声水平图像。

为了适应多种噪声等级, Zhang 等人在 2018 年引入了快速灵活的去噪神经网络 FFDNet^[49], 该网络结构和 DnCNN 一致, 其主要特点在于引入了可调节噪声的水平图, 其去噪模型为:

$$\hat{x} = F(y, M; \Theta_\sigma) \quad (12)$$

其中, $\hat{x}$ 表示模型输出结果, y 表示观测到的图像, M 是噪声等级图, 参数 Θ_σ 固定。

DnCNN 去噪算法等主要倾向于过度拟合高斯噪声, 但对于复杂的真实噪声图像泛化能力较差。针对真实图像的去噪, Guo 等人在 2019 年提出了由噪声子网络和非盲去噪子网络两部分组成的卷积盲去噪网络 CBDNet^[50], CBDNet 模型是关于 FFDNet 模型的升级版, 主要利用五层全卷积神经网络来学习噪声强度参数 σ , 从而达到自适应噪声的目的。

与 CNN 去噪模型不同的是, CBDNet 提出的是更接近真实的噪声生成模型:

$$\sigma^2(L) = L \cdot \sigma_s^2 + \sigma_c^2 \quad (13)$$

其中, L 为原始像素的辐照度图像, σ_c 是稳态噪声组成的, σ_s 是信赖噪声组成的, 通常与图像的像素值有关。

CBDNet^[50] 主要训练的是更近真实的噪声模型, 以此来提升模型泛化能力, 从而可以更好地对真实场景进行降噪, 但该模型不够高效灵活且计算成本较高。基于此, Anwar 等人在 2019 年相继提出了一种端到端的架构 RIDNet, 可以用来学习噪声并在真实图像上进行去噪, 不需要单独的子网络 and 人为干预。RIDNet 模型^[51] 是首个在去噪模型中加入特征注意的模型, 即利用不同通道之间的依赖关系对不同通道的特征进行差异化处理, 提升图像的泛化能力。同时在 RIDNet 网络结构中加入了一个模块化网络, 其主要目的是通过增加网络模块的数量来提高去噪性能。

与以前的 CNN 模型不同, RIDNet 模型^[51] 不仅利用新的恢复模块来学习特征, 进一步增强网络能力, 还考虑通道之间的依赖关系, 利用特征注意来调整通道之间的特征关系。

3.2 基于生成对抗网络（GAN）

为了解决CNN模型获取成对训练样本较难的问题,Chen等人在2018年利用GAN模型^[52]对在真实噪声图像上提取到的噪声进行建模,主要是因为GAN模型有非常好的图像生成能力,可以仿真真实的图像噪声,改善模型在真实噪声上的泛化能力。

生成对抗网络(GAN)的目标主要是通过生成器生成干净的无噪声的图像,而判别器通过真实的图像来提高生成器生成图像的质量^[53-54]。在图像去噪中,GAN可以用来学习噪声的分布并生成与真实噪声相似的噪声数据,利用这些生成的噪声数据和对应的干净图像进行训练,通过在带有噪声的图像中学习到干净图像表示。

其目标函数公式为:

$$\min_D \max_G V(D, G) = E_{p_X} [\log_a I(X)] + E_{p_Y} [\log_a (1 - I(D(Y)))] \quad (14)$$

其中, E 表示分布函数的期望值, E_{p_X} 表示训练样本的分布, E_{p_Y} 表示噪声分布, $I(X)$ 表示判别器对真实数据 X 的输出, $I(D(Y))$ 表示判别器对生成数据 Y 的数据。

Alsaiani等人在2019年利用提出来的GAN方法^[55]训练数据,通过对抗的方式提高生成器质量,从而提高去噪效率。与Alsaiani等人不同的是,Lin等人利用ADGAN方法^[56]在生成器中加入视觉注意力计算,以准确确定噪声区域,同时引入金字塔注意力估计网络,其主要目的是找到需要关注的噪声区域,从而在保证去噪时提高网络特征提取能力,避免出现图像过度平滑的情况。

通过使用生成器和判别器之间的对抗学习策略,不仅可以保持图像的结构信息,还能够有效地避免过度平滑和细节丢失的问题,使得去噪后的图像更加真实和清晰。但该算法仍有局限性,Gong等人^[57-58]提出的生成器和判别器很难做到同步更新数据,即导致网络训练过程不太稳定且在训练时容易受到过度拟合,使得图像细节模糊和边缘保持性较差,去噪效果可能有所影响。



(a) $\sigma=45(15.07\text{dB})$ (b) DnCNN(30.14dB) (c) FFDNet(30.33dB) (d) IRCNN(30.43dB) (e) FDNnCNN(30.44dB)

Fig. 3 Comparison of different deep learning denoising methods on the Kodak24 dataset when $\sigma=45$

图3 $\sigma=45$ 时不同深度学习去噪方法在Kodak24数据集上的去噪对比

在图3中,我们选取Kodak24数据集进行实验,将不同深度学习的去噪算法进行对比,从对比图中可以看出来,无论是在图像去噪程度还是细节恢复方面,FDnCNN算法的表现比DnCNN算法更好。其中,FDnCNN算法的PSNR值高于DnCNN算法约0.3dB。

3.3 基于图神经网络（GNN）

图神经网络是一类能够从图结构数据中学习的神经网络,尤其是适合结构数据较为复杂的图。Valsesia等人基于此提出了一种去噪神经网络GCDN^[59],采用图卷积对隐藏特征之间的相似度进行计算,再利用强大的网络学习能力来发现自相似模式,其次还引入了边缘条件卷积,主要是为了解决梯度消失和过度参数化问题。

在图卷积层里面,图被构造为特征空间中的K近邻图,需要计算每个像素的特征向量和搜索窗口内像素的特征向量之间的欧氏距离,并在像素与K个距离最小的像素之间画一条边。经典

的局部卷积在处理局部邻域以提供其对当前像素的输出时,主要通过图连接非局部像素的特征向量进行聚合。其中,非局部聚合计算为:

$$\begin{aligned} H_i^{l+1,NL} &= \sum_{j \in S_i^l} \gamma^{l,j \rightarrow i} \frac{F_{w_j^l}^l(d^{l,j \rightarrow i})H_j^l}{|S_i^l|} \\ &= \sum_{j \in S_i^l} \gamma^{l,j \rightarrow i} \frac{\Theta^{l,j \rightarrow i} H_j^l}{|S_i^l|} \end{aligned} \quad (15)$$

其中, $F_{w_j^l}^l$ 表示全连接网络, w_j^l 表示 F^l 的权重参数, $d^{l,j \rightarrow i}$ 表示两个特征向量之间的差, S_i^l 是节点 i 的邻域集, $H_i^{l+1,NL}$ 表示为卷积的输出层。

图卷积神经网络(GNN)^[60-61]能有效地利用非局部的信息进行去噪,但也存在一定的局限性,其表现为在高噪声水平中构建干净图像有一定的困难,而且相比于传统的卷积神经来说,GNN模型具有更高的复杂计算度,容易出现过度拟合的现象。基于此Zeng等人^[62-63]从卷积神经网络的输出中构建稀疏邻域图,然后利用相应的图拉普拉斯正则化作为先验项,通过求解无约束二次规划问题对图像进行恢复。Yu等人^[64-65]提出来的方法在实验数据较少的情况下不容易出现过度拟合而且还具有强大的跨域泛化能力,去噪效果优于其它深度学习算法。Zeng等和Yu等提出来的方法在一定程度上缓解了过度拟合的问题,但计算复杂度仍然较高。在此基础上诞生了DenseGNN^[66],它是一种新型的图神经网络模型通过密集连接策略,使每一层都能直接访问前面所有层的特征信息,减少信息丢失,提高网络性能。同时更新边、节点和图级别的特征,通过残差连接策略实现更直接和密集的信息传播。为了减少边的连接数量,Zeng等人提出DeepGLR^[85-86]深度网络结构,将图拉普拉斯正则化集成到深度学习框架中,尽管其优化策略减少了边连接数量,但在训练过程中,反向传播的计算成本仍然较高,特别是在处理大规模图数据时。

3.4 基于 Transformer

相较于传统的图像去噪,深度学习去噪方法能够很好地学习和利用图像中的复杂结构和模式。Transformer作为一种新兴的深度学习结构,在图像去噪方面表现出强大的潜力。Transformer模型将图像视为一系列像素的序列,并利用自注意力机制对像素间的依赖关系进行建模。为了更好地提取图像特征和重建细节,Yao等^[93]提出基于Transformer的密集残差跳过连接网络DenSformer,该网络在Sformer组之间采用密集残差跳过连接来提取深层特征并桥接不同层之间的信息。Gao等在此基础上提出多尺度双分支Transformer^[94]的图像去噪,有效融合浅层和深层特征的多尺度信息,在恢复图像细节时保留整体特征。但与双重CNN去噪网络DudeNet^[95]需要长距离依赖全局上下文的信息来增加其性能不同的是,多尺度双分支Transformer主要通过其独特的自注意力机制和多尺度特征提取能力来捕捉全局细节特征。

然而,DenSformer等模型是对全局进行处理,无法捕捉到图像的局部特征。Zhang等通过结合空间维度和通道维度的Transformer块提出Xformer结构^[96],增加不同范围的全局和局部表示能力,并通过双向连接单元(BCU)进行融合,其去噪效果在不同测试集上较为理想。但该模型在训练过程中过度拟合数据,在含真实噪声数据集上表现不理想。为了在复杂场景下获得清晰图像,Tian等提出交叉Transformer去噪卷积神经网络CTNet^[97],CTNet模型以深度和广度的搜索方式增强像素特征之间关系,提高图像去噪效果。目前常用的Transformer都使用了层归一化模块,但层归一化模块会导致顶层梯度消失,如何解决梯度消失是未来探索的方向。

3.5 基于扩散模型

基于扩散模型的图像去噪是利用扩散模型来去除图像噪声并恢复图像原始内容的方法。扩散模型是一种生成模型,通过模拟扩散过程来生成数据。Jonathan等^[98]在2020年首次提出扩散模型用于图像去噪,DDPMs模型通过模拟噪声扩散过程,学习逆扩散从噪声数据中恢复出干净的图像,该方法运用概率模型和深度学习技术,在变分自编码器(VAE)和生成对抗网络外(GAN)提供新的生成模型框架。然而,DDPMs模型对超参数的选择非常敏感,需要更多的调参和优化。为了

强化扩散模型对真实噪声的泛化能力，Yang等^[99]将去噪扩散模型用于真实世界的图像去噪，通过线性插值来控制添加噪声的量，使得扩散过程中添加的噪声更接近真实世界的噪声，从而实现更有效的去噪。但由于扩散过程中不精确性，导致样本质量比直接采样生成的样本质量还低，解决扩散过程中的不精确性并优化采样算法是未来扩散工作的重点。现有的扩散去噪模型依赖于大规模数据集进行训练，Kulikov等为了解决这个问题，提出了一个在单张图像上训练的扩散模型SinDDM^[100]。SinDDM通过多尺度扩散过程学习训练图像内部的信息，并使用轻量级全卷积去噪器驱动逆扩散过程。该模型允许生成任意尺寸的样本，并以粗到细的方法进行。图4是SinDDM论文中的结构图，以时间步长 t 和尺度 s 为条件整合到四个总感受野为 35×35 的完全卷积块模型中，方便模型能够在不同时间步骤中适当地处理图像数据：




Fig.4 The structure diagram of the N2V network

图4 SinDDM 结构图

Xie等^[101]讨论了对三种噪声模型（高斯、伽马和泊松噪声）的去噪，将去噪任务视为估计给定噪声图像条件下干净图像的后验分布问题，并应用扩散模型的思想来实现生成式图像去噪。根据去噪任务的不同，重新定义扩散过程，减少生成图像中的失真。为了提高去噪效率，Zhang等在2024年提出来DDDM模型^[102]，通过少步骤采样生成逼真的图像，同时保留多步骤采样以获得更好的性能。DDDM模型通过自身迭代生成的目标进行条件训练，不需要精心设计的采样器。

扩散模型在生成高质量图像方面表现出色，但在扩散过程中涉及多个时间步骤，导致计算成本高昂，特别是在处理高分辨率图像时。此外，扩散模型采样过程相对缓慢，如何提高采样效率和降低计算资源消耗是未来去噪扩散模型研究的重要方向。

3.6 基于BSN

自监督图像去噪N2V、N2S等主要通过遮蔽输入图像的像素来引入自监督信号，但这些方法依赖于噪声是逐像素独立的假设，在处理含真实噪声时存在局限。为了克服上述局限，BSN被开创性地引入了自监督学习框架，通过在感受野中心遮蔽像素，并利用周围的像素信息来重建中心像素。

现有BSN算法在处理大规模空间相关噪声时效率较低，为了提高去噪效率，Lee等提出了一种非对称像素分解和BSN结合的方法AP-BSN^[103]，通过非对称分解打破噪声的空间相关性，同时避免对图像细节的过度损害，但该模型在真实图像数据集上表现较差。为了提升BSN模型对真实噪声的泛化能力，Zhang等在2023年提出了多掩模模型MM-BSN^[104]，通过多个卷积掩模核进一步破坏噪声的空间相关性，并有效融合多掩模层提取的特征。Li等通过分析设计通道和空间注意力以满足盲点要求，构建一个基于Transformer的盲点网络TBSN^[105]，该算法具有较强的局部拟合能力与全局视角能力，并引入了知识蒸馏策略，将TBSN蒸馏成较小的去噪器。MM-BSN和TBSN在保持性能的同时提高了去噪效率，极大地扩展了感受野，在真实图像数据集上表现出良好的去噪效果。

但MM-BSN等算法在处理高噪声水平时，容易丢失高频细节，为了克服这些局限，Xia等提出一种动态自适应盲点网络DA-BSN，DA-BSN结合了Transformer和CNN提取全局和局部的图像细节，同时也能够根据不同的空间噪声特性动态调整去噪策略。DA-BSN^[106]通过动态自适应机制和多尺度特征提取，在去除高噪声水平的同时，更好地保留了图像边缘和细节。

早期的自监督去噪方法N2V、N2S到现在的BSN及其改进方法都取得了极大的进步，尽管现有的去噪方法在面临含真实噪声的图像时仍然面临挑战，但DA-BSN等方法通过结合Transformer

和CNN的优势显著提升了去噪性能。未来对自监督图像去噪的研究可以从优化网络结构、提高去噪效率以及探索更多自监督引入方式入手。

4 对比实验

4.1 评价指标

对图像去噪效果的分析主要通过视觉分析和评价指标两方面来进行。利用视觉分析来进行图像去噪效果的分析主要从以下几方面来看：

- (1)去噪后的图像是否还有孤立点；
- (2)去噪后的图像边缘是否遭到破坏；
- (3)去噪后的图像细节是否有所保留。

但用视觉分析图像的去噪效果有一定的局限性,所以一般需要用标准的指标来对去噪后的图像进行评价分析,其中主要包括峰值信噪比(PSNR)和结构相似比(SSIM)^[67]：
峰值信噪比（PSNR）

给定一个大小为 $m \times n$ 的干净图像 I 和噪声图像 K ,其PSNR定义为：

$$PSNR = 10 \cdot \log_{10} \left(\frac{255^2}{MSE} \right) \quad (16)$$

其中, MSE 的计算公式为：

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [I(i,j) - K(i,j)]^2 \quad (17)$$

PSNR的值越大表示去噪后的图像与干净图像越接近,即去噪效果更好。

结构相似比(SSIM)

给定一个干净图像 x ,其去噪图像的结构

相似比SSIM定义为：

$$SSIM = \frac{(2\mu_x \mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)} \quad (18)$$

其中, μ_x 、 $\mu_{\hat{x}}$ 分别是干净图像 x 和噪声图像 $\hat{x}$ 的均值, σ_x 、 $\sigma_{\hat{x}}$ 分别是干净图像和噪声图像的方差, $\sigma_{x\hat{x}}$ 是协方差, C_1 、 C_2 表示用来稳定常数。


SSIM值介于0到1之间,越接近1,表示降噪后的图像质量越接近原始清晰图像,即降噪效果越好。

4.2 测试数据集

在图像去噪研究中,常用的测试数据集主要分为三类：灰度图像数据集、彩色图像数据集以及真实图像数据集。其中,灰度图像数据集主要Set12^[48]、BSD68^[68]、彩色图像数据集主要有CBSD68^[68]、Kodak24^[69]、McMaster^[70]和CSet12^[48]。

常用的真实图像数据集主要有 DND^[71]、SIDD^[72]、PolyU^[73]和 RENOIR^[74]。DND 数据集涵盖50个场景,这些场景均由4种不同类型的相机拍摄而成,每个场景都包含真实的噪声图像和对应无噪声图像。SIDD 数据集由5种具有代表性的智能手机相机拍摄10个不同场景,每个场景提供噪声图像及其对应的 GroundTruth。PolyU 数据集由5种场景和弱光场景。RENOIR 数据集由三种不同传感器尺寸的相机拍摄120个低场景,每个场景均提供噪声图像和 GroundTruth。

在图5中展现出不同去噪方法在BSD68上的效果对比图,将基于深度学习的去噪算法与传统算法中突出的BM3D和WNNM进行对比,从对比图中可以看出来,无论是在图像去噪程度还是细节恢复方面,FFDNet算法等都比WNNM、BM3D算法表现更优。



(a) BM3D(15.07dB) (b) WNNM(26.65dB) (c)DnCNN(26.90dB) (d) FDN-CNN(26.91dB) (e)FFDNet(27.07dB)

Fig. 5 Comparison of different denoising methods on the BSD68 dataset when $\sigma=50$

图5 $\sigma=50$ 时不同去噪方法在BSD68数据集上的去噪对比

Table 1 Comparison and Summary of Different Image Denoising Methods

表1 不同图像去噪方法的对比总结

基础网络	方法	适用噪声	优点	缺点
空间滤波	MF ^[2-3] GF ^[4-5] BF ^[6-7] PID ^[77] NLM ^[8] AWT ^[78]	合成噪声	(1)平衡去噪与细节保留,避免过度平滑导致的边缘模糊或纹理丢失 (2)基于图像局部或全局特性自适应调整过滤强度 (3)参数量少,内存占用少	(1)边缘保持效果差,高频细节损失 (2)参数敏感,实时性差 (3)特征表达能力不足,难以去除密集的噪声
	FT ^[25-26] WT ^[27-28] BM3D ^[29] CBM3D ^[30]	合成噪声	(1)提供多尺度分析能力,能够同时捕捉信号的全局和局部特征 (2)具有高效的算法,能够在较短时间内完成复杂的计算 (3)FT和BM3D等通过变换域来分离噪声和信号	(1)边界处可能出现明显的伪影,伪影可能影响图像的整体质量 (2)对于非线性噪声,变换域滤波的效果可能不佳
	MAP ^[32] MRF ^[33] GMM ^[34] HMM ^[35]	合成噪声	(1)MAP等统计模型对图像的噪声和信号进行建模,能更好地处理图像中的噪声分布 (2)GMM和HMM通过调整先验分布或模型参数以适应不同类型的参数 (3)在多种噪声类型上去噪效果保持好	(1)在处理大规模图像时,去噪速度慢 (2)可能导致图像丢失部分细节 (3)对模型假设敏感
	K-SVD ^[36] NCSR ^[37-38] GSR ^[79] TWSC ^[80] LSCC ^[81]	合成噪声 真实噪声	(1)具有良好的泛化能力和对数据变化的适应性 (2)NCSR等通过稀疏表示来提取关键特征和降低数据维度 (3)在处理高噪声水平时能较好保留图像细节	(1)计算成本显著增加 (2)存在陷入局部最优解的问题 (3)参数选择不当可能导致去噪效果不佳
	LRMF ^[42] LLRT ^[83] WNNM ^[40] WCNNM ^[82]	合成噪声	(1)在处理的不同噪声水平的图像时,能表现出较好的鲁棒性 (2)利用图像之间的自相似性可以更好地保留图像的纹和细节 (3)WNNM等通过调整参数处理不同噪声水平	(1)高度依赖参数的选择 (2)过度拟合训练数据,导致图像泛化能力下降 (3)在图像边缘或细节区域容易出现伪影
卷积神经 (CNN)	DnCNN ^[48] FFDNet ^[49] FOCNet ^[84] RIDNet ^[50] CBDNet ^[51]	合成噪声	(1)端到端优化方便,多层次特征提取 (2)处理效率高,轻量可拓展 (3)残差学习优化效果好,有效解决梯度爆炸 (4)能够处理不同噪声水平的噪声,还能扩展到盲噪声	(1)泛化性受限,真实噪声效果差 (2)训练稳定性差,需大量训练数据 (3)对于复杂的数据,特征提取能力有限
生成对抗 (GAN)	GAN ^[52] ADGAN ^[56] GCBD ^[57]	真实噪声	(1)可以生成真实的噪声图像,样本泛化能力强,数据匹配性好	(1)训练难度大,容易过拟合 (2)结果不可控
图神经 (GNN)	GCDN ^[59] DeepGLR ^[85] OverNet ^[86] DenseGNN ^[66]	真实噪声	(1)通过拓扑结构可以很好地拟合复杂噪声分布 (2)对噪声空间变化的适应性较好,适合高分辨率图像去噪 (3)密集连接结构促进特征复用,提升去噪效果	(1)图的大小不可控,拓扑结构复杂 (2)不稳定的动态拓扑结构会降低特征的表达能力 (3)需大量计算资源

Transformer	DenSformer ^[93] 双Trans ^[94] Xformer ^[96] CTNet ^[97]	真实噪声	(1) 利用Transformer的自注意力机制，捕捉图像的全局信息，从而更好地处理复杂的图像结构 (2) Transformer的多头注意力机制能够从多个子空间提取特征，增强模型的表达能力 (3) 相比CNN，Transformer架构支持并行计算，更高效处理大规模图像数据，显著加快训练速度	(1) 对输入数据的细微变化较为敏感，导致对不同数据集的泛化能力有限 (2) Transformer主要关注全局信息，局部信息提取不如CNN (3) 训练成本高，需要大量的训练数据和计算资源达到最佳
扩散模型	DDPMs ^[98] DDDM ^[102] SinDDM ^[100]	真实噪声	(1)在去噪过程中生成高质量的图像样本，能够有效捕捉数据分布 (2)DDPMs能适应不同的去噪任务和数据集	(1)采样效率低，迭代很多次，才能生成高质量样本 (2)可能引入伪影
BSN	AP-BSN ^[103] MM-BSN ^[104] DA-BSN ^[106]	真实噪声	(1)减少了对大规模数据的依赖，能在没有干净图像的情况下直接对单张噪声图像训练	(1)由于自监督学习的复杂性，训练时间较长

注：每类方法里面越靠后的方法去噪效果越好。

Table 2 Denoising results of different methods on the Kodak24 Dataset at various noise level

表2 Kodak24数据集上不同噪声水平下各方法去噪

噪声水平	DnCNN		FDnCNN		FFDNet		IRCNN	
	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM
25	30.36	0.8325	32.11	0.8788	32.12	0.8778	32.01	0.8764
35	28.68	0.7792	30.53	0.8421	30.54	0.8404	32.39	0.8381
45	27.62	0.7413	29.42	0.8106	29.43	0.8084	29.30	0.8061
50	27.36	0.7372	28.95	0.7965	28.96	0.7941	28.80	0.7928

表2说明DnCNN、FDnCNN、FFDNet和IRCNN在Kodak24数据集上不同噪声水平下的平均PSNR和SSIM结果。从两种评价指标中可以发现,FFDNet算法在低噪声水平($\sigma \leq 25$)时,其表现效果优于DnCNN、FDnCNN和IRCNN。在高噪声水平($\sigma \geq 25$)时,FFDNet算法的去噪效果较比于其它三种算法也表现出显著的效果,尤其是噪声为50时,FFDNet算法的PSNR值和SSIM值分别高于DnCNN算法约1.6dB和0.0569。

为了更进一步地观察不同方法在不同噪声程度下的去噪效果，我们在CBSD68、Kodak24、McMcMaster数据集上进行了不同噪声水平下的不同去噪方法的结果分析。表格3展示了传统去噪方法CBM3D和基于深度学习去噪方法BRDNet等的分析结果。

Table 3 Average PSNR Results of Different Methods on CBSD68, Kodak24, and McMaster Datasets
表3 各方法在 CBSD68、Kodak24 和McMaster数据集上的平均PSNR 结果

数据集	噪声水平	CBM3D PSNR/dB	IRCNN PSNR/dB	FFDNet PSNR/dB	DnCNN PSNR/dB	ADNet PSNR/dB	BRDNet PSNR/dB
CBSD68	15	33.52	33.86	33.87	33.88	33.97	<u>34.10</u>
	25	30.71	31.14	31.20	31.22	31.29	<u>31.42</u>
	50	27.36	27.84	27.94	27.91	28.02	<u>28.13</u>
Kodak24	15	34.28	34.67	34.62	34.46	34.74	<u>34.87</u>
	25	31.67	32.01	32.11	32.01	32.25	<u>32.39</u>
	50	28.46	28.91	28.96	28.83	29.08	<u>29.21</u>
McMaster	15	34.06	34.56	34.64	33.42	34.92	<u>35.06</u>
	25	31.66	32.16	32.33	31.48	32.53	<u>32.73</u>
	50	28.87	28.89	29.16	28.59	29.34	<u>29.53</u>

经过表3对比发现：基于深度学习的去噪算法在不同噪声水平上的去噪效果明显优于传统算法CBM3D；其次，BRDNet算法在不同噪声水平上的去噪表现十分突出,远超同类算法；最后,随着噪声水平的增加,不同去噪方法的去噪能力并未被削弱，反而逐渐在提升。由此可见，基于深度学习的去噪算法在去噪性能方面远超市传统去噪方法。表格中的黑色下划线“—”表示同一噪声水平下的最优去噪方法。

4.3 实验结果分析

通过对以上实验结果的分析可知,当前的图像去噪技术在恢复图像效果方面仍然存在一些问题：首先,客观评价指标与实际的主观视觉效果之间存在不匹配的情况；其次,去噪算法的特征提取能力有限,导致去噪后的图像中仍有残留的噪声；最后，对于图像中的纹理细节和边缘信息的恢复效果不够理想。

5 结语

图像去噪在当今的应用范围十分广泛,对该领域的研究依然有非常高的需求。本文主要介绍了传统和深度学习去噪方法的典型,并对它们的优缺点进行了介绍。传统去噪方法不仅没有考虑噪声种类的多样性,而且对盲噪声的处理效果也不佳；随着深度学习的图像去噪方法出现,不仅对大量数据集进行训练获得更准确的噪声外,还能精准捕捉到复杂图像的结构和纹理。但是也容易出现训练稳定性差、参数量大、结果不可控以及易过拟合等结果，因此未来期望的去噪网络结构应该是考虑轻量级、训练稳定性、泛化能力和去噪结果可控的架构。

近年来,传统和深度学习去噪方法得到了广泛的应用,而且也取得了不错的效果,但仍然还有需要改进的几个地方：

(1) 提升去噪方法对真实噪声的泛化能力

大多数的图像去噪方法对合成噪声的去噪效果表现十分优异,但对于真实含噪声图像的去噪效果较差,这是由于真实噪声分布广泛、种类丰富而且难以参数化等。所以,对于真实含噪声图像的去噪效果研究还需要进一步提高,提升真实噪声去噪模型的泛化能力是一项极具挑战的任务。

（2）减少数据依赖性

基于深度学习的图像去噪方法大多依赖于标注的数据，但获得高质量的标注数据可能非常困难。无监督学习通过构建自编码器的去噪网络来减少对数据的依赖性，主要依赖于图像数据本身的结构特性和先验特性去除噪声。因此，无监督的图像去噪方法也是以后关注的重点。

（3）动态图像去噪

图像去噪的方法大多都只针对静态图像进行处理，如何实现动态图像的实时去噪也是未来图像去噪研究的方向。

（4）提高计算效率

基于深度学习的去噪模型常常需要大量的计算资源和时间进行训练，限制了在资源受限的环境中的应用。因此，研究更高效的网络架构、知识蒸馏以及根据训练过程调整学习率加快收敛速度是一项颇具挑战的工作。

（5）模型集成和融合

现有的图像去噪算法对于图像噪声和细节的处理过于单一，不能完成复杂的图像去噪任务。未来的图像去噪可能会结合多个模型的优势来提高去噪性能，在处理速度、去噪效果和模型鲁棒性方面有更大的可能性。

总的来说，本文主要概述现有去噪方法。由于不同的噪声类型需要不同的去噪方法，所以对噪声进行分析可以开发出不同去噪方案。因此，只有把图像去噪这项工作完成好，才会对后续图像处理的相关研究打好基础。

参考文献

- [1] LIU D, JIA J L, ZHAO Y Q, et al. A Survey on Image Denoising Methods Based on Deep Learning[J]Journal of Computer Engineering & Applications, 2021, 57 (7)
- 刘迪, 贾金露, 赵玉卿, 等. 基于深度学习的图像去噪方法研究综述[J]. 计算机工程与应用, 2021, 57 (7)
- [2] JAIN A K. Fundamentals of digital image processing [M]. Englewood Cliffs: Prentice-Hall, Inc, 1989.
- [3] XIAO X S, WEI Q. Comparison between mean filter and median filter algorithm in image denoising field[J]. Applied Mechanics and Materials, 2014, 644: 4112–4116, .
- [4] BK SHREYAMSHA KUMAR. Image denoising based on Gaussian/bilateral filter and its method noise thresholding[J]. Image Video Process, 2013, 7(6): 1159–1172.
- [5] PIAO W Y, YUAN YIBAO, LIN HAIJUN. A digital image denoising algorithm based on Gaussian filtering and bilateral filtering[C]// ITM Web of Conferences, 2018.
- [6] TOMASI CARLO, MANDUCHI ROBERTO. Bilateral filtering for gray and color images[C]// Sixth International Conference on Computer Vision, 1998: 839–846.
- [7] DEVANAND BHONSLE, VIVEK CHANDRA, GR SINHA. Medical image denoising using bilateral filter[J]. International Journal of Image, Graphics and Signal Processing, 2012, 4(6): 36.
- [8] GOOSSENS BART, LUONG HIÊP, PIZURICA ALEKSANDRA, PHILIPS WILFRIED. An improved non-local denoising algorithm[C]// 2008 International Workshop on Local and Non-Local Approximation in Image Processing, 2008: 143–156.
- [9] WANG J, GUO Y W, YING Y T, LIU Y L, PENG Q S. Fast non-local algorithm for image denoising[C]// 2006 International Conference on Image Processing, 2006: 1429–1432.
- [10] TANAPHOL THAI PANICH, BYUNG TAE OH, PING-HAO WU, DARU XU, C-C JAY KUO. Improved image denoising with adaptive nonlocal means (ANL-means) algorithm[J]. IEEE Transactions on Consumer Electronics, 2010, 56(4): 2623–2630.
- [11] PANG C, YANG W, ZOU F. A fast NL-means method in image denoising based on the similarity of spatially sampled pixels[C]// 2009 IEEE International Workshop on Multimedia Signal Processing, 2009: 1–4.
- [12] RAMANATHAN VIGNESH, BYUNG TAE OH, C-C JAY KUO. Fast non-local means (NLM) computation with probabilistic early termination[J]. IEEE Signal Processing Letters, 2009, 17(3): 277–280.
- [13] JACQUES FROMENT. Parameter-free fast pixelwise non-local means denoising[J]. Image Processing On Line, 2014, 4: 300–326.
- [14] KARNATI VENKATESWARLU, ULIYAR MITHUN, DEY SUMIT. Fast non-local algorithm for image denoising[C]// 2009 16th IEEE International Conference on Image Processing (ICIP), 2009: 3873–3876.
- [15] Xing X X, Wang H L, Li J. Asymptotic non-local means image denoising algorithm[J]. Acta Automatica Sinica, 2020, 46(9): 1952–1960.

- [16] XUE B D, YANG J H. Fast nonlocal remote sensing image denoising using cosine integral images[J]. IEEE Geoscience and Remote Sensing Letters, 2013, 10(6): 1309–1313.
- [17] ZHANG X B. Two-step non-local means method for image denoising[J]. Multidimensional Systems and Signal Processing, 2022, 33(2): 341–366.
- [18] GREWENIG SVEN, ZIMMER SEBASTIAN, Weickert Joachim. Rotationally invariant similarity measures for nonlocal image denoising[J]. Journal of Visual Communication and Image Representation, 2011, 22(2): 117–130.
- [19] FAN L W, LI X M, GUO Q. Nonlocal image denoising using edge-based similarity metric and adaptive parameter selection[J]. Science China. Information Sciences, 2018, 61(4): 049101.
- [20] LENG KAIQUN. An improved non-local means algorithm for image denoising[C]// 2017 IEEE 2nd International Conference on Signal and Image Processing (ICSIP), 2017: 149–153.
- [21] ZHANG L W, XUE X J, LI H. A PCB image denoising algorithm based on improved NLM[J]. Computer Engineering & Science, 2021, 43(9).
- [22] BIC CLAUDIU, TEREDES ROMULUS. An improved NLM filter with increased noise robustness and adaptive similarity function[C]// 2019 IEEE 15th International Conference on Intelligent Computer Communication and Processing (ICCP), 2019: 365–370.
- [23] ZHONG H, YANG C, ZHANG X. A new weight for nonlocal means denoising using method noise[J]. IEEE Signal Processing Letters, 2012, 19(8): 535–538.
- [24] LU J R, LUO X G. Image denoising via fast and fuzzy non-local means algorithm[J]. Journal of Information Processing Systems, 2019, 15(5): 1108–1118.
- [25] ÖKTEM RUSEN, YAROSLAVSKY LEONID, EGIAZARIAN KAREN, ASTOLA JAAKKO. Transform domain approaches for image denoising[J]. Journal of Electronic Imaging, 2002, 11(2): 149–156.
- [26] MATALON BOAZ, ELAD MICHAEL, ZIBULEVSKY MICHAEL. Image denoising with the contourlet transform[J]. Proceedings of SPARSE'05, 2005.
- [27] CHEN G Y, KÉGL BALÁZS. Image denoising with complex ridgelets[J]. Pattern Recognition, 2007, 40(2): 578–585.
- [28] PARTHASARATHY SUBASHINI, MARIMUTHU KRISHNAVENI. Image denoising based on wavelet analysis for satellite imagery[J]. Advances in Wavelet Theory and Their Applications in Engineering, Physics and Technology, 2012: 449–474.
- [29] KOSTADIN DABOV, ALESSANDRO FOI, VLADIMIR KATKOVNIK, KAREN EGIAZARIAN. Image denoising by sparse 3-D transform-domain collaborative filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8): 2080–2095.
- [30] KOSTADIN DABOV, ALESSANDRO FOI, VLADIMIR KATKOVNIK, KAREN EGIAZARIAN. Color image denoising via sparse 3D collaborative filtering with grouping constraint in luminance-chrominance space[C]// 2007 IEEE International Conference on Image Processing, 2007, 1: 1–313.
- [31] MATTEO MAGGIONI, VLADIMIR KATKOVNIK, KAREN EGIAZARIAN, ALESSANDRO FOI. Nonlocal transform-domain filter for volumetric data denoising and reconstruction[J]. IEEE Transactions on Image Processing, 2012, 22(1): 119–133.
- [32] A BEN HAMZA, H KRIM. A variational approach to maximum a posteriori estimation for image denoising[C]//International Workshop on Energy Minimization Methods in Computer Vision and Pattern Recognition. Springer, 2001: 19–34.
- [33] ADRIAN BARBU, SONG C Z. Learning Real-Time MRF Inference for Image Denoising[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2009: 233–240.
- [34] DELEDALLE. Image Denoising with Generalized Gaussian Mixture Model Patch Priors[J]. arXiv preprint arXiv, 2018,1802.01458v2.
- [35] Wen Z H, Xin X X. Research on the New Image De-Noising Methodology Based on Neural Network and HMM-Hidden Markov Models[C]// Proceedings of the International Conference on Information Engineering, 2024: 123–134.
- [36] MICHAL AHARON, MICHAEL ELAD, ALFRED BRUCKSTEIN. K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation[J]. IEEE Transactions on Signal Processing, 2006, 54(11): 4311–4322.
- [37] Wei S D, Lei Z, Xin L. Nonlocally centralized sparse representation for image restoration[J]. IEEE Transactions on Image Processing, 2012, 22(4): 1620–1630.
- [38] WU J F. Image Denoising Algorithm based on Improved NCSR Model[C]// Journal of Physics: Conference Series, 2019, 1314(1): 012209.
- [39] Yan H G, ABDULKADIR ŞENGÜR. A novel image thresholding algorithm based on neutrosophic similarity score[J]. Measurement, 2014, 58: 175 – 186.
- [40] SHU H G, LEI Z, WANG M Z, XIANG C F. Weighted nuclear norm minimization with application to image denoising[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 2862 – 2869.

- [41] WEI S D, GUANG M S, XIN L. Nonlocal image restoration with bilateral variance estimation: A low-rank approach[J]. *IEEE Transactions on Image Processing*, 2012, 22(2): 700 – 711.
- [42] XIANG Y C, YANG C, QIAN Z, YAO W. Low-rank matrix factorization under general mixture noise distributions[C]// *Proceedings of the IEEE International Conference on Computer Vision*, 2015: 1493 – 1501.
- [43] LIU X Y, MA J, ZHANG X M, HU Z Z. Image denoising of low-rank matrix recovery via joint Frobenius norm[J]. *J Image Graph*, 2014, 19(4): 502–511.
- [44] HUI JI, SIBIN HUANG, ZUOWEI SHEN, YUHONG XU. Robust video restoration by joint sparse and low rank matrix approximation[J]. *SIAM Journal on Imaging Sciences*, 2011, 4(4): 1122–1142.
- [45] JIAN F C, EMMANUEL J CANDES, ZUO W S. A singular value thresholding algorithm for matrix completion[J]. *SIAM Journal on Optimization*, 2010, 20(4): 1956–1982.
- [46] PASCAL VINCENT, HUGO LAROCHELLE, YOSHUA BENGIO, PIERRE-ANTOINE MANZAGOL. Extracting and composing robust features with denoising autoencoders[C]// *Proceedings of the 25th International Conference on Machine Learning*, 2008: 1096–1103.
- [47] YUN J C, Thomas Pock. Trainable nonlinear reaction diffusion: A flexible framework for fast and effective image restoration[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2016, 39(6): 1256–1272.
- [48] KAI Z, WANG M Z, YUN J C, DE Y M, LEI Z. Beyond a Gaussian denoiser: Residual learning of deep CNN for image denoising[J]. *IEEE Transactions on Image Processing*, 2017, 26(7): 3142–3155.
- [49] KAI Z, WANG M Z, LEI Z. FFDNet: Toward a fast and flexible solution for CNN-based image denoising[J]. *IEEE Transactions on Image Processing*, 2018, 27(9): 4608–4622.
- [50] SHI G, ZI F Y, KAI Z. Toward convolutional blind denoising of real photographs[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019: 1712–1722.
- [51] SAEED ANWAR, NICK BARNES. Real image denoising with feature attention[C]// *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019: 3155–3164.
- [52] JING W C, HONG Y C, MING Y. Image blind denoising with generative adversarial network based noise modeling[C]// *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018: 3155–3164
- [53] TRAN L D, NGUYEN S M, ARAI M. GAN-based noise model for denoising real images[C]// *Proceedings of the Asian Conference on Computer Vision*, 2020.
- [54] TIAN C W, FEI L K, ZHENG W X, XU Y, ZUO W M, LIN C W. Deep learning on image denoising: An overview[J]. *Neural Networks*, 2020, 131: 251–275.
- [55] ALSAIARI A, RUSTAGI R, THOMAS M M, FORBES A G, et al. Image denoising using a generative adversarial network[C]// *2019 IEEE 2nd International Conference on Information and Computer Technologies (ICICT)*. IEEE, 2019: 126–132.
- [56] LIN K, LI T H, LIU S, LI G. Real photographs denoising with noise domain adaptation and attentive generative adversarial network[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2019: 0–0.
- [57] GONG P Z, LIU J, LV S Q. Image denoising with GAN based model[J]. *Journal of Information Hiding and Privacy Protection*, 2020, 2(4): 155.
- [58] DEY R, BHATTACHARJEE D, NASIPURI M. Image denoising using generative adversarial network[J]. *Intelligent Computing: Image Processing Based Applications*, 2020: 73–90.
- [59] VALSESIA D, FRACASTORO G, MAGLI E. Deep graph-convolutional image denoising[J]. *IEEE Transactions on Image Processing*, 2020, 29: 8226–8237.
- [60] MA Y, LIU X R, ZHAO T, LIU Y, TANG J, SHAH N. A unified view on graph neural networks as graph signal denoising[C]// *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*, 2021: 1202–1211.
- [61] REY S, SEGARRA S, HECKEL R, MARQUES A G. Untrained graph neural networks for denoising[J]. *IEEE Transactions on Signal Processing*, 2022, 70: 5708–5723.
- [62] ZENG J, PANG J H, SUN W X, CHEUNG G. Deep graph Laplacian regularization for robust denoising of real images[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2019: 0–0.
- [63] HAN K, WANG Y, GUO J Y, TANG Y, WU E. Vision GNN: An image is worth a graph of nodes[J]. *Advances in Neural Information Processing Systems*, 2022, 35: 8291–8303.
- [64] YU Y, CHEN J, GAO T, YU M. DAG-GNN: DAG structure learning with graph neural networks[C]// *International Conference on Machine Learning*. PMLR, 2019: 7154–7163.
- [65] ZHOU K X, HUANG X, SONG Q Q, CHEN R, HU X. Auto-GNN: Neural architecture search of graph neural networks[J]. *Frontiers in Big Data*, 2022, 5: 1029307.
- [66] DU H, WANG J, HUI J, ZHANG L, WANG H. DenseGNN: universal and scalable deeper graph neural networks for high-performance property prediction in crystals and molecules[J]. *npj Computational Materials*, 2024, 10: 292.
- [67] SARA U, AKTER M, UDDIN M S. Image quality assessment through FSIM, SSIM, MSE and PSNR — a comparative study[J]. *Journal of Computer and Communications*, 2019, 7(3): 8–18.
- [68] ROTH S, BLACK M J. Fields of experts[J]. *International Journal of Computer Vision*, 2009, 82: 205–229.

- [69] MOLCHANOV P, MALLYA A, TYREE S, FROSIO I, KAUTZ J. Importance estimation for neural network pruning[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 11264-11272.
- [70] ZHANG L, WU X, BUADES A, LI X. Color demosaicking by local directional interpolation and nonlocal adaptive thresholding[J]. Journal of Electronic Imaging, 2011, 20(2): 023016-023016.
- [71] PLOTZ T, ROTH S. Benchmarking denoising algorithms with real photographs[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 1586-1595.
- [72] ABDELHAMED A, LIN S, BROWN M S. A high-quality denoising dataset for smartphone cameras[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018: 1692-1700.
- [73] XU J, LI H, LIANG Z, ZHANG D, ZHANG L. Real-world noisy image denoising: A new benchmark[J]. 2018.
- [74] ANAYA J, BARBU A. Renoir — a dataset for real low-light image noise reduction[J]. Journal of Visual Communication and Image Representation, 2018, 51: 144-154.
- [75] ZENG J, PANG J H, SUN W X, CHEUNG G. Deep graph Laplacian regularization for robust denoising of real images[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2019: 0-0.
- [76] BEHJATI P, RODRÍGUEZ P, MEHRI A, HUPONT I, GONZÁLEZ J, FERNÁNDEZ TENA C. Overnet: Lightweight multi-scale super-resolution with overscaling network[C]// Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). IEEE, 2021: 2724-2733.
- [77] KNAUS C, ZWICKER M. Progressive image denoising[J]. IEEE Transactions on Image Processing, 2014, 23(7): 3114-3125.
- [78] WU G W, WANG C M, BAO J D, et al. A wavelet threshold de-noising algorithm based on adaptive threshold function[J]. Journal of Electronics & Information Technology, 2014, 36(6): 1340-1347.
- [79] ZHANG J, ZHAO D, GAO W. Group-based sparse representation for image restoration[J]. IEEE Transactions on Image Processing, 2014, 23(8): 3336-3351.
- [80] XU J, ZHANG L, ZHANG D. A trilateral weighted sparse coding scheme for real-world image denoising[C]// Proceedings of the European Conference on Computer Vision (ECCV). Springer, 2018: 20-36.
- [81] Mairal J, Bach F, Ponce J, Sapiro G, Zisserman A. Non-local sparse models for image restoration[C]// 2009 IEEE 12th International Conference on Computer Vision (ICCV). IEEE, 2009: 2272-2279.
- [82] XU J, ZHANG L, ZHANG D, FENG X. Multi-channel weighted nuclear norm minimization for real color image denoising[C]// Proceedings of the IEEE International Conference on Computer Vision (ICCV). IEEE, 2017: 1096-1104.
- [83] CHANG Y, YAN L, ZHONG S. Hyper-laplacian regularized unidirectional low-rank tensor recovery for multispectral image denoising[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017: 4260-4268.
- [84] JIA X, LIU S, FENG X, ZHANG L. FocNet: A fractional optimal control network for image denoising[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019: 6054-6063.
- [85] ZENG J, PANG J H, SUN W X, CHEUNG G. Deep graph Laplacian regularization for robust denoising of real images[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2019: 0-0.
- [86] BEHJATI P, RODRÍGUEZ P, MEHRI A, HUPONT I, GONZÁLEZ J, FERNÁNDEZ TENA C. Overnet: Lightweight multi-scale super-resolution with overscaling network[C]// Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). IEEE, 2021: 2724-2733.
- [87] ZI Z, CHENG H, HE J. Intelligent Waste Classification Technology Based on Deep Learning [J]. Science and Technology Innovation, 2023, (21): 46-49.
- 资政, 程慧, 何佳. 基于深度学习的垃圾智能分类技术[J]. 科技与创新, 2023, (21): 46-49.
- [88] JEBUR R S, MOHAMED ZABIL M H B, HAMMOOD D A, LIM K C. A comprehensive review of image denoising in deep learning[J]. Multimedia Tools and Applications, 2024, 83(20): 58181-58192.
- [89] MORAN N, SCHMIDT D, ZHONG Y, et al. Noisier2noise: Learning to denoise from unpaired noisy data[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 12064-12072.
- [90] KRULL A, BUCHHOLZ T-O, JUG F, et al. Noise2void: Learning denoising from single noisy images[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 2129-2137.
- [91] BATSON J, ROYER L. Noise2self: Blind denoising by self-supervision[J]. Proceedings of the International Conference on Machine Learning, 2019: 524-533.
- [92] QUAN Y H, CHEN M Q, PANG T Y, et al. Self2self with dropout: Learning self-supervised denoising from single image[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 1890-1898.
- [93] YAO C, JIN S, LIU M Q, et al. Dense residual transformer for image denoising[J]. Electronics, 2022, 11(3): 418.
- [94] GAO Y B, WEN Z C, DUAN X S, et al. Image denoising method based on multi-scale dual-branch transformer[J]. Journal of Yunnan University: Natural Sciences Edition, 2024.

- [95] TIAN C W, XU Y, ZUO W M, et al. Designing and training of a dual CNN for image denoising[J]. Knowledge-Based Systems, 2021, 226: 106949.
- [96] ZHANG J L, ZHANG Y L, GU J J, et al. Xformer: Hybrid x-shaped transformer for image denoising[J]. arXiv preprint arXiv:2303.06440, 2023.
- [97] LIAN Z, LIU B, TAO J H. CTNet: Conversational transformer network for emotion recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 985-1000.
- [98] JONATHAN HO, AJAY JAIN, PIETER ABBEEL. Denoising Diffusion Probabilistic Models[J]. arXiv preprint arXiv:2006.11239, 2020.
- [99] YANG Y. Real-World Image Denoising with Diffusion Models[J]. arXiv preprint :2205.14892, 2022.
- [100] KULIKOV G. SinDDM: Single-Image Denoising with Diffusion Models[J]. arXiv preprint arXiv:2206.09642, 2022.
- [101] XIE Y, LI J, ZHANG H. Diffusion-based image denoising for Gaussian, Gamma, and Poisson noise[J]. IEEE Transactions on Image Processing, 2023, 30(4): 1234-1245.
- [102] ZHANG D. Directly Denoising Diffusion Models[J]. arXiv preprint arXiv:2405.13540, 2024.
- [103] LEE W, SON S, LEE K M. Ap-BSN: Self-supervised denoising for real-world images via asymmetric PD and blind-spot network[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 17725-17734.
- [104] ZHANG D, ZHOU F, JIANG Y, et al. MM-BSN: Self-supervised image denoising for real-world with multi-mask based on blind-spot network[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 4189-4198.
- [105] LI J Y, ZHANG Z L, ZUO W M. TBSN: Transformer-based blind-spot network for self-supervised image denoising[J]. arXiv e-prints, 2024: arXiv-2404.
- [106] XIA H Z, LIU H Y, WEI Z H. DA-BSN: Self-Supervised Real-World Image Denoising based on Dynamic Adaptive Blind Spot Network[J]. Proceedings of the 2024 6th International Conference on Video, Signal and Image Processing, 2024: 94-99.