

计算机集成制造系统
Computer Integrated Manufacturing Systems
ISSN 1006-5911, CN 11-5946/TP

《计算机集成制造系统》网络首发论文

题目：基于 Diffusion Transformer 的样本不平衡数据增强方法
作者：王旻杰，陈良，陈启通
DOI：10.13196/j.cims.2025.0119
收稿日期：2025-03-25
网络首发日期：2025-08-04
引用格式：王旻杰，陈良，陈启通. 基于 Diffusion Transformer 的样本不平衡数据增强方法[J/OL]. 计算机集成制造系统. <https://doi.org/10.13196/j.cims.2025.0119>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

DOI:10.13196/j.cims.2025.0119

基于 Diffusion Transformer 的样本不平衡数据增强方法

王旻杰, 陈良⁺, 陈启通

(苏州大学 机电工程学院, 江苏 苏州 215137)

摘要：样本不平衡是“AI+制造”面临的一个典型问题，设备故障诊断和智能维护常常因为不同健康状态数据分布不平衡而导致分类困难。针对样本不平衡问题，提出了一种基于 Diffusion Transformer (DiT) 的数据增强方法。该方法结合了 Transformer 架构的特征提取能力的高效性和扩散过程的随机性，显著提升了生成样本的质量和多样性。首先，在前向扩散过程中，输入数据被分割为嵌入表示并融入位置编码与条件信息，同时利用自适应层捕捉加噪样本之间的特征关系。其次，在反向去噪阶段，基于模型的预测模块进行随机抽样与逐步去噪以生成新样本。与传统生成方法相比，DiT 在生成过程中引入了更多随机性，有效缓解了过拟合。最后，在滚珠丝杠数据集上的实验结果表明，采用 DiT 方法的平均诊断精度为 97.25%，比传统对抗生成网络提高了 5.03%，同时通过多核最大均值差异和可视化分析验证了 DiT 在数据增强方面的优势。

关键词：故障诊断；数据增强；生成模型；扩散模型

中图分类号：TH165+.3

文献标识码：A

Research on sample imbalance data augmentation method based on Diffusion Transformer

WANG Minjie, CHEN Liang⁺, CHEN Qitong

(School of Mechanical and Electrical Engineering, Soochow University,
Suzhou 215137, China)

Abstract: Sample imbalance is a typical issue faced by 'AI + Manufacturing'. Equipment fault diagnosis and intelligent maintenance frequently encounter classification difficulties due to imbalanced data distributions across different health states. To address the issue of sample imbalance, a data augmentation method based on Diffusion Transformer (DiT) is proposed. This method combines the feature extraction capabilities of the Transformer architecture with the stochastic nature of the diffusion process, significantly enhancing the quality and diversity of the generated samples. First, during the forward diffusion process, the input data is decomposed into embedded representations, and augmented with positional encodings and conditional information, while adaptive layers are employed to capture the feature relationships among noisy samples. Second, in the reverse denoising phase, a prediction module performs stochastic sampling to gradually remove noise and generate new samples. Compared with conventional generative methods, DiT incorporates greater stochasticity into the

收稿日期：2025-03-25；**修订日期：**2025-06-04。Received 25 Mar. 2025; accepted 04 June 2025.

基金项目：国家自然科学基金资助项目(52375114, 52272440, 52175056)。**Foundation items:** Project supported by the National Natural Science Foundation, China (No. 52375114, 52272440, 52175056).

generation process, effectively mitigating overfitting. Finally, the experimental results on the ball screw dataset indicate that the DiT-based method achieves an average diagnostic accuracy of 97.25%, which is 5.03% over conventional adversarial generative networks, and the superiority of DiT for data augmentation is further validated through quantitative analysis using Multi-Kernel Maximum Mean Discrepancy and qualitative visualization assessments.

Key words: fault diagnosis; data augmentation; generative model; diffusion model

0 引言

在信息化与自动化技术深度融合的背景下,现代工业生产系统正朝着大型化、复杂化方向快速发展。在复杂恶劣的工作条件下,设备运行状态易受多重扰动因素影响。旋转机械作为工业装备的核心部件,若未能及时识别其潜在故障,可能导致设备损坏、生产中断,甚至引发安全事故。因此,高效的设备状态监测与故障诊断,已成为保障现代工业系统可靠运行、防控风险的关键技术^[1]。

传统的人工经验驱动的诊断模式在面对工业生产中产生的海量实时监测数据时,逐渐暴露出处理效率低下、实时性不足等局限^[2]。随着深度学习的突破性进展,智能故障诊断(Intelligent Fault Diagnosis, IFD)技术已成为设备健康管理领域的研究热点。得益于卷积神经网络(Convolutional Neural Network, CNN)独特的层次化特征提取机制,基于 CNN 的 IFD 模型通过自主挖掘监测信号中的深层故障特征,显著提升了诊断精度与效率,目前已被广泛应用于信号分析与故障模式识别领域。如 ZHANG 等^[3]提出了一种宽内核架构的 CNN 模型,通过在网络第一层构建较大尺寸的感受野,有效地提取了特征并抑制高频噪声。尽管 IFD 技术在故障诊断领域取得了重要进展,但其性能表现深度依赖于规模庞大且类别分布均衡的高质量数据集。在工业现场中,机械设备长期处于正常工况运行状态,导致故障样本与正常样本存在数量级差异。此外,人工标注过程存在标注周期长、经济成本高等固有缺陷,标注总量受限,难以缓解样本类间分布失衡问题。这最终形成制约 IFD 技术向工业现场实际落地应用的关键瓶颈^[4]。

数据增强方法是缓解样本不平衡问题的有效手段。当前相关研究聚焦于生成模型的改进,通过生成稀缺故障样本构建适用于诊断的均衡训练集^[5]。目前,主流的生成模型是生成对抗网络(Generative Adversarial Network, GAN),通过生成器与判别器的对抗训练逼近数据真实分布,达到高质量的生成与判别效果^[6]。SON 等^[7]设计了基于边界类条件 GAN(Conditional GAN, CGAN)的过采样方法,构建多数类邻域内的边界类样本生成机制,实现类别边界区域的精准数据补偿。李可等^[8]提出了一种基于约束式自编码器-GAN(Constrained Autoencoder-GAN, CAE-GAN)的生成方法,引入类间距离约束损失解决生成模式单一化问题。廖珂等^[9]改进了深度卷积 GAN(Deep Convolutional GAN, DCGAN),利用振动信号特征引导生成器优化,实现对少数样本的高精度生成。然而,GAN 的

对抗生成本质导致其训练过程存在模式崩溃与梯度消失等固有问题。针对这些局限性,研究者提出了多种改进方案^[10]。Xu 等^[11]设计了双路径优化架构,在生成器中集成空间通道注意力机制,同时在判别器中构建全局特征交叉的抗干扰模块。陆钦华等^[12]开发了基于 WGAN-GP(Wasserstein GAN with Gradient Penalty)的预训练框架,通过引入新的距离损失与梯度惩罚协同优化训练稳定性。尽管这些方法提升了生成质量,但普遍面临网络结构复杂化与生成特征同质化的问题,限制了数据多样性的提升。

近年来,扩散模型凭借其显式概率建模机制与强大的数据生成能力,在解决样本不平衡问题中展现出显著潜力^[13]。YANG 等^[14]采用去噪扩散概率模型(Denoising Diffusion Probabilistic Model, DDPM),借鉴热力学扩散原理实现从随机噪声到故障样本的精准重构。ZHANG 等^[15]设计了可解释的矢量量化引导的扩散模型(Vector Quantized Latent Diffusion Model, VQ-LDM),在隐空间特征约束下实现生成质量、计算效率和特征可解释性方面的多维度提升。LIU 等^[16]开发的脉冲电压引导的条件扩散模型(Conditional Diffusion Model, CDM)增强了生成过程的动态可控性。相较于传统生成方法,扩散模型通过渐进式扩散操作提高了训练生成过程的稳定性^[17]。多尺度噪声嵌入机制和随机抽样步骤提升了样本多样性,为构建均衡化数据集提供了可靠支持。然而,现有方法中噪声预测网络多采用基础的 U-Net 架构,在应对工业信号复杂特征及强噪声干扰等场景时,仍存在特征提取维度受限和噪声敏感性等问题。

针对上述的样本不平衡问题,本文提出了一种基于 Diffusion Transformer 的数据增强方法。该方法包含两个核心阶段:在正向扩散阶段,利用马尔可夫链将复杂初始样本分布转换为高斯分布,采用基于 Transformer 架构的噪声预测网络实现加噪样本的上下文建模与噪声预测;在反向去噪阶段,从高斯分布采样并迭代重构,生成符合真实数据分布的增强样本。

本文的主要贡献如下:

- ① 提出了一种基于扩散模型的 DiT 数据增强方法,通过扩散去噪过程实现故障样本生成,有效缓解诊断数据中的类别失衡问题;
- ② 设计信息嵌入机制,在 Transformer 架构中融合时域位置编码与工况条件编码,利用多头注意力实现加噪样本的多尺度特征关联,在保证生成精度的同时提升样本多样性;
- ③ 建立综合评估体系,采用多项指标对生成样本进行定量与定性分析。基于多工况滚珠丝杠数据集开展实验。结果表明,所提方法生成的样本与原始数据分布高度一致,且特征表达丰富,提升了后续诊断模型的准确率和鲁棒性。

1 理论基础

1.1 扩散模型

扩散模型是一种基于马尔可夫过程的显式概率生成模型，模拟了气体从高浓度扩散到低浓度的热力学过程。扩散模型通过先向原始数据中逐步注入噪声杂质，破坏数据的初始分布。然后经过训练来学习逆转这一过程，最终实现从噪声中重构出新样本^[18]。

扩散模型由正向传播和反向去噪两个过程组成。在正向扩散过程中，模型通过马尔可夫前向链逐步向初始数据中添加细微的噪声扰动，在积累一定的时间步后，复杂的原始数据分布被转化为一个简单的先验高斯分布^[19]。具体而言，给定初始数据分布 $x_0 \sim q(x)$ ，逐步向初始数据中添加噪声， t 时间步下添加噪声的标准差由人为设定的噪声表 β_t 确定，且满足 $0 < \beta_1 < \beta_2 < \dots < \beta_t < 1$ 。基于此过程来推导 $q(x_t|x_{t-1})$ ，在给定 x_{t-1} 的条件下， x_t 服从均值为 $\sqrt{1-\beta_t}x_{t-1}$ ，方差为 β_t 的正态分布。定义条件概率分布为高斯分布，如公式（1）所示：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I) \quad (1)$$

利用重参数技巧，令 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ，经过累乘得到：

$$q(x_t|x_0) = \int q(x_{1:t}|x_0)dx_{1:(t-1)} = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I) \quad (2)$$

基于上式可以用 x_0 和噪声变量 ε 的线性组合来表示任一中问步骤的样本状态 x_t 。当时间步达到一定的数量级时， $\bar{\alpha}_T$ 接近于 0， $q(x_t|x_0)$ 将收敛到明确的先验高斯分布，即 $p(x_T) \approx \mathcal{N}(x_T; 0, I)$ 。

在反向去噪的过程中，模型将被训练逆转上述扩散操作，通过可学习的转移核来构建反向马尔可夫链来代替 $q(x_{t-1}|x_t)$ ，这个过程的计算原理如下：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \quad (3)$$

其中 $p_\theta(x_t)$ 表示 x_t 在反向过程中的概率分布， $\mu_\theta(x_t, t)$ 和 $\Sigma_\theta(x_t, t)$ 分布表示时间步 t 处样本可学习的均值和方差。通过优化负对数似然的变分下界来学习拟合数据分布 $q(x_0)$ 的参数 θ ：

$$\max_{\theta} \mathbb{E}_{q(x_0)} [\log p_\theta(x_0)] \leq \max_{\theta} \mathbb{E}_{q(x_0, \dots, x_T)} [\log p_\theta(x_{0:T}) - \log q(x_{1:T}|x_0)] \quad (4)$$

其中 $\mathbb{E}$ 表示期望。将方差 $\Sigma_\theta(x_t, t)$ 固定为常数值 $\sigma_t^2 = \beta_t$ ，公式（4）可以简化为：

$$\mathcal{L}(\varepsilon_\theta) = \sum_{t=1}^T \mathbb{E}_{x_0, \varepsilon, t} [\|\varepsilon_t - \varepsilon_\theta(x_t, t)\|_2^2] \quad (5)$$

通过深度神经网络训练实现对 $\varepsilon_\theta(x_t, t)$ 的预测，由噪声 ε 生成对应的样本 x_t 。反向过程的噪声均值 $\mu_\theta(x_t, t)$ 可由下式表示：

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\alpha_t}} \varepsilon_\theta(x_t, t) \right) \quad (6)$$

最终，基于上述反向推理过程可以从随机变量中采样，根据公式（7）反复迭代去噪生成全新的数据

样本。

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\alpha_t}} \varepsilon_\theta(x_t, t) \right) + \sigma_t z, z \sim \mathcal{N}(0, I). \quad (7)$$

1.2 注意力机制

注意力机制是 Transformer 架构的核心，它允许模型在处理序列数据时动态地分配不同信息的重要性权重。在噪声预测模块中引入注意力层，实现有选择地强调输入信号分割块之间的联系。检索和查询输入条件与各层间的信息，帮助模型关注不同表示子空间中的输入序列，增强深层特征之间的交互，从而实现对加噪样本的局部与全局特征的精准捕捉。

在注意力层，通过计算每个位置的注意力权重，选择缩放点积注意力作为评分函数，以便模型根据当前任务需求来调整不同位置的重要性。首先将输入数据 $\mathbf{Z}$ 与线性变换参数矩阵相乘，得到对应的查询矩阵 $\mathbf{Q}$ ，键矩阵 $\mathbf{K}$ 和值矩阵 $\mathbf{V}$ ，分别描述当前需要关注的内容、存储在记忆空间的信息和与前者对应的内容^[20]。通过点积计算相似度再除以 $\sqrt{d_k}$ ，最终由 softmax 函数归一化得到自注意力权重矩阵 $\mathbf{A}$ 。计算公式如下所示：

$$\text{Attn}_{\text{self}}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V} \quad (8)$$

其中 $\mathbf{Q} = \mathbf{Z}\mathbf{W}_Q$, $\mathbf{K} = \mathbf{Z}\mathbf{W}_K$, $\mathbf{V} = \mathbf{Z}\mathbf{W}_V$, $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{N \times d_k}$, N 表示输入矩阵 $\mathbf{Z}$ 的维数, d_k 表示键矩阵 $\mathbf{K}$ 的维数。

2 基于 Diffusion Transformer 的数据增强

2.1 方法框架

数据增强技术是提升故障诊断模型性能的关键手段，但当前主流的数据生成方法存在显著局限性：一方面，对抗训练机制固有的博弈不稳定性易使生成样本在特征空间呈现单一分布，严重制约样本质量和多样性；另一方面，传统 U-Net 架构受限于局部感受野，难以有效捕获振动信号中的多尺度故障特征，影响生成样本的故障表征完备性。

为解决上述问题，本文从理论机理与模型架构两个维度，深度融合扩散模型的渐进式扩散生成特性与 Transformer 的全局特征建模能力，提出了一种基于 Diffusion Transformer 的数据增强方法。该方法的核心目标是生成符合初始数据分布且特征丰富的新样本，为后续诊断提供均衡数据集。方法的整体框架如图 1 所示，主要包括以下四个部分：原始信号采集与处理、基于 DiT 模型的数据增强、生成样本的质量评估以及不平衡数据集的故障诊断。




图1 基于 Diffusion Transformer 的数据增强与诊断框架

总体工作流程如下:

1) 信号处理: 本文首先使用固定滑动窗口截取原始信号片段, 接着通过快速傅里叶变换 (Fast Fourier Transform, FFT), 归一化与信号重塑等处理步骤, 将一维时域信号转换为二维频域图像, 作为诊断模型的初始输入样本。

2) 数据增强: 将初始训练集输入 DiT 中, 利用正向扩散处理后的加噪样本训练扩散模型的噪声预测网络。通过反向传播过程从随机噪声图中迭代去噪生成各种类型符合真实数据分布的新样本, 以此平衡初始数据集。

3) 质量评估: 结合多核最大均值差异定量度量和可视化定性分析, 从生成样本的真实性和多样性角度综合评估生成模型的性能。

4) 故障诊断: 通过扩充不平衡的数据样本来协调不同健康状态样本的比例。然后将比例均衡的数据集输入诊断模型测试分类效果, 通过不同工况与比例配置的实验验证所提方法的有效性和泛化性。

2.2 基于 DiT 的数据增强模型

本文使用 DiT 模型来生成高质量且多样的旋转机械故障样本，以此生成故障样本平衡的数据集，从而提高诊断模型的故障分类效果。DiT 模型的训练与生成过程如图 2 所示。模型首先对输入的初始样本进行加噪处理，以不同时间步下的加噪样本作为后续模块的训练数据；之后训练相应模块使得模型能够精准预测附加信息提示下的噪声图相对于原型样本所添加的总噪声；最终基于反向马尔科夫链的推导，对随机高斯抽样进行推理重构来生成新样本。




图 2 DiT 的训练生成过程

2.2.1 输入预处理

利用 FFT 方法将截取的原始一维时域信号转换为频域信号，接着将 1×1024 的向量结果归一化、重组等操作变换为 $1 \times 32 \times 32$ 的二维矩阵 x_0 。本文的扩散模型采用 Cosine 噪声表，时间总步长 T 设置为 1000。在正向扩散过程中，将输入信号 x_0 按照公式 (1) 中的条件概率公式添加随机噪声，得到一系列时间步 t 对应的加噪样本 x_t ，根据公式 (2) 的推理最终 x_T 将近似服从标准高斯分布。

在 Transformer 架构中，加噪后的图像矩阵 x_t 被 4×4 的卷积核切分成固定大小相同的序列片段。每个序列展平后通过线性层映射到相应的维度，并附加额外的序列位置信息。同时样本标签 y 和对应时间步 t 也被编码作为条件信息嵌入到每个序列中，构成一个包含丰富信息的序列矩阵，确保模型可以充分有效地实现局部特征和上下文位置关系表示。相较于常规方法，该预处理方法展现出更好的计算效率与特征提取的精准性，为后续模型训练提供了更优质的输入数据。输入信号的整个处理流程如图 3 所示。




图3 数据预处理与输入定义

2.2.2 噪声预测模块

噪声预测模块是扩散模型生成新样本、实现数据增强的核心。根据该模块训练得到的预测噪声，后续模块可以通过反向马尔科夫链按照公式（7）逐步推导出符合训练集分布的全新数据。本文选择 Transformer 架构下的自适应层归一化，而非更为常见的基于卷积的 U-Net 架构。具体而言，噪声预测模块采用了两层的 DiT Block 框架，该框架在层归一化的基础上引入了自适应机制，使得预测模块能够根据输入数据调整子网络，而非固定的归一化参数，使得模块更好地适应不同任务需求和数据分布；同时对于追加在输入序列中的时间步和标签等条件信息，将其上下文条件化，通过在多头自注意力块中添加额外的交叉注意力层来提高模型条件处理与特征提取的能力；为了提高数值稳定性，各线性映射层的参数初始化后每层都经过回归的缩放和平移的操作，最后在残差模块结束前进行缩放回归。

噪声预测模块通过注意力机制和残差操作在不同层间分配权重，关注输入序列与条件信息。相较于 U-Net 架构，通过改进特征提取和条件处理机制提升了模型泛化能力和样本生成质量，实现更高效的数据增强效果。噪声预测模块的整体结构如图 4 所示。




图4 噪声预测模块

2.2.3 结果重构

从高斯分布中随机抽取一个噪声图作为反向传播的起点 x_T ，按照公式 (7) 迭代计算前一时间步的样本 x_{t-1} ，时间步 t 从 T 依次递减到 1。由随机噪声图反向推理出新样本来实现在去噪过程中引入新的随机性。考虑到初始数据分布的复杂性，迭代推理设置模型每次仅需逆转一个微小的噪声扰动，从而有效调控整体的反向推理误差，实现高效精准的数据生成。

DiT 模型的训练目标是最小化以下损失函数，该函数采用均方根误差形式，衡量正向扩散过程中实际添加的噪声 ε_t 与噪声预测模块输出 ε_θ 之间的差异：

$$\mathcal{L}_{\text{DiT}} = \mathbb{E}_{x_t, \varepsilon_t} \left[\left\| \varepsilon_t - \varepsilon_\theta(\sqrt{\alpha_t}x_t + \sqrt{1 - \alpha_t}\varepsilon, t, y) \right\|_2^2 \right] \quad (9)$$

3 实验结果与分析

3.1 实验设置说明

采用 SCARA (Selective Compliance Assembly Robot Arm) 滚珠丝杠数据集验证 DiT 方法的有效性。实验平台如图 5 所示，主要包括 J3 轴驱动电机、控制面板、计算机、J3 轴和滚珠丝杠等部件。该工业数据集共三种故障类别：螺旋螺母卡滞、花键螺母卡滞和滚珠脱落，以下简称为卡滞 1、卡滞 2 和球脱落。图 6 展现了在 9kg 负载条件下采集到的电流信号时域与频域图像。从时域图 6 (a) 观察到，四种数据类型的波形整体上相似，但丝杠与螺母间的转动受阻，丝杠受到较大冲击导致卡滞 1 波形整体呈现出更明显的高频振荡趋势。而在正常的运行故障状态下，丝杠的电流信号则保持相对稳定。从频域图 6 (b) 观察到，卡滞故障图像呈现宽频带能量分布。卡滞 1 状态下丝杠因机械冲击产生了丰富谐波和高频成分。同样地，花键轴直线运动受阻也导致了卡滞 2 状态的特征性边频成分。球脱落状态的频率成分则相对简化，以基频及其二次谐波为主，这表明滚珠脱落的丝杠仍能维

持较为规律的电流波动。而正常状态下，频率则主要集中在基频与其附近谐波，能量较为集中，信号质量良好。综上，SCARA 传动电机的 d 轴电流信号包含丰富的故障信息，适用于滚珠丝杠的故障诊断。




图 5 SCARA 丝杠实验平台




图 6 9kg 负载下电流信号时频图

实验中设置工作负载分别为 0kg, 3kg, 6kg 和 9kg, 验证所提方法在不同工况下的泛化性能, 丝杠转速为 4000r/min。系统的采样频率设定为 8kHz, 每个样本长度为 20480。在实际生产环境中, SCARA 机器人在正常工作状态下的运行数据样本远多于故障状态下运行数据。因此, 实验中设置不平衡数据集来研究样本不平衡对诊断模型分类性能的影响。测试集选择状态平衡的全新数据集, 每种健康状态的样本数量为 200。

为了验证 DiT 模型的生成效果, 本文选取了 CGAN^[7]、CAE-GAN^[8]、DCGAN^[9]、WGAN-GP^[12]、DDPM^[14]、VQ-LDM^[15]以及 CDM^[16]等主流生成模型作为对比。其中, CGAN 通过引入条件信息增强了生成器的可控性; CAE-GAN 利用卷积自编码器提取输入特征, 实现精准的对抗生成; DCGAN 采用深度卷积结构优化了生成器与鉴别器的特征提取能力; WGAN-GP 通过距离损失函数和梯度惩罚

机制提升了训练稳定性;DDPM 基于逆向扩散的生成机制,其训练过程稳定且能充分学习数据分布;VQ-LDM 通过对矢量量化的潜在特征进行扩散,为高质量生成提供了新范式;CDM 在扩散过程中融入条件信息以增强生成针对性。

本文实验具体配置如下:操作系统为 Windows11, CUDA12.6, GPU 为 NVIDIA 4060, 8GB 独显,调用 GPU 进行训练,框架基于 Pytorch。在数据生成实验中,参考相关文献的推荐值和网格搜索结果选择各模型的超参数,DiT 生成模型的学习率设置为 0.005,训练迭代次数为 1000,批量大小为 128。

3.2 生成质量评估

一个优秀的生成模型首先需要能有效捕捉真实数据的局部与全局特征,使得生成样本分布充分拟合输入的初始数据分布。为了衡量这一点,本实验采用了多核最大均值差异(Multi-kernel Maximum Mean Discrepancy, MK-MMD)度量来量化生成数据与初始数据的拟合程度。针对复杂高维矩阵, MK-MMD 将其通过一个相同的映射函数将其映射到再生核希尔伯特空间,特征核由不同核的加权和构成,映射后数据的均值差异即为这两部分的分布差异。

DiT 模型和各对比模型基于不平衡比例 1:10 的训练集进行数据生成,采用 MK-MMD 度量结果如表 1 所示。观察表格发现,生成数据集与真实数据集的均值差异均在一个较小的范围内,证明生成模型能够拟合输入样本来输出符合初始状态分布的新样本,以帮助后续诊断模型的训练。整体工况的差异均值显著小于各类故障的差异均值,这是因为在工况度量中生成与真实数据集均采用相同的正常样本。相较于对抗生成模型,扩散模型通过多次迭代不断去除微小的噪声从而实现更精准的样本生成,生成样本分布与初始分布也更为拟合。而 DiT 模型不同工况下整体最小的均值差异显示了其独特输入信息处理架构下优异的特征捕捉能力。

表 1 真实样本与生成样本的 MK-MMD 度量

模型	负载 (kg)					故障类型			
	0	3	6	9	平均值	卡滞 1	卡滞 2	球脱落	平均值
DiT (Ours)	0.0269	0.0302	0.0360	0.0447	0.0345	0.1264	0.0975	0.0802	0.1013
DDPM	0.0633	0.0656	0.0670	0.0483	0.0611	0.1829	0.1703	0.1837	0.1790
VQ-LDM	0.0358	0.0703	0.1555	0.1220	0.0959	0.2257	0.2321	0.3138	0.2572
CDM	0.0841	0.1705	0.0984	0.1222	0.1188	0.2675	0.2817	0.3376	0.2956

CAE-GAN	0.4839	0.3142	0.3817	0.4180	0.3995	1.2437	1.2545	1.0658	1.1880
WGAN-GP	0.1152	0.1233	0.1634	0.1476	0.1374	0.5118	0.2982	0.2310	0.3470
DCGAN	0.3771	0.3680	0.3259	0.1733	0.3111	1.4232	1.2882	0.7326	1.1480
CGAN	0.2953	0.3368	0.4398	0.1937	0.3164	1.0963	1.1835	1.1344	1.1380

为了直观展现与评估模型生成样本的多样性，本部分采用 t-分布随机邻域嵌入（t-SNE）方法，基于 Kullback-Leibler 散度将高维数据映射到低维空间，从而实现目标数据特征在二维图像上的可视化聚类。实验中生成样本和真实故障样本根据故障类型分别用不同颜色的图标表示，其中真实样本使用实心图标，生成样本使用空心图标。从图 7 中可以直观地观察到，各个模型的生成样本都聚合在对应的真实故障样本附近，符合数据初始分布。GAN 模型变体的生成样本在特征空间中呈现出单一集中的布局，与大多数真实样本存在一定的偏差，这表明 GAN 系列模型虽然很好地捕捉到初始数据的分布，但局限于学习特征甚至过度拟合，导致其虽能和真实分布中学到的特征部分靠近却产生偏移现象，即便采用梯度下降等策略也难以弥补缺陷。而 DiT 模型生成样本特征在不同故障状态之间呈现出清晰边界的同时分布在真实样本间进一步发散，符合扩散生成的本质。这表明所提出的模型为不平衡样本初始受限的数据分布提供了更为多样化的特征表示。DDPM、CDM、VQ-LDM 模型的生成样本分布也体现出一定程度的分散趋势。总体来看，所有模型生成的样本都可以学习原始故障样本的特征，达到补充样本集实现数据增强的效果，而所提出的 DiT 模型能够为诊断任务提供特征信息更加精准丰富的生成样本。




图 7 t-SNE 可视化结果

综上，通过 MK-MMD 指标度量生成样本与真实样本的整体分布匹配度，验证生成数据的分布一致性。同时结合 t-SNE 可视化的定性分析，直观展现生成样本在特征空间的分布状态，评估生成样本的多样性和与真实样本的聚合情况。具体而言，提出的 DiT 模型生成样本在特征空间中分布合

理且多样性良好,同时 MK-MMD 值较低,证明该方法能准确拟合初始数据分布并具备强泛化能力。相比之下, WGAN-GP 等模型在定量指标上表现尚可,但可视化显示生成样本分布单一或存在偏移,说明其仍存在过拟合和特征表达不足的问题。因此,实际应用中应优先选择定量与定性表现均优的模型,以兼顾生成样本的真实性和多样性,从而提升下游诊断模型的性能与鲁棒性。

3.3 故障诊断结果

在不平衡故障诊断实验中,本实验构建了不同工况下的小样本不平衡训练集和平衡测试集,将经过生成模型数据增强的样本集输入到多层卷积诊断模型中,通过 10 次实验结果取平均值来作为最终诊断精度。表 2 为典型不平衡比例 1:10 下各模型增强数据的诊断结果,图 8 为对应的柱形图。根据实验结果本文得到以下结论:

表 2 1:10 不平衡比例下诊断结果

模型	0kg	3kg	6kg	9kg	平均值
DiT(Ours)	97.88±2.06	97.38±1.32	96.25±0.72	97.50±0.96	97.25±1.02
DiT(U-Net)	96.78±2.97	93.46±2.16	95.86±1.21	96.48±1.59	95.65±1.98
DDPM	96.51±3.01	96.63±1.05	95.00±1.40	95.50±2.86	95.91±2.08
VQ-LDM	93.46±2.92	94.12±1.93	95.46±1.72	91.13±1.64	93.54±2.05
CDM	91.20±2.98	94.85±1.70	94.13±1.46	96.01±1.50	94.05±1.91
CAE-GAN	83.79±7.50	86.66±6.81	86.85±3.53	87.51±6.69	86.20±6.13
WGAN-GP	91.00±5.32	92.75±3.42	93.50±3.79	91.63±1.92	92.22±3.61
DCGAN	80.38±5.42	87.00±4.21	89.75±3.90	88.13±1.98	86.31±3.88
CGAN	80.15±3.92	91.53±2.52	89.86±4.25	80.13±2.42	85.42±3.28
None	25.00±0.00	25.00±0.00	25.00±0.00	25.00±0.00	25.00±0.00




图8 1:10 不平衡比例下诊断结果柱形图

(1)当初始不平衡训练集未经处理直接输入到诊断模型时,不同工况下诊断精度均值仅为 25%。受限于数量有限且分布极不均衡的数据集,模型偏向于大多数类,即只简单地将所有测试样本都归类为正常样本。这表明诊断模型近乎完全无法区分故障样本,低效的分类性能反映了诊断模型在处理不平衡样本问题的局限性,原始稀少的样本数量以及不同健康状态分布的不均衡严重阻碍了模型对真实数据集的有效学习。

(2)在数据增强后充足数据集的支持下诊断模型的分类精度均得到了极大提升,表明基于生成模型的数据增强方法能够有效生成缺失样本,为后续诊断训练提供了平衡数据集。GAN 模型由于其对抗生成的本质,不稳定的训练过程仍导致分类网络难以精确平稳地学习真实分布。表 2 中可以观察到 GAN 模型变体的精度方差显著大于扩散模型,其中 CAE-GAN 的诊断波动最大,其自编码器部分在特征提取与重建的过程中丢失部分重要信息,导致生成样本质量不一致。CGAN 的生成器未能充分融合条件信息,与特征信息并不完全匹配,导致其在 0kg 和 9kg 工况下表现不佳。基于深度卷积层的 DCGAN 难以捕捉复杂的数据分布,提供的样本特征过于集中,阻碍了分类网络泛化性能的提升。WGAN-GP 采取距离损失和梯度惩罚等策略,有效提高了训练稳定性,取得了 GAN 模型中较优的生成效果 (92.22%)。

(3)扩散模型支持下的模型诊断精度和方差均值整体优于对抗模型,这表明扩散过程引入的随机扰动和严格迭代去噪保证了生成数据集的多样性与真实性。DDPM 采用经典的扩散模型框架,通过细致的噪声预测和稳定的训练过程,确保分类网络能够准确学习真实分布。VQ-LDM 结合矢量量化与潜在扩散模型,提升了计算效率,但在某些工况下,矢量量化可能导致样本细节丢失。CDM 作为条件扩散模型,条件信息的引导使其在特定工况下表现出色,但其对条件信息的依赖导致条件信息与特征信息不匹配时其性能出现下降。

(4) 在不同工况下本文提出的方法均取得了最高的诊断精度, 精度均值达到了 97.25%, 与 DDPM 模型 (95.91%) 相比有一定的提高。DiT 模型基于 Transformer 架构, 利用注意力机制与自适应层归一化有效地融合了所添加的位置与条件信息, 取得了更好的生成效果。为进一步验证所提方法的优越性, 本文在实验部分专门设置了以 U-Net 为噪声预测模块主干结构的扩散模型 DiT(U-Net) 作为对照组。DiT 模型在不同负载下的分类准确率均高于 DiT (U-Net) 模型, 准确率提升了 1.6%, 且标准差更小, 说明模型不仅整体性能更优, 同时具有更好的鲁棒性。尤其在 3kg 负载下, 所提出的模型准确率为 97.38%, 而采用 U-Net 的方法仅为 93.46%, 进一步体现了 Transformer 架构在复杂工况下的优势。综上, 在扩散生成任务中, DiT 模型更强的特征表达能力和对条件信息的高效融合, 能够使生成样本更贴近真实分布, 有效提升了下游诊断任务的性能。

为验证所提方法在具体故障分类任务中的表现, 绘制了不平衡比例 1:10 下的混淆矩阵。从图 9 可以看出, 仅基于初始数据训练的模型完全无法有效分类, 因样本不平衡将所有测试样本错误地预测为训练集中的多数类。而输入 DiT 增强数据的模型在不同负载下的混淆矩阵均表现出较高的分类准确率, 尤其是在卡滞 1 和卡滞 2 两类故障的识别上, 几乎实现了 100% 的准确率。说明通过 DiT 生成的数据极大地丰富了这两类故障样本的特征表达, 有效提升了模型对这两类故障的诊断能力。相比之下, 球脱落故障的识别准确率略低, 9kg 下该故障诊断均值为 91.5%, 部分样本被误判为正常状态。这一现象与原始数据分析结果相一致: 球脱落故障由于仅取下少量钢珠, 导致其电流信号与正常状态较为接近, 特征区分度较小。因此, 即便采用 DiT 进行数据增强, 模型在该类故障上的区分能力仍受到一定限制, 但整体识别率依然显著优于未增强数据的情况。进一步分析可以发现, 随着负载的增加, DiT 模型在各类故障的诊断精度保持稳定, 说明其生成的数据不仅能够补充样本数量, 更能有效覆盖不同工况下的特征变化, 提高模型的泛化能力。在样本不平衡的情况下, DiT 生成的故障样本为模型提供了更多的判别信息, 提升了对少数类故障的识别效果。




图9 1:10 不平衡比例下诊断结果的混淆矩阵

在多种不平衡比例（1:100、1:50、1:20、1:10、1:5）下开展实验以验证模型的泛化性能，诊断准确率如表3所示，同时绘制雷达图10以直观展现实验结果。随着训练集中的少数类样本比例逐渐增加，所有模型的性能均有所提升。这说明类分布的均衡性对于生成模型的表达能力具有重要影响。本文提出的 DiT 方法在所有不平衡比例下均取得最优的分类准确率，尤其在 1:100 的极度不平衡场景下仍达到 69.30%，优于次优模型 DDPM（67.27%），展示了其在高不平衡条件下的鲁棒性。None 模型在 1:100 到 1:20 的比例下准确率仅为 25.00%，在数据极度不平衡且无任何处理措施时，模型难以有效学习到故障特征。扩散模型通过严格的迭代去噪过程，不同比例下生成质量显著优于对抗生成方法。而 GAN 模型变体由于对抗生成的过程在不同比例下的准确率波动较大，性能不够稳定。WGAN-GP 模型使用 Wasserstein 距离和辅助分类器在一定程度上稳定了训练过程，提高了生成样本的质量，虽低于扩散模型，但优于其他 GAN 变体。

表3 不同比例下不平衡诊断结果

模型	1:100	1:50	1:20	1:10	1:5	平均值
DiT (Ours)	69.30±5.00	79.96±2.26	86.50±2.67	97.50±0.96	97.86±1.27	86.23±2.80
DiT(U-Net)	63.95±5.45	77.53±2.98	83.20±2.79	96.48±1.59	96.53±1.16	83.54±3.10
DDPM	67.27±5.80	78.37±2.74	84.15±3.93	95.50±2.86	94.25±1.74	83.91±3.55
VQ-LDM	62.96±6.74	71.70±2.32	82.46±2.51	91.13±1.64	95.76±1.81	80.80±3.35
CDM	54.88±6.83	75.24±3.21	76.38±4.66	96.01±1.50	92.65±2.32	79.03±4.25
CAE-GAN	28.21±9.41	53.57±4.18	71.38±6.74	87.51±6.69	86.25±5.01	65.38±6.33

WGAN-GP	51.64±6.61	65.51±2.43	76.63±5.97	91.63±1.92	93.10±3.15	75.70±4.54
DCGAN	37.17±9.79	63.43±5.67	63.13±3.99	88.13±1.98	89.31±3.63	68.23±5.77
CGAN	49.13±6.29	49.85±5.51	70.09±7.12	80.13±2.42	87.88±2.39	67.41±5.33
None	25.00±0.00	25.00±0.00	25.00±0.00	25.00±0.00	30.69±9.71	26.14±2.43




图 10 不同比例下不平衡诊断雷达图

4 结束语

本文提出了一种基于 Diffusion Transformer 的样本不平衡数据增强方法，旨在解决实际生产中真实样本数量有限且分布不平衡的问题。在扩散模型的基础上使用改进的 DiT 模型进行数据增强，该模型首先通过 Transformer 架构处理加噪样本，嵌入位置信息和条件信息，经过自适应归一化层实现精准的噪声预测。其次，在反向传播过程中，经过迭代推理从随机抽样中获取去噪样本，补充初始数据集。最后，质量评估和不平衡诊断实验表明，与传统生成模型 GAN 相比，DiT 模型基于扩散的思路在生成过程中很好地引入了随机变量，避免了生成样本与小样本过度拟合的问题；同时相较于扩散模型噪声预测模块中广泛使用的 U-Net 结构，Transformer 架构下的 DiT Block 通过自适应层归一化、注意力机制、残差与上下文条件化等策略使得模块能够更好地捕捉局部和全局特征。本方法的生成样本不仅符合真实数据分布，还具备高度的多样性，能够为后续诊断模型的训练提供充足的数据支持。

在未来的研究中，将针对实际工业环境中的旋转机械数据集对 DiT 模型结构进行优化，通过引入知识蒸馏和模型剪枝等策略改进网络架构，提高计算效率。并进一步探索扩散模型在迁移学习中的应用潜力，提高模型的泛化性能，实现跨工况故障诊断。

参考文献:

- [1] JIANG Li, XIANG Shizhao. Rolling bearing fault diagnosis based on CEEMDAN-VSSLMS[J]. Computer Integrated Manufacturing System, 2024, 30(3): 1138-1148(in Chinese). [江莉, 向世召. 基于 CEEMDAN-VSSLMS 的滚动轴承故障诊断[J]. 计算机集成制造系统, 2024, 30(3): 1138-1148.]
- [2] Hu Y, Liu R, Li X, et al. Task-sequencing meta learning for intelligent few-shot fault diagnosis with limited data[J]. IEEE Transactions on Industrial Informatics, 2021, 18(6): 3894-3904.
- [3] ZHANG W, PENG G, LI C, et al. A New Deep Learning Model for Fault Diagnosis with Good Anti-Noise and Domain Adaptation Ability on Raw Vibration Signals[J]. Sensors, 2017: 425.
- [4] GUO Junfeng, WANG Miaosheng, SUN Lei, et al. New method of fault diagnosis for rolling bearing imbalance data set based on generative adversarial network[J]. Computer Integrated Manufacturing System, 2022, 28(9): 2825-2835(in Chinese). [郭俊锋, 王淼生, 孙磊, 等. 基于生成对抗网络的滚动轴承不平衡数据集故障诊断新方法[J]. 计算机集成制造系统, 2022, 28(9): 2825-2835.]
- [5] CHEN Z, CHEN J, FENG Y, et al. Imbalance fault diagnosis under long-tailed distribution: Challenges, solutions and prospects[J]. Knowledge-Based Systems, 2022: 110008.
- [6] YANG G, ZHONG Y, YANG L, et al. Fault Diagnosis of Harmonic Drive With Imbalanced Data Using Generative Adversarial Network[J]. IEEE Transactions on Instrumentation and Measurement, 2021: 1-11.
- [7] SON M, JUNG S, JUNG S, et al. BCGAN: A CGAN-based over-sampling model using the boundary class for data balancing[J]. The Journal of Supercomputing, 2021, 77(9): 10463-10487.
- [8] LI Ke, HE JianGuang, SU Lei, et al. Fault diagnosis method for rolling bearing based on CAE-GAN [J]. Journal of Vibration and Shock, 2023, 42(23) 65-70 (in Chinese). [李可, 何坚光, 宿磊, 等. 基于 CAE-GAN 的滚动轴承故障诊断方法[J]. 振动与冲击, 2023, 42(23): 65-70.]
- [9] LIAO Ke, JING Xiaoyuan, Li Shuangyuan, et al. Unbalanced Data Bearing Fault Diagnosis Based on SC-DCGAN[J]. Machine Tool and Hydraulics. 2024, 52(24): 208-213. [廖珂, 荆晓远, 李双远, 等. 基于 SC-DCGAN 的不平衡数据轴承故障诊断[J]. 机床与液压, 2024, 52(24): 208-213.]
- [10] HAN B, JIANG X, WANG J, et al. A Novel Domain Adaptive Fault Diagnosis Method for Bearings Based on Unbalance Data Generation[J]. IEEE Transactions on Instrumentation and Measurement, 2023: 1-11.

- [11] Xu X, Chen X, Zhao Y. Data imbalance bearing fault diagnosis based on fusion attention mechanism and global feature cross GAN network[J]. Measurement Science and Technology, 2024, 35(10): 106136.
- [12] LU Qinhua, CHEN Jiayu, WANG Xuhang, et al. Fault Diagnosis for Imbalanced Data: a Pre-Trained Data Enhancement Method[J]. Measurement and Control Technology. 2025,44(01):10-21(in Chinese). [陆钦华,陈嘉宇,王旭航,等.数据不平衡故障诊断:一种预训练数据增强方法[J].测控技术,2025,44(01):10-21].
- [13] Song Y, Sohl-Dickstein J, Kingma D P, et al. Score-based generative modeling through stochastic differential equations[J]. arXiv preprint arXiv:2011.13456, 2020.
- [14] Yang X, Ye T, Yuan X, et al. A novel data augmentation method based on denoising diffusion probabilistic model for fault diagnosis under imbalanced data[J]. IEEE Transactions on Industrial Informatics, 2024.
- [15] Zhang T, Lin J, Jiao J, et al. An interpretable latent denoising diffusion probabilistic model for fault diagnosis under limited data[J]. IEEE Transactions on Industrial Informatics, 2024.
- [16] Liu X, Chen J, Xie J, et al. Generating hsr bogie vibration signals via pulse voltage-guided conditional diffusion model[J]. IEEE Transactions on Intelligent Transportation Systems, 2024.
- [17] Zhao P, Zhang W, Cao X, et al. Denoising diffusion probabilistic model-enabled data augmentation method for intelligent machine fault diagnosis[J]. Engineering Applications of Artificial Intelligence, 2025, 139: 109520.
- [18] WU Jingyuan, SHU Qilin, WANG Geng, et al. Research on Early Fault Diagnosis of Rolling Bearings Based on Diffusion Models [J]. Modular Machine Tool & Automatic Manufacturing Technique, 2024(12):117-122 (in Chinese). [吴静远,舒启林,王耿,等.基于扩散模型的滚动轴承小样本故障诊断研究[J].组合机床与自动化加工技术,2024(12):117-122.]
- [19] Zhang Y, Zhou P, Ma E. Anomaly detection of industrial smelting furnace incorporated with accelerated sampling denoising diffusion probability model and conv-transformer[J]. IEEE Transactions on Instrumentation and Measurement, 2024.
- [20] BRAUWERS G, FRASINCAR F. A General Survey on Attention Mechanisms in Deep Learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2023: 3279-3298.

作者简介:

王旻杰(2001-), 男, 江苏南通人, 苏州大学硕士研究生, 研究方向: 扩散模型等, E-mail: mingeraint95@163.com。

+ 陈良(1981-), 男, 江苏苏州人, 苏州大学教授, 博士, 博士生导师, 研究方向: 新一代人工智能与深度学习理论, 工业人工智能, 故障诊断与预测性维护等, E-mail: ChenL@suda.edu.cn。

陈启通(1996-), 男, 河南商丘人, 苏州大学博士研究生, 研究方向: 故障诊断、对抗模型、小样本学习和迁移学习等, E-mail: qtchen0730@163.com。

