

基于噪声变化的扩散模型高质量人像检测算法

张正宇², 李明轩^{1*}, 程泊宣¹, 屈音璇¹, 李春宇¹, 杨玉柱¹¹中国人民公安大学侦查学院, 北京 100038;²中国人民公安大学信息网络安全学院, 北京 100038

摘要 针对现有的生成式人像检测方法普遍存在的泛化性不足和数据集缺乏问题,提出一种基于噪声变化的扩散模型高质量人脸图像检测模型。所提方法通过基于去噪扩散隐式模型(DDIM)的反演算法,在文本指引下得到反演图像,对比真实与生成图像反演后的底层噪声分布差异,并优化残差网络以鉴别图像的真实性,显著增强检测模型的准确率和泛化性。此外,为进一步提高模型的泛化性,构建一个包含 10000 张高质量多类别人脸图像的数据集,弥补现有领域中高质量人脸数据的空白。实验结果表明,所提检测算法对生成人脸的检测准确率可以达到 98.7%,泛化性优于现有方法,能在不同种类人脸图像之间实现有效迁移检测。

关键词 扩散模型;生成式图像;深度学习;图像检测

中图分类号 TP391.4

文献标志码 A

DOI: 10.3788/LOP250542

Diffusion Model High-Quality Facial Image Detection Algorithm Based on Noise Variation

Zhang Zhengyu², Li Mingxuan^{1*}, Cheng Boxuan¹, Qu Yinxuan¹, Li Chunyu¹, Yang Yuzhu¹¹School of Criminal Investigation, People's Public Security University of China, Beijing 100038, China;²School of Information Network Security, People's Public Security University of China, Beijing 100038, China

Abstract The limited generalization and dataset scarcity of existing generative facial image detection methods present significant challenges. To address these issues, this study proposes a high-quality facial image detection model based on noise variation and the diffusion model. The proposed method employs an inversion algorithm using the denoising diffusion implicit model (DDIM) to generate inverted images with text-based guidance. By comparing the noise distribution differences between real and generated images after inversion, the method optimizes a residual network to identify image authenticity, and enhances both accuracy and generalization. Additionally, a dataset of 10000 high-quality, multi-category facial images is constructed to address the shortage of available facial data. Experimental results demonstrate that the proposed algorithm achieves 98.7% accuracy in detecting generated facial images and outperforms existing methods, enabling effective detection across diverse facial images.

Key words diffusion model; generated image; deep learning; image detection

1 引言

近年来,生成式人工智能技术迅速发展,其应用范围拓展至图像、声音和视频生成等多个领域^[1],极大地促进了内容创作与传播的便捷化。在图像生成领域,生成式人工智能技术的应用尤为广泛且深入,如换脸技术、风格迁移,以及基于文本描述的人像或场景生成等。这些技术不仅丰富了数字内容的多样性和表现

力,而且为广告、影视和游戏等行业带来了前所未有的创作自由度与效率提升^[2]。然而,生成式人工智能技术在带来诸多便利的同时,也潜藏着巨大的隐患与挑战,基于该技术的犯罪数量每年呈指数级上升,这一趋势对图像检测技术,尤其是生成人像图像检测技术提出了更高的要求。

目前,主流的生成模型可以分为 2 类。一类为生成对抗网络(GAN)^[3]及其变种模型,如参考文献[4-5]。

收稿日期: 2025-01-19; 修回日期: 2025-02-24; 录用日期: 2025-03-03; 网络首发日期: 2025-03-24

基金项目: 中国人民公安大学刑事科学技术双一流创新研究项目(2023SYL06)

通信作者: *20236990@ppsuc.edu.cn

这类模型提出的时间较早,相关的检测工作如参考文献[6-8]等,已经能有效识别生成的伪造图像,但 GAN 模型中的判别器在学习高分辨率图像复杂模式时,容易出现梯度消失问题,这限制了 GAN 模型在高质量人像生成领域的应用。另一类为利用潜在扩散技术的扩散模型^[9]。这类模型使用的去噪网络能在逐步去噪生成图像的过程中更好地处理高分辨率图像中的细节纹理和局部信息^[10],且在融合变分自编码器(VAE)^[11]后,能大大降低时空资源的消耗。因此,扩散模型成为高质量人像生成领域的主流选择,这也对高质量生成人像的检测提出了更高的要求。

现有针对扩散模型生成人像检测的研究尚处于初级阶段,尤其是针对高质量人脸图像的检测研究更为缺乏。目前的生成式人脸图像检测模型主要存在 2 类问题。第一,大多数针对其检测的模型仍然只依赖于深度学习对原始图像提取像素级特征进行训练和检测,忽视了扩散模型底层的生成原理,导致这种方法仅能针对特征分布较集中、特征信息相似的一类图像进行检测,当检测其他类型图像时会出现抓取特征的偏移和性能退化,即泛化性不强。第二,缺乏高质量人脸数据集。现有的扩散模型生成图像的数据集大多数集中在建筑和物品上,没有高质量、多种类的人脸图像数据集。这也导致虽然也有一些检测模型尝试利用扩散模型的底层生成原理,如 DIRE(Diffusion Reconstruction Error)^[12]利用扩散模型重建真实与生成图像,从而获取重建图像,通过分析重建图像与原始图像噪声分布的误差进行检测,但由于训练集的人像质量低、种类少,这些模型在针对人像伪造检测时的正确率和效率都普遍较低。

针对现有问题,本文进行了 2 方面的工作。第一,提出一种对比底层噪声变化的扩散模型人脸图像检测模型(CNC)。该模型通过去噪扩散隐式模型(DDIM)^[13]反演技术,将生成图像与真实图像的噪声分布差异放大,着重分析利用扩散过程中的噪声变化,而非仅仅注重于图像像素级的特征,极大提高检测模型的泛化性。此外,为提升 DDIM 反演的准确率,引入基于统一视觉语言理解与生成模型(BLIP)^[14]和对比式语言-图像模型(CLIP)^[15]的图像-文本多模态对齐嵌入模块,保证反演过程尽可能贴近扩散的逆过程。同时,创新性地 ResNet50 神经网络中引入通道注意力机制,帮助检测模型集中关注人像的五官等关键信息,避免受到冗余信息的干扰。即使输入人脸的类型不同,它们仍具有相似的注意力,可以利用这种注意力机制指导模型的检测,进一步提升模型在人像检测方面的泛化性。第二,构建一个高质量、多类别的人脸数据集,为扩散模型人像检测领域提供一个专注人脸图像的数据集。该数据集由 10000 张扩散模型生成的人脸图像构成,包含不同性别和年龄的人脸。经过此训练集训练的检测模型能正确识别由扩散模型生成的不同种类人像。

2 现有工作

2.1 图像生成

无论是根据一段话还是基于某种风格的原始图像,利用现有模型都可以生成对应的图像,这不仅可以用于创作,而且能欺骗人眼甚至是机器。在过去几年中,已经有很多关于图像生成的模型,可以将其分为 2 类,分别为基于对抗网络的 GAN 模型和基于去噪网络的扩散模型。GAN 模型主要用于相似风格图像的生成,基于大量训练集进行的生成器与识别器的对抗过程,能生成与训练集风格相差无几的伪造图像。但 GAN 模型也存在很多缺点,如 GAN 的对抗性训练常常导致训练过程不稳定,生成器和判别器之间的博弈可能导致模型收敛困难,使 GAN 模型极其不稳健,难以广泛应用。扩散模型的核心框架是 DDIM 采样^[13],DDIM 提出确定性采样,避免随机噪声的引入,通过引入特定的映射直接从噪声到目标分布生成数据,可以通过较少的迭代步数生成高质量图像。在扩散模型训练阶段,逐步将数据替换为噪声,直到数据变成纯噪声;在扩散模型生成阶段,则从噪声开始,逐步去噪恢复成原始数据,这个过程可以视作利用 U-Net 神经网络逐步移除噪声,重建出干净的图像。在生成过程中,文本被 CLIP^[15]模型编码为潜在空间中的嵌入向量,实现文本和图像的跨模态对齐。同时引入 VAE^[9],不直接在高分辨率图像像素空间中计算,而是将图像压缩到一个更低维的潜在空间,并在该潜在空间中进行扩散。扩散模型在保留生成图像细节的同时,大大降低计算复杂度和显存需求。

2.2 生成式图像检测

生成式图像检测是一种识别和分析由生成式人工智能技术生成的图像的方法。它通常结合深度学习和计算机视觉技术,旨在确定图像是否由生成模型(如 GANs、扩散模型或其他生成式模型)创建,并进一步分析其生成过程的特征。

生成式图像检测模型可以根据图像的生成模型分为 2 类。一类是针对 GAN 模型的检测模型,但 GAN 模型自身在训练过程中存在缺陷,且生成图像的质量不高,导致其在水像领域的应用并不突出,因此对 GAN 模型生成式人脸图像的检测需求并不大。另一类是针对基于去噪网络扩散模型^[9]的检测模型,扩散模型在水像图像生成领域应用广泛,且生成的高质量人脸图像往往难以分辨,因此生成式人脸图像检测工作得到广泛研究并暴露出许多不足。现阶段,针对扩散模型的水像伪造检测模型主要有 DIRE^[12]、F³Net(Fusion, Feedback and Focus Network)^[16]、卷积神经网络检测(CNNDet)^[17]模型,这些模型存在 2 个明显不足:第一,后 2 个模型基于机器学习在原始像素层面进行检测,在跨类别人脸图像检测工作中暴露出特征抓取偏移的问题,导致检测模型的泛化性不强;第二,

DIRE 检测模型利用扩散模型重建误差进行生成式图像检测,避免了仅在原始图像层面的检测,在跨类别检测方面取得一定的进步,但该模型的训练数据并非以人像为主,且人像质量普遍较差,随着生成模型的飞速发展,该模型在高质量人像检测任务中出现明显短板,难以适应新技术的需求。

为解决生成式人像检测工作中暴露出来的 2 大问题,并适应新时期人像伪造检测的新需求,本文深入研究扩散模型的生成原理,提出一个专精人像伪造的检测模型,设计并构建一个高质量人脸数据集,解决了生成式人像检测工作暴露出的问题,极大地推动人像伪造检测领域的进步。

3 基于底层噪声变化的人脸图像检测模型

3.1 模型的检测流程

模型的检测流程如图 1 所示,其中,实线箭头是数据流向,虚线是模块区域边界。流程最左边模块为图像-文本多模态对齐嵌入模块,包括 BLIP 和 CLIP,能分别实现图像-文本对齐和嵌入。DDIM 反演是检测模型的核心步骤,能根据给定的条件信息,即嵌入的高维文本向量,在潜在空间中逐步反演生成符合特定要求的潜在噪声表示。VAE 是潜在空间编码器模块,能

将原始高维图像映射到低维潜在空间,将输入数据的复杂特征压缩为较小的连续表示,并能通过解码器重建输入数据,尽量保持数据的原始形状或分布。VAE-E 是将原始图像编码为潜在空间表示的过程,VAE-D 是将潜在空间表示映射回原始空间的过程。SE-ResNet50 是添加通道注意力模块的残差神经网络,通过全连接网络根据损失来自动学习特征权重,获取特征图每个通道的重要程度,能在检测时注重人脸的五官和轮廓等关键信息。

举例来说,模型首先从外部获取 1 个原始图像 x ,通过图像-文本多模态对齐嵌入模块获取与人像对齐的文本信息,并生成可嵌入的高维向量 $T(T_1, T_2, \dots, T_n)$ 。然后,利用潜在空间编码器将原始图像 x 映射到潜在空间,获取图像在潜在空间的表示 Z_0 。随后,嵌入高维向量指引 T 并通过稳定扩散的 U-Net 对 Z_0 进行 DDIM 反演,获得在潜在空间的噪声表示 $\hat{Z}_t$ 。最后,利用潜在空间编码器将 $\hat{Z}_t$ 解码回原始空间,获得原始噪声分布 $D(\hat{Z}_t)$ 。利用 Kolmogorov-Smirnov(K-S)检验反演后人脸图像的噪声分布,将反演图像的噪声分布 $D(\hat{Z}_t)$ 与正态性检验统计值 P 连接起来作为 SE-ResNet50 二元分类器的输入,实现对输入原始图像的检测。




图 1 所提检测模型流程

Fig. 1 Flowchart of proposed detection model

3.2 图像-文本多模态对齐嵌入模块

生成式图像在生成过程中受到文本提示词的指引,为尽可能让反演过程符合生成过程的逆过程,利用生成式图像扩散过程中的特性来鉴别图像的真实性。所提网络采用图像-文本多模态对齐嵌入模块,该模块由 BLIP 和 CLIP 2 个部分构成。BLIP 提出一种编码器-解码器混合架构(MED),通过跨模态的编码器和解码器,实现跨模态信息流动,能给图像生成较准确的提示词,用来模拟扩散模型生成图像时的提示词部分。CLIP 将生成的提示词转换成相应的高维向量指引,并

引导图像的反演过程。

3.3 潜在空间编码器

生成式人脸图像在原始图像空间的数据分布往往具有高度非线性,因此直接在原始空间中对噪声进行操作可能会非常困难。为实现对复杂生成式图像的反演操作,提出潜在空间编码器模块。该模块由预训练的 VAE 构成,其结构如图 2 所示。VAE 是一种生成式深度学习模型,通过结合自编码器架构与变分推断方法,能在不依赖复杂采样过程的情况下,学习高维数据的潜在表示。VAE 通过最大化变分下界来优化模




图2 VAE编码和解码流程

Fig. 2 Flowchart of VAE encoding and decoding

型,在确保原始空间与潜在空间可映性的基础上,提高模型处理数据的效率和质量。

如图2所示,NN Encoder模块是编码器,用来将高维输入数据压缩为潜在空间的分布表示(m 和 q)。Sampling模块从标准正态分布中随机选取噪声向量 $[e_1, e_2, e_3]$ 。中间的模块为重参数化模块,用来将上述3个向量 m 、 q 和 e 输出采样后的潜在变量:

$$c_i = \exp(q_i)e_i + m_i \quad (1)$$

式中: $\exp(q_i)$ 用来确保生成的标准差为非负数。这样处理使得采样的过程可微,方便通过反向传播优化。

NN Decoder模块是神经网络解码器,其任务是将潜在空间中的变量映射回输入数据空间,生成与原始输入数据尽可能接近的重建数据(输出)。解码器的损失优化主要包括重建误差优化和Kullback-Leibler(KL)散度优化。重建误差优化的目标是 minimized 重建数据与输入数据之间的差异,使解码器输出尽可能逼近原始输入,通过均方根误差(MSE)或交叉熵来度量。KL散度度量的是编码器生成的潜在分布 $q(z|x)$ 与标准正态分布 $N(0, 1)$ 的差异,该优化过程的核心公式为

$$\text{KL}[q(z|x)|p(z)] = \sum_{i=1}^3 [\exp(q_i) - 1 - q_i + m_i^2] \quad (2)$$

在所提检测模型中,VAE的作用体现在几个方面:1)将原始空间的高分辨率(512 pixel×512 pixel×3 pixel)RGB图像映射成低分辨率(64 pixel×64 pixel×4 pixel)潜在图像 Z_0 ,并将其作为DDIM反演的输入,输出潜在噪声分布图像 $\hat{Z}_t$;2)通过预训练的解码器几乎完美地恢复原始空间的噪声分布 $D(\hat{Z}_t)$ 。这一处理不仅极大减少了资源的需求,而且反演效果与直接在原始像素空间操作几乎无异。

3.4 DDIM反演

DDIM采样相比传统的去噪扩散概率模型(DDPM)^[18]采样有2个优势:第一,提出一种使过程非马尔可夫的方法,可以将预训练的扩散模型的采样过程离散化为更少的步骤,不需要在当前状态之前访问所有过去的状态;第二,使每一步的噪声变化成为一个确定性过程。第一个优势可确保反演过程可以在较少

的步数下添加足够的噪声,放大真实图像与原始图像的差异。第二个优势实现反演过程是对生成过程的精准逆向,准确捕捉扩散过程的噪声变化。

为获得一个以某个条件向量 c 为条件生成图像,原始噪声,条件扩散模型从生成人脸图像 Z_0 开始,使用一个学习到的去噪网络 ϵ_θ 并嵌入文本条件进行固定步数的迭代添加噪声,直至获得一个恢复的噪声图像 Z_t 。为反转一个图像 Z_0 ,即获得一个对应的噪声图像 Z_t ,通过式(3)逐步向当前估计的 Z_t 添加噪声:

$$Z_{t+1} = \sqrt{\bar{\alpha}_{t+1}} f_\theta(Z_t, t, c) + \sqrt{1 - \bar{\alpha}_{t+1}} \epsilon_\theta(Z_t, t, c) \quad (3)$$

式中: Z_t 为 t 时刻的噪声潜在图像; c 为通过图像-文本对齐嵌入模块获取并嵌入的高维向量; α_{t+1} 为第 $t+1$ 步的DDIM噪声缩放因子; $\bar{\alpha}_{t+1}$ 为第1~ $t+1$ 步缩放因子的累乘结果; $\epsilon_\theta(Z_t, t, c)$ 为在 t 时刻由已学习的去噪函数 ϵ_θ 预测的噪声; $f_\theta(Z_t, t, c)$ 为当前对于干净潜在图像 Z_0 的最佳估计:

$$f_\theta(Z_t, t, c) = Z_t - \frac{\sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(Z_t, t, c)}{\sqrt{\alpha_t}} \quad (4)$$

针对生成图像与真实图像在DDIM反演过程中的特征差异,提出一种基于噪声分布分析的检测方法。结果表明,当迭代步数设为7时,2类图像的反演差异达到最大。扩散模型生成过程的初始噪声由Torch.rand函数生成,其符合标准正态分布的特性在DDIM反演过程中得以保持,经验证,生成式人脸图像反演后的噪声仍能通过K-S检验($p > 0.05$),而真实图像因初始噪声干扰,其正态性显著降低($p < 0.01$)。最终构建的二元分类器以反演噪声分布 $D(\hat{Z}_t)$ 及其K-S检验统计量作为多维特征输入。

3.5 基于SE-ResNet50的二元分类器

如图3所示,SE-ResNet50核心的挤压激励(SE)模块^[19]分为挤压和激励2个部分,其先将给定信息 X 经 F_{tr} 映射到 U ,然后经过挤压操作,即对每个通道的整个空间维度进行特征聚合映射,最后经过激励层,采用一种简单的自选门机制形式,将嵌入作为输入,并产生每个通道调制权值的集合。这些权重被应用到特征映射 U 上,生成SE模块的最终输出 $\tilde{X}$ 。 F_{tr} 是特征变换模块,将输入图像转换成尺寸为 $H \times W \times C$ 的特征图,其中, H 和 W 为空间维度,是特征在垂直和水平方




图 3 SE 模块图像处理流程

Fig. 3 Flowchart of image processing by SE module

向的维度, C 为特征通道数。 $F_{sq}(\cdot)$ 是压缩层, 作用是利用全局平均池化将空间维度 $H \times W$ 压缩为全局的一个值, 其输出尺寸为 $1 \times 1 \times C$, 即每个通道都被压缩成一个标量, 表示该通道在整个特征图上的全局统计。该过程的核心公式为

$$z_c = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W U_{c,i,j} \quad (5)$$

式中: z_c 为第 c 个通道的全局平均值; $U_{c,i,j}$ 为第 c 个通道中, 第 i 行第 j 列维度的特征值。 $F_{ex}(\cdot)$ 为激励层, 首先将尺寸为 $1 \times 1 \times C$ 的输入经过第一个全连接层, 降维到 $1 \times 1 \times (C/r)$, 其中 r 为缩放系数, 用来减少参数量, 本文取值为 16, 然后经过第二个全连接层尺寸恢复到 $1 \times 1 \times C$, 并通过 Sigmoid 函数归一化到 $(0, 1)$ 范围。该过程的核心公式为

$$s = \sigma[w_2 \delta(w_1 z)] \quad (6)$$

式中: w_1 和 w_2 分别为 2 层全连接层的权重, 一般采用 Xavier/Glorot 初始化权重, 根据输入和输出维度自动确定初始化范围, 无显式的硬性数值范围限制; δ 为 ReLU 激活函数; σ 为 Sigmoid 函数; s 为通道的注意力权重, 该权重值基于 w_1 和 w_2 计算得出, 因此也无显式的硬性数值范围限制。 $F_{scale}(\cdot)$ 是加权模块, 将注意力权重 s 重新作用在输入特征图 U 上, 核心公式为 $\tilde{X}_c = s_c U_c$, 其中, s_c 是第 c 个通道的注意力权重, 是 s 的子变量, 因此也无显式的硬性数值范围限制, U_c 是对应的特征图通道。

采用损失函数和反向传播来优化通道注意力机制的权重。已知生成图像和真实图像的训练集 $(\mathbf{x}, \mathbf{y})$, 其中, $\mathbf{x}$ 为数据集中的原始图像 $\mathbf{x}$, 对于给定输入图像 $\mathbf{x}$, $\mathbf{y}$ 为原始图像的标签, 分为生成图像和真实图像 2 类。首先经过图像-文本对齐嵌入模块生成可嵌入的文本向量 $\mathbf{T}(T_1, T_2, \dots, T_n)$, 然后通过预训练的潜在空间编码器计算相应的潜在图像 $\mathbf{Z}_0$, 并通过嵌入文本条件的 DDIM 反演获得潜在的原始噪声图 $\hat{\mathbf{Z}}_t$, 最后使用潜在空间编码器的解码模块 VAE-D 将潜在噪声图 $\hat{\mathbf{Z}}_t$ 映射回图像空间, 获取原始噪声分布 $\mathbf{D}(\hat{\mathbf{Z}}_t)$ 。通过 K-S 检验获取正态性检验统计值 P , 对 $\mathbf{D}(\hat{\mathbf{Z}}_t)$ 和 P 二维信息的组合使用二元交叉熵损失函数 $\ell(\hat{\mathbf{y}}, \mathbf{y})$ 的反向传播来学习该函数的参数 ϕ , 将一个学习到的映射函数 h_ϕ :

$X2 \rightarrow R$ 应用于这些“图像”, 以获取预测的 logit 值。 $\ell(\hat{\mathbf{y}}, \mathbf{y})$ 用来计算预测的标签与真实标签的损失值, $\hat{\mathbf{y}}$ 为残差网络预测的图像标签, ϕ 为训练好的检测模型权重, 权重范围主要通过反向传播中的梯度下降自动调整, 通常配合 L2 正则化控制权重幅值, 无先验的显式数值范围规定。 $X2$ 是包含反演图像和正态性检验统计值 P 的二维信息, $h_\phi: X2 \rightarrow R$ 是最终的检测函数, 能将输入的图像映射为生成或真实的标签。上述过程的核心公式为

$$\phi^* = \arg \min_{\phi} E_{\mathbf{x}, \mathbf{y}} \left\{ \ell \left(h_{\phi} \left[P, \mathbf{D}(\hat{\mathbf{Z}}_t) \right], \mathbf{y} \right) \right\} \quad (7)$$

$$\ell = -\frac{1}{N} \sum_{i=1}^N \left\{ y_i \log[\sigma(x_i)] + (1 - y_i) \log[1 - \sigma(x_i)] \right\} \quad (8)$$

式中: $E_{\mathbf{x}, \mathbf{y}}$ 为对输入数据 $\mathbf{x}$ 和标签 $\mathbf{y}$ 的联合分布取数学期望; $\sigma(x_i) = 1/(1 + e^{-x_i})$ 。

4 实验结果与分析

4.1 实验数据集

扩散模型作为新兴的图像生成模型, 其高质量的生成图像是伪造检测领域的重点与难点, 尤其是人像检测领域, 目前人像领域缺乏有效检测手段的主要原因是缺乏高质量、多种类的生成图像数据。

为解决人像检测领域存在的问题, 在提出高效检测算法的同时, 构建一个有 1×10^4 张高质量生成式人脸图像和 1×10^4 张真实人脸图像的训练数据集。其中, 生成式人脸图像利用 Stability AI 最新发布的 Stable Diffusion 3.5 项目生成, 真实图像是在百度图片官网上爬取的明星人脸图像, 通过标准化图像格式去除遮挡、模糊人脸图像等方法进行数据清洗, 部分图片如图 4 所示。生成图像包含 8 种类别, 包括性别、人种、年龄等, 能极大提升检测模型的泛化性与跨域检测性能。该数据集包含 5000 张男性图像, 其中老年、中年、青少年、少年各 1250 张, 其余 5000 张女性图像构成与男性图像相同, 按照数量比为 7:3 划分为训练集和验证集。

为检测所提模型的性能和训练数据集的效果, 以 Genimage 数据集^[20]为基础, 从中选取由扩散模型生成的 500 张高清人脸生成图像和 500 张高清人脸真实图像, 构成检测数据集 Genimage*。Genimage 使用最先进的扩散模型生成器, 利用包括扩散模型、ADM^[21]、




图4 自制的高质量人脸数据集部分图像

Fig. 4 Partial images of the self-made high-quality facial image dataset

GLIDE^[22]、Wukong 和 VQDM^[23]等在内的先进扩散模型生成图像,确保数据集的质量和多样性,能高效评估模型跨类别检测的泛化性。

4.2 对比实验

如表 1 所示,实验结果表明,提出的 CNC 模型经过自制的高质量人脸数据集训练后,在检测多类别的扩散模型生成式人脸图像时可达 98.7% 的正确率,体现了所提检测算法的健壮性和高质量人脸数据集的高效性。使用原来的预训练权重时的结果表明:CNNDet 和 F³Net 忽略底层噪声变化,在检测扩散模型生成的高质量人脸图像时的平均正确率均低于 70.0%;DIRE 作为基于扩散重建噪声误差进行检测的模型,在面对高质量人脸图像时也仅有 81.0% 的正确率。在经过自制的高质量人脸数据集训练后,CNNDet 和 F³Net 在检测扩散模型生成高质量人脸图像时的平均正确率提升至 80.0% 以上,DIRE 则提升至 89.0%。自制数据集使检测模型的平均正确率最多提升 33.5 百分点,说明了自制的高质量人脸数据集能有效提升检测模型的泛化性。

表 1 不同模型的对比实验结果

Table 1 Comparative experimental results of different models unit: %

Model	Training dataset	Test dataset	Average accuracy	
			Generated image	Real image
CNNDet ^[9]	Original dataset	Genimage*	69.2	57.1
	Self-made dataset	Genimage*	83.4	78.5
F ³ Net ^[11]	Original dataset	Genimage*	50.1	70.6
	Self-made dataset	Genimage*	83.6	91.7
DIRE ^[13]	Original dataset	Genimage*	81.0	88.3
	Self-made dataset	Genimage*	89.0	92.1
CNC (proposed)	Self-made dataset	Genimage*	98.7	100.0

为验证注意力机制对模型性能的提升效果,在 ResNet-50 骨干网络基础上,分别嵌入积压激励(SE)、卷积块注意力模块(CBAM)和 SK(Selective Kernel)

3 种典型注意力模块。实验采用 1×10^4 张自制数据集的图像,按数量比为 8:1:1 划分训练集、验证集、测试集,通过控制变量法确保网络深度与参数初始化策略一致。

SE:在残差模块最后一个卷积层之后插入 SE 注意力机制,通道压缩比设为 16。CBAM:在残差模块末端串联通道注意力与空间注意力子模块。SK:采用自适应核大小的一维卷积替代 SE 中的全连接层。网络训练使用 Adam 优化器,初始学习率设为 3×10^{-4} ,使用余弦退火调度,batch size 为 128,迭代 50 个 epoch。损失函数采用带标签平滑的交叉熵,平滑因子设为 0.1。评价指标为 F1-score、计算参数量(Params)、模型计算量(FLOPs)和推理时延。

实验结果如表 2 所示,SE 模块在多项指标中表现最优,其通道注意力机制有效提升了网络对伪造痕迹的定位能力。值得注意的是,相比于 SK 模块,SE 模块在保持可比性能(F1-score 仅降低 0.8 百分点)的同时,将参数量降低 5.1%,体现了通道注意力的高效性。

表 2 不同注意力机制的对比实验结果

Table 2 Comparative experimental results of different attention mechanisms

Attention mechanism	F1-score / %	Params / 10^6	FLOPs / 10^9	Time / ms
SE	93.4	26.89	4.28	16.1
CBAM	92.8	27.05	4.35	16.8
SK	94.2	28.33	4.57	17.5

4.3 超参数调优实验

基于扩散过程噪声变化进行生成式人脸图像检测,为尽可能扩大真实图像与生成图像反演后噪声维度的差异,进行超参数调优实验。预实验的迭代步数设为 $[0, 25]$,步长为 5,结果表明在迭代步数超过 15 后,真实与生成图像反演后的噪声分布图中均无法提取出人像的特征。因此,实验选定 DDIM 反演的迭代步长范围为 $[0, 15]$,步长为 1,分别反演 1000 张真实与生成图像,并计算与原始图像的差异度。设真实图像反演后与原始图像的相似度为 R_s ,生成图像反演后与原始图像的相似度为 F_s 。最佳的迭代步数即 F_s/R_s 最大时的迭代步数。采用结构相似性指数(SSIM)、定向 FAST 和旋转 BRIEF(ORB)和 Hu Moments Difference 来分析相似度,结果如图 5 所示。其中,横坐标为反演迭代步数,纵坐标为 3 种相似度分析算法得出的相对相似度 F_s/R_s 。实验结果表明,当迭代步数为 7 时,生成图像和真实图像的反演差异最大。

4.4 消融实验

为评估图像-文本多模态对齐嵌入模块在 DDIM 反演过程的重要性,进行针对该模块的消融实验,分为 2 个子实验。




图5 不同方法的超参数调优实验结果。(a) SSIM; (b) ORB; (c) Hu Moments Difference

Fig. 5 Hyperparameter tuning experimental results by different methods. (a) SSIM; (b) ORB; (c) Hu Moments Difference

第一个实验是对生成图像进行无图像-文本多模态对齐嵌入模块的DDIM反演,并记录前3步的反演结果。从Genimage数据集中选取500张高质量人脸生成图像和500张真实人脸图像进行实验。实验过程

和结果如图6所示。其中,过程①是提取原始图像的噪声光谱图,过程②、③、④是无图像-文本多模态对齐嵌入模块的DDIM反演过程前3步。




图6 无图像-文本多模态对齐嵌入模块反演过程和结果

Fig. 6 Inversion process and results without image-text multimodal alignment embedding module

实验结果表明,无图像-文本多模态对齐嵌入模块的DDIM反演过程会引入极大的误差噪声,添加的噪声与扩散过程去除的对应噪声存在极大差异,导致生成图像从反演的第1步起便成为几乎纯粹的噪声图,生成图像中用以鉴定真实性的关键性特征几乎全部消失,与真实图像反演后的结果无异,表明了无文本指引反演过程的不稳定性。

第二个实验是将实验一反演后的500张真实图像和500张生成图像组成新的数据集,简称Genimage**,将其和K-S正态检验统计值 P 输入到提出的CNC检测模型中进行检测,并与Genimage*数据集的检测结果进行对比。如表3所示,去除图像-文本多模态对齐嵌入模块的检测模型的检测性能大幅下降,鉴别生成图像和真实图像的正确率分别仅有61.3%和69.2%。

表3 图像-文本多模态对齐嵌入模块消融实验结果

Table 3 Ablation experimental results for image-text multimodal alignment embedding module
unit: %

Model	Training dataset	Test dataset	Average accuracy	
			Generated image	Real image
With	Self-made dataset	Genimage*	97.9	98.1
Without	Self-made dataset	Genimage**	61.3	69.2

结果表明了图像-文本多模态对齐嵌入模块在CNC检测模型的必要性和重要性。

为评估SE模块的效果,设计基于基线模型(ResNet-50)的通道注意力消融实验,评价指标为F1-score、计算参数量、FLOPs和推理时延,结果如表4所示。结果表明,添加SE模块的模型相比于基线模型性能得到提升。

表4 SE模块消融实验结果

Table 4 Ablation experimental results for SE module

Model	F1-score / %	Params / 10^6	FLOPs / 10^9	Time / ms
Baseline	91.2	25.56	4.12	15.2
Baseline+SE	93.4	26.89	4.28	16.1

5 结 论

提出基于底层噪声变化的扩散模型高质量检测模型,利用图像-文本多模态对齐嵌入模块,将高维文本向量指引嵌入DDIM反演过程中,并基于SE-ResNet50的二元分类器,使检测模型能精准捕捉图像的关键性特征,输出图像的鉴别结果。此外,提出涵盖多种类别的高质量人脸图像数据集,该数据集由微调后的Stable Diffusion 3.5生成,涵盖性别、人种和年龄等元素。实验结果表明,提出的检测模型相比于现有典型的检测模型,检测准确率和泛化性均有提升。经过自制数据集训练的检测模型,其检测准确率最多可提升

33.5 百分点。未来可以尝试在多人脸、遮挡人脸检测方面进行研究,以提升所提模型的检测能力。

参 考 文 献

- [1] 郝文月, 蔡怀宇, 左廷涛, 等. 基于扩散模型的自监督预训练血管内超声图像分割方法[J]. 激光与光电子学进展, 2024, 61(18): 1837005.
Hao W Y, Cai H Y, Zuo T T, et al. Self-supervised pre-training for intravascular ultrasound image segmentation method based on diffusion model[J]. Laser & Optoelectronics Progress, 2024, 61(18): 1837005.
- [2] 刘玉娟, 刘颜达, 闫振, 等. 注意力机制的混合卷积高光谱图像分类方法[J]. 光谱学与光谱分析, 2024, 44(10): 2916-2922.
Liu Y J, Liu Y D, Yan Z, et al. Classification of hybrid convolution hyperspectral images based on attention mechanism[J]. Spectroscopy and Spectral Analysis, 2024, 44(10): 2916-2922.
- [3] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [4] 秦魁, 侯新国, 周锋, 等. Fire-GAN: 基于生成对抗网络的火焰图像生成算法[J]. 激光与光电子学进展, 2023, 60(12): 1210008.
Qin K, Hou X G, Zhou F, et al. Fire-GAN: flame image generation algorithm based on generative adversarial network[J]. Laser & Optoelectronics Progress, 2023, 60(12): 1210008.
- [5] 鲁晓涵, 李洋, 贾耀东, 等. 基于GAN改进的红外光与可见光图像融合算法研究[J]. 电光与控制, 2024, 31(6): 42-46, 73.
Lu X H, Li Y, Jia Y D, et al. An improved infrared and visible image fusion algorithm based on GAN[J]. Electronics Optics & Control, 2024, 31(6): 42-46, 73.
- [6] Liu Z Z, Qi X J, Torr P H S. Global texture enhancement for fake face detection in the wild[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 13-19, 2020, Seattle, WA, USA. New York: IEEE Press, 2020: 8057-8066.
- [7] Jeon H, Bang Y, Kim J, et al. T-GD: transferable GAN-generated images detection framework[EB/OL]. (2020-08-10)[2024-12-12]. <https://arxiv.org/abs/2008.04115v1>.
- [8] Zhang M X, Wang H X, He P S, et al. Improving GAN-generated image detection generalization using unsupervised domain adaptation[C]//2022 IEEE International Conference on Multimedia and Expo (ICME), July 18-22, 2022, Taipei, China. New York: IEEE Press, 2022.
- [9] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models [C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 18-24, 2022, New Orleans, LA, USA. New York: IEEE Press, 2022: 10674-10685.
- [10] 肖珀麟, 刘进锋. 扩散模型与傅里叶滤波器结合的图像去雾方法[J]. 液晶与显示, 2024, 39(11): 1532-1543.
Xiao P L, Liu J F. Image dehazing method combining diffusion model and Fourier filter[J]. Chinese Journal of Liquid Crystals and Displays, 2024, 39(11): 1532-1543.
- [11] Kingma D P, Welling M. Auto-encoding variational Bayes[EB/OL]. (2013-12-20)[2024-12-12]. <https://arxiv.org/abs/1312.6114v11>.
- [12] Wang Z D, Bao J M, Zhou W G, et al. DIRE for diffusion-generated image detection[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV), October 1-6, 2023, Paris, France. New York: IEEE Press, 2023: 22388-22398.
- [13] Song J M, Meng C L, Ermon S. Denoising diffusion implicit models[EB/OL]. (2020-10-06) [2024-12-12]. <https://arxiv.org/abs/2010.02502v4>.
- [14] Li J N, Li D X, Xiong C M, et al. BLIP: bootstrapping language-image pre-training for unified vision-language understanding and generation[EB/OL]. (2022-01-28) [2024-12-12]. <https://arxiv.org/abs/2201.12086>.
- [15] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[EB/OL]. (2021-02-26)[2024-12-12]. <https://arxiv.org/abs/2103.00020>.
- [16] Wei J, Wang S H, Huang Q M. F³Net: fusion, feedback and focus for salient object detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(7): 12321-12328.
- [17] Wang S Y, Wang O, Zhang R, et al. CNN-generated images are surprisingly easy to spot... for now[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 13-19, 2020, Seattle, WA, USA. New York: IEEE Press, 2020: 8692-8701.
- [18] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[EB/OL]. (2020-06-19) [2024-12-12]. <https://arxiv.org/abs/2006.11239>.
- [19] Hu J, Shen L, Sun G. Squeeze-and-excitation networks [C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, June 18-23, 2018, Salt Lake City, UT, USA. New York: IEEE Press, 2018: 7132-7141.
- [20] Zhu M J, Chen H T, Yan Q Y, et al. GenImage: a million-scale benchmark for detecting AI-generated image [EB/OL]. (2023-06-14)[2024-12-12]. <https://arxiv.org/abs/2306.08571>.
- [21] Dhariwal P, Nichol A. Diffusion models beat GANs on image synthesis[EB/OL]. (2021-05-11) [2024-12-12]. <https://arxiv.org/abs/2105.05233>.
- [22] Nichol A, Dhariwal P, Ramesh A, et al. GLIDE: towards photorealistic image generation and editing with text-guided diffusion models[EB/OL]. (2021-12-20) [2024-12-12]. <https://arxiv.org/abs/2112.10741v3>.
- [23] Gu S Y, Chen D, Bao J M, et al. Vector quantized diffusion model for text-to-image synthesis[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 18-24, 2022, New Orleans, LA, USA. New York: IEEE Press, 2022: 10686-10696.