

狭小空间内圆环靶标检测及位姿估计算法研究

作者姓名 唐亚娇

学校导师姓名、职称 沈沛意 教授

企业导师姓名、职称 梅林 研究员

申请学位类别 电子信息硕士

学校代码 10701
分类号 TP183

学号 21031211741
密级 公开

西安电子科技大学

硕士学位论文

狭小空间内圆环靶标检测及位姿估计算法研究

作者姓名：唐亚娇

领 域：计算机技术

学位类别：电子信息硕士

学校导师姓名、职称：沈沛意 教授

企业导师姓名、职称：梅林 研究员

学 院：计算机科学与技术学院

提交日期：2024 年 6 月

Research on Circular Target Detection and Pose Estimation Algorithms in Confined Spaces

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Electronic Information

By
Tang Yajiao
Supervisor: Shen Peiyi Title: Professor
Supervisor: Mei Lin Title: Researcher
June 2024

摘 要

近年来,手术机器人技术快速发展,极大地推进了手术流程向稳定性、效率、安全性以及成本效益方面的优化。在手术中,机器人执行的操作需要极高的精度,以确保避免对周边健康组织或器官造成伤害。通过位姿估计,机器人能够精确掌握其末端执行器的具体位置与朝向,从而精确执行切割、缝合或其他操纵任务。然而,在本文实际应用场景口腔咽喉狭小空间内,完成对末端执行器的检测及位姿估计面临诸多挑战:(1)狭小空间内尺寸极其狭窄导致成像范围有限,视角单一,末端执行器在图像中显示不全;(2)空间内壁组织表面纹理特征极度匮乏并附着大量组织液,增加目标检测背景复杂度;(3)末端执行器种类繁多且几何形状复杂,提高自身目标检测难度。

针对在狭小空间内完成目标的精准检测与位姿估计这一挑战,本文从传统目标检测和深度学习两个视角,分别提出了基于弧线结构和基于 2-WD 损失改进的目标椭圆检测算法获得椭圆边界特征,依靠椭圆边界特征进行位姿解算,从而获得目标相对于相机的精准位置,指导末端执行器完成相应手术任务。本文的主要工作和创新点如下:

(1) 首先针对在口腔咽喉该狭小空间内对末端执行器检测的挑战,本文设计了一款适用于外科手术环境的微型高精度圆环靶标,并将其集成于末端执行器内,确保靶标与执行器动作保持一致。通过识别显著的靶标特征,间接实现对末端执行器的精准检测。进一步地,本文依靠该圆环靶标独立构建了一个狭小空间内数据集,该数据集来自模拟口腔咽喉环境下,包含不同光照、组织遮挡、抖动失焦等复杂情况,此外,对数据集内的图像均进行精确的标注工作,旨在为算法性能评估提供充足且质量高的实验数据。

(2) 其次针对检测自行设计的圆环靶标挑战,本研究提出并实现了两种圆环靶标检测算法:第一种是基于弧线结构的传统方法检测靶标,该方法首先利用边缘检测技术确定图像中的边缘弧线。接着,将符合角度偏差和跨角限制条件的弧线段连接起来,形成弧线段组。通过并行实施局部与全局搜索策略,识别出符合极性约束、区域限制以及自适应内点条件的有效弧线段对。利用这些有效弧线段对,拟合出初始椭圆集合。然后,通过分层聚类椭圆参数来消除重复椭圆,生成候选椭圆集。最终,对候选椭圆集进行严格评估,确保算法的高效性和准确性;第二种是基于 2-WD 损失改进的深度学习方法完成圆环靶标检测任务,首先在 Faster R-CNN 框架的基础上实现了专用于椭圆边界预测的 GPN, GPN 将边界椭圆建模为图像平面上的二维高斯分布,通过最小化候选椭圆的高斯分布与真实椭圆的高斯分布来预测真实椭圆位置,并

在 GPN 架构中引入 RoI 池化和回归分支进一步拓展功能，同时提出将 2-WD 作为椭圆候选区域精细化的损失函数，实现了在复杂背景下圆环靶标的精准检测。特别地，对于本文自行构建的狭小空间圆环靶标数据集，基于弧线结构的检测算法在处理速度方面展示了显著的优势，而基于 2-WD 损失改进的算法在精确率上达到了 86.31% 的显著效果。此外，为了验证检测算法的泛化能力，本研究亦将该算法应用于包含中至大尺度目标特征的数据集上，均取得了良好的表现。

(3) 针对无法获得狭小空间内末端执行器位姿参数问题，本文使用所提出的两种椭圆检测算法对圆环靶标边界检测，通过椭圆边界检测、靶标尺寸已知信息以及圆心校正后的坐标，精确求解出圆环靶标相对于内窥镜的位姿参数，因此获得了末端执行器的位姿参数，具体包括平移分量和旋转分量。通过在多个场景下进行大量实验分析及验证，本文方法展示了出色的性能，其中平移分量的最佳平均误差为 0.045mm，旋转矩阵的最佳平均误差达到 3.40° 。这项工作在复杂手术环境中执行精确的目标检测与位姿估计提供了有效的方法和技术支持，有望显著提升微创手术的精度与安全性。

关键词：狭小空间，椭圆检测，高斯建议网络，目标位姿估计

ABSTRACT

In recent years, the rapid development of surgical robot technology has significantly propelled the advancement of surgical procedures towards stability, efficiency, safety, and cost-effectiveness. During surgeries, robot-operated maneuvers demand high precision to avoid harming adjacent healthy tissues or organs. Pose estimation allows robots to precisely determine the position and orientation of their end-effectors, enabling accurate cutting, suturing, or manipulation tasks. However, in the context of this study's practical application within the confined space of the oral and pharyngeal area, detecting the end-effector and estimating its pose present numerous challenges: the extremely narrow dimensions of confined spaces limit imaging range and offer a singular perspective, preventing the end-effector from being fully displayed in images; the lack of distinctive texture features on the inner wall tissues, coupled with the presence of tissue fluids, increases the complexity of target detection backgrounds; and the diversity and complex geometrical shapes of end-effectors themselves elevate the difficulty of target detection.

To address the challenge of precise target detection and pose estimation in confined spaces, this study proposes two algorithms from traditional target detection and deep learning perspectives, respectively: an arc-based method and an improved method based on 2-WD loss, for obtaining elliptical boundary features to calculate the pose, thereby determining the target's precise position relative to the camera and guiding the end-effector to complete the corresponding surgical tasks. The main contributions and innovations of this study are as follows:

(1) Specifically targeting the challenge of detecting the end-effector within the narrow space of the oral and pharyngeal area, this study uniquely designs a micro high-precision circular target suitable for surgical environments and ingeniously integrates it into the end-effector, ensuring synchronization between the target and the actuator movements. By recognizing distinct target features, this study indirectly achieves precise detection of the end-effector. Further, a high-precision circular target dataset within confined spaces was independently constructed, simulating real-world oral and pharyngeal environments with varying lighting, tissue occlusion, and motion blur scenarios, and precisely annotated to provide ample and high-quality experimental data for algorithm performance evaluation.

(2) In addressing the challenge of detecting the custom-designed circular target, this study developed two detection algorithms: a traditional method based on arc structures that first identifies edge arcs in images, then connects arc segments meeting angle deviation and cross-angle restrictions, forming groups of arc segments. By parallelly implementing local and global search strategies, effective arc segment pairs meeting polarity constraints, regional limitations, and adaptive inlier conditions are identified. These pairs are used to fit initial ellipse collections, which are then processed through hierarchical clustering of ellipse parameters to eliminate duplicates and generate candidate ellipse sets, ultimately undergoing stringent evaluation to ensure the algorithm's efficiency and accuracy. The second method, an improvement based on 2-WD loss within a deep learning framework, starts with the implementation of a Gaussian Prediction Network (GPN) on the Faster R-CNN architecture for elliptical boundary prediction, modeling boundary ellipses as two-dimensional Gaussian distributions on the image plane. By minimizing the discrepancy between the Gaussian distributions of candidate and actual ellipses, the algorithm predicts the real ellipse location, incorporating RoI pooling and a regression branch within the GPN architecture and introducing 2-WD as a loss function for refining the candidate ellipse regions, achieving precise detection of circular targets against complex backgrounds. Notably, for the confined space circular target dataset constructed in this study, the arc-structure-based detection algorithm demonstrated significant speed advantages, while the 2-WD loss improved algorithm achieved a remarkable accuracy of 86.31%. Additionally, to validate the detection algorithms' generalizability, they were also applied to datasets featuring medium to large scale target characteristics, showing good performance.

(3) Addressing the inability to ascertain the real position of end-effectors in confined spaces, this study employs the two proposed ellipse detection algorithms to detect circular targets. By combining ellipse boundary detection, known target dimensions, and coordinates corrected for the ellipse center, the study precisely solves for the camera's extrinsic parameters, including translational and rotational components, informing the robot of its end-effector's location and orientation. Through extensive experimental analysis across multiple scenarios, the methods demonstrated excellent performance, with the best average error for translational components at 0.045mm and for rotational matrices at 3.40 degrees. This work provides effective methods and technical support for performing accurate target detection and pose estimation in complex surgical environments, promising to significantly enhance the precision and safety of minimally invasive surgery.

ABSTRACT

Keywords: Confined space, elliptical detection, gaussian proposal network, target pose estimation

插图索引

图 1.1	机器人协同手术示意图	1
图 1.2	本文主要研究内容关系图	8
图 2.1	直角坐标系下椭圆的表示	10
图 2.2	基于霍夫变换的椭圆检测算法比较	12
图 2.3	基于边缘连接的椭圆检测算法流程	13
图 2.4	初始图像	14
图 2.5	Sobel 算子	14
图 2.6	Prewitt 算子	14
图 2.7	Roberts 交叉算子	14
图 2.8	Canny 算子	14
图 2.9	Laplace 算子	14
图 2.10	Canny 边缘检测流程图	15
图 2.11	直线段和弧线段及其角度示意	16
图 2.12	判定弧线段极性示意图	17
图 2.13	目标检测算法时间轴一览表	19
图 2.14	Faster R-CNN 网络结构图	20
图 2.15	RPN 网络结构图	21
图 3.1	手术机器人及其末端执行器展示	25
图 3.2	口腔咽喉模型	27
图 3.3	狭小空间仿真模型搭建	27
图 3.4	内窥镜对口腔咽喉采集图像示例	28
图 3.5	不同光照对成像影响对比	28
图 3.6	抖动对成像影响对比	29
图 3.7	不同焦距下模型成像对比	29
图 3.8	数据集收集设备图（内窥镜、末端执行器、自行设计圆环靶标）	30
图 3.9	末端执行器与圆环靶标集成示意图	31
图 3.10	图像采集场景及采集软件使用示意图	31
图 3.11	VIA 标注软件标注使用示例	31
图 3.12	基于弧线结构的椭圆检测算法示意图	32
图 3.13	形成弧线段组示意图	33

图 3.14	对两个弧线段组的区域限制	35
图 3.15	Prasad 数据集实验结果可视化	40
图 3.16	TSE 数据集实验结果可视化	40
图 3.17	PCB 数据集实验结果可视化	41
图 3.18	TY 数据集实验结果（局部区域放大）可视化	41
图 3.19	Prasad 数据集上 D_0 与评价指标的对比	44
图 3.20	TSE 数据集上 D_0 与评价指标的对比	44
图 3.21	PCB 数据集上 D_0 与评价指标的对比	44
图 3.22	TY 数据集上 D_0 与评价指标的对比	44
图 3.23	TY 数据集内 T_{ac} 变化与评价指标的关系	45
图 3.24	TY 数据集内 T_r 变化与评价指标的关系	45
图 3.25	像素数量与检测时间相关性	46
图 4.1	数据集内椭圆靶标正常情况与椭圆长短轴长度相近情况图片展示	50
图 4.2	基于 2-WD 损失改进的椭圆目标检测算法流程	51
图 4.3	椭圆的二维高斯分布概率密度函数可视化	52
图 4.4	椭圆通过旋转矩阵的变换	53
图 4.5	GPN 网络架构图	53
图 4.6	IoU 指标获取示意图	58
图 4.7	弧线结构、RPN 与 2-WD 损失改进数据集实验结果可视化	58
图 4.8	TY 数据集弧线结构与 2-WD 圆环靶标检测结果可视化示例 1	59
图 4.9	TY 数据集弧线结构与 2-WD 圆环靶标检测结果可视化示例 2	60
图 4.10	TY 数据集上 2-WD 损失改进算法训练各项指标变化过程	62
图 5.1	圆环靶标及其针孔投影模型	66
图 5.2	透视变换后的同心圆示意	68
图 5.3	微动云台与高精度硬质棋盘格标定板	71
图 5.4	同心圆与加入噪声投影变换后图像	74
图 5.5	多视角高精度棋盘格标定板	75
图 5.6	医用单目内窥镜相机标定可视化	76
图 5.7	医用单目内窥镜内参标定误差	77
图 5.8	基于 Pangolin 的靶标运动及轨迹可视化-x 轴	78
图 5.9	基于 Pangolin 的靶标运动及轨迹可视化-z 轴	78
图 5.10	预设轨迹引导的位姿参数估计结果可视化	79

表格索引

表 3.1	形成弧线段组伪代码	34
表 3.2	不同椭圆检测算法精确率结果对比	42
表 3.3	不同椭圆检测算法召回率结果对比	42
表 3.4	不同椭圆检测算法 F 值结果对比	42
表 3.5	不同椭圆检测算法运行时间结果对比	43
表 3.6	椭圆平均重叠率 (MOR) 结果对比	46
表 4.1	椭圆检测精确率结果对比	60
表 4.2	椭圆检测召回率结果对比	61
表 4.3	椭圆检测 F 值结果对比	61
表 4.4	椭圆检测运行时间结果对比	61
表 4.5	TY 数据集内 GPN 与 RPN 使用不同损失函数的 IoU 指标	63
表 4.6	RPN 网络不同数量候选框下精确率	63
表 4.7	GPN 网络不同数量候选框下精确率	64
表 5.1	室内环境中使用两种椭圆检测算法检测性能评估	74
表 5.2	圆心校正结果对比	75
表 5.3	内窥镜标定结果表	76
表 5.4	不同椭圆特征提取的目标位姿估计方法性能结果表	79
表 5.5	不同位移距离对应各方法的平移距离估计 95% 置信区间表	80

符号对照表

符号	符号名称
$c(x; y)$	代价函数
T_l	弧线段集
T_r	生成线段的弧支撑区域
α	角度公差
S	线段使用状态
T_{ss}	阈值
ρ_d	距离阈值
$SI(L_j)$	弧线段 L_j 的内点集合
N_{g_1}	组 g_1 中弧线段数目
E^{init}	初始椭圆集
T_{ai}	各子区域与支撑区域的夹角间隔
T_{ss}	显著性评分阈值
ρ_d	区域约束采用距离阈值
ϵ	距离公差
T_r	椭圆上支持内点的比值和
T_{ac}	椭圆角覆盖阈值
(μ_x, μ_y)	中心坐标
(σ_l, σ_s)	长短轴的标准差
θ	旋转角度
$\boldsymbol{T}$	平移向量
$\boldsymbol{R}$	旋转矩阵

缩略语对照表

缩略语	英文全称	中文对照
HT	Hough Transform	霍夫变换
LS	Line Segment	线段
RHT	Randomized Hough transform	随机霍夫变换
PHT	Probabilistic Hough transform	概率霍夫变换
IRHT	Iterative stochastic Hough transform	迭代随机霍夫变换
RANSAC	Random Sample Consequence	随机抽样共识
MOR	Mean Overlap Ratio	平均重叠比
PCB	Printed Circuit Board	印刷电路板
VIA	VGG Image Annotator	VGG 图像标注器
KLD	Kullback-Leibler Divergence	相对熵
2-WD	2-Wasserstein Distance	二阶瓦瑟斯坦距离
RPN	Region Proposal Networks	区域提议网络
IoU	Intersection over Union	交集与并集的比值
WCS	World Coordinate System	世界坐标系
ONNX	Open Neural Network Exchange	开放神经网络交换

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统椭圆检测研究方法.....	2
1.2.2 深度学习椭圆检测研究方法.....	4
1.2.3 目标位姿估计研究方法.....	5
1.3 本文主要研究内容.....	6
1.4 论文组织结构.....	7
第二章 相关技术研究	9
2.1 椭圆的几何特性.....	9
2.1.1 椭圆的定义.....	9
2.1.2 椭圆的参数化表示.....	10
2.2 椭圆检测相关技术.....	11
2.2.1 基于霍夫变换的椭圆检测.....	11
2.2.2 基于边缘连接的椭圆检测.....	13
2.2.3 弧线段及其特征.....	16
2.2.4 椭圆拟合原理及其叠加.....	17
2.3 基于深度学习的目标检测方法	19
2.3.1 Faster-RCNN 整体架构	19
2.3.2 RPN 网络架构.....	21
2.3.3 RPN 网络损失函数.....	22
2.4 本章小结.....	22
第三章 狭小空间圆环靶标设计及检测	25
3.1 引言.....	25
3.2 狭小空间高精度圆环靶标设计	26
3.2.1 狭小空间介绍.....	26
3.2.2 狭小空间内环境多样性分析.....	27
3.2.3 狭小空间内高精度圆环靶标数据集构建	30
3.3 基于弧线结构的椭圆检测算法	32
3.3.1 弧线段组的形成.....	32
3.3.2 初始椭圆集生成.....	33
3.3.3 椭圆聚类.....	36
3.3.4 椭圆候选验证.....	37
3.4 实验设计及结果分析.....	38

3.4.1 实验设置.....	38
3.4.2 实验结果可视化及指标评估.....	39
3.4.3 参数设置与定量实验.....	43
3.4.4 定位精度与效率分析.....	45
3.5 本章小结.....	47
第四章 基于 2-WD 损失改进的椭圆目标检测算法	49
4.1 问题研究与意义.....	49
4.2 算法框架.....	50
4.3 高斯建议网络 GPN.....	51
4.3.1 椭圆的二维高斯分布.....	52
4.3.2 GPN 网络架构.....	53
4.3.3 KL 散度损失	54
4.4 基于 2-WD 损失的椭圆回归的损失函数	55
4.5 实验设计及结果分析.....	56
4.5.1 实验设置.....	57
4.5.2 实验结果可视化及指标评估.....	57
4.5.3 参数设置与定量实验.....	62
4.6 本章小结.....	64
第五章 基于椭圆检测的位姿估计模型	65
5.1 引言.....	65
5.2 基于椭圆特征的位姿估计算法	65
5.2.1 圆环的针孔投影模型.....	66
5.2.2 圆环圆心校正.....	67
5.2.3 位姿参数估计.....	69
5.2.4 主点恢复.....	70
5.3 实验设计及结果分析.....	71
5.3.1 实验环境.....	71
5.3.2 实验方案设计.....	72
5.3.3 实验模块分析.....	73
5.3.4 位姿参数精度评估.....	77
5.4 本章小结.....	80
第六章 总结与展望	81
6.1 本文工作总结.....	81
6.2 后续工作展望.....	82
参考文献.....	85

第一章 绪论

1.1 研究背景与意义

自上世纪机器人技术问世之日起^[1], 机器人就逐渐进入了人们的日常生活, 从航天领域到厨房中的拉面机器人, 极大地丰富了人类的生活方式。目前, 科技界正处在一个快速发展的黄金时期, 在多个交叉学科领域, 诸如机器学习、自动化控制、神经网络等领域频频涌现新成果。这些新兴技术的加入极大地推动了机器人技术的进步。机器人的演进可分为三个阶段: 第一阶段为示教型机器人, 它通过重复执行计算机内存储的动作序列而运作, 缺乏感知能力; 第二阶段则为装备了初级感知器的机器人, 能够通过触觉、视觉和听觉等传感器获取信息; 第三阶段的机器人已演化为能够进行思考和学习的人工智能机器人, 虽然目前还在开发中, 尚未构建出成熟的自主学习系统。机器人的这一演变不仅为工业化进程带来了便利, 而且通过替代手工操作, 显著提升了工作效率和产品品质。




图 1.1 机器人协同手术示意图

伴随着将机器人技术同样应用于医学领域中, 使得手术机器人领域也迎来了革命性的变革, 如今已渗透到几乎所有的临床手术领域。这些手术机器人能够适应不同的手术需求和环境, 从胸腹腔镜手术到骨科手术, 再到特殊的口腔咽喉手术, 都有相应的机器人解决方案。这些基于先进计算和感知的自动或半自动机器人, 在提高手术安全性、稳定性和精确度方面取得了重大成就, 同时极大地减轻了外科医生的工作负担并降低了手术成本。手术机器人技术的发展不仅在不断突破传统手术的界限, 重新定义手术和器械的概念, 而且在降低医疗成本、减少手术创伤以及提高手术的安全性和效率方面发挥着至关重要的作用。

在当前计算机视觉技术的研究背景下, 手术机器人的开发重点正在向提高其自主状态识别和周边环境感知的能力倾斜。这意味着, 这些机器人能够依靠自身配备的

传感技术,实时监测和评估其状态变化。特别是这项技术主要通过集成的单目或双目微型内窥镜来实施,这些设备能捕获环境中的关键特征,并基于这些数据进行精确的位姿估计。位姿估计精确地定义了目标物体在三维空间中的方位与位置,是实现在特定环境下精确定位物体姿态的关键技术。因此,精度高且稳定的特征识别及位姿估计模块是确保外科手术机器人操作安全不可或缺的一环,尤其在人体内复杂狭窄的工作环境中,这一任务的复杂度更加凸显。

虽然最近几年在目标位姿估计方面已经取得了一定的进展,但其性能和精确度仍然在很大程度上依赖于能够检测到的目标特征信息以及如何根据这些特征进行位姿的精确估计。特别是在口腔咽喉这样的狭窄空间内,手术机器人依靠内窥镜在采集数据时,容易遭遇到多种挑战性问题,包括复杂的纹理特征、光照条件的变化、组织的遮挡、图像的抖动以及失焦等问题,这些因素均会大大增加目标特征提取的难度,进而影响到位姿估计的精度。

鉴于上述挑战,本研究将专注于狭小空间内目标特征的检测及位姿估计,特别是在口腔和咽喉这样的特殊环境中。这一环境的特殊性为现有的目标检测和位姿估计算法带来了诸多困难,如数据采集的难度、空间限制以及噪声干扰等。本文的目标是探索如何有效利用医用单目内窥镜所采集的数据,在这一特定场景中识别和定位目标物体,并依据其特征进行位姿估计。通过这一研究,本文旨在为该领域提供创新的技术方案,以支持更加精确和鲁棒的目标检测与位姿估计,对于提升手术机器人的操作精度和安全性具有深远的意义。

1.2 国内外研究现状

1.2.1 传统椭圆检测研究方法

圆作为圆锥曲线的一种,是一种能够相对轻松辨认的几何形状。当从不同的视角观察现实世界中的圆形物体时,往往会看到它们呈现为椭圆形状。因此椭圆的检测成为了众多计算机视觉任务的基础。能够从图像中迅速且准确地识别出椭圆,为计算机视觉领域中的多种应用提供了重要的分析能力。目前相关的传统椭圆检测算法基本分为两类:基于霍夫变换(Hough Transform, HT)的检测算法和基于边缘连接的检测算法。

基于 HT 的椭圆检测算法^[2]基本原理是通过在参数空间进行曲线拟合,对图像边缘进行分析以识别椭圆形状。算法首先执行边缘检测,然后基于边缘像素及其邻域信息计算椭圆参数,并在参数空间中进行累加,形成峰值代表可能的椭圆。通过阈值筛选,选择最可能的椭圆参数,最后对边缘点进行拟合得到椭圆检测结果。然而,由于需要遍历所有边缘点,这种方法的计算成本较高。

Xu 等^[3]提出了一种随机霍夫变换 (Randomized Hough transform, RHT) 方法, 该方法使用边缘像素的一个子集在霍夫空间进行投票, 不但适用于传统的直线检测, 还适用于圆形特征的识别。在此基础上, McLaughlin^[4]改进了求解方程并将其扩展至椭圆检测领域。然而, 该算法在处理重叠椭圆图像上的检测效果不佳, 容易发生漏检现象。概率霍夫变换 (Probabilistic Hough transform, PHT)^[5]则假设边缘点在图像中呈均匀分布, 并根据其中一部分坐标点来拟合目标曲线。但真实图像通常不符合此假设条件, 缩小了其适用范围。迭代随机霍夫变换 (Iterative stochastic Hough transform, IRHT)^[6]通过寻找椭圆轮廓上的坐标点, 在一维空间上进行投票, 减少了算法的运算时间。但实际场景中往往无法提取得到准确的边缘点坐标, 一定程度上降低了椭圆检测的精度。

第二类椭圆检测方法依靠边缘连接技术, 主要通过边缘像素之间的连通性、弧段的凸度和几何约束等条件连接边缘。边缘连接的一般思路总是从计算二元边缘图和 Canny 或 Sobel 检测器获取的相应梯度开始^[7], 然后从二元边缘中提炼出弧段进行椭圆拟合。

基于边缘连接的椭圆检测算法一般使用从二元边缘中提取的线段 (Line Segment, LS) 作为中介来查找弧段。Kim 等人提出的方法^[8]合并了非常短的 LS 来表示弧段。Mai 等人^[9]与 Kim 等人的方法^[8]有着相似的想法, 都是从边缘图中提取短 LS, 不同之处在于使用简单的预设邻接阈值和适当的曲率条件将 LS 以及 LS 的边缘点连接起来形成弧段。该方法^[9]还进一步对两个弧段进行迭代分组, 并对弧段组应用随机抽样共识 (Random Sample Consequence, RANSAC) 来恢复椭圆模型, 但尽管其尝试通过迭代分组和 RANSAC 来提高椭圆检测器的鲁棒性, 但还是出现了大量的漏检 (FN) 和误检 (FP) 现象。

Chiaet 等人^[10]提出的方法改进了 Mai 等人说明的框架^[9], 该方法通过采用更为复杂的片段合并和分组程序, 将弧线片段的合并视作一项对齐问题, 其中引入了对齐函数对合并的合理性进行评分。此外, 建立了一个总成本函数, 用于指导对最佳配对弧线片段进行分组的逐步搜索过程。尽管这种复杂的迭代数学优化在一定程度上提升了检测的性能, 但其在处理实际图像时的速度较慢。Prasad 等人提出的椭圆检测^[11]结合了边缘曲率和凸度来提取平滑的边缘轮廓, 并执行二维 HT, 根据关系分数对一组中的边缘轮廓进行排序, 以更好地生成候选椭圆, 但它也存在计算时间长的问題。

另一种基于边缘跟踪的椭圆检测方法尝试直接从二进制边缘中提取弧段, 并对直边进行修剪, 以达到快速检测的目的。Fornaciari 等人提出的椭圆检测方法^[12]为每个弧线分配一个边界框, 以去除直线部分, 并通过比较弧线下方与上方区域的面积差异来评估弧线的凸度。进一步地, 利用了椭圆中心应与其平行弦的中点相交的性质, 从而加快了检测流程。然而, 在加速检测过程的同时, 这种方法牺牲了定位的精度与

系统的鲁棒性。Qi 等人提出的方法^[13]继承了 Fornaciari 的方法^[12]，使用了类似的凸度分类方法，但不同之处在于 Qi 的方法^[13]通过计算直线和圆锥上的可区分特征数来过滤直边。但上述这两种方法都要求至少有三个弧段才能恢复椭圆模型，这可能会使算法在处理不完整椭圆时失效。

Pautruauean 等人^[14]又试图将线段检测方法推广为多功能检测器，提出的 ELSDc 算法可以联合检测线段和圆弧，具体使用 LSD^[15]检测线段，然后从检测到的线段的起点和终点迭代搜索剩余的线段。值得注意的是，ELSDc 从灰度图像而非二元边缘中检测 LS，有别于其他方法，从而充分利用了丰富的梯度和几何线索。

1.2.2 深度学习椭圆检测研究方法

在过去的几年里，随着深度学习技术的迅速发展，基于深度学习的椭圆检测研究也取得了显著进展。这一领域的研究不仅关注于提高椭圆检测的准确性和效率，还致力于解决实际应用中的各种挑战，例如复杂背景、遮挡、椭圆形状的多样性等。

基于深度学习的椭圆检测方法主要集中在改进卷积神经网络 (Convolutional Neural Networks, CNN) 结构、设计特定的损失函数和提出针对椭圆检测任务的新型网络架构上。例如，CNN、Faster R-CNN 等目标检测模型被成功应用于椭圆形状的检测和分割任务中。Li 等人^[16]用于检测由计算机断层扫描 (CT) 扫描描绘的病变边界椭圆，针对现有网络并未充分利用椭圆几何特性问题，将 Gaussian Proposal Networks (GPN) 作为 Region Proposal Networks (RPN) 的一个扩展，将边界椭圆表示为图像平面上的二维高斯分布，并最小化提出的高斯分布与真实高斯分布之间的 Kullback-Leibler (KL) 散度以进行对象定位。同样对于椭圆参数估计的 Liu 等人提出^[17]的基于 CNN 的方法，专门用于工业图像中的椭圆目标检测，通过引入了扩展提议操作模块来解决在椭圆回归过程中丢失旋转角度方向的问题，有效的在预测椭圆参数时保留其旋转角度特征，从而提高检测准确性；同时设计了一种新的损失函数，将符合椭圆公理的高斯角度距离与平滑 L1 损失函数相结合，用作椭圆参数回归任务的损失函数，通过采用这种损失函数设计，有效增强了对于椭圆旋转角度预测的精度，解决了仅依赖单一损失函数可能导致局部参数（如旋转角度）估计不准确的问题。

同时还有大量研究者从椭圆的具体形状出发提出新的网络架构，这类模型通过引入额外的椭圆参数回归分支，设计算法模型实现椭圆检测。Dong 等人提出的 Ellipse R-CNN^[18]通过扩展 Mask R-CNN^[19]架构，首次提出了一个基于 CNN 的椭圆检测器，能够在复杂场景中（如树上的果实簇）代表和推断被遮挡的对象作为椭圆。该方法可以推断出即使被相邻物体遮挡的多个椭圆形对象的参数，并通过细化特征区域并集成 U-Net 结构来更好地处理遮挡，计算最终的检测得分。通过在合成数据集上的实验验证了椭圆回归的正确性，进一步地定量和定性展示了该方法相较于最先进的模

型及其三个变种在合成和真实数据集上的优越性。该研究提高了在遮挡和聚集情况下椭圆物体检测的准确性和鲁棒性。Wang 等人提出的 EIDet^[20]是一个锚点自由、单阶段的通用椭圆检测器，特别侧重于边缘信息的利用，通过边缘融合模块合成具有更完整边界和更好连续性的总体边缘图作为增强输入，以此提高椭圆回归的准确性。此外还设计了专门的损失函数，包括角度损失、IoU 损失和二值掩膜预测损失，以共同优化椭圆检测性能。广泛的实验表明，所提出的 EIDet 模型在合成和真实数据集上表现出了极具竞争力的性能，特别是在处理边缘信息方面，显示出了其对于椭圆形状对象检测的强大潜力。

基于深度学习的椭圆检测技术都展现出广泛的应用潜力，在医学影像分析^[21]、交通监控^[22]、工业检测^[23]以及农业监测^[24]等领域大放光芒。随着技术的进一步发展，预计将有更多创新的方法和应用出现，推动椭圆检测技术在更多领域的实际应用。

1.2.3 目标位姿估计研究方法

目标位姿估计 (Object Pose Estimation)^[25]是指从给定数据 (通常是图像或视频帧) 中估计出一个物体在三维空间中的位置 (平移) 和方向 (旋转) 的过程。简而言之，它旨在确定物体相对于某个参考坐标系的精确“姿态”。这一任务是机器视觉、机器人学、增强现实和许多其他领域中的一个关键问题。

通常，目标物体位姿估计可以根据基本原理被归类为不同的类别，主要包括几何方法、模板匹配以及深度学习方法，这些方法为精确地确定物体在空间中的位置和方向提供了多种途径。

早期的位姿估计方法主要基于几何学原理，如 ICP (Iterative Closest Point) 算法和 PnP (Perspective-n-Point) 算法。ICP 算法^[26]通过迭代地最小化两组点之间的距离来精确地对齐三维模型与观察到的数据，而 PnP 算法^[27]则通过解决如何从 n 个三维到二维的对应点中恢复出相机的位姿问题。

基于模板匹配的这类方法^[28]通过比较输入图像与预先定义的模板或者三维模型的投影，来确定物体的位姿。虽然这种方法在某些简单场景中效果不错，但在面对复杂背景、遮挡和光照变化时，性能会受到限制。

近年来，基于深度学习的方法因其强大的特征提取能力而在目标位姿估计任务中获得了广泛的应用。这些方法通常利用 CNN 来从图像中直接预测物体的位姿，或者首先检测出物体的关键点，然后使用这些关键点来估计位姿。深度学习方法能够处理复杂的场景，并且具有较好的泛化能力。PoseNet^[29]提出了使用 CNN 进行实时六自由度 (6-DOF) 相机重定位的方法，该系统通过训练一个 CNN，直接从单张 RGB 图像中回归出 6-DOF 相机姿态，无需额外工程处理或图优化。该方法在室内外都表现出了鲁棒性，室外大尺度场景下的定位精度约为 2 米和 6 度，室内则为 0.5 米和 10

度。系统基于一个高效的 23 层深度卷积网络，并利用从大规模分类数据的迁移学习，展现了 CNN 解决复杂图像平面外回归问题的能力。

同样，国内在位姿估计领域也取得了很好的进展。He 等人^[30]于 2020 年发布在 CVPR 论文中所提出的 Pvn3d 是一种新颖的深度学习模型，用于 6-DoF 姿态估计，该模型利用了三维关键点投票网络。它使用 RGB-D 图像提取特征，并采用深度霍夫投票机制检测三维关键点，随后是姿态参数拟合模块。这种方法利用深度学习在姿态估计任务中，通过集成语义分割和实例区分，尤其是在复杂环境下提高了准确性和鲁棒性，显著改进了传统方法。Chen 等人^[31]同年提出的 G2L-Net 是一种用于实时 6D 姿态估计的网络，它通过嵌入向量特征将全局信息和局部信息相结合。该网络能够有效处理不同尺度和视角下的物体，提供准确的姿态估计。通过深度学习技术，G2L-Net 可以在复杂环境中实现高效的特征提取和匹配，使其在实时应用中表现出色。此外，该方法还通过引入嵌入向量来增强模型的泛化能力，提高对新场景的适应性。随着硬件性能的显著提升及对复杂和特定任务需求的日益增长，国内外在目标位姿估计领域的研究进展持续加速。

1.3 本文主要研究内容

在复杂的人体脏器空间中，特别是口腔咽喉区域，对手术机器人采取柔性连接的末端执行器进行精确检测和位姿估计，可以帮助机器人获得其末端执行器的具体位置与朝向，对于推进外科手术机器人技术朝着智能化发展具有至关重要的意义。因此本文针对末端执行器的检测及位姿估计主要研究内容有以下几个方面：

(1) 首先针对口腔咽喉狭小空间内对末端执行器检测的挑战，具体包括：空间限制导致的单一视角和有限的成像范围可能导致末端执行器在成像平面显示不完整；空间内壁组织表面缺乏特征且常有组织液覆盖，增加了检测背景的复杂度；末端执行器种类多样和形状复杂性提高了检测难度。针对上述问题，本文特别设计了一种适合狭小空间使用的微型高精度圆环靶标，并将其集成到末端执行器顶部，确保靶标与执行器动作的同步。通过识别圆环靶标的显著特征，间接实现了对末端执行器的精确检测。此外，利用这一特殊设计的圆环靶标，本文构建了一个狭小空间内圆环靶标数据集，该数据集涵盖了各种光照条件、组织遮挡和抖动失焦等模拟口腔咽喉复杂场景，并对数据集中的圆环靶标椭圆边界进行了精确的标注，以提供充分的实验数据支持算法性能的评估。

(2) 其次针对在狭小空间内准确识别圆环靶标，本文提出并实现了基于弧线结构和基于 2-WD 损失改进的圆环靶标检测算法。基于弧线结构算法首先通过边缘检测识别图像中的边缘弧线，将符合角度偏差和跨角限制的弧线段连接形成弧线段组，实施局部与全局搜索并行策略，识别出满足极性约束、区域限制和自适应内点条件的有

效弧线段对,接着椭圆拟合有效弧线段对形成初始椭圆集合,随后分层聚类椭圆参数来消除重复的椭圆并生成候选椭圆集,最后对候选椭圆集进行严格评估,以确保算法的高效性和准确性。

基于 2-WD 损失改进的算法将 Faster R-CNN 中的 RPN 与椭圆的二维高斯分布相融合,提出专门针对椭圆形物体的检测进行优化 GPN 网络。并且在 GPN 的基础上引入 RoI 池化和回归分支,同时,采用 2-Wasserstein 距离 (2-WD) 作为椭圆候选区域精细化的损失函数,以准确预测椭圆形物体的具体位置。

(3) 最后为了解决在狭小空间内无法直接获取末端执行器位姿参数的问题,本文通过分析集成在末端执行器上的圆环靶标,在针孔相机模型成像后所形成的椭圆形状,应用基于弧线结构和 2-WD 损失改进的椭圆检测算法对成像平面中的圆环靶标进行识别,从而获得该靶标椭圆边界的特征信息。使用检测到的椭圆边界特征,结合圆环靶标已知尺寸信息对圆环投影中心坐标进行精确校正,综合利用已知医用内窥镜内参、椭圆边界特征、校正后圆心坐标真值信息,完成对末端执行器在狭小空间内的位姿参数估计,提高了位姿估计的精度和可靠性。

综上所述,本文通过对椭圆检测技术的创新研究和位姿估计模型的构建,不仅解决了狭小空间内目标检测的技术瓶颈,还为相关领域的实际应用提供了新的思路和解决方案,尤其在手术机器人技术中,有效提升了定位精度和安全性,对未来医疗机器人系统的研发和应用具有重要意义。

1.4 论文组织结构

本文旨在探讨狭小空间内目标检测及位姿估计领域的核心问题,提出了一种创新的解决方案并通过一系列实验验证了方法的有效性。本文的主要研究内容关系图如图 1.2,各章的组织架构如下:

第一章为绪论。主要介绍了在狭小空间内对目标特征检测的困难及挑战,分析了现有技术的不足与可改进之处。在此背景下,对国内现有目标检测以及定位现状进行详细阐述,并分析了该课题的研究价值。最后概述了本文的主要研究内容,并对论文的组织结构进行了说明。

第二章为相关技术及理论。主要介绍了本文在后续章节中所使用的科学理论基础和技术实现,首先通过介绍椭圆的定义和其参数化表示介绍了椭圆的几何特性,从椭圆的特殊几何性质出发讨论了传统椭圆检测算法与深度学习椭圆检测算法的原理,最后通过介绍边缘连接椭圆检测的弧线段及相关几何属性,为后续椭圆检测奠定基础。阅读本章内容有助于理解后文所提方法。

第三章为狭小空间圆环靶标设计及检测。从问题研究与意义入手,探讨了狭小空间环境的多样性,专门定制适用于此环境内的圆环靶标,并在此狭小空间内构建高精




图 1.2 本文主要研究内容关系图

度圆环靶标数据集。接着详细介绍了为检测圆环靶标，提出并实现的基于弧线结构的椭圆检测算法，具体包括圆弧线段组的形成、初始椭圆集生成、椭圆聚类和椭圆候选验证。最后，通过大量对比实验及结果可视化验证该方法的良好性能。

第四章为基于 2-WD 损失改进的椭圆目标检测算法。从深度学习角度出发，提出了一种针对椭圆边界检测的网络模型，介绍了算法框架，重点讨论了基于二维高斯分布的区域提议网络，包括椭圆的二维高斯分布、KL 散度和损失函数设计。接着，通过实验及分析验证了算法性能，对比实验和结果可视化进一步展示了所提方法的有效性。

第五章为基于椭圆检测的位姿估计模型。详细讨论了根据前两章节椭圆检测算法的结果，实现的一种基于椭圆检测的位姿估计方法，从而获得目标物体相对内窥镜的位姿估计参数，并通过充分实验验证该方法的有效性。

第六章为总结与展望。总结了本文所使用方法的创新点、优点以及不足之处。最后，展望了将来可发展的研究方向，可继续优化和泛化算法性能，同时可以着手构建包含更多模态信息的数据集，如深度信息、纹理信息等，以丰富算法的训练基础，并探索多模态数据融合技术在此类任务中的应用潜力。

第二章 相关技术研究

本章将深入探讨与椭圆检测密切相关的几种关键技术。首先介绍椭圆的基本几何属性，包括其数学定义及参数化表示方式，为理解椭圆在图像中的识别提供基础。随后，转向图像处理领域，详细讨论边缘检测和边缘跟踪技术，这些是实现精确椭圆检测的基石。进一步将展开关于基于边缘跟踪的椭圆检测方法的讨论，探讨其核心原理及应用。最后，本章还将概述基于深度学习的目标检测方法，尤其是 Faster R-CNN 的架构和网络特性，为后续的深入研究和应用提供了坚实的理论和技術基础。

2.1 椭圆的几何特性

椭圆作为圆锥曲线家族的一部分，在多个学科领域发挥着重要作用。这一形状不仅在数学理论中有其独特位置，而且在物理学的天体运动、工程学的设计问题，以及计算机视觉的物体识别等应用中都非常关键。

特别地，当从非正面角度观察圆形物体时，其二维平面投影常呈椭圆形，这种现象体现了视觉感知中形状变换的基本原理。例如，实际的硬币轮廓是标准圆形，但斜视一个硬币时看到的却是椭圆形状，展示了通过改变观察角度，形状的外观随之变化，但仍保持某些基本特征，如封闭性和平滑性。这不仅说明了椭圆形状的普遍性，还强调了其在模拟和分析现实世界现象中的实用价值。

2.1.1 椭圆的定义

在平面上，对于两个固定点 F_1 和 F_2 （这两个点称为焦点），椭圆是所有点 P 的集合，这些点满足从 P 到两焦点 F_1 和 F_2 的距离之和是一个常数，且这个常数大于焦点间的距离。数学上，这可以表示为等式 2-1，其中 $|PF_1|$ 和 $|PF_2|$ 分别是点 P 到两个焦点的距离， $2a$ 是常数，且 a 是椭圆的半长轴长度。焦点间的距离 $|F_1F_2|$ 小于 $2a$ ，椭圆的几何中心位于两焦点的中点上，如图 2.1（a）中所示。

$$|PF_1| + |PF_2| = 2a \quad (2-1)$$

椭圆的标准方程在直角坐标系中的定义是对椭圆几何属性的一种数学表述，这使得在代数上研究和理解椭圆的性质。在直角坐标系中，假设椭圆的中心位于原点 $(0,0)$ ，且其主轴分别平行于 x 轴和 y 轴，那么椭圆的标准方程就可以表示为等式 2-2，其中 x 和 y 分别是椭圆上任意一点的横坐标和纵坐标； a 是椭圆的半长轴长度，即从中心到椭圆最远点的距离； b 是椭圆的半短轴长度，即从中心到椭圆最近点的距离。




图 2.1 直角坐标系下椭圆的表示

$$\frac{x^2}{a^2} + \frac{y^2}{b^2} = 1 \quad (2-2)$$

这个方程本质上描述了椭圆上每一点的 x 坐标和 y 坐标之间的关系, 所有满足这个方程的 (x, y) 坐标点共同构成了椭圆的形状。

该方程还具有相应的几何意义。当 $x = 0$ 时, y 的绝对值等于 b , 这表示椭圆在 y 轴上的交点; 当 $y = 0$ 时, x 的绝对值等于 a , 这表示椭圆在 x 轴上的交点; 当 $a = b$ 时, 椭圆变为一个圆, 这时标准方程简化为 $x^2 + y^2 = a^2$, 此时 a 是圆的半径。

椭圆方程在直角坐标系中表示具有显著优势: 首先, 它简化了椭圆上点的确定、面积和周长的计算, 以及与其他几何形状关系的分析; 其次, 这种表示法便于在计算机图形学和图像处理中实现, 使得椭圆的绘制和形状分析更加高效; 此外, 它提供了一个统一的分析框架, 便于研究椭圆与其他几何形状 (如直线、圆等) 的相互作用, 对解决几何问题 (如相交、切线问题) 特别有帮助; 最后, 直角坐标系下的表达形式也方便对椭圆进行几何变换 (如平移、旋转) 和在更高维度 (如三维的椭球) 中的扩展, 为椭圆的参数化表示提供理论支持。

2.1.2 椭圆的参数化表示

椭圆的参数化表示是一种使用参数 (通常是角度) 来描述椭圆上每一点位置的方法。椭圆的参数化方程通常定义如下: 假设椭圆的中心位于坐标系的原点 $(0, 0)$, a 和 b 分别是椭圆的半长轴和半短轴的长度, 则椭圆上任意一点 $P(x, y)$ 可以通过参数 θ 表示为如下等式 2-3, 其中 θ 是参数, 取值范围从 0 到 2π , 代表了椭圆上一点与椭圆中心连线和椭圆半长轴之间的夹角, 如图中 2.1 (b) 中所示。

$$\begin{cases} x = a \cos \theta \\ y = b \sin \theta \end{cases} \quad (2-3)$$

椭圆的参数化表示简化了其几何和代数的计算处理,使得在计算机图形学和图像处理中绘制和分析椭圆更为直接和高效。此方法允许通过调整参数轻松生成动态椭圆轨迹,有利于创造平滑连贯的动画效果。同时,参数化方便了对椭圆性质的深入分析,如计算弧长、面积和周长,并为椭圆的数学研究提供了统一框架,推动了理论的发展和理解。

总之,椭圆的参数化表示不仅为理论研究提供了一种强有力的工具,而且在实际应用中也展现了极大的灵活性和效率,是连接数学理论与实际应用的重要桥梁。

2.2 椭圆检测相关技术

椭圆,作为现实世界中极为常见的几何形状之一,其检测技术已成为图像处理领域的基础技术,并广泛应用于多个领域,包括但不限于人脸识别^[32]、交通标志检测^[33]、平台物体跟踪^[34]以及医学图像分析^[35]。尽管近年来提出了众多椭圆检测算法,高精度的实时椭圆检测在现实世界图像中仍面临诸多挑战。这些挑战主要源于几个方面:噪声的存在可能会导致椭圆轮廓的不连续性或将其分割成较短的边缘片段,使得检测变得复杂;真实图像中的椭圆形物体可能会被其他物体遮挡,导致其轮廓的完整性受损;此外,数字化和量化的效应可能使椭圆曲线呈现不平滑,进而影响曲线参数(如曲率、切线等)的连续性和可靠性。这些因素共同给椭圆的准确检测带来了巨大的挑战。尤其值得注意的是,相较于圆的检测仅需三个参数,椭圆检测所需的五个参数显著增加了问题的复杂度,这使得高效且准确地检测椭圆成为一个不小的挑战。在大多数实际应用场景中,对更高的定位精度和更快的处理速度的迫切需求,进一步加剧了这一挑战的程度。当前研究中应用的椭圆检测方法主要归入两个范畴:霍夫变换与边缘连接技术。

2.2.1 基于霍夫变换的椭圆检测

霍夫变换,其起初设计目的是为了识别图像中的直线元素,随后该技术得到了拓展,以便于识别包括圆形和椭圆在内的多种几何形态。由于椭圆具有更多的自由度,使得基于霍夫变换的椭圆检测比直线或圆的检测更为复杂。

在基于霍夫变换的椭圆检测算法^[2]中,其核心理念是通过在参数空间内应用霍夫变换来实现曲线的适配。此过程首先涉及对图像执行边缘检测步骤,以识别图像中的边缘元素。接着,针对图像的每个边缘像素点,根据其周围像素的信息,计算潜在的椭圆参数,并在参数空间内进行累积操作。由此,每一个椭圆都会在参数空间中形成一个独特的峰值位置。通过在参数空间中识别这些峰值,可以找到对应的椭圆形状。根据筛选出的椭圆参数,对原始图像中的边缘点进行椭圆拟合,得到最终的椭圆检测结果。




图 2.2 基于霍夫变换的椭圆检测算法比较

概率霍夫变换 (Probabilistic Hough Transform, PHT)^[36]是一种改进的霍夫变换方法,旨在通过随机抽样的方式提高图像特征检测的效率并降低计算复杂度。与传统霍夫变换相比, PHT 通过从图像中随机选择边缘点的子集,而不是分析图像中的每一个点,来填充参数空间并检测图像中的几何形状,如直线、圆和椭圆。这种方法的核心优势包括:通过减少参与投票的边缘点数量, PHT 显著减少了处理时间,使其更适合实时应用和处理大型数据集;尽管采用的边缘点数减少, PHT 仍能有效地检测图像中的特征,并对噪声保持鲁棒; PHT 能够适用于多种几何形状的检测,具有较高的适应性和灵活性;由于限制了参与计算的点数, PHT 降低了对计算资源的需求,特别适用于资源有限的环境。总的来说, PHT 通过在特征检测中引入随机抽样策略,有效平衡了检测准确性和计算效率,增强了霍夫变换在复杂或要求高效的图像处理任务中的应用潜力。

Yuen 等人^[37]采用了一种创新的方法,通过分解 5D 参数空间,以两个阶段识别图像中的椭圆。在第一阶段,他们利用椭圆固有的几何特性,如共线性和对称性,有效地定位了椭圆的中心。随后,在第二阶段,剩余的三个参数——椭圆的长短轴半径和倾斜角度被精确地计算出来。进一步地, Xu 等人^[3]引入了随机化霍夫变换 (RHT) 这一概念,对曲线检测的传统方法进行了革新。与将每个边缘点全部映射至五维参数空间的做法不同, RHT 通过随机选取像素点的策略,直接将这些点映射至椭圆参数空间的特定位置。这一方法显著降低了计算的复杂性,同时简化了直线、圆和椭圆等各种曲线的检测流程。RHT 不仅提升了处理速度,还大幅度减少了对内存的需求,使得它成为了适用于实时应用和处理大规模图像数据集的有效技术,而这一切并不以牺牲检测的精确度为代价。

McLaughlin 等人^[4]采取了一种创新的方法,将先前提到的两阶段分解法与随机化霍夫变换 (RHT) 相结合,旨在同时减少计算时间并提升椭圆检测的性能。这种融合策略,相较于标准的霍夫变换 (HT),标志性地提高了处理效率和检测精准度,从

而在椭圆检测技术中设立了一个新的基准。然而，尽管这种方法在理论上具有显著的优势，但在实际应用场景中，由于缺少创新的验证机制，它偶尔也会引发误检。

2.2.2 基于边缘连接的椭圆检测

第二类著名的椭圆检测方法主要利用图像中的边缘信息来识别椭圆形状的方法。与基于全局特征分析的方法不同，边缘连接方法侧重于从局部边缘出发，逐步追踪和分析边缘的连续性和几何属性，从而识别出椭圆，背后的核心原理不仅仅是识别单个边缘像素，而是了解并利用这些像素之间的连通性，形成连贯的线段或弧线，从而暗示椭圆形的存在，如图 2.3 所示。这种方法特别适用于图像中椭圆部分遮挡或只有部分边缘清晰可见的情况。




图 2.3 基于边缘连接的椭圆检测算法流程

基于边缘连接的椭圆检测算法原理步骤依靠以下步骤实现：（1）边缘检测：通过应用边缘检测算法，以提炼出图像中的边缘细节。这一过程旨在明确图像中所有可能的边缘点，从而为接下来的边缘连接步骤铺垫基础。（2）边缘连接起点选定：根据不同的应用场景使用不同的边缘跟踪策略，选择一个起始边缘点作为跟踪的开始作为，通常会选择边缘强度较高或符合某些几何特征的点作为起点。（3）边缘连续性分析：从起始点出发，根据边缘的连续性原则，沿着边缘的方向逐点进行连接，分析每个点 nab 的邻域内的像素值，确定边缘的走向。（4）几何特性分析：在边缘连接的过程中，根据椭圆的几何特性，如曲率的连续性和变化规律，判断跟踪到的边缘是否符合椭圆的特征。这可能涉及到复杂的几何计算和模式匹配。（5）椭圆参数估计：确认边缘追踪结果为椭圆形状之后，随即需对该椭圆的特征参数进行详细评估，包括确定其中心位置、长短轴长度和倾斜角度。这通常通过数学模型和最小二乘法等拟合技术实现。（6）验证和优化：对于估计出的椭圆参数进行验证，确保检测到的椭圆与实际图像中的椭圆形状吻合。依据需求进行参数的调整与优化，旨在增强检测过程的精确度。

边缘检测算法是边缘连接实现椭圆检测中的第一步，边缘通常由图像亮度的突变来定义，边缘检测的目的是从图像中找出亮度变化显著的点，从而描绘出物体的轮廓。以下是几种经典的边缘检测算法对同一张图片检测后的效果展示：

（1）Sobel 算子通过计算图像亮度的一阶导数的近似来检测边缘，使用两个 3×3 的卷积核（式 2-4），分别对图像的水平 and 垂直方向进行卷积，计算每个像素点在水平




图 2.4 初始图像




图 2.5 Sobel 算子




图 2.6 Prewitt 算子




图 2.7 Roberts 交叉算子



图 2.8 Canny 算子




图 2.9 Laplace 算子

方向 G_x 和垂直方向 G_y 的梯度近似值, 其中 $G = \sqrt{G_x^2 + G_y^2}$ 和 $\theta = \arctan(G_y/G_x)$ 表示梯度的大小和方向。

$$G_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix} * I \quad G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix} * I \quad (2-4)$$

(2) Prewitt 算子与 Sobel 算子相似, 同样使用两个 3×3 的卷积核对图像进行计算图像亮度的一阶导数来检测图像中的边缘, 但卷积核的权重 (式 2-5) 不同。Prewitt 算子主要用于识别图像中水平、垂直和对角线方向的边缘, 并通过突出这些边缘来描绘出图像中物体的轮廓。

$$G_x = \begin{bmatrix} -1 & 0 & +1 \\ -1 & 0 & +1 \\ -1 & 0 & +1 \end{bmatrix} * I \quad G_y = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ +1 & +1 & +1 \end{bmatrix} * I \quad (2-5)$$

(3) Roberts 交叉算子通过计算像素点对角邻域差异的方法来识别边缘, 具体使用两个 2×2 的卷积核 (式 2-6), 其中第一个卷积核用来检测 45° 方向的边缘, 第二个卷积核用来检测 135° 方向) 来计算对角像素差的绝对值来估计图像梯度。它特别适用于描绘图像中的高频细节, 主要用于检测高频细节部分的边缘, 同时由于所使用的卷积核较小对噪声也更加敏感。

$$G_x = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad G_y = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \quad (2-6)$$

(4) Canny 算子是一种多阶段的算子, 旨目标是在尽可能减小错误率的同时, 准

确地检测图像中的边缘。Canny 算法首先使用高斯滤波器与图像进行卷积操作来平滑图像以降低噪声，然后使用 Sobel 算子计算图像在水平和垂直方向的梯度强度和方向。为了消除边缘检测带来的厚边缘效应，确保边缘尽可能细，使用非极大值抑制 (Non-Maximum Suppression, NMS) 算法仅保留梯度强度最大的点，并抑制其它非边缘 (非最大值) 点。接下来，算法应用两个阈值 (高阈值 T_{high} 和低阈值 T_{low}) 来确定真实的和潜在的边缘。高于 T_{high} 的点被认为是强边缘点；低于 T_{low} 的点被排除；介于两者之间的点被认为是弱边缘点。最后，算法通过抑制孤立的弱边缘点并保留连接到强边缘点的弱边缘点，从而完成边缘检测。其流程图如图 2.10 所示。

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (2-7)$$




图 2.10 Canny 边缘检测流程图

(5) Laplace 算子通过识别亮度变化的“变化率”来检测边缘，其在二维图像处理中的表达式通常写作等式 2-8，这里 $f(x, y)$ 代表图像的亮度函数， ∇^2 表示 Laplace 算子， $\frac{\partial^2 f}{\partial x^2}$ 和 $\frac{\partial^2 f}{\partial y^2}$ 分别表示图像亮度函数沿 x 和 y 轴的二阶导数。

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \quad (2-8)$$

在边缘检测中，Laplace 算子用于识别图像中的突变区域，这些突变区域通常对应于边缘。由于 Laplace 算子是二阶导数，它对图像中亮度的微小变化非常敏感，能够在边缘的两侧产生正负响应，使边缘处于零交叉点。因此，通过查找 Laplace 算子处理后结果中的零交叉点，可以定位边缘。实际应用中，Laplace 算子通过与图像卷积来实现，常见的 Laplace 算子卷积核包括如下两种：

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix} \quad \begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad (2-9)$$

Laplace 算子的主要优点是能够明显地标识边缘位置，适用于强调图像中的细节。然而，由于其对噪声极为敏感，直接应用 Laplace 算子于原始图像可能会导致大量的假边缘被检测出来。

在边缘连接椭圆检测算法中，弧线段及其相关属性作为基本的几何单元将被详

细介绍。同时，本文也将阐述椭圆拟合的叠加法则，这一原理能够实现对椭圆轨迹的快速拟合，从而有效减少生成椭圆所需的计算时间。

2.2.3 弧线段及其特征

在图像中检测到的曲线往往并非完美的椭圆形状，而是由于噪声、变形或其他因素而略有偏差，弧线段的提出则可以帮助对这些曲线进行近似，将其表示为更简单的直线段，从而更容易进行椭圆拟合。曲线的一部分被近似为一条称为弧线段，通过使用该弧线段可以简化曲线的表示形式，并且在某些情况下可以提高曲线检测的效率和准确性。

在图像中线段主要来源于两种情况，如图 2.11 所示。第一种线段如图 2.11 (a) 所示，通过将梯度角顺时针旋转 90° 获得水平线角，该类型线段在该区域内的点位大体上展现出一致的水平线角度，形成了近似直线的分布模式；另一种线段源自弧形区域，如图 2.11 (b)、(c) 所示，其中图 2.11 (b) 为灰度图像，图 2.11 (c) 为 (b) 拟合产生的线段，观察发现该弧形区域分布呈曲线变化趋势，因此，将从弧形区域拟合的线段称为弧线段。因此在弧线段的衬托下，直线段被剪切掉，而弧的几何线索则保留下来，接下来将详细介绍弧线段对椭圆检测至关重要的弧线段凸性和弧线段极性两个特征。

(1) 弧线段凸性。与直线段不同，弧线段表现为凸性特质^[38]，其指向符合椭圆弧中心的方向，如图 2.11 所示，其中图 2.11 (a) 显示边缘局部灰度区域的整体梯度方向与弧线段方向一致，相应水平线图上的三个主要角度呈逆时针方向变化；(b) 为 (a) 的反例。




图 2.11 直线段和弧线段及其角度示意

设弧形区域的定界矩形两端分别为 A 和 B ，中心为 C ，则该区域的主角记为 $\angle \overrightarrow{AB}$ ，并且可设为如下式 2-10。同理，两个子区域 $\angle \overrightarrow{AC}$ 和 $\angle \overrightarrow{CB}$ 的主角也可以通过等式 2-10 获得。因此，在 $\angle \overrightarrow{AC}$ ， $\angle \overrightarrow{AB}$ ， $\angle \overrightarrow{CB}$ 的角度沿着逆时针或顺时针方向发生变化时，如果 $\{\angle \overrightarrow{AC}, \angle \overrightarrow{AB}\}$ 和 $\{\angle \overrightarrow{AB}, \angle \overrightarrow{CB}\}$ 至少存在 T_{ai} 的角度间隔，则通过将 $\angle \overrightarrow{AB}$ 逆时针或顺时针旋转 90° ，即可以确定弧线段方向。

$$\arctan \left(\frac{\sum_{p_i \in \text{Region}} \sin(\text{level-line angle}(p_i))}{\sum_{p_i \in \text{Region}} \cos(\text{level-line angle}(p_i))} \right) \quad (2-10)$$

(2) 弧线段极性。在灰度图像中，局部区域的整体梯度方向表示光照变化的趋势。经分析，椭圆弧整体梯度方向与其局部弧线段方向的对应关系可分为两种情形：若梯度方向与弧线段方向不相符，则该弧线段的极性被定义为负 (-1)，否则为正 (+1)。因此通过评估主角 $\angle \overrightarrow{AC}$ 、 $\angle \overrightarrow{AB}$ 和 $\angle \overrightarrow{CB}$ 的旋转方向，可以快速有效地判断弧线段的极性，如图 2.12 所示。




图 2.12 判定弧线段极性示意图

2.2.4 椭圆拟合原理及其叠加

在椭圆检测过程中，椭圆拟合扮演了极为关键的角色，其质量直接决定了检测出的椭圆的准确性。Fitzgibbon 等人^[39]提出了一种基于代数距离的椭圆拟合方法，该方法的核心思想是将椭圆拟合问题转化为一个优化问题，通过最小化代数距离的平方和来寻找最佳拟合椭圆。

椭圆用等式 $F(x, y) = Ax^2 + Bxy + Cy^2 + Dx + Ey + F = 0$ 的二次方程表示，其中 x 和 y 是平面上的坐标，而 A, B, C, D, E, F 是描述椭圆形状和位置的参数，满足约束条件 $B^2 - 4AC < 0$ 。

定义向量 $A = [a, b, c, d, e, f]^T$ ， $X = [x^2, xy, y^2, x, y, 1]$ ，则椭圆方程转化为等式 2-11，但此时若直接用最小二乘法^[40]求得解，所得到的拟合结果将是一般的圆锥曲线，而非特定的椭圆形状。重新考虑约束条件 $B^2 - 4AC < 0$ ，将不等式约束转化为 $B^2 - 4AC = 1$ 。

$$\min \sum_{i=1}^N F(x_i, y_i)^2 = \min \sum_{i=1}^N (F_A(x_i))^2 = \min \sum_{i=1}^N (X_i \cdot A)^2 \quad (2-11)$$

定义矩阵 D (等式 2-12) 和常数矩阵 C (等式 2-13)，椭圆拟合问题变为当满足 $a^T C a = 1$ 的条件下，求解 $\min \|Da\|^2$ 。构造拉格朗日函数 $L(D, \lambda) = Daa^T D^T -$

$\lambda(a^T Ca - 1)$, 对其求偏导并令其为 0, 得到 $D^T Da = \lambda Ca$, 令 $D^T D = S$, 等式变为 $Sa = \lambda Ca$, 因此简化为求取特征值的问题: $S^{-1}Ca = \frac{1}{\lambda}a$ 。所以椭圆拟合问题转化为求取 $S^{-1}C$ 的特征值、特征向量问题。

$$\mathbf{D} = \begin{bmatrix} x_1^2 & x_1 y_1 & y_1^2 & x_1 & y_1 & 1 \\ x_2^2 & x_2 y_2 & y_2^2 & x_2 & y_2 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_n^2 & x_n y_n & y_n^2 & x_n & y_n & 1 \end{bmatrix}_{n \times 6} \quad (2-12)$$

$$\mathbf{C} = \begin{bmatrix} 0 & 0 & -1 & \cdots & 0 \\ 0 & 2 & 0 & & \\ -1 & 0 & 0 & & \vdots \\ \vdots & & & \ddots & \\ 0 & \cdots & & & 0 \end{bmatrix}_{6 \times 6} \quad (2-13)$$

鉴于椭圆拟合问题涉及的约束条件为二次形, 其在迭代求解过程中常常遭遇效率低下的问题。从叠加原理的有效性出发, 本文在^[39]的基础上发展了叠加原理。

设集合 $\Gamma_1 = \{p_1, p_2, \dots, p_n\}$, $p_i = \{x_i, y_i\}$ 中有 n 个数据点。首先计算 Γ_1 的散点矩阵 $\mathbf{S} = \mathbf{D}^T \mathbf{D}$, 然后求解广义特征系统 $\mathbf{S}^{-1} \mathbf{C}$, 其中 $\mathbf{C}$ 是常数约束矩阵 (等式 2-13), 得到的特征值为正的特征向量即为 Γ_1 的拟合椭圆。

在实施椭圆检测过程时, 经常需要尝试拟合大量不同的点集的组合, 以便确定最佳的拟合椭圆。设已对一组点 Γ_1 进行椭圆拟合, 并随后识别出几个附加的同属一椭圆的几个额外的点集, 标记为 $\Gamma_1, \Gamma_2, \dots, \Gamma_k$, 则基于先前的结果寻求一种高效的方法来拟合新增点集形成的新椭圆。每个 Γ_i 的设计矩阵和散点矩阵分别以 $\mathbf{D}(\Gamma_i)$ 和 $\mathbf{S}(\Gamma_i)$ 。因此, k 个点集 $\Gamma_1, \Gamma_2, \dots, \Gamma_k$ 组合的矩阵 $\mathbf{D}_c$ 可表示为:

$$\mathbf{D}_c = \begin{bmatrix} \mathbf{D}(\Gamma_1) \\ \vdots \\ \mathbf{D}(\Gamma_k) \end{bmatrix}, \quad (2-14)$$

, 并且其对应的散点矩阵 $\mathbf{S}_c$ 为:

$$\begin{aligned} \mathbf{S}_c &= \mathbf{D}_c^T \mathbf{D}_c = \mathbf{D}(\Gamma_1)^T \mathbf{D}(\Gamma_1) + \cdots + \mathbf{D}(\Gamma_k)^T \mathbf{D}(\Gamma_k) \\ &= \mathbf{S}(\Gamma_1) + (\mathbf{S}(\Gamma_2) + \cdots + \mathbf{S}(\Gamma_k)). \end{aligned} \quad (2-15)$$

因此由 2-15 可知, 任意组合点集的散点矩阵等于每个点集散点矩阵的和, 这表明计算各组散点矩阵一次的方法是可行的。在将单个或多个集合拟合至同一椭圆时,

利用上述叠加特征能有效降低计算时长。

2.3 基于深度学习的目标检测方法

近年来,随着深度学习技术的迅猛发展,如图 2.13所示,其在目标检测领域的应用也实现了快速进步并被广泛采纳。基本思想主要为算法自动从大量数据中搜寻图像特征,进而改变目标检测传统的人为设计、选取特征的初始模式。因此,与传统目标检测算法相比,采用深度学习技术进行目标检测能更有效地提取图像中的深层特征,得到更精准的类别信息和目标位置信息,显示了更好的检测效果。




图 2.13 目标检测算法时间轴一览表

目前使用深度学习进行目标检测的算法主要分为一阶段算法模型和二阶段算法模型,其中一阶段算法模型以 SSD (Single Shot MultiBox Detector) 算法^[41]、YOLO (You Only Look Once) 系列算法为主要代表,二阶段算法模型则主要以 RCNN^[42]、Fast R-CNN^[43]、Faster R-CNN^[44]算法为代表。在这里主要介绍二阶段算法模型中 Faster R-CNN 的网络架构及其实现原理,为后续第四章使用基于 Faster R-CNN 中的 RPN 框架进行椭圆边界检测奠定基础。

2.3.1 Faster-RCNN 整体架构

基于 R-CNN 和 Fast R-CNN 的先行研究,Girshick 等人又于 2016 年提出了更为先进的模型——Faster R-CNN。此模型的架构创新性地整合了特征提取、候选区域提取、边界框回归(即矩形框调整)以及分类任务,将这些功能融合到一个单一的网络中,实现了检测流程的高度整合。这一创新不仅显著提升了模型的综合性能,尤其在检测速度方面的提升尤为突出,标志着目标检测技术正步入一个更迅捷、更优化的新阶段。

Faster R-CNN 的网络结构主要包括以下几个关键部分:(1)特征提取网络(Feature




图 2.14 Faster R-CNN 网络结构图

Extraction Network)。在此部分，深度卷积神经网络（如 VGG-16、ResNet 等^[45]）被作为基础架构，以便从输入图像中提取特征图（feature map）。特征图包含了图像中的重要信息，为后续的目标检测提供了基础。（2）区域候选网络（Region Proposal Network, RPN）。RPN 是 Faster R-CNN 的核心创新之一。它在特征图上滑动小窗口，通过卷积层快速生成目标的候选区域，每个候选区域都有一个对象分数和四个坐标值，分数反映了这个区域是对象的概率，坐标值用于精确定位。RPN 通过使用锚点机制来提高区域提议的质量，锚点是预定义的一组不同形状和大小的框，它们与每个滑动位置相关联，用于适应不同尺寸的目标。（3）RoI 池化层（Region of Interest Pooling Layer）。源自 RPN 的候选区域框在特征图上展示出多样化的形状与尺寸，RoI 池化层负责将这些候选区域框统一转换为固定尺寸的特征图块，便于进行后续的分析处理。（4）分类和边界框回归（Classification and Bounding Box Regression）。在此阶段，利用 RoI 池化层产出的固定尺寸特征图块作为输入，这些图块经过一连串全连接层的处理，以产生每个候选区域框的类别预测及边界框细微调整的最终输出。类别预测指出候选区域中包含的对象类别，边界框回归则调整候选区域的位置和尺寸，以更准确地覆盖检测到的对象。（5）整合优化。Faster R-CNN 通过端到端的训练，同时优化 RPN 和分类及边界框回归的参数，实现了检测流程的高度整合和自动化。

Faster R-CNN 通过这样的结构设计，有效地整合了区域提议和目标检测的流程，大幅提升了检测速度，同时保持了较高的准确率，成为目标检测领域的一种重要技术。

2.3.2 RPN 网络架构

RPN 作为 Faster R-CNN 框架中的一个关键组成部分，它的主要功能是从输入图像中快速生成高质量的候选区域，这些候选区域随后会被用于识别图像中的目标对象，RPN 的引入大幅提升了目标检测流程的速度和效率。




图 2.15 RPN 网络结构图

下面是 RPN 网络结构的详细介绍：(1) 共享卷积层 (Shared Convolutional Layers)。RPN 构筑于预训练的卷积神经网络之上，该卷积神经网络充当特征提取器的角色，向 RPN 及其后续的目标检测流程提供共享的特征映射。通过这种特征提取层的共享机制，RPN 能够在不显著增加计算负荷的前提下，有效利用深度网络挖掘的深层特征。(2) 3x3 卷积层。在提取的特征图上，RPN 首先应用一个 3x3 的卷积层，这个卷积层的目的是为了同时处理多个尺度的特征，并减少参数数量，增加网络的非线性。该层的输出将被送往后续的两个分支：分类层和边界框回归层。(3) 锚点机制。锚点是 RPN 的核心概念之一，它们是一系列预定义的固定大小和比例的矩形框，每个锚点都作为一个潜在的对象候选区域，覆盖在特征图的每个位置上，通过使用不同尺寸和比例的锚点，RPN 能够有效地覆盖不同形状和大小的对象。(4) 分类层 (Classification Layer)。对于每个锚点，RPN 通过一个小网络（通常是一个全连接层）预测该锚点是前景（即含有对象）还是背景，这个过程生成了每个锚点的二分类得分。(5) 边界框回归层 (Bounding Box Regression Layer)。同时，RPN 还会预测每个锚点相对于真实对象边界框的四个坐标偏移量，这使得即使原始的锚点位置不是非常精确，通过学习到的偏移量也能够调整锚点以更好地匹配真实对象的位置和大小。(6) 非极大值抑制^[46] (Non-maximum Suppression, NMS)。最后，RPN 通过 NMS 处理，去除重叠较大的候选区域框，保留得分最高的候选区域框，以减少冗余，生成最终的候选区域框集合。

通过这样的结构，RPN 能够高效地在整个图像中生成具有不同位置、大小和纵横比的目标候选区域，极大地提高了后续目标检测步骤的效率和准确性。

2.3.3 RPN 网络损失函数

在 RPN 中，损失函数是用来评估预测的区域提议与真实标注之间的差异，并通过反向传播算法来更新网络权重。RPN 的损失函数融合了分类损失与边界框回归损失两个部分，形成了一种多任务损失函数。该函数旨在通过并行训练，实现对目标候选区域的分类以及对边界框进行精准调节的双重目标。

其中分类损失被定义为一个二分类问题，旨在判别锚点是前景（即包含对象）还是背景。这一过程采用对数损失函数，亦即交叉熵损失，具体表达如公式 2-16 所示。在该公式中， p 是预测为前景的概率， p^* 代表锚点的真实标签（前景标记为 1，背景标记为 0）。

$$L_{cls}(p, p^*) = -[p^* \log(p) + (1 - p^*) \log(1 - p)] \quad (2-16)$$

边界框回归损失用于测量预测的边界框与真实边界框之间的差异。平滑 L1 损失 (Smooth L1 loss) 是常选的一种损失函数，如公式 2-17 所示，其中 t 是预测的边界框属性（通常包括中心点坐标、宽度和高度的变化）， t^* 是与之对应的真实边界框损失，平滑 L1 损失与传统 L1 损失相比，展现了对异常值更强的鲁棒性。

$$L_{reg}(t, t^*) = \sum_{i \in \{x, y, w, h\}} \text{smooth}_{L1}(t_i - t_i^*)$$

$$\text{smooth}_{L1}(x) = \begin{cases} 0.5x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise} \end{cases} \quad (2-17)$$

为了同时优化锚点的分类任务和边界框调整任务，RPN 使用多任务综合损失函数，如公式 2-18 所示，其中 N_{cls} 和 N_{reg} 分别是分类和回归的归一化项（通常为小批量中的锚点总数）， λ 是平衡分类损失和回归损失的权重参数。通过这个损失函数，RPN 可以有效地学习如何生成高质量的对象候选区域，同时对这些候选框进行精确的位置调整，从而提高后续目标检测任务的准确性和效率。

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*) \quad (2-18)$$

2.4 本章小结

本章对椭圆检测的相关技术进行了全面的介绍和研究，从椭圆的几何特性出发，详细阐述了椭圆的定义和参数化表示方法。接着，介绍了椭圆检测的相关技术，其中重点介绍了基于边缘连接的椭圆检测算法中弧线段及其特征和椭圆拟合的原理。最

后，本章还涵盖了基于深度学习的目标检测方法，特别是 **Faster R-CNN** 的整体架构、**RPN** 网络架构以及 **RPN** 网络的损失函数，为后续章节椭圆检测算法的实现和优化提供了理论基础和技术支持。

第三章 狭小空间圆环靶标设计及检测

本章专注于探讨狭小空间内末端执行器目标检测的挑战。面对狭小空间内显著性特征缺失及末端执行器几何形状复杂的问题，本文设计了一种适用于此类空间的微型圆环靶标。通过将末端执行器与圆环靶标集成，实现了利用圆环靶标的特征进行末端执行器目标的相对检测。本章节内容组织如下：首先，介绍本文工作的背景、任务场景及研究动机；其次，深入探讨狭小空间环境的复杂性，并详述针对该空间自主设计的圆环靶标及由该靶标构建的高精度圆环靶标数据集；然后针对检测圆环靶标问题，提出了一种基于弧线结构的椭圆检测算法，阐述该算法的理论基础和实施步骤；最终，通过广泛的实验验证及结果分析，评估该检测算法的性能。

3.1 引言

本文所依托的基于飞秒激光技术实现外科手术机器人系统项目，旨在口腔咽喉部位等狭小空间内对不同类型的病灶进行自动化切割和缝合，同时在外科医生的监督和辅助下运行。该系统包括监控和控制中心、辅助机械臂、激光发射单元、柔性连接臂以及集成了手术钳、激光反射装置、辅助照明设备和单目内窥镜等手术必需器械的末端执行器，如图 3.1 所示。末端执行器通过柔性连接臂与外部辅助机械臂及控制中心相连，确保了手术过程的精准和灵活。




图 3.1 手术机器人及其末端执行器展示

手术过程主要分为两个阶段：漫游阶段和执行阶段。在漫游阶段，辅助机械臂利用柔性连接控制并引导末端执行器从人体外部移动至口腔咽喉内的指定病灶位置，并在确定最佳的观测位姿后停止移动，固定执行器的位置。执行阶段则涉及末端执行

器通过其配备的激光反射装置和手术钳等工具进行具体的手术操作，同时单目内窥镜和辅助照明设备提供实时的手术视野，以精准切割和缝合肿瘤、息肉等病灶，最后完成手术任务并撤离目标区域。

通常情况下，辅助机械臂可以通过手眼标定技术获得关节节点间或传感器之间的相对位姿转换信息，并利用运动学来估计机械臂末端或本身的位姿状态。然而，在本项目中，由于实际应用需求，末端执行器是通过柔性体与主机和辅助机械臂相连接的，这种配置意味着完全依靠运动学进行位姿估计可能无法为导航系统提供稳固的支持。柔性体可能因碰撞、负载等多种因素而发生形变，这些因素在运动学中无法进行有效预测。在这一情况下，对视野范围内的末端执行器在手术执行阶段提供有效的检测及位姿估计成为一个解决方案。

综上所述，本文针对此项目完成的主要工作内容为：（1）针对口腔咽喉这一狭小空间，专门设计了一种适用于外科手术环境的微型高精度圆环靶标，并巧妙地将其集成于末端执行器中，通过对显著的圆环靶标椭圆特征检测，间接实现了对末端执行器的精确检测；（2）针对由于柔性体连接导致无法获得末端执行器准确的位姿参数，通过椭圆检测算法提取出圆环靶标边界，并基于靶标边界的特征及先验知识，完成该靶标的位姿估计，进而实现对末端执行器的位姿估计。

3.2 狭小空间高精度圆环靶标设计

本节首先详细介绍了手术机器人末端执行器操作的狭小空间环境，随后分析了使用医用内窥镜在这种环境下进行图像采集所面临的高度复杂性，以及导致这种成像复杂性的具体原因。接着，本节展示了如何构建针对该狭窄空间的高精度圆环靶标数据集，包括该数据集的构建方法及其具体规模。

3.2.1 狭小空间介绍

在实际应用环境中，通过操作机械臂使末端执行器伸入人体口腔内部并完成相关任务，本课题主要负责对末端执行器伸入后依靠医用单目内窥镜构建可靠的成像系统，对末端执行器的运动以及位置进行显示、检测以及定位工作，本文主要完成的工作为通过内窥镜成像，对末端执行器的运动进行检测定位。

实际实验环境主要为口腔咽喉内部空间，但其内部结构极其复杂，如图 3.2 所示为人体口腔咽喉内部的结构图，具体为口腔内部包含舌头、牙龈、牙齿等结构，而咽喉部进一步延伸更为精密复杂的区域，各部位之间相互连接形成了多个生理通道和功能性空间。鉴于在末端执行器进入口腔或咽喉时，由于解剖结构和生理功能的复杂性，可能引起患者的恶心、呕吐反应或不适感，尤其是对于敏感的喉部，可能导致肌肉紧张，医生在使用内窥镜进行临床操作时面临较大挑战，需要精确掌握技术并适应




图 3.2 口腔咽喉模型

不断变化的生理条件，对医生以及患者都具有极高的要求。


在此挑战下，搭建仿真模型模拟真实口腔咽喉环境就显得尤为重要，因此分别使用如下图 3.3 中所示模型极大仿真模拟人体口腔咽喉这一狭小空间。其中图 3.3 (a) 为 3D 打印的狗头模型，严格按照 1:1 比例还原狗头口腔咽喉内部结构环境及光照条件，为末端执行器在其中运动创造运行空间，为后续目标检测算法提供仿真实验环境；图 3.3 (b) 为成人口腔咽喉模具，同采用 1:1 比例全真还原成人口腔咽喉环境；图 3.3 (c) 则是按照 1:5 等比放大的人体口腔咽喉结构仿真模型，通过五倍放大还原人体口腔咽喉内部基本结构，为后续实验提供环境。



(a) 狗头模型



(b) 人体口腔咽喉模具



(c) 人体口腔咽喉结构仿真模型

图 3.3 狭小空间仿真模型搭建

3.2.2 狭小空间内环境多样性分析

通过前面观察人体口腔模型、狗头口腔咽喉模型能够发现，由于口腔咽喉这一狭小空间具有极大的特殊性，在该空间内部采集图像就难度极高，具体来说有以下几点困难：(1) 内部空间狭窄。人体或狗头口腔咽喉内部空间非常狭窄，末端执行器伸入后的运动受限且易受到内部组织的遮挡，难以对目标检测；(2) 组织纹理特征匮乏。实际口腔咽喉内部组织表面纹理特征不易检测，提取特征难度极大，并且组织臂表面黏附大量组织液体，如图 3.4 这些因素都会严重影响基于视觉输入的检测算法的运行效果；(3) 末端执行器与采集图像设备距离极近。由于口腔内部这一狭小空间限制，负责采集图像的内窥镜与末端执行器之间距离极近，实验观察得出两者距离主要分布在 $1\text{cm} - 10\text{cm}$ 之间，因此极易出现内窥镜失焦、图像模糊等不利情况，影响目标物体的检测。




图 3.4 内窥镜对口腔咽喉采集图像示例

其次在这一特殊狭小空间内使用内窥镜拍照成像时，受限的环境对成像图片有显著影响。首先，由于视角和透视原理，在采用内窥镜镜头时易出现明显的透视变形，使得空间感扭曲，还容易产生畸变现象进而影响空间真实性；其次，狭小空间内光线条件复杂，常伴随着光照不均、阴影过多及反光等问题，给曝光控制带来挑战；此外，受限的距离可能导致内窥镜需要求得较大景深，来获得清晰待提取目标特征，但这也可能牺牲画面的清晰度。另外，拥挤的目标元素和移动、设备使用的不便也是狭小空间内采集图片需要克服的问题。

对在狭小空间内采集到的图像进行分析，发现造成成像图片质量低的原因主要有以下几个：（1）光照条件对图像影响。首先，光源的布置方式和强度分配直接决定了图像的亮度和曝光等级。在如此狭小的空间里，过强或过弱的光照均可能带来负面影响。过强的光照可能导致高光溢出，细节丧失，过弱的光照则会使图像整体偏暗，细节隐藏；其次，狭小空间内的阴影和反光管理尤为重要。由于空间结构紧凑，物体间的遮挡和镜面反射容易造成图像的局部过暗或过亮，甚至出现眩光现象，影响对末端执行器的观察。如下图 3.5 所示分别展示了不同光照补充条件下的检测目标和仿真模型成像图片，证实了选择合适的补充光源对于采集图像的重要性。




图 3.5 不同光照对成像影响对比

（2）抖动影响成像质量。由于空间的局限性以及被摄物体与镜头间的近距离接触，任何微小的震动或不稳定性都可能带来显著的负面效应，而该抖动对成像质量的

影响不容忽视。首先，抖动会导致图像的清晰度大幅降低，无论是设备自身的颤动还是光源晃动等，都有可能产生运动模糊，使得原本细腻的目标变得模糊不清，极大地影响了图像的解析度和细节表达。其次，抖动在一定程度上会提高图像噪声，降低信噪比，特别是在需要长时间曝光或对微弱目标敏感的成像条件下，细微的目标特征可能淹没在噪声中，为后续分析和解读图像中目标信息增加难度。另外，内窥镜设备在狭小空间内的抖动还可能加重几何畸变，尤其是在执行扫描或旋转拍摄时，图像的方位和空间比例关系可能出现失真，降低了目标检测的准确性。如图 3.6展示了当由于设备自身颤动导致抖动现象发生，进而影响成像质量。




图 3.6 抖动对成像影响对比

(3) 焦距选择的影响。在操作中焦距的选择对图像质量与表现力同样具有深远的影响。首先，焦距产生不同的视野覆盖与透视效果，不同焦距镜头决定了拍摄的视角范围，短焦距镜头能够提供更宽广的视野，利于展现口腔咽喉的整体构造，显示出目标在整体空间内的具体位置，但可能带来较大的透视变形。相反，长焦距镜头虽视野受限，却能更精确地聚焦于特定圆环靶标，减少透视畸变，突显微小结构，如图 3.7分别显示了不同焦距下的模型成像。




图 3.7 不同焦距下模型成像对比

除上述光照、抖动、焦距等因素导致狭小空间内采集到的数据图像具有极大的多样性外，内部组织对于目标的遮挡和在不合适光源下图像中产生阴影进而导致图像

完整性受损、空间定位不准，也提高了狭小空间内数据图像的多样性。

3.2.3 狭小空间内高精度圆环靶标数据集构建

在本研究中，为了在特定的狭小空间内实施目标检测算法，并对算法性能进行准确评估，由于现有公开数据集无法满足实际的需求，因此自主构建了一个针对狭小空间内的高精度圆环靶标数据集。

(1) 数据集收集设备：基于本节上部分对狭小空间介绍及该空间内环境多样性的分析，可以看出在该环境内对成像设备、特征来源均具有极高的要求，所以该数据集内图像采集均使用定制专用设备完成。




图 3.8 数据集收集设备图（内窥镜、末端执行器、自行设计圆环靶标）

将上文中介绍过的 3D 打印狗头模型作为主采集场景；相机使用定制 1080P 医用单目高清内窥镜，如图 3.8 (a) 所示，采集频率为 30fps，具备体积小、成像高清等特点，便于在狭小口腔咽喉空间内采集图像；末端执行器使用医用级显微喉钳，图 3.8 (b) 所示，使用游标卡尺测量其钳口宽度仅为 6mm，极大程度模拟口腔咽喉实际手术场景；圆环靶标使用 3D 打印技术定制而成，如下图 3.8 (c) 所示，为了贴合末端执行器尺寸，自行设计并定制圆环靶标整体尺寸为 37.5mm^2 ，长 7.5mm，宽 5mm，整体尺寸极小，用肉眼难以识别，同时该靶标的主体材质和表面均添加了特殊涂料，使得靶标在极近视距情况下仍不会产生局部反光，导致特征点丢失等不利情况发生。

(2) 数据集收集方法：为了模拟手术机器人末端执行器在口腔咽喉空间内的运动，本文将自行设计定制圆环靶标与末端执行器集成，采用如图 3.9 所示方法将圆环靶标附着于医用喉钳最头部。在末端执行器动态运动过程中，使用内窥镜成像设备软件收集一系列包含圆环靶标的图片，将这些图片收集于数据集内，如图 3.10 所示。

(3) 数据集的结构：经过初步筛选和预处理后，狭小空间内高精度椭圆标注数据集内共收集 2257 张图片，图片均为彩色 JPG 格式，每张图片分辨率均为 1920×1080 规格，数据集内图片包含不同光照条件（如无补充光源、50% 补充光源、100% 补充光源等）、靶标部分遮挡情况等，通过在末端执行器运动过程中采集图像，充分完善




图 3.9 末端执行器与圆环靶标集成示意图




图 3.10 图像采集场景及采集软件使用示意图

数据集的普适性，最大程度模拟在真实口腔咽喉空间内手术时不同场景。




图 3.11 VIA 标注软件标注使用示例

(4) 数据集标注：为了检验算法效果便于对实验结果进行评价，本文对狭小空间内高精度圆环靶标数据集内 2257 张图像均经过人工精确标注。在标注过程中使用 VGG Image Annotator (VIA)^[47]开源标注软件进行标注，首先使用矩形框标出圆环靶

标所在区域,再使用椭圆标注出圆环靶标椭圆边界轮廓,如图 3.11所示,标注出的信息包含圆环靶标内外边界椭圆的中心坐标、半长短轴长度以及椭圆的旋转参数等具体参数信息,对每个图片的标注信息导出为 JSON 文件格式,方便后续使用。

3.3 基于弧线结构的椭圆检测算法

针对狭小空间内设计的圆环靶标,我们需要检测出在医用内窥镜成像下每张图像内包含的圆环靶标边界,然而圆环靶标在内窥镜投影变换过程中,其原本圆形边界会呈现为椭圆边界,因此针对圆环靶标的检测问题转变为对图像中圆环靶标椭圆边界的检测问题,基于此,本节提出了一种基于弧线结构的椭圆检测算法来获取图像中靶标椭圆边界信息,进而得到圆环靶标在图像中的信息。

该算法整体流程如图 3.12所示,首先对图像进行 Canny 边缘检测,通过计算梯度来揭示图像内丰富的边缘细节,将满足连续性和凸性条件的边缘连接为弧线段,不满足条件的直线滤波剔除,接下来将通过角度偏差及跨角限制筛选,将符合条件的弧线段连接成弧线段组。




图 3.12 基于弧线结构的椭圆检测算法示意图

接着,使用局部与全局搜索并行策略,将满足极性约束、区域限制的弧线段组认定为有效弧线段组对,通过判断有效弧线段组内内点数量进行椭圆拟合,生成初始椭圆集。其次,考虑到初始椭圆集中含有大量重复点,使用对椭圆参数分层聚类的方法进一步筛选初始椭圆集中的重复点,生成更纯净的候选椭圆集。最后,在椭圆检测流程的最终阶段,设计并实施一套严格且有效的验证机制,通过参数验证与二次拟合椭圆生成检测椭圆。

3.3.1 弧线段组的形成

(1) 稳健连接弧线段形成组:由于椭圆曲线可能由多个弧线段组成,因此可以将这些发现的弧线段连接成一组。但需要注意的是连接任何两个连续的弧线段时需满

足连续性和凸性条件：对于连续性条件，一个弧线段的头部与另一个弧线段的尾部之间的距离应足够近；对于凸性条件，连接的弧线段应该保持不论是顺时针还是逆时针都是同一方向的变化。需要注意的是，弧线段的水平线角度与该弧线区域的角度之间的偏差应控制在公差 α 之内，因此两个连续的弧线段之间的角度偏差应小于 2α 。为了避免在噪声存在时错误连接弧线段，还计算每一个下一个弧线段在当前弧线段（第 k 个线段的支持点数量表示为 $\sum p_i^{L_k}$ ）的末端附近局部统计区域内的支持点数量，并创建直方图以选择最大票数的线段与当前线段连接，如图 3.13 所示。表 3.1 详细描述了弧线段的连接和弧线段组形成的算法过程。




图 3.13 形成弧线段组示意图

(2) 对每个弧线段组的跨角测量：每个由若干弧线段组成的组本质上是曲线的多边形近似。如果第 i 个组包含 n 个弧线段，则它将有 $n-1$ 个由每两个连续的弧线段派生出的角度间隔。假设第 i 个组的角度间隔序列为 $\{\theta_1^i, \theta_2^i, \dots, \theta_{n-1}^i\}$ ，则第 i 个组的跨越角度为 $\sum_{j=1}^{n-1} \theta_j^i$ 。如果一个弧线段组对椭圆更加显著，其跨越角度将会更大。因此，我们有 $S^i \propto \left(\sum_{j=1}^{n-1} \theta_j^i\right) / 360^\circ$ ，其中 S^i 是第 i 组的显著性得分。为了便于计算，将比例系数设为 1，因此 S^i 的范围是 $[0, 1]$ 。

弧线段组形成过程主要是通过对图中直线线段进行滤波，只保留弧线段，通过稳健的弧线段连接过程，将属于同一曲线的线段合并为一个弧线段组。

3.3.2 初始椭圆集生成

考虑到一个弧线段组可能包含一条曲线的所有弧线段或仅包含一个单独的弧线段，因此，本文采用两种互补的方法来生成初始椭圆集。首先，从局部视角看，具有相对较高显著性得分的弧线段组很可能是椭圆多边形近似的主要成分，一种简单有效的方式是完全依赖于阈值 T_{ss} 。单独拟合弧线段组至椭圆，从而优先挑选出显著的椭圆，例如跨越角度接近 360° 的椭圆。其次，从全局视角看，全局搜索所有有效的弧线段组来重建图像上的潜在椭圆，其中一个优势是能够处理共同椭圆的弧线段组相距遥远的棘手情况。因此所有有效的弧线段组都应满足以下三个标准：(1) 极性约束；(2) 区域限制；(3) 自适应内点准则。此外，为了避免繁琐的拟合过程，椭圆拟

表 3.1 形成弧线段组伪代码

输入:	弧线段集 T_l 、生成线段的弧支撑区域 T_r 、角度公差 α ; 线段使用状态 S ;
输出:	弧线段组 G ;
流程:	1. 初始化 $G = \emptyset$; 2. 重复: (1) 从 T_l 选取一个满足 $S(l_i) \neq used$ 的弧线段 l_i; (2) 从 l_i 的头部和尾部搜索满足 $g_{head} = \emptyset$ 和 $g_{tail} = \emptyset$ 条件的弧线段组; (3) 将 l_i 设为 l_s 的候选; (4) 重复: - 在 l_s 头部搜索连续弧线段; - 排除 l_s 中搜索到是 $used$ 状态和超过 2α 角度公差的线段; - 确定 l_s 头部统计面积; - 通过 T_r 获取最高投票数的线段 l_k; - 通过 $g_{head} = g_{head} \cup L_k, S(l_k) = used, l_s = l_k$ 更新; (5) 直到 $l_s = \emptyset$; (6) 再次将 l_i 设为 l_s 的候选; (7) 重复上述搜索 l_s 尾部获得 g_{tail}; (8) 将搜索到的弧支持组 $g_{head} = \{L_{h1}, \dots, L_{hn}\}$ 和 $g_{tail} = \{L_{t1}, \dots, L_{tn}\}$ 合并为 $g = \{L_{tn}, \dots, L_{t1}, L_i, L_{h1}, \dots, L_{hn}\}$; (9) 通过 $G = G \cup g$ 更新; (10) 通过 $S(l_i) = used$ 更新; 3. 直到 遍历所有弧线段; 4. 返回 G;

合时采用了第二章相关技术中介绍的椭圆拟合叠加原则，以提高时间效率。

(1) 极性约束。在观察椭圆边缘周围的图像区域时，椭圆的内部总是比外围要亮或暗，其中亮表示弧线段的极性为正，暗则表示极性为负。如果所有弧线段均来源于同一椭圆，一般而言，它们的极性也应该相同。因此，第一个标准是配对的弧线段组的极性应该一致。在某些情况下，可能只需要检测比背景亮（或暗）的椭圆形物体。根据我们的方法，可以轻松识别具有特定极性的椭圆，对于源自共同椭圆但具有不同极性的弧支持组，例如椭圆与不同背景相接，通过寻找具有相同极性的最显著的弧线段组对进行椭圆拟合，也能成功检测到。

(2) 区域限制。实际上，大多数弧线段组并不会构成有效的弧线段对，因为两个组很可能来源于不同的椭圆或曲线，因此，在进行椭圆拟合前对弧线段组也应进行

一定限制。如图 3.14 所示，弧线段组 $\{g_1, g_3\}$ 和组 $\{g_1, g_4\}$ 不应构成有效的弧线段对，原因在于弧线段组 g_3 位于 g_1 的有效区域之外，这个有效区域是沿着 g_1 中每个弧线段的方向，虽然 g_4 位于 g_1 的有效区域内，但 g_1 并不在 g_4 的有效区域内。因此，如果两个组进行配对，它们应该位于彼此的有效区域内。在图 3.14 中，组 g_i 的起点记为 $P_s^{g_i}$ ，终点记为 $P_e^{g_i}$ ；起始弧线段为 $L_s^{g_i}$ ，终止弧线段为 $L_e^{g_i}$ ； $P_s^{g_i}$ 和 $P_e^{g_i}$ 的中点是 M_i ，然后，我们得到等式 3-1，其中 $\overrightarrow{ARC_L}$ 是 L 的归一化弧线段方向向量， $Dir_{\perp}(\vec{v})$ 表示顺时针旋转 $\vec{v}$ 90° 后得到的归一化向量。当配对组 $\{g_1, g_2\}$ 极性为正时， $Pol = +1$ ，否则为 -1 。 ρ_d 为距离阈值。同时， (i, j) 取值为 $(1, 2)$ 和 $(2, 1)$ 。

$$\begin{cases} \overrightarrow{ARC_{L_s^{g_i}}} \cdot \overrightarrow{P_s^{g_i} P_e^{g_j}} > \rho_d \\ \overrightarrow{ARC_{L_e^{g_i}}} \cdot \overrightarrow{P_e^{g_i} P_s^{g_j}} > \rho_d \\ (-Pol) \cdot Dir_{\perp}(\overrightarrow{P_s^{g_i} P_e^{g_i}}) \cdot \overrightarrow{M_i M_j} > \rho_d \end{cases} \quad (3-1)$$




图 3.14 对两个弧线段组的区域限制

(3) 自适应内点标准。对于通过极性约束和区域限制的弧线段对 $\{g_1, g_2\}$ ，将立即对该对中弧线段的端点进行椭圆拟合。假设拟合得到的椭圆为 $\mathbf{e}$ ，边缘点 P 到 $\mathbf{e}$ 的法向量为 $\nabla e(P)$ （其方向指向椭圆外部），我们将边缘点 P_i 定义为 $\mathbf{e}$ 的支持内点，如果满足距离容差 ϵ 和法线容差 α ，即 P_i 到 $\mathbf{e}$ 的 Rosin 近似距离^[48]小于 ϵ ，并且 $\nabla e(P)$ 与 $-Pol_e \cdot \text{Grad}(P_i)$ 之间的绝对角度差小于 α ，其中 Pol_e 是 $\mathbf{e}$ 的极性， $\text{Grad}(P_i)$ 是 P_i 的图像梯度。从几何角度看，我们可以通过边缘像素的数量来近似弧长。因此，弧线段对 $\{g_1, g_2\}$ 中每个弧线段组的支持内点数量应大于对应弧线段的长度，如公式 3-2 所示：

$$\# \{p_i : p_i \in \text{SI}(L_j)\} > \text{Length}(L_j) \quad (3-2)$$

其中 $\text{SI}(L_j)$ 表示弧线段 L_j 的支持内点集， $j = 1, 2, \dots, N_{g_1} + N_{g_2}$ ， N_{g_1} 与 N_{g_2}

分别是 g_1 和 g_2 中弧线段的数量。在这一步骤中，线段的长度是对应支持内点的自适应阈值。如果椭圆 e 满足自适应内点阈值，我们将对支持内点进行拟合以生成初始椭圆。最终，所有有效的弧线段对都转换为初始椭圆集。

3.3.3 椭圆聚类

考虑到初始椭圆集合中存在重复点，一种高效的聚类方法对削减重复点极为重要，它不仅保留孤立点，还要抑制非最大值。为此，本文在基于均值漂移的分层聚类方法^[49]上改进，将 5D 椭圆参数空间聚类问题分解为三个低维度和级联维度空间聚类问题（中心、方向和半轴）。

设初始椭圆集为 E^{init} ，其元素数量为 N^{init} 。我们有 $E^{\text{init}} = \bigcup_{1 \leq i \leq N^{\text{init}}} e_i$ ，其中 $e_i = \{(x, y)_i, \varphi_i, (a, b)_i\}$ ，其中 $(x, y)_i$ 、 φ_i 、 $(a, b)_i$ 分别为初始椭圆 e_i 的中心、方向和半轴。

首先，我们的方法基于均值漂移对 E^{init} 的椭圆中心进行聚类，迭代次数有限，然后产生 n^c 个椭圆聚类中心 $(x, y)_1^c, (x, y)_2^c, \dots, (x, y)_{n^c}^c$ ，如果 e_i 最接近 $(x, y)_k^c$ ，将把 e_i 加入集合 Ω_k 。因此， E^{init} 可以分为 n^c 个分区。第 k 个 ($1 \leq k \leq n^c$) 分区表示为等式 3-3。

$$\Omega_k = \{e_i \mid (x, y)_i \in e_i \text{ and } (x, y)_i \rightarrow (x, y)_k^c\} \quad (3-3)$$

其中 $(x, y)_i \rightarrow (x, y)_k^c$ 表示数据点 $(x, y)_i$ 与聚类中心 $(x, y)_k^c$ 之间的欧氏距离在所有聚类中心中最小。

其次，对每个初始椭圆子集 Ω_k 的方向进行聚类。这样就产生了 n_k^{φ} 个方向聚类中心，分别是 $\varphi_1^c, \varphi_2^c, \dots, \varphi_{n_k^{\varphi}}^c$ 。以类似的方式， Ω_k 也可以分成 n_k^{φ} 个子集，对应于方向聚类中心 φ_s^c 的第 s 个 ($1 \leq s \leq n_k^{\varphi}$) 子集 $\Omega_{k,s}$ 定义为等式 3-4。

$$\Omega_{k,s} = \{e_i \mid e_i \in \Omega_k, \varphi_i \in e_i \text{ and } \varphi_i \rightarrow \varphi_s^c\} \quad (3-4)$$

最终，我们对每个初始椭圆子集 $\Omega_{k,s}$ 实现基于半轴的聚类步骤，因此产生 $n_{k,s}^{\text{axes}}$ 个聚类中心： $(a, b)_1^c, (a, b)_2^c, \dots, (a, b)_{n_{k,s}^{\text{axes}}}^c$ 。最后，组合 $\{(x, y)_k^c, \varphi_s^c, (a, b)_t^c\} (1 \leq t \leq n_{k,s}^{\text{axes}})$ 是初始椭圆聚类的结果，即候选椭圆。因此候选椭圆集合 E^c 和候选椭圆个数可以表示为等式 3-5。

$$E^c = \bigcup_{k,s,t} \{(x, y)_k^c, \varphi_s^c, (a, b)_t^c\} N^c = \sum_k \sum_s n_{k,s}^{\text{axes}} \quad (3-5)$$

通过将分层聚类方法应用于初始椭圆集合，可以生成更纯净的椭圆候选集合。这

种椭圆参数空间分解的好处有两个方面。首先区分了椭圆中心、方向和半轴对于分层聚类的不同几何意义，因为直接赋予两个椭圆之间一个准确的距离度量是困难的。其次，本聚类方法易于实现，且其计算复杂度为二次方，这远比直接在 5D 空间中进行聚类行为表现得更优。

3.3.4 椭圆候选验证

根据上述步骤所学习的候选椭圆几乎涵盖了图像中所有可能存在的椭圆，同时几乎不包含重复项，这大大节省了验证时间，且由于其数量少和显著性高而保证了良好的召回率。在本节中，为了进一步确保检测椭圆的质量，进行了椭圆候选验证，整合了严格的 *Goodness* 指标和结合了椭圆几何属性的约束对候选椭圆验证并再次验证。

(1) Goodness 指标。一般而言，椭圆上的支持内点的数量与其对应周长 $\mathcal{B}$ 呈正相关关系。虽然 $\mathcal{B}$ 的精确计算公式尚未明确，但在实际应用场景下中，用 a 和 b 分别表示椭圆半长轴和半短轴，使用公式 $\mathcal{B} \approx \pi \left[\frac{3}{2}(a+b) - \sqrt{ab} \right]$ 近似计算^[50]。此外，支持内点值的椭圆连通分量的角覆盖范围 $\mathcal{C}$ 越大，椭圆候选就会显得更加显著。基于这些事实，采用以下评估方式，同时考虑支持内点的数量和角覆盖范围：支持内点应满足距离容差 $\frac{\epsilon}{2}$ 和法线容差 α 。因此，“Goodness” 指标可以定义为等式 3-6：

$$\text{Goodness}(e) = \sqrt{\frac{\#\{p_i : p_i \in \text{SI}(e)\}}{\mathcal{B}} \cdot \frac{\mathcal{C}}{360^\circ}} \quad (3-6)$$

其中 $\text{SI}(e)$ 表示椭圆 e 的支持内点集合。但需要注意的是，为了排除噪声将距离容差 ϵ 收紧至 $\frac{\epsilon}{2}$ ，从而使“Goodness” 指标更加可信。最后，按照优良度得分对椭圆候选进行伪降序排列（在线性时间内完成），优先选择候选项进行后续验证。但需要注意的是，可以将距离容差 ϵ 收紧到 $\frac{\epsilon}{2}$ ，以排除噪声，因此 *Goodness* 测量结果更可信。最终，依据椭圆的优度评分，对候选椭圆进行伪降序排序（该过程可在线性时间内完成），以此优先选择候选椭圆进行进一步的验证工作。

(2) 验证及再次拟合。在验证阶段，所提出的方法将距离容差从 ϵ 收紧到 $\frac{\epsilon}{2}$ ，并针对以下两个方面单独验证候选椭圆：（1）支持内点的数量；（2）椭圆的角覆盖范围。具体采用比例阈值 T_r ，并期望椭圆上有 $T_r \mathcal{B}$ 个支持内点，同时，仅接受角覆盖范围至少为 T_{ac} 度的椭圆。

如果有足够的支持内点，就可以得到更好的椭圆结果，回顾验证步骤中已经找到了每个候选项相应的支持内点，如果一个候选生成了真实椭圆（简称 TP），其支持内点应比之前的更充分，这促使了再次进行椭圆拟合，因此能够提高整体准确性并显示出自我校准的能力。尤其值得注意的是，额外拟合的时间复杂度仅与最终检测到的椭圆数量相关，这不会在运行时间上带来显著变化。

在本节中通过引入弧线段提出了一种高质量的椭圆检测方法。整个过程包括: (1) 弧线段组形成, (2) 初始椭圆集的生成, (3) 椭圆聚类, (4) 候选验证。弧线段组收集了属于同一曲线的连续弧线段, 可以避免无用的直线线段的干扰。在初始椭圆集生成步骤中, 借助于快速的椭圆拟合和有效的几何约束, 精度和效率保持同步。高效的聚类和严格的验证拟合进一步保证了该算法的高检测性能。

3.4 实验设计及结果分析

本节将深入探讨所提出的基于弧线结构的椭圆检测方法对于本文所提出的狭小空间圆环靶标检测的实验设计及其结果分析。首先将介绍实验的具体设置, 包括所提出算法的参数介绍、评价指标、选用同类型椭圆检测比较方法以及数据集的选择。接着将对实验结果可视化, 通过详细的图表和数据分析对各项指标进行评估, 以及与现有椭圆检测方法的比较。然后将分析算法的定位精度与效率, 通过对检测时间与图像尺寸之间的关系进行探讨, 旨在评估方法在实际应用中的可行性与效率。本节旨在通过全面的实验验证和分析, 证明所提出的椭圆检测方法在准确性、效率方面的优越性。

3.4.1 实验设置

(1) 模型参数: 本文的模型参数主要涉及如下七个参数: 1) 角容差 α 用于评价几何基元 (如点的水平线角或梯度角) 与相应参考角的角度偏差。 α 可以根据经验设置为 22.5° , 这对数千张图像产生最佳效果^[15]; 2) 在初始椭圆集生成中使用显著性评分阈值 T_{ss} 。需要找到生成初始椭圆的所有有效的弧支持组对, 可以根据实际需求调整该参数; 3) 区域约束采用距离阈值 ρ_d , 在处理某些极端情况时, 可以取负值, 因此 ρ_d 固定为 -3ϵ ; 4) 距离公差 ϵ 用于将内点恢复为圆弧支撑的 LS 或椭圆。如果 ϵ 的限制更严格, 即使存在虚假边缘或噪声, 内点也会更纯净, 我们将 ϵ 设置为 2 像素; 5) T_r 为椭圆上支持内点的比值和 6) T_{ac} 为椭圆角覆盖阈值, 由于他们都用于椭圆验证, 根据它们的几何意义, 大多数真实的椭圆在现实世界的图像有一定程度的完整性, T_r 和 T_{ac} 很容易调整, 因此同样可以根据具体的数据集以及使用场景设置 T_r 和 T_{ac} 。

(2) 模型评估指标: 本文采用精确率、召回率和 F 值指标对模型评估, 每种指标具体计算方法如下式所示, 其中 TP 表示正确预测的正样本, 在本文的算法中, 如果检测到的椭圆与相应标注椭圆的重叠面积比大于 D_0 , 则视为 TP, 后续实验若不专门强调 D_0 则设其为 0.8, FP 表示错误预测为正样本 (实际为负样本), FN 表示错误预测为负样本 (实际为正样本)。因此精确率是指在所有被模型预测为正类的样本中, 实际为正类的样本比例; 召回率是指在所有实际为正类的样本中, 被模型正确预测为正类的样本比例; F 值是准确率和召回率的调和平均数, 用于综合反映模型的性能。

$$\text{Precision} = \frac{TP_s}{TP_s + FP_s} \quad (3-7)$$

$$\text{Recall} = \frac{TP_s}{TP_s + FN_s} \quad (3-8)$$

$$\text{F-measure} = \frac{2}{(\text{precision}^{-1} + \text{recall}^{-1})} \quad (3-9)$$

(3) 比较方法：本文选择了五种最流行和最具竞争力的算法进行定量和定性比较，这几种方法已经在本文第一章中关于椭圆检测的国内外研究现状被说明，分别是 RHT^[4]、ELSDc^[14]、Prasad 等^[11]、Fornaciari 等^[12]和 Qi 等^[13]提出的方法。为了公平比较，所有实验均在 Intel 酷睿 i7-7500U、2.7GHz CPU 和 8GB 内存的同一台计算机上使用默认参数进行。

(4) 数据集选择：为了测试椭圆检测算法的适用性，实验主要使用了本文自主构建并进行精确标注的狭小空间高精度圆环靶标进行算法性能的验证，为方便后续使用，将其命名为 TY 数据集。同样为了验证该椭圆检测算法的性能，还使用了与本文数据集具有不同方面相似性的三个公开的现实世界数据集：Prasad 数据集是一个复杂的真实世界图像数据集，被多个椭圆算法使用^[11-14]，该数据集内图像中包含了大量难以预测的条件和干扰，使得其特征极为复杂，可以充分模拟狭小空间内口腔咽喉环境的复杂性。作为 Fornaciari 等人创建的交通标志数据集^[12]，展示了在多种现实场景中拍摄的圆形交通标志的椭圆投影，均源自于智能手机拍摄视频的帧截取，由于运动和自动对焦功能，它们受到了模糊和不稳定光照条件的影响，选择此数据集旨在最大限度地模拟在狭窄空间内，由末端执行器携带目标在运动过程中采集图像的场景，为了方便后续的研究和引用，该数据集被命名为 TSE 数据集。PCB (Printed Circuit Board) 数据集^[51]是由 Lu 等人创建的印刷电路板图像，所有的 PCB 图像都经过了人工的精确标注，选用此数据集是由于该数据集内图像大部分含有同心圆环特征，与本文所设计的圆环靶标相似性高，可以更好验证算法性能。

3.4.2 实验结果可视化及指标评估

本研究选用多种椭圆检测算法共同对选用四个数据集进行了深入的比较实验，实验中不仅运用了现有的几种经典椭圆检测技术，还包括了本文提出的新方法，旨在全面对比本文基于弧线结构的椭圆检测算法在实际应用场景中的效果和局限性。

(1) 实验结果可视化

实验过程中对每个数据集中图片均进行了检测，随后，为了直观展示各算法的检测性能，将部分典型图片的椭圆边界检测结果进行了可视化处理，清晰地展示了每种算法在边界识别准确度、检测完整性以及对复杂背景的适应能力方面的表现。




图 3.15 Prasad 数据集实验结果可视化




图 3.16 TSE 数据集实验结果可视化

通过对比实验和结果可视化的方法，本文详尽地分析了每种算法在不同类型的数据集上的表现。图 3.15 来自 Prasad 数据集，该数据集内包含多场景图片，由于噪声、遮挡、轮廓模糊和各种背景，该数据集在四个真实世界数据集中具有最复杂的特征；该图 3.16 中图像来自 TSE 数据集，其中存在光照、偏心率变化等多种情况，尤其是交通标志中半椭圆轮廓多，更加考验算法对于椭圆曲线的检测的能力；来自 PCB 数据集的三张示例图像检测结果如图 3.17 所示，该数据集内图像由工业相机拍摄，具有大量高斯白噪声和模糊，椭圆检测算法具有极高的难度实现准确、高效地检测出此类图像中的椭圆边界；自行收集并在 TY 数据集内实验结果同样如图 3.18 所




图 3.17 PCB 数据集实验结果可视化




图 3.18 TY 数据集实验结果（局部区域放大）可视化

示, 该 TY 数据集内图片均存在目标椭圆在图像中成像占比小, 存在较多抖动、模糊、失焦、部分遮挡等不利于检测的情况, 尤其考验算法对于椭圆边界目标的检测能力。值得注意的是, 为了更好展示椭圆检测实验结果, 图 3.18 所示内 TY 数据集内图片均只展示了椭圆边界附近区域放大成像, 实验过程中输入图像展示范围更广、椭圆目标更加微小。

观察不同椭圆检测算法对数据集内椭圆检测效果, 本文发现 RHT 倾向于检测每一个可能的椭圆, 但同时会产生许多假阳性椭圆, 而当在噪声和纹理较多的图像中, 其检测性能较差, 不能精准检测出目标边界。尽管 Fornaciari 等人和 Qi 等人提出的椭

圆检测器非常高效，但这两种方法都报告了许多椭圆重复，因此导致定位精度较差。相反，Prasad 方法和 ELSDc 可以相对地更精准定位椭圆，但这两个算法所带来的相关问题却是对真实椭圆边界的大量检测缺失，也会将图像中小轮廓特征建模为椭圆边界，导致该算法整体的椭圆检测性能恶化。值得对比的是，本节所提出的基于弧线结构的方法能够清楚的定位出图像中椭圆边界的特征，依靠其严格的算法流程能够有效过滤掉图像中的重复椭圆，针对狭小空间内圆环靶标成像占比少、存在抖动、失焦等现象，该算法能够检测出圆环靶标的内外圆边界。

(2) 评价指标对比

实验结果的评价不仅依靠实验结果可视化，还通过精确率、召回率、F 值指标以及运行时间等指标对算法性能进行综合评估。在 Prasad 数据集、TSE 数据集、PCB 数据集以及 TY 数据集上进行实验后，详细椭圆检测结果如下表所示，精确率、召回率、F 值和运行时间的最高分以黑体字强调。

表 3.2 不同椭圆检测算法精确率结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构
Prasad 数据集	Precision	0.0932	0.7049	0.1951	0.2370	0.7161	0.7533
TSE 数据集	Precision	0.0425	0.4508	0.0752	0.1412	0.5824	0.9008
PCB 数据集	Precision	0.4178	0.8943	0.4175	0.7655	0.9383	0.9705
TY 数据集	Precision	0.1543	0.2568	0.1042	0.3652	0.5878	0.6084

表 3.3 不同椭圆检测算法召回率结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构
Prasad 数据集	Recall	0.2950	0.2164	0.2489	0.3155	0.2393	0.3514
TSE 数据集	Recall	0.6943	0.7287	0.5159	0.5675	0.7334	0.8821
PCB 数据集	Recall	0.9254	0.8692	0.9510	0.7125	0.8933	0.9192
TY 数据集	Recall	0.1754	0.2054	0.1053	0.3248	0.5273	0.5674

表 3.4 不同椭圆检测算法 F 值结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构
Prasad 数据集	F 值	0.1416	0.3311	0.2180	0.2706	0.3587	0.4792
TSE 数据集	F 值	0.0800	0.5570	0.1313	0.2262	0.6492	0.8914
PCB 数据集	F 值	0.5757	0.8816	0.5803	0.7380	0.9152	0.9442
TY 数据集	F 值	0.1641	0.2282	0.1047	0.3438	0.5559	0.5871

通过上述算法评价指标对比，可以清楚看到，本章节的方法在 Prasad 数据集、TSE 数据集、PCB 和 TY 数据集上分别获得了 47.92%、89.14%、94.42%、58.71% 的最佳 F 值分数，突出了其出色的整体椭圆检测能力，综合展示了该算法对于椭圆形

表 3.5 不同椭圆检测算法运行时间结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构
Prasad 数据集	时间 (s)	1.4358	0.0949	0.2021	3.9021	0.0539	0.1695
TSE 数据集	时间 (s)	4.6016	0.2885	1.2885	0.9928	0.1498	0.5791
PCB 数据集	时间 (s)	3.4840	0.0990	0.2281	1.0768	0.0748	0.1693
TY 数据集	时间 (s)	1.4253	0.0995	0.2243	0.9521	0.0541	0.2785

状的敏锐度。

综合上述实验结果,结合多种算法原理分析可得,不同于其他快速的弧选择策略和简单的聚类策略算法, Qi 和 Fornaciari 等提出的方法优点突出,其算法的运行时间短,能在短时间内高效检测椭圆边界。随机迭代搜索有助于 RHT 提高召回率,但由于缺乏新颖的验证候选椭圆策略,其精度和 F-measure 得分令人不满意。ELSDc 尝试同时检测椭圆和线段,但同时也带来了椭圆检测性能受限、计算时间长等副作用。实际上,可以观察出 ELSDc 更适合处理 PCB 图像,因为它在 PCB 数据集集中的性能得到了极大的提升。与 ELSDc 类似, Prasad 方法由于检测程序较多,计算时间较长。

不同于其他椭圆检测算法在精度与效率之间难以找到平衡点的挑战,本研究提出的方法在大尺度场景下对 Prasad 数据集、TSE 数据集、PCB 数据集展现了高效且精确的椭圆检测能力,当针对本文所处小尺度口腔咽喉空间内,特别是在针对狭小空间内圆环靶标检测表现了优秀的性能,可以看到在 TY 数据集上其他椭圆检测方法中表现最好的是 Qi 的方法,但本章节方法与之相比,精确率提升约 2.1%,召回率提升约 4%,F 值提升约 3.1%,这表明本方法尤其在本文所构建的狭小空间内 TY 数据集上依旧展现了出色的检测效果。





3.4.3 参数设置与定量实验

基于弧线结构的椭圆检测算法中引入了不同的外部参数,来增强所提出椭圆检测算法的适应性和应用范围,因此本节将对这些参数进行一系列的定量分析。

(1) 椭圆重叠比阈值 D_0 变化对评价指标的影响

为了综合评价基于弧线结构的椭圆检测算法性能,并与其他椭圆检测方法比较,本文将算法中判断候选椭圆为真阳性的重叠比阈值 D_0 从 0.65 变化到 0.95,步长为 0.05, D_0 越高表示检测到的椭圆越严格被认为是真阳性,分别对四个数据集采用不同方法进行大量充分实验,结果如下图所示,图 3.19 分别展示了 Prasad 数据集上精确率、召回率、F 值伴随 D_0 变化相应变化情况,图 3.20、图 3.21、图 3.22 分别依次为 TSE 数据集、PCB 数据集、TY 数据集的相应变化情况。

观察结果更加验证了本文所使用的方法在四个真实数据集中实现了最佳的整体椭圆检测性能,F 值曲线均高于比较方法,表明该方法具有较高的椭圆检测性能。继

图 3.19 Prasad 数据集上 D_0 与评价指标的对比图 3.20 TSE 数据集上 D_0 与评价指标的对比图 3.21 PCB 数据集上 D_0 与评价指标的对比图 3.22 TY 数据集上 D_0 与评价指标的对比

续观察图中曲线走势，可以看到随着重叠比阈值 D_0 的增加，提高了图像中候选椭圆的检验标准，所以综合评价指标 F 值曲线成总体下降趋势，但观察本文所使用的方法在四个真实数据集中 F 值曲线均高于比较方法，均实现了最佳的整体椭圆检测性能，表明该方法具有较高的椭圆检测性能。

(2) T_r 和 T_{ac} 变化对评价指标的影响

在本研究中引入了两个关键外部参数 T_r 和 T_{ac} ，以增强所提出的椭圆检测方法

的适应性和应用范围。这两个参数均具有明显的几何意义,使得它们能够紧密贴合实际应用需求,并允许根据不同应用场景下的表现进行灵活调整。

为了评估参数 T_r 和 T_{ac} 针对狭小空间内圆环靶标检测的鲁棒性,本节专门对 TY 数据集进行了深入分析,这个数据集专为狭小空间内的圆环靶标检测而构建,通过一系列定量评估,旨在验证所提出的椭圆检测算法在此类狭小空间内的有效性。在实验中,首先固定 T_r 为 0.6,然后将 T_{ac} 从 105° 以 10° 的步长调整至 225° ,并观察精确率、召回率及 F 值的变化,如图 3.23 所示。此外同样也探索了 T_r 参数对算法检测效果的影响,将其从 0.4 递增至 0.8 (步长 0.05),同时固定 T_{ac} 为 225° ,以评估对椭圆检测性能的影响,相应结果展示于图 3.24 中。




图 3.23 TY 数据集内 T_{ac} 变化与评价指标的关系




图 3.24 TY 数据集内 T_r 变化与评价指标的关系

实验结果表明,随着 T_r 和 T_{ac} 参数的调整,召回率呈现下降趋势,这是因为随着检测标准的严格化,部分椭圆被剔除。相对地,精确率因检测标准的严格而得到提升。值得一提的是,无论是图 3.23 还是图 3.24 中, F 值曲线均展示出较为平滑的变化趋势,即使在参数调整的较大范围内,性能波动较小,这进一步印证了本方法对于参数设置的高度鲁棒性,显示了该基于弧线结构的椭圆检测算法在该狭小空间应用场景下的良好使用性,这些参数表现出了良好的鲁棒性,方法的性能仍然保持稳定。

3.4.4 定位精度与效率分析

(1) 定位精度

定位精度是评价椭圆边界检测算法质量的重要指标,为此计算了每种椭圆检测方法在四个真实数据集上正确检测到的椭圆的平均重叠比 (Mean Overlap Ratio, MOR),结果如表 3.6 所示。

本章节所探讨的方法,在 TSE 数据集、Prasad 数据集以及我们自主构建的 TY 数据集上均获得了最高的 MOR 分数,在 PCB 数据集上,该方法也取得了紧随 Prasad 方法之后的第二高 MOR 分数 (0.9564 对比 0.9593)。这一优异的 MOR 分数反映了我

表 3.6 椭圆平均重叠率 (MOR) 结果对比

MOR	Prasad 数据集	TSE 数据集	PCB 数据集	TY 数据集
ELSDc	0.8808	0.9219	0.9342	0.8088
Fornaciari	0.9070	0.9264	0.9432	0.8253
RHT	0.8953	0.9070	0.9449	0.8145
Prasad	0.9134	0.9216	0.9593	0.8044
Qi	0.9037	0.9229	0.9418	0.8255
弧线结构	0.9281	0.9373	0.9564	0.8569

们方法对高定位精度目标的追求,而不仅仅是满足于识别出真实的阳性椭圆。该方法在处理具有显著封闭性特征的椭圆时,与其他椭圆边界检测技术相比,展示了更加卓越的性能表现。

(2) 算法时间复杂度分析

为了全面评估所提椭圆检测方法的性能,算法的运行效率也被纳入了评价指标。本研究通过对四个数据集中不同尺寸的真实世界图像进行时间复杂度分析,来验证基于弧线结构的椭圆检测方法在图像尺寸为 N 且弧线段组数为 N_G 时的表现。所选图像尺寸范围从 46×51 到 4600×5100 ,覆盖了广泛的像素数量。通过图 3.25 中显示,本节所提出的基于弧线结构的椭圆检测算法发现像素数量与检测时间之间存在线性关系,即随着像素数的增加,椭圆检测时间也以线性趋势增长。这一结果表明,本方法的时间复杂度与图像尺寸 N 呈二次关系 (在大多数情况下 $N > N_G$)。




图 3.25 像素数量与检测时间相关性

尽管从理论上,该椭圆检测算法的时间复杂度高于线段和圆形检测器,但本

研究提出的方法在实际应用中展现出了较高的效率。即便面对真实世界的图像数据，在二次时间复杂度的条件下也能够有效处理，这一性能显著优于现有的大部分椭圆检测算法。这一发现不仅证明了所提方法的实用性，同时也为椭圆检测领域提供了一种高效且可靠的技术解决方案。

3.5 本章小结

本章通过引入对手术机器人的介绍，概述了本文的主要研究内容。接着深入探讨了这些狭小空间的特性及其环境的多样性，并为此特别设计了微型的定制圆环靶标。利用这些圆环靶标，本文成功构建了一个高精度的狭小空间圆环靶标数据集，并对数据集中图片所包含的圆环靶标内外边界均使用手工标注真实椭圆边界，以准确界定圆环靶标的内外椭圆边界，为后续椭圆检测算法性能评估提供充足的实验数据。

接着，本文提出了一种基于弧线结构的椭圆检测算法，该算法显著提升了对虚假目标的识别能力，并依靠严格的几何约束条件有效地生成了初始椭圆集合。通过采用新颖的验证标准和自我校正机制，为椭圆的精确检测提供了额外的支持。最终，通过一系列详尽的实验比较，充分证明了本方法在图像椭圆检测方面的有效性，进一步验证了其实用性及在椭圆检测领域的技术贡献。

第四章 基于 2-WD 损失改进的椭圆目标检测算法

本文在第三章中介绍了基于弧线结构的椭圆检测算法，并且在 Prasad 数据集和 PCB 数据集以及 TSE 数据集中取得了良好的效果，但是在本文自行构建的狭小空间内高精度圆环靶标 TY 数据集中其性能指标并未达到预期的理想状态。随着深度学习的发展，深度学习在鲁棒性、适用性等方面表现了良好效果，其中针对目标检测任务的 Faster R-CNN^[44]表现的尤为亮眼，但是作为一个适用性极广的目标检测网络，在椭圆检测方面性能却不尽如人意。主要原因是由于 Faster R-CNN 网络只提出边界框优化，而边界框优化是基于矩形边界框的，这类方法无法充分利用椭圆特性，导致检测准确性和定位精度受限。

因此本文对 Faster R-CNN 网络中的区域建议网络 (Region Proposal Networks, RPN) 进行了改进，RPN 主要通过多任务学习策略联合优化分类损失来确定锚框是否包含对象与多个回归损失实现调整锚框位置、尺寸以匹配真实边界框，但在处理椭圆的旋转角度、非对称长宽比等特征时面临挑战。因此在本章中创新性地将 Faster R-CNN 中的 RPN 与椭圆的二维高斯分布相融合，提出高斯建议网络 (Gaussian Proposal Networks, GPN) 针对椭圆形物体的检测进行优化。并且在 GPN^[16]的基础上引入 RoI 池和回归分支，同时，采用 2-Wasserstein 距离 (2-WD) 作为椭圆候选区域精细化的损失函数，以准确预测椭圆形物体的具体位置。

4.1 问题研究与意义

深度学习方法因其卓越的表征能力和端到端的学习机制，在解决目标检测类问题上展现出明显优势。尤其是在物体边界描述方面，相比于依赖于规则形状假设的传统方法，深度神经网络能够自适应地学习和表达复杂的边界信息。然而，现有 RPN 框架下的改进大多直接引入额外参数来预测边界椭圆的旋转角度^[52-53]，这不仅增加了模型的复杂度，同时这些方法均需要对椭圆的旋转角度进行额外的参数预测，然而在椭圆长轴和短轴长度相近（椭圆类似于圆）的特殊情况下会产生严重的过拟合问题，从而降低了整体定位性能。在图4.1中展示了 TY 数据集中椭圆靶标正常情况和椭圆长短轴长度相近的极限情况。

本研究以 Faster R-CNN 及其 RPN 为基础架构，在 RPN 的基础上通过高斯函数对椭圆形物体进行建模提出 GPN，并通过添加 RoI 池化和回归分支，对 GPN 架构进行进一步的完善。GPN 通过将边界椭圆表示为图像平面上的二维高斯分布，并运用相对熵 (Kullback-Leibler Divergence, KL 散度) 损失来衡量所提分布与实际标注高




图 4.1 数据集内椭圆靶标正常情况与椭圆长短轴长度相近情况图片展示

斯分布之间的重叠程度，在无需对椭圆旋转角度参数估计的情况下对椭圆检测实现初步的目标定位。然而，考虑到 KL 散度的不对称性和数值上的不稳定性等限制，在对 GPN 生成的椭圆候选区域精细化上，本文采用了满足对称性且在数值分布上更稳定的二阶瓦瑟斯坦距离（2-Wasserstein Distance, 2-WD）作为损失函数，这种方法旨在改进神经网络生成的预测结果，以便更准确地预测椭圆形物体的精确位置。

实验证明，本文对 GPN 以及损失函数的改进尤其在狭小空间内椭圆靶标数据集上表现显著优于传统的 RPN 架构。无论是在精确率指标还是召回率指标还是在不同实验设置下的交并比（Intersection over Union, IoU）指标，改进 GPN 都展现出了更低的定位错误率和更高的敏感度。这些发现进一步印证了改进 GPN 在网络结构设计上的优越性。

总结来说，本方法成功之处在于其充分利用了深度学习的优势，即通过模拟边界椭圆的自然统计分布特性，简化并优化了目标定位过程，不仅解决了传统方法难以有效捕捉复杂边界形状的问题，而且避免了因过度关注单个参数（例如旋转角度等）而牺牲整体定位精度的情况。因此，该方法在物体检测领域的探索具有深远意义，它为处理非刚性边界物体提供了一种新颖且更为精准的解决方案，有望在未来推动相关领域检测技术的发展和應用。

4.2 算法框架

本节提出了一种基于 Faster R-CNN 框架的方法，将其中的 RPN 改进为 GPN，并使用 KL 散度取代 L2 平滑损失以适应椭圆检测任务，同时提出了一个基于 2-WD 的损失函数用于进一步优化 GPN 产生的椭圆候选，提升模型预测的准确精度。具体来说，GPN 通过将边界椭圆表示为图像平面上的二维高斯分布，特别针对出现长短轴比值较大情况下的椭圆形状目标进行了优化设计，此外 GPN 利用 KL 散度来量化预测的高斯分布与真实分布之间的差异进一步生成椭圆的候选区域，从而实现椭圆的初步检测。最后使用 2-WD 损失函数对 GPN 产生的椭圆候选区域进行进一步的优化，

以及一个分类损失函数判断椭圆候选区域是否为图片的前景。




图 4.2 基于 2-WD 损失改进的椭圆目标检测算法流程

在图 4.2 中展示了基于 2-WD 损失改进的椭圆目标检测算法的具体流程。类似于传统的 Faster R-CNN 网络，首先网络通过一个骨干网络 VGG-16 得到图像的特征图，之后本文的网络不采用常规的矩形边界框提议，而是利用 GPN 生成候选边界椭圆。GPN 将每个候选的边界椭圆视为图像平面上二维高斯分布的等概率轮廓，这使得可以通过优化两个高斯分布之间的距离度量来实现椭圆回归，而非直接回归旋转角度或其他传统的矩形框参数。具体而言，GPN 根据五个参数 $(c_x, c_y, r_x, r_y, \theta)$ 来参数化一个椭圆，其中 c_x 和 c_y 代表椭圆中心在 x 轴和 y 轴上的坐标， r_x 和 r_y 表示沿 x 轴和 y 轴方向的半径大小， θ 为椭圆的旋转角度。不同于原有的 RPN 只预测四个边框参数，GPN 增加了旋转角度，并使用 KL 散度作为损失函数替代原来的平滑 L_1 损失，最小化候选椭圆与真实椭圆之间的差异。紧接着，本章提出在 Faster R-CNN 模型的基础上重新引入 RoI 池化操作以及分类损失和优化损失。对于每个由 GPN 生成的椭圆候选，找到最紧致的覆盖候选的轴对齐边界框，然后以类似 Faster R-CNN 的方式对该区域内的特征图进行池化操作。紧接着，基于候选椭圆中心应用全连接层以及每个检测到的椭圆的方向和形状预测参数偏移量。最后，为了更好地适应椭圆检测任务，本章还提出了使用 2-WD 损失作为椭圆回归损失函数的替代方案，从而更精确地预测椭圆位置。

4.3 高斯建议网络 GPN

在本节中，首先详细阐述了二维高斯分布下椭圆表示的基础理论，其次说明为了适配椭圆边界检测所以对 Faster R-CNN 检测中 RPN 网络进行改进的 GPN，最后创新性的提出将 KL 散度损失应用于改进的 GPN 模型中进行训练。

4.3.1 椭圆的二维高斯分布

二维坐标系下的不带旋转角度的椭圆方程式如式 4-1 所示, 其中椭圆的中心坐标表示为 μ_x, μ_y , 沿 x 轴和 y 轴的半轴长度为 σ_x, σ_y 。

$$\frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} = 1 \quad (4-1)$$

$$f(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)}{2\pi|\boldsymbol{\Sigma}|^{\frac{1}{2}}} \quad (4-2)$$

二维高斯分布的概率密度函数如式 4-2 所示, 其中 $\mathbf{x}$ 是坐标 (x, y) 的向量表示, $\boldsymbol{\mu}$ 是均值, $\boldsymbol{\Sigma}$ 是协方差矩阵, $|\boldsymbol{\Sigma}|$ 是协方差矩阵的行列式。如果假设 $\boldsymbol{\Sigma}$ 中的非对角项为 0, 并将 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 参数化为 $\boldsymbol{\mu} = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}$, $\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{bmatrix}$, 则式 4-1 中的椭圆方程对应当 $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = 1$ 时该椭圆方程二维高斯分布的密度轮廓线。如图 4.3 示例为两个不同的椭圆其不同二维高斯分布概率密度函数可视化。




图 4.3 椭圆的二维高斯分布概率密度函数可视化

当椭圆的长轴相对于 x 轴旋转了一个角度 θ 时, 可以定义一个旋转矩阵 $R(\theta)$, 将原始的 (x, y) 坐标系中的坐标映射到新的 (x', y') 坐标系中, 如等式 4-3 表示当椭圆的主轴相对于 x 轴旋转角度 θ 情况, 使用旋转矩阵 $R(\theta)$ 将原始 (x, y) 系统中的坐标映射到新的 (x', y') 系统中, 此时椭圆的长轴与 (x', y') 系统中的 x' 轴对齐, 如图 4.4 所示。

$$R(\theta) = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}, \begin{bmatrix} x' \\ y' \end{bmatrix} = R(\theta) \begin{bmatrix} x \\ y \end{bmatrix} \quad (4-3)$$

在 (x, y) 坐标系中 $(1, 0)$ 和 $(0, 1)$ 的坐标在 (x', y') 坐标系中是 $(\cos \theta, -\sin \theta)$ 和 $(\sin \theta, \cos \theta)$, 如果用 σ_l, σ_s 表示椭圆在 (x', y') 系统中的半长轴和半短轴的长度, 并假定它以 (μ'_x, μ'_y) 为圆心, 那么在 (x', y') 坐标系中的椭圆方程如等式 4-4 所示, 其中 $\mathbf{x}'$ 和 $\boldsymbol{\mu}'$ 是 (x', y') 和 (μ'_x, μ'_y) 的向量表示。




图 4.4 椭圆通过旋转矩阵的变换

$$(\mathbf{x}' - \boldsymbol{\mu}')^T (\boldsymbol{\Sigma}')^{-1} (\mathbf{x}' - \boldsymbol{\mu}') = 1, (\boldsymbol{\Sigma}')^{-1} = \begin{bmatrix} \frac{1}{\sigma_l^2} & 0 \\ 0 & \frac{1}{\sigma_s^2} \end{bmatrix} \quad (4-4)$$

因此，以 $\boldsymbol{\mu}(\mu_x, \mu_y)$ 为中心，半长轴和半短轴长度分别为 σ_l 和 σ_s ，并且其长轴与 x 轴之间的旋转角度为 θ (θ 的取值在 $[-\frac{\pi}{2}, \frac{\pi}{2}]$ 范围内) 的椭圆，该椭圆可以通过具有以下参数的二维高斯分布来描述：

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \boldsymbol{\Sigma}^{-1} = R^T(\theta) \begin{bmatrix} \frac{1}{\sigma_l^2} & 0 \\ 0 & \frac{1}{\sigma_s^2} \end{bmatrix} R(\theta) \quad (4-5)$$

4.3.2 GPN 网络架构

GPN 的核心思想是将边界椭圆视为图像平面上的二维高斯分布，不同于 RPN 进行边界框的初步位置偏移以及前景、背景的划分，GPN 的独特之处在于它将每个锚点关联到一个拟合边界椭圆的参数集合上，这些参数包括中心坐标 (μ_x, μ_y) 、长短轴的标准差 (σ_l, σ_s) 以及旋转角度 θ 。为了利用 KL 散度衡量两个高斯分布之间的重叠程度，GPN 将这些参数整合进一个表示边界椭圆的二维高斯分布模型中。




图 4.5 GPN 网络架构图

如图4.5所示，在网络结构内部，GPN 使用一组特定的卷积层分别输出各个高斯

分布参数。对于中心坐标的预测，采用的是 1×1 卷积层；而对于长轴和短轴的标准差，则同样运用独立的 1×1 卷积层输出。至于旋转角度，尽管 GPN 并不直接回归这个参数，而是通过优化预测得到的椭圆候选区域与真实椭圆标签区域之间的 KL 散度间接得到更为精确的椭圆姿态。在网络训练过程中，GPN 的核心是基于 KL 散度损失函数，这种损失能够直接量化所提议的边界椭圆高斯分布与真实分布之间的差异，并且当旋转角度 θ 为 0 时，KL 散度损失近似于 RPN 框架下用于边界框定位的回归损失。因此，GPN 不仅实现了对边界椭圆参数的联合优化，还有效地避免了传统方法在处理旋转角度时可能导致的问题，特别是当椭圆的长轴和短轴长度相近时，直接回归旋转角度并非必要且可能会引入误差。得益于 KL 散度损失对定位错误率的有效降低，在不同的实验数据集下 GPN 相比与 RPN 均表现出稳健的性能提升。

4.3.3 KL 散度损失

GPN 的目标是提出候选椭圆边界，使得其五个参数 $(\mu_x, \mu_y, \sigma_l, \sigma_s, \theta)$ 通过 KL 散度匹配真实椭圆边界^[16]，将提出的二维高斯分布 $\mathcal{N}_p$ 与目标二维高斯分布 $\mathcal{N}_t$ 之间的 KL 散度表示为：

$$D_{\text{KL}}(\mathcal{N}_t \parallel \mathcal{N}_p) = \frac{1}{2} \left[\text{tr}(\Sigma_p^{-1} \Sigma_t) + (\boldsymbol{\mu}_p - \boldsymbol{\mu}_t)^\top \Sigma_p^{-1} (\boldsymbol{\mu}_p - \boldsymbol{\mu}_t) + \ln \frac{|\Sigma_p|}{|\Sigma_t|} - 2 \right] \quad (4-6)$$

其中 $\text{tr}(\cdot)$ 是矩阵的迹。GPN 通过最小化 KL 散度，即通过优化椭圆参数使候选椭圆尽可能接近目标椭圆，从而实现对椭圆边界的精准检测。

在 Faster R-CNN 中，L1 或 L2 损失函数常被用来预测矩形目标的四个预测参数与实际参数之间的偏差。然而，由于角度参数需要与其他四个参数分开处理，这些损失函数在椭圆检测问题上表现并不理想。

在 RPN 中，对于边界框的回归旨在将每个候选框的参数 (x_a, y_a, w_a, h_a) ，分别代表候选框中心的横纵坐标、宽度和高度，与真实边界框的参数进行对齐。为此，RPN 采用 L1 损失进行回归分析。当损失值较低时，L1 损失过渡到 L2 损失，以确保更平滑的损失变化。因此，针对中心坐标的 L2 损失表达式转化为 $(t_x^p - t_x^t)^2 = \frac{\Delta x^2}{w_a^2}$ 和 $(t_y^p - t_y^t)^2 = \frac{\Delta y^2}{h_a^2}$ ，其中 Δx 和 Δy 分别表示预测框与真实框中心点在横纵坐标上的差异， $t_x^p, t_w^p, t_x^t, t_w^t$ 可以从公式 4-7，4-8 中推导出。

$$\begin{aligned} t_x^p &= (x_p - x_a) / w_a, t_y^p = (y_p - y_a) / h_a \\ t_w^p &= \ln(w_p / w_a), t_h^p = \ln(h_p / h_a) \end{aligned} \quad (4-7)$$

$$\begin{aligned} t_x^t &= (x_t - x_a) / w_a, t_y^t = (y_t - y_a) / h_a \\ t_w^t &= \ln(w_t / w_a), t_h^t = \ln(h_t / h_a) \end{aligned} \quad (4-8)$$

GPN 通过简化模型假设，将旋转角度 θ_p 和 θ_t 视为始终为零，这样 σ_l 和 σ_s 便直接对应于围绕椭圆边界的最紧凑边界框的半宽和半高。在这种假设下，其 KL 散度的计算公式简化为等式 4-9 所示。为了方便与 RPN 的回归损失进行对比，将式中的 $(\sigma_{lp}, \sigma_{lt})$ 以 (w_p, w_t) 表示，并将 $(\sigma_{sp}, \sigma_{st})$ 替换为 (h_p, h_t) 。这种替换允许在不涉及旋转角度的情况下，直接将椭圆边界框的宽度和高度用于回归损失的计算，从而便于与 RPN 进行效果比较。

$$D_{KL}(\mathcal{N}_t || \mathcal{N}_p) = \frac{1}{2} \left[\frac{w_t^2}{w_p^2} + \frac{h_t^2}{h_p^2} + \frac{\Delta^2 x}{w_p^2} + \frac{\Delta^2 y}{h_p^2} + \ln \frac{w_p^2}{w_t^2} + \ln \frac{h_p^2}{h_t^2} - 2 \right] \quad (4-9)$$

从公式 4-9 中可以看出当直接比较候选高斯分布与真实高斯分布时，若忽略旋转角度，即当 θ 接近 0 时，KL 散度损失函数的形式简化为更类似于 RPN 框架中用于边界框回归的标准平滑 L1 损失。

4.4 基于 2-WD 损失的椭圆回归的损失函数

为了进一步完成从候选框到精确位置的过渡，重新引入了感兴趣区域池化 (RoI pooling) 机制，并添加了分类和回归分支。具体来说，在得到 GPN 生成的候选椭圆后，找出包围该提议的最紧致的轴对齐边界框，并采用类似 Faster R-CNN 的方式对该区域内的特征图进行池化操作。然后，使用全连接层根据提议中心点以及每个检测到的椭圆的方向和形状来预测参数的偏移量，从而达到更精确地定位目标椭圆的目的。这表明在无旋转或近似圆形的情况下，KL 散度损失可以直接作为定位误差的一种有效替代指标。使用 KL 散度是椭圆回归损失的一个直观选择，可以用于衡量生成椭圆候选框时两个高斯分布之间的距离。然而，KL 散度也存在一些明显的限制。首先，KL 散度是非对称的，这意味着对于两个分布 $\mathcal{D}_1$ 和 $\mathcal{D}_2$ ， $D_{KL}(\mathcal{D}_1 || \mathcal{D}_2)$ 不一定等同于 $D_{KL}(\mathcal{D}_2 || \mathcal{D}_1)$ 。其次，当两个分布相差较远时，KL 散度有时数值上不稳定，其值可能异常大，这可能导致梯度估计问题，从而阻碍神经网络的训练过程。最后，由于 KL 散度不满足三角不等式，因此它并不构成一个严格的数学度量。因此本文不使用 KL 散度损失函数作为椭圆候选区域精细化损失函数。2-WD 损失是一种用于衡量两个概率分布之间差异的度量方法。不同于 KL 散度，2-WD 损失函数具有对称性，并遵循三角不等式原则。近年来，为了提升神经网络模型的生成质量，研究人员开始探索使用 Wasserstein 距离替换传统的非对称损失函数。例如，Arjovsky 等人^[54]在其研究中引入了 Wasserstein GAN，旨在通过应用 Wasserstein 距离来增强 GAN 训练的稳定性。两个概率分布 μ 和 ν 之间的 p-Wasserstein 距离如公式 4-10 所示。

$$W_p(\mu, \nu) = (\inf \mathbb{E} [d(X, Y)^p])^{1/p} \quad (4-10)$$

其中 $d(\cdot, \cdot)$ 是一个 $X \sim \mu$ 和 $Y \sim \mu$ 的距离函数。根据研究^[55]对于两个二维高斯分布 $\mathcal{N}_p(\boldsymbol{\mu}_p, \boldsymbol{\Sigma}_p)$ 和 $\mathcal{N}_t(\boldsymbol{\mu}_t, \boldsymbol{\Sigma}_t)$ ，其基于欧几里得距离的 2-Wasserstein 距离表达式为如公式4-11所示。

$$[W_2(\mathcal{N}_p, \mathcal{N}_t)]^2 = \|\boldsymbol{\mu}_p - \boldsymbol{\mu}_t\|_2^2 + \text{tr}[\boldsymbol{\Sigma}_p + \boldsymbol{\Sigma}_t - 2\left(\boldsymbol{\Sigma}_p^{\frac{1}{2}}\boldsymbol{\Sigma}_t\boldsymbol{\Sigma}_p^{\frac{1}{2}}\right)^{\frac{1}{2}}] \quad (4-11)$$

在满足条件 $\boldsymbol{\Sigma}_p\boldsymbol{\Sigma}_t = \boldsymbol{\Sigma}_t\boldsymbol{\Sigma}_p$ 时，两个二维高斯分布之间的 2-Wasserstein 距离可进一步简化如公式4-12所示。

$$[W_2(\mathcal{N}_p, \mathcal{N}_t)]^2 = \|\boldsymbol{\mu}_p - \boldsymbol{\mu}_t\|_2^2 + \left\|\boldsymbol{\Sigma}_p^{\frac{1}{2}} - \boldsymbol{\Sigma}_t^{\frac{1}{2}}\right\|_F^2 \quad (4-12)$$

其中 $\|\cdot\|_F$ 是矩阵的 F-范数，协方差矩阵可通过求解椭圆参数在等式 4-5 中的逆矩阵得出。半方根矩阵 $\boldsymbol{\Sigma}_p^{\frac{1}{2}}$ 和 $\boldsymbol{\Sigma}_t^{\frac{1}{2}}$ 的求解过程如公式4-13所示。

$$\begin{aligned} \boldsymbol{\Sigma}_p^{\frac{1}{2}} &= R_p^T(\theta) \begin{bmatrix} \sigma_{p,l} & 0 \\ 0 & \sigma_{p,s} \end{bmatrix} R_p(\theta) \\ \boldsymbol{\Sigma}_t^{\frac{1}{2}} &= R_t^T(\theta) \begin{bmatrix} \sigma_{t,l} & 0 \\ 0 & \sigma_{t,s} \end{bmatrix} R_t(\theta). \end{aligned} \quad (4-13)$$

因此，本文所使用的总损失函数是由三个部分组成的加权和。具体来说：(1) GPN 椭圆候选框损失 (KL 散度)：生成椭圆形候选框（即预测椭圆的位置和形状）的过程中产生的损失。(2) 椭圆回归损失 (2-WD 损失)：这部分损失用于优化椭圆的中心位置、长轴、短轴和旋转角度等参数，以使预测的椭圆尽可能贴近真实的椭圆。(3) 椭圆和背景分类损失 (交叉熵损失)：用于区分图像中的椭圆区域（前景）和非椭圆区域（背景）。

总损失函数将这三个部分通过加权和的形式结合起来，以便同时优化模型在这三个方面的性能。每个部分的损失都会乘以一个权重系数，然后相加得到总损失，模型训练的目标就是最小化这个总损失。这种方法使模型能够在检测椭圆位置、预测椭圆形状以及区分椭圆和背景方面达到较好的平衡和性能。

4.5 实验设计及结果分析

在本节中，我们对多个数据集进行了指标测试，以评估本章提出的算法模型。首先介绍了实验的总体设计和模型评估指标。随后，通过可视化结果对比分析了第三章实现的基于弧线结构的椭圆检测算法与本章提出的基于 RPN 和 2-WD 损失改进的椭圆检测算法，特别地，本文深入分析并对比了针对本研究的主要应用场景——TY 数

据集上的可视化结果,以获得更精细的理解和评估,随后展示了基于 2-WD 损失改进的方法相比于 RPN 和其他传统椭圆检测算法,在精确度、召回率、F 值和检测时间等关键指标上的性能表现。此外,本节还通过调整不同的损失函数以及候选框数量参数设置,进行了一系列定量实验,以全面评估模型的性能。

4.5.1 实验设置

(1) 实验总体设置: 首先将四个数据集中的图片全部转化为 512×512 像素大小,每一个像素含有三个通道,每一个通道的取值在 0 到 255 之间;此外将四个数据都划分为训练集、验证集、测试集,分别占比为 70%、15%、15%。同时无论是 GPN 网络还是 RPN 网络均对训练集进行 30 个轮次 (Epoch) 的训练,每一个批次 (Batch) 为 128 张图片。本章节的模型是基于 PyTorch 框架实现的,并使用一个 GeForce RTX 3090 GPU 进行训练。本文使用具有 “Inverse” 衰减策略的 Adam 优化器,并且设定 0.4 的动量和 1.5×10^{-3} 的学习率,以端到端的方式训练模型,在 10 轮、15 轮和 20 轮次后将学习率衰减 5 倍。为保证实验结果的可信性,针对 RPN 和 GPN 均是使用相同的预训练骨干网络 VGG-16^[56],并且设定提取特征图的特征维度 128 维。此外由于 GPN 和 RPN 都是单阶段的检测网络,在检测过程中会产生大量的背景候选框,为了避免这些大量的背景候选框对检测精度产生影响,根据每一个候选框的得分高低筛选出 16 个候选框来缓解这个问题。

(2) 模型评价指标: 除了采用与第三章基于弧线结构的椭圆检测算法相同的精确率、召回率、F 值以及检测时间等评价指标,本节还计算了所有检测到的椭圆与实际椭圆之间的交集与并集的比值 (IoU) 的平均值。鉴于不存在直接计算两个椭圆重叠面积的封闭式解,本文采用了一种基于点网格的离散化采样方法。这个方法通过对覆盖两个椭圆的最小轴对齐边界矩形内绘制一个点阵,以此来估算两椭圆之间的 IoU。点网格的尺寸,即其宽度和高度,与该边界矩形的宽度和高度一致,且每个网格点代表一个像素位置。这种方法能够近似地计算并量化两个椭圆之间的重叠程度,从而为检测方法的性能提供一个有效的评价指标,如图 4.6 所示为估计两椭圆之间的 IoU 示意图。

4.5.2 实验结果可视化及指标评估

本节将对上文所述的基于 2-WD 损失改进的椭圆检测算法在四个数据集上分别运行,并对算法的检测结果进行可视化展示。特别针对本研究的核心应用场景—TY 数据集,通过对其上的可视化结果进行比较和分析,本文深入探讨了该算法在狭窄空间中检测靶标的性能。紧接着,本研究将通过一系列详尽的性能评估指标,对算法的效果进行精细化分析。




图 4.6 IoU 指标获取示意图

(1) 实验结果可视化

为了全面评价本章提出的基于 RPN 和 2-WD 损失的改进方法，以及第三章介绍的基于弧线结构的椭圆检测算法的检测效果对比，对 Prasad、TSE、PCB 以及自行构建的 TY 数据集进行实验测试，分别使用了弧线结构检测、RPN 以及基于 2-WD 损失改进的算法进行椭圆形目标的检测，并对比了这些方法的检测结果，图 4.7进行了部分可视化展示，其中从图片第一列至第四列依次为 Prasad 数据集、TSE 数据集、PCB 数据集以及 TY 数据集。




图 4.7 弧线结构、RPN 与 2-WD 损失改进数据集实验结果可视化

纵向对比图 4.7中结果可以看出，在处理 Prasad 数据集中部分椭圆形态缺失的情况时，基于弧线结构的椭圆检测算法相较于 RPN 和 2-WD，尽管存在一定的误检风

险,但能较好地识别出椭圆被部分遮挡或图像中显示不全的曲线。继续深入比较 RPN 与 2-WD 的检测效果, RPN 容易在目标区域附近生成多个重叠的椭圆边界。相对地, 2-WD 损失改进的方法通过直接回归真实椭圆边界并采用 2-Wasserstein 距离作为损失函数的策略, 实现了对图像中椭圆特征的精准检测。

(2) 针对 TY 数据集实验结果可视化

为了深入比较本文所提出的基于弧线结构和 2-WD 损失改进的椭圆检测算法在狭小空间应用场景中的实际效果, 本文研究了这两种方法在 TY 数据集上的检测性能, 此外, 值得一提的是, 为了更大程度模拟真实口腔咽喉手术环境, 我们还在数据集中加入了在复杂背景下的圆环靶标成像, 以尽可能地真模拟该场景下的真实手术过程。对集成在末端执行器上的圆环靶标进行了检测, 检测结果如图 4.8 和 4.9 所示。




图 4.8 TY 数据集弧线结构与 2-WD 圆环靶标检测结果可视化示例 1

由于圆环靶标与末端执行器集成, 通过医用内窥镜在狭小空间内对末端执行器运动成像时, 附着在末端执行器顶部的圆环靶标在实际图像中所占的比例非常小, 这极大地增加了检测圆环靶标的难度。从图像 4.8 和 4.9 中可以看出, 当圆环靶标与内窥镜的距离较近时, 基于弧线结构和 2-WD 损失改进的方法, 都能有效地识别出圆环靶标的椭圆边界。然而, 当末端执行器携带圆环靶标伸入口腔咽喉深处, 采用 2-WD 损失改进的深度学习椭圆检测方法表现出更优的性能, 能够相对明显地检测出圆环靶标内外椭圆边界。因此, 对于图像中圆环靶标椭圆边界完整显示且椭圆特征明显的情况, 基于弧线结构的算法与 2-WD 能准确地识别边界。在遇到圆环靶标显示不完整的情况时, 弧线结构算法有能力拟合出部分椭圆曲线, 2-WD 损失改进方法则在保持对完整边界精准检测方面表现更为出色。

(3) 评价指标对比




图 4.9 TY 数据集弧线结构与 2-WD 圆环靶标检测结果可视化示例 2

为了验证本章节提出的 2-WD 损失改进算法性能效果，本文采用与第三章相同的评价指标精确率、召回率、F 值指标以及运行时间对算法在 Prasad 数据集、TSE 数据集、PCB 数据集以及 TY 数据集上进行综合评估。

表 4.1 椭圆检测精确率结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构	RPN	2-WD
Prasad 数据集	Precision	0.0932	0.7049	0.1951	0.2370	0.7161	0.7533	0.7928	0.8431
TSE 数据集	Precision	0.0425	0.4508	0.0752	0.1412	0.5824	0.9008	0.8965	0.9728
PCB 数据集	Precision	0.4178	0.8943	0.4175	0.7655	0.9383	0.9705	0.8621	0.9983
TY 数据集	Precision	0.1543	0.2568	0.1042	0.3652	0.5878	0.6084	0.6667	0.8631

在表 4.1 中展示了 ELSDc、Fornaciari、弧线结构等传统算法与基于深度学习的 RPN 算法和 2-WD 算法在 Prasad 数据集、TSE 数据集、PCB 数据集以及 TY 数据集数据集上的准确率指标对比。从总体上看，在所有数据集中基于 2-WD 损失改进的算法都取得了最高性能表现，这表明该算法对多个数据集数据的拟合效果都远超过了其他的算法，尤其是在 PCB 数据集中 2-WD 算法的准确率接近 100%，主要原因是由于 PCB 数据集内椭圆特征较明显且椭圆边界占据成像平面比例较大。详细来说，其中在 Prasad 数据集领先第二名 RPN 网络 5.03%；在 TSE 数据集中 2-WD 算法领先第二名弧线结构算法 7.2%；在 PCB 数据集中 2-WD 领先第二名弧线结构算法 2.78%；在 TY 数据集中本文所提出的 2-WD 算法领先第二名 RPN 网络高达 19.61%。此外发现在 TSE 数据集和 PCB 数据集数据中基于深度学习的 RPN 网络性能低于基于弧线结构的椭圆检测算法，但是 GPN 网络均取得了最佳性能，这从侧面表明本文针对 RPN 网络改进的有效性。

在表 4.2 中展现了各椭圆检测方法在不同数据集上召回率指标对比。首先从总体

表 4.2 椭圆检测召回率结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构	RPN	2-WD
Prasad 数据集	Recall	0.2950	0.2164	0.2489	0.3155	0.2393	0.3514	0.9078	0.9327
TSE 数据集	Recall	0.6943	0.7287	0.5159	0.5675	0.7334	0.8821	0.9105	0.9155
PCB 数据集	Recall	0.9254	0.8692	0.9510	0.7125	0.8933	0.9192	0.9179	0.9320
TY 数据集	Recall	0.1754	0.2054	0.1053	0.3248	0.5273	0.5674	0.8621	0.8931

上看, 在所有数据集中 2-WD 算法都取得了最高的召回率表现, 其中 Prasad 数据集领先第二名 RPN 网络 2.49%; 在 TSE 数据集中 2-WD 算法网络领先第二名 RPN 网络 0.5%; 在 PCB 数据集中 2-WD 算法领先第二名弧线结构 1.28%; 在 TY 数据集中 2-WD 算法网络领先第二名 RPN 网络最高为 3.1%。

表 4.3 椭圆检测 F 值结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构	RPN	2-WD
Prasad 数据集	F 值	0.1416	0.3311	0.2180	0.2706	0.3587	0.4792	0.8464	0.8856
TSE 数据集	F 值	0.0800	0.5570	0.1313	0.2262	0.6492	0.8914	0.9034	0.9432
PCB 数据集	F 值	0.5757	0.8816	0.5803	0.7380	0.9152	0.9442	0.8891	0.9640
TY 数据集	F 值	0.1641	0.2282	0.1047	0.3438	0.5559	0.5871	0.7519	0.8778

表 4.3 中展示了综合评估 F 值指标对比。首先从总体上看, 在所有数据集 2-WD 算法在 F 值指标上都取得了最佳性能表现, 其中 Prasad 数据集领先第二名 RPN 网络 3.92%; 在 TSE 数据集中 2-WD 算法网络领先第二名 3.98%; 在 PCB 数据集中 2-WD 算法网络领先第二名弧线结构 1.98%; 在 TY 数据集中 2-WD 算法网络领先第二名 RPN 网络高达 12.59%。

表 4.4 椭圆检测运行时间结果对比

数据集	指标	ELSDc	Fornaciari	RHT	Prasad	Qi	弧线结构	RPN	2-WD
Prasad 数据集	时间 (s)	1.4358	0.0949	0.2021	3.9021	0.0539	0.1695	0.3361	0.3086
TSE 数据集	时间 (s)	4.6016	0.2885	1.2885	0.9928	0.1498	0.5791	0.4278	0.3982
PCB 数据集	时间 (s)	3.4840	0.0990	0.2281	1.0768	0.0748	0.1693	0.3972	0.3419
TY 数据集	时间 (s)	1.4253	0.0995	0.2243	0.9521	0.0541	0.1785	0.2695	0.2524

在表 4.4 中展示了不同方法处理一张图片所消耗的时间。可以看出, 虽然 2-WD 损失改进的算法处理图片的速度不如基于弧线结构的椭圆检测算法, 但是相比于同样基于深度学习的 RPN 网络, 在所有数据集上都具有一定速率上的优势, 能够满足课题实际应用需求。同时在图 4.10 中展示了针对狭小空间内 TY 数据集上基于 2-WD 损失改进的网络各个指标随训练过程的变化。

综上所述, 主要对比本文所提出的基于弧线结构和基于 2-WD 损失改进的椭圆检测算法, 基于 2-WD 损失改进的椭圆检测算法在各个数据集上都表现了出了较好




图 4.10 TY 数据集上 2-WD 损失改进算法训练各项指标变化过程

的性能，其准确率、召回率、F 值均相对较高，基于弧线结构的椭圆检测算法占有经典检测算法检测时间短的优势，能够在较短时间内得出检测结果，对于后续位姿估计算法需要快速反应检测结果的场景同样具有优点。

4.5.3 参数设置与定量实验

本节将探讨不同损失函数及网络中候选框数量对模型性能的影响，鉴于本研究的主要应用场景是在狭小空间内检测圆环靶标，特别地将针对狭小空间内圆环靶标数据集进行模型训练，评估本章提出的利用 2-WD 损失改良的椭圆检测算法在模型评估方面的表现。

(1) 不同损失函数对评价指标的影响

为了评估本文所提出的基于 2-WD 损失改进椭圆检测方法的性能，针对其损失函数的选用对模型的影响，因此只考虑狭小空间内圆环靶标 TY 数据集，分别考虑了以下实验设置评估不同损失函数对于椭圆检测算法评价指标 IoU 的影响：第一种是使用 L2 损失的 RPN，在 Faster R-CNN 中使用 RPN 来生成椭圆候选框，不同于描述矩形的四个参数，RPN 输出描述椭圆的五个参数；第二种是使用 L2 损失的 GPN，将 Faster R-CNN 中的 RPN 替换为 GPN 来生成椭圆候选框；第三种是使用 KL 散度的 GPN；最后是，使用 2-WD 损失的 GPN。需要注意的是，GPN 在候选区域生成网络中使用 KL 散度，而 RPN 使用平滑 L1 损失。本文在每种损失函数设置下针对狭小空间内圆环靶标 TY 数据集训练了模型四次，报告了每次重复实验中每种设置下检测到的椭圆与真实椭圆之间的 IoU，以及平均 IoU。

表 4.5 TY 数据集内 GPN 与 RPN 使用不同损失函数的 IoU 指标

设置	RPN&L2	GPN&L2	GPN&KLD	GPN&2-WD
TY-Exp1	0.7131	0.7546	0.8322	0.8412
TY-Exp2	0.7420	0.7715	0.8421	0.8526
TY-Exp3	0.7509	0.7632	0.8453	0.8562
TY-Exp4	0.7528	0.7717	0.8527	0.8605
IoU 均值	0.7397	0.7653	0.8431	0.8526

如表 4.5 所示, 本文针对 TY 数据集中训练了模型四次, 分别报告了 RPN 和 GPN 在结合不同损失函数的情况下 IoU 指标的性能表现。从总体上来看, RPN 网络结合 L2 损失函数在每批次上表现的结果都是最低的, 而 GPN 网络结合 2-WD 损失函数则是取得了最好的效果, 两者相比平均 IoU 提升约 11.3%。而直接将 Faster R-CNN 中的 RPN 替换为 GPN, 平均 IoU 提高了约 2.7%。用 KL 散度或 2-WD 损失替换通用的 L2 损失都显著提高了椭圆检测性能, 特别是, 使用 2-WD 的模型比使用 KL 散度的模型性能提高了 0.9% 以上。因此, 针对本研究的主要应用场景 TY 数据集, 本节通过不同损失函数的比较分析, 证明本节椭圆检测算法对于损失函数的改进凸显了显著优势, 证实了在狭小空间内改进方法的有效性。

(2) 不同数量候选框对评价指标的影响

在表格 4.6 和表格 4.7 中分别展示了 RPN 网络和 GPN 网络在不同的候选框数量的情况下, 模型预测结果在精确率指标上的表现结果。总体上看, 在数据集 Prasad 和 TSE 上 GPN 与 RPN 均在 16 个候选框设定下效果是最好的, 在 PCB 数据集上则是 8 个候选框效果最佳, 而 TY 数据集上 32 个候选框则能达到最佳性能, 相同的是当候选框数量为 64 个的时候 GPN 和 RPN 均在所有数据集上表现出最差效果。具体来看, 在 TY 数据集上 RPN 是 66.67% 的精确率, 而 GPN 是 86.31% 的精确率, 同时当候选框的数量为 32 个时获得了最好的性能, 在候选框数量超过 32 个的时候 RPN 和 GPN 网络在 TY 数据集上指标的表现都开始出现下降的趋势。并且当候选框数量达到 64 个的时候指标准确率最低。

表 4.6 RPN 网络不同数量候选框下精确率

候选框数量	8	16	32	64
Prasad	0.7223	0.7928	0.7326	0.7061
TSE	0.8656	0.8965	0.8611	0.8076
PCB	0.8521	0.8487	0.8434	0.7985
TY	0.6549	0.6601	0.6667	0.6583

表 4.7 GPN 网络不同数量候选框下精确率

候选框数量	8	16	32	64
Prasad	0.8211	0.8431	0.8319	0.7864
TSE	0.9485	0.9728	0.9540	0.9218
PCB	0.9983	0.9951	0.9553	0.9421
TY	0.8421	0.8415	0.8631	0.7921

4.6 本章小结

作为本章提出的基于 2-WD 损失改进的椭圆检测算法，本方法创新性地将 Faster R-CNN 中的 RPN 与椭圆的二维高斯分布相融合，提出使用 GPN 针对椭圆形物体的检测进行优化，通过将边界椭圆表示为图像平面上的二维高斯分布，并运用 KL 散度损失来衡量所提分布与实际标注高斯分布之间的重叠程度。在 GPN 架构中引入 RoI 池化和回归分支，又进一步拓展功能。此外还提出将 2-WD 作为椭圆候选区域精细化的损失函数，以准确预测椭圆形物体的具体位置。最后通过大量的实验及评价指标的分析验证了该方法的有效性及高效性，尤其针对本文主要应用场景狭小空间内 TY 数据集表现了优异的性能，同时，本文还对前一章节提出的基于弧线结构和本章提出的算法检测效果及具体指标进行了对比，总结得出两种椭圆检测算法各自的优点。

第五章 基于椭圆检测的位姿估计模型

本章基于前文提出的使用弧线特征和 2-WD 损失改进的椭圆检测算法对圆环靶标检测后,根据检测所提取出的圆环靶标边界特征,结合圆环靶标已知尺寸、内窥镜内参等先验信息实现的一种目标位姿估计算法。本章的内容安排如下,首先介绍本章的任务场景和研究动机;其次详细介绍本章所提出的算法原理和步骤;最后通过大量实验,从多个角度验证本章提出的算法的高效性。

5.1 引言

在本文工作所依托的狭小空间三维图像实时获取与导航定位课题中,目标的位姿估计是一个核心问题,它对手术机器人导航、定位等工作都有着举足轻重的作用。传统的相机标定与位姿估计方法一般依赖于复杂的图案或大量特征点,无法将包含特征的标定板放入空间内部,在本课题所应用的狭小口腔咽喉特殊场景下并不适用,无法将包含特征的标定板放入空间内部。为此,本章节提出了一个简化的位姿估计流程,该流程通过分析已知几何形状的成像来计算相机的外参。特别是,使用的是两个已知尺寸同心圆的平面特征圆环靶标,这种设计在投影成像时,可转化为图像中两个明显的椭圆形状,再使用弧线结构和改进 GPN 的椭圆检测算法共同提取出椭圆特征,针对椭圆环投影后圆心坐标不一致,本文也提出了有效的圆环圆心校正算法。通过综合利用已知内窥镜的内参、椭圆特征以及投影圆环圆心坐标真值,实现了相机外参的精确求解,完成了世界坐标系与相机坐标系的转换,进而实现目标位姿估计。在这里将详细介绍本文所提出的基于椭圆特征的相机位姿估计方法,以及该方法在各种环境下的应用与性能分析。

5.2 基于椭圆特征的位姿估计算法

本节将阐述一种高效的位姿估计技术,它利用对已知几何形状的成像分析来确定相机的外部参数(姿态)。与传统位姿估计方法不同,本方法不依赖于棋盘格等包含大量特征的图案,而是采用了特制的微小圆环靶标设计,它由同心圆环和额外的标识点组成。通过应用前面章节中论述的椭圆检测算法能够精确获取椭圆边界特征,并对投影后椭圆环的圆心坐标进行精准校正。结合内窥镜的内在参数、椭圆特征以及圆心的实际坐标,有效地求解相机的外在参数,实现世界坐标系到相机坐标系的转换,从而准确估计目标的位姿。

5.2.1 圆环的针孔投影模型

在本研究中采用了前文已经介绍过的圆环靶标构成的平面目标进行位姿估计,该圆环靶标如图 5.1 左部分所示的,其内径和外径分别为 1mm (r_1) 和 2.5mm (r_2)。本文将圆环靶标平面的中心指定为世界坐标系的原点,且这两个同心圆位于世界坐标系的 $X_W Y_W$ 平面内,垂直于 Z_W 轴。在针孔相机模型的投影变换过程如图 5.1 右半部分所示,通常采用一个内在参数矩阵 (A) 和一个外在参数矩阵 (M) 来进行描述,内在参数矩阵 A 用来描述相机的焦距和图像的主点位置,外在参数矩阵 M 则根据给定的全局坐标系确定摄像机的姿态 (位置和方向),相机投影矩阵 P 用来将世界坐标系 (WCS) 中的三维点映射到图像平面上相应的二维像素坐标,即 $P = AM$ 。




图 5.1 圆环靶标及其针孔投影模型

$$A = \begin{bmatrix} f & 0 & u_0 \\ 0 & f & v_0 \\ 0 & 0 & 1 \end{bmatrix} \quad M = \begin{bmatrix} R_{11} & R_{12} & R_{13} & T_x \\ R_{21} & R_{22} & R_{23} & T_y \\ R_{31} & R_{32} & R_{33} & T_z \end{bmatrix} \quad (5-1)$$

给定世界坐标系中的一个点 X , 方程 $\lambda x = P X$ 可以计算其在图像坐标系中的齐次坐标, 由于两个同心圆位于平面 $Z_W = 0$ 上, 因此该方程表示为等式 5-2:

$$\begin{bmatrix} \lambda u \\ \lambda v \\ \lambda \end{bmatrix} = \begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ p_{31} & p_{32} & p_{33} & p_{34} \end{bmatrix} \begin{bmatrix} X_W \\ Y_W \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} p_{11}X_W + p_{12}Y_W + p_{14} \\ p_{21}X_W + p_{22}Y_W + p_{24} \\ p_{31}X_W + p_{32}Y_W + p_{34} \end{bmatrix} \quad (5-2)$$

假设图像坐标系以图像的主点为中心,那么在等式 5-2 中 $u_0 = 0, v_0 = 0$, 由此可推导出等式 5-3, 其中 $\mathbf{x} = \begin{bmatrix} u & v & f \end{bmatrix}^t$, $M = \begin{bmatrix} \mathbf{R}_1 & \mathbf{R}_2 & \mathbf{R}_3 \mathbf{T} \end{bmatrix}$ 。

$$X_W = \frac{\mathbf{x}^t (\mathbf{R}_2 \times \mathbf{T})}{\mathbf{x}^t \mathbf{R}_3} \text{ and } Y_W = \frac{\mathbf{x}^t (\mathbf{T} \times \mathbf{R}_1)}{\mathbf{x}^t \mathbf{R}_3} \quad (5-3)$$

在世界坐标系中,半径为 r_2 的外圆的坐标满足 $C(X_W, Y_W) = X_W^2 + Y_W^2 - r_2^2 = 0$ 条件,将等式 5-3 代入这个条件并进行因式分解,则可得到图像坐标系下外圆方程,如式 5-4 所示:

$$C'(x, y) = Ax^2 + Bxy + Cy^2 + Dx + Ey + F = 0 \quad (5-4)$$

5.2.2 圆环圆心校正

在投影变换下,任何二次曲线都会转化为另一个二次曲线。具体来说,圆在相机成像时会转化为椭圆。摄像机坐标系中 Z_W 轴 (或 $\mathbf{R}_3$) 的方向可通过等式 5-5 计算,其中 (x_c, y_c) 是投影圆心在图像坐标系中的坐标, N 表示归一化为单位向量, Q 是描述椭圆的矩阵,如等式 5-6 所示,其中参数 $A \sim F$ 为椭圆的参数, f 为相机焦距。

$$\begin{bmatrix} R_{13} \\ R_{23} \\ R_{33} \end{bmatrix} = \pm N \left\{ Q \begin{bmatrix} x_c \\ y_c \\ f \end{bmatrix} \right\} \quad (5-5)$$

$$Q = \begin{bmatrix} A & B/2 & D/2f \\ B/2 & C & E/2f \\ D/2f & E/2f & F/f^2 \end{bmatrix} \quad (5-6)$$

为了恢复支撑平面的法线,必须计算圆的投影中心,然而原始圆的投影中心一般不会与图像中的椭圆中心重合,导致出现一定的偏心误差,进而带来系统误差。he 等人提出^[57]的从透视投影变换性质和椭圆的几何特征对偏心误差进行了分析,得到了偏心误差在图像中的误差公式 5-7:

$$\varepsilon_u = u_B - u_{C'} = \frac{c(x_p/l) \sin^2 \omega}{(l/r)^2 - \sin^2 \omega}, \varepsilon_v = v_B - v_{C'} = \frac{-c(d/l) \sin \omega \cos \omega}{(l/r)^2 - \sin^2 \omega} \quad (5-7)$$

根据误差公式 5-7，考虑在本文应用场景中曝光距离 l 远大于圆环靶标内外圆半径 r_1 、 r_2 ，所以可以忽略式 5-7 中分母 $\sin \omega$ ，则误差公式就变成了：

$$\begin{aligned} \varepsilon_u &= u_B - u_C \approx \frac{c(x_p/l) \sin^2 \omega}{l^2} \cdot r^2 = K_u \cdot r^2 \\ \varepsilon_v &= v_B - v_C \approx \frac{-c(d/l) \sin \omega \cos \omega}{l^2} \cdot r^2 = K_v \cdot r^2 \end{aligned} \quad (5-8)$$

该误差公式说明，偏心误差与圆形目标半径的平方成正比，比例只与圆形目标与相机的关系有关，而与 K_u 、 K_v 与圆的大小无关。而对于本文两个半径不同但处于同一平面的圆环靶标而言，它们具有相同的比例 K_u 、 K_v 。如图所示，圆环靶标在通过针孔投影后，它们成像为两个具有不同中心的椭圆，如图 5.2 所示，圆环靶标的中心 C 相同，经过投影后该圆环成像上变成不同的椭圆，内椭圆中心标记为 B_1 ，外椭圆中心标记为 B_2 ， C' 为同心圆 C 的投影点。




图 5.2 透视变换后的同心圆示意

分析同心圆的成像过程，由误差公式可得到圆环靶标投影后内外圆各自的误差公式：

$$\begin{aligned} x_{B1} - u_C &= K_u \cdot r_1^2, y_{B1} - v_C = K_v \cdot r_1^2 \\ x_{B2} - u_C &= K_u \cdot r_2^2, y_{B2} - v_C = K_v \cdot r_2^2 \end{aligned} \quad (5-9)$$

在上述方程中，两个椭圆中心 (x_{B1}, y_{B1}) 、 (x_{B2}, y_{B2}) 坐标通过前文讲述的两种椭圆检测算法处理确定，在设计靶标时两个同心圆的半径 r_1 、 r_2 是已知的，现在四个方程和四个未知数，求解方程组得到圆环靶标投影后圆心投影点 (u_c, v_c) 为：

$$\begin{aligned} x_C &= K_1 \cdot x_{B2} - K_2 \cdot x_{B1} \\ y_C &= K_1 \cdot y_{B2} - K_2 \cdot y_{B1} \end{aligned}, K_1 = \frac{r_1^2}{r_1^2 - r_2^2}, K_2 = \frac{r_2^2}{r_1^2 - r_2^2} \quad (5-10)$$

由此可得到：通过将两个已知半径为 r_1 、 r_2 的同心圆环靶标，对其拍摄后，它们在像平面上成为两个中心不同的椭圆；椭圆检测算法确定出两个椭圆中心 (x_{B1}, y_{B1}) ， (x_{B2}, y_{B2}) ；通过式 5-10 对椭圆中心 (x_{B1}, y_{B1}) ， (x_{B2}, y_{B2}) 线性组合，得到圆环靶标投影后圆心校正坐标 (x_c, y_c) ，为位姿参数估计提供准确投影后圆环圆心坐标。

5.2.3 位姿参数估计

将椭圆方程 5-6 带入摄像机坐标系中 Z_W 轴方向的计算公式 5-5，并根据针孔投影模型推导出以下关系：

$$T_X = \frac{T_z x_c}{f} \quad \text{and} \quad T_y = \frac{T_z y_c}{f} \quad (5-11)$$

由此可得等式 5-12：

$$Q' = \begin{bmatrix} \alpha_1^2 & -\alpha_1^2 r_2^2 & (\alpha_1^2 + \alpha_2^2) y_c^2 + 2\alpha_2 \alpha_3 y_c + \alpha_3^2 \\ 2\alpha_1 \alpha_2 & -2\alpha_1 \alpha_2 r_2^2 & -2(\alpha_2 \alpha_3 x_c + (\alpha_1^2 + \alpha_2^2) x_c y_c + \alpha_1 \alpha_3 y_c) \\ \alpha_2^2 & -\alpha_2^2 r_2^2 & (\alpha_1^2 + \alpha_2^2) x_c^2 + 2\alpha_1 \alpha_3 x_c + \alpha_3^2 \\ -2\alpha_1 (\alpha_1 x_c + \alpha_2 y_c) & -2\alpha_1 \alpha_3 r_2^2 & -2\alpha_3 (\alpha_3 x_c + \alpha_2 x_c y_c - \alpha_1 y_c^2) \\ -2\alpha_2 (\alpha_1 x_c + \alpha_2 y_c) & -2\alpha_2 \alpha_3 r_2^2 & -2\alpha_3 (-\alpha_2 x_c^2 + \alpha_1 x_c y_c + \alpha_3 y_c) \\ (\alpha_1 x_c + \alpha_2 y_c)^2 & -\alpha_3^2 r_2^2 & \alpha_3^2 (x_c^2 + y_c^2) \end{bmatrix} \quad (5-12)$$

其中

$$\alpha_1 = \frac{2Ax_c + By_c + D}{2} \quad \alpha_2 = \frac{Bx_c + 2Cy_c + E}{2} \quad \alpha_3 = \frac{Dx_c + Ey_c + 2F}{2} \quad (5-13)$$

因此，图像坐标系下的外圆 5-4 可以表示为式 5-14，内窥镜内参通过标定已知，因此需要计算的未知数是 T_z^2 ，其中 $G = [x^2 \quad xy \quad y^2 \quad x \quad y \quad 1]^t$ 。为了便于求解，将公式 5-14 常数项保留在展开式的右侧，则得到式 5-15：

$$C'(x, y) = \left(Q' \begin{bmatrix} f^2 \\ f^2/T_z^2 \\ 1 \end{bmatrix} \right)^t G = 0 \quad (5-14)$$

$$\left(\begin{bmatrix} q_{11} & q_{21} & q_{31} & q_{41} & q_{51} & q_{61} \\ q_{12} & q_{22} & q_{32} & q_{42} & q_{52} & q_{62} \end{bmatrix} G \right)^t \begin{bmatrix} f^2 \\ f^2/T_z^2 \end{bmatrix} = - \begin{bmatrix} q_{13} & q_{23} & q_{33} & q_{43} & q_{53} & q_{63} \end{bmatrix} G \quad (5-15)$$

其中 q_{ij} 是矩阵 Q' 第 i 行第 j 列的元素。

根据本文第三章节和第四章节实现的椭圆检测算法，得到目标图像中椭圆边界，根据检测结果建立一个 N 次超定方程 $WX = B$ ，如式 5-16 所示：

$$\begin{bmatrix} W_{11} & W_{12} \\ W_{21} & W_{22} \\ \vdots & \vdots \\ W_{N1} & W_{N2} \end{bmatrix} \begin{bmatrix} f^2 \\ \frac{f^2}{T_z^2} \end{bmatrix} = \begin{bmatrix} B_1 \\ B_2 \\ \vdots \\ B_N \end{bmatrix} \quad (5-16)$$

其中 W_{i1} 、 W_{i2} 和 B_i 使用 5-15 计算， (x, y) 用检测到的椭圆边界上像素点的坐标位置 (x_i, y_i) 代替。该超定方程可用最小二乘违逆方法求解得到 T_z ，从而可以从式 5-11 求解 T_x 和 T_y 。

至此，包含圆环平面的法线 ($\mathbf{R}_3$) 和世界坐标系中摄像机坐标原点位置 ($\mathbf{T}$) 已知。将给定图像中 $\mathbf{X}_w$ 轴标记的像素坐标重投影到同心圆的平面上，该平面由其法线 ($\mathbf{R}_3$) 和其上的一个点 ($\mathbf{T}$) 定义。记 X 轴标记的位置在世界坐标系中为 $(r_3, 0, 0)$ ，在图像坐标中为 (x_m, y_m) ，在摄像机坐标中为 $\mathbf{X}_m$ ，则 $\mathbf{X}_m = \mu [x_m y_m f]^t$ ，其中 μ 为式 5-17 所示，且 $D = -\mathbf{R}_3^t \mathbf{T}$ 。

$$\mu = \frac{-D}{R_{13}x_m + R_{23}y_m + R_{33}f} \quad (5-17)$$

在摄像机坐标系中给出了 $\mathbf{X}_w$ 轴标记的三维坐标，以及在摄像机坐标系下给出的世界坐标系中原点的三维坐标后， $\mathbf{X}_w$ 轴（或 $\mathbf{R}_1$ ）由 $\mathbf{X}_w = N \{\mathbf{X}_m - \mathbf{T}\}$ 定义，其中 N 是归一化算子。显然，在右手坐标系中 $\mathbf{Y}_w = \mathbf{Z}_w \times \mathbf{X}_w$ 或 $\mathbf{R}_2 = \mathbf{R}_3 \times \mathbf{R}_1$ 。

5.2.4 主点恢复

到目前为止，上述的讨论基于一个假设：摄像机的光轴正好对准图像的中心，也就是说摄像机的主点位于图像中心。但由于镜头畸变和制造误差等，实际位置可能会有所偏移，因此在这一节将放弃这一假设，利用上述过程来重新确定主点的实际位置。

实际上，对主点位置的估计并不总是准确的，而且直接使用之前计算出的参数对原始圆进行重投影，通常无法与原图像中椭圆边界重合，这种误差正比于估计主点位置时的误差大小。为了精确恢复主点位置，需要最小化这种误差。

恢复主点后，可以利用恢复的参数将半径为 r_2 的圆重投影为图像上的椭圆。重投影误差可以定义为校准椭圆的中心与重投影椭圆的中心之间的距离，或者定义为两个椭圆的主轴之间的角度差异，通过最小化重投影误差能够近似地计算出主点的位置，具体的算法步骤如下：（1）从图像中心作为主点的初始猜测开始；（2）基于假

设的主点位置，定义图像上的椭圆和 X 轴标记；(3) 对相机进行标定；(4) 利用步骤 (3) 中得到的参数，对原始圆（半径为 r_2 ）进行重投影；(5) 计算重投影误差，并据此调整主点位置。

至此，完成了对世界坐标系和摄像机坐标系之间的相对转换，通过逆变换即可以实现微型平面靶标相对于摄像机的位姿参数估计。

5.3 实验设计及结果分析

本节专注于对狭小空间中基于椭圆检测的姿态估计方法进行实验验证和结果分析。首先，将介绍实验所依赖的软硬件环境以及具体的实验装置。紧接着，详细说明整个实验过程的设计方案，并对基于椭圆特征的姿态估计方法的各个组成部分进行实验验证。此外，通过对姿态参数结果的可视化展示和精确度评估，全面验证了该姿态估计算法的鲁棒性和准确性。

5.3.1 实验环境

实验所采用的硬件设备除了前文所介绍的模拟狗头口腔咽喉模型、定制 1080P 高清医用单目内窥镜、末端执行器、特殊定制圆环靶标外，在本章节的实验中还需要使用 SWEBO 千分尺微动云台和高精度硬质棋盘格标定板，如下图所示 5.3。




图 5.3 微动云台与高精度硬质棋盘格标定板

SWEBO 千分尺微动云台是专为位姿估计实验所使用的设备，其主要作用是提供在 X-Z 双轴方向上的可参考真实位移数据，以便对算法的精度进行评估。此微动云台具备毫米级的调节行程，并且调节精度高达 0.01 毫米，通过手动操作能够实现极为精准的毫米级位移调节。同时该云台还能够支持单轴（前后移动）或双轴（前后和左右移动）的组合调节，为实验提供了稳定的装置位移运动，从而为位姿估计算法精度评估提供了准确的数据支持。

GT0080-5 高精度硬质光学棋盘格标定板整体外型尺寸为 80×80 平方毫米,有效棋盘格标定面积为 60×45 平方毫米,内部棋盘格采用 12×9 的黑色小正方形阵列组成,小正方形边长为 5 毫米,最高精度偏差在 $1\mu m$ 范围以内。

实验环境主要分为两部分,常规室内环境和模拟狗头口腔咽喉模型环境。在室内环境下,通过使用 SWEBO 千分尺微动云台,为检测目标提供多视角、多位置的精确位姿值,以便对本章提出的位姿估计算法精度进行评估;而 3D 打印的狗头口腔咽喉模型内部空间狭小,尺寸仅能放入一个乒乓球,旨在模仿末端执行器进入人体口腔咽喉区域的实际操作环境以及其他小规模应用场景,在该环境下通过检测与末端执行器一体的圆环靶标边界并获得相应位姿参数,完成对末端执行器的位姿参数估计,获得末端执行器相对于医用内窥镜的位置。

本章节算法代码使用 Python 实现,其中基于高斯建议网络的椭圆检测算法使用 PyTorch 框架搭建,并使用一个 GeForce RTX 3090 GPU 进行训练,将训练后的模型转换为 ONNX (Open Neural Network Exchange) 格式,部署于相同硬件资源的实验主机上,算法同样运行在 Intel 酷睿 i7-7500U、2.7GHz CPU 和 32GB 内存的处理器上。

5.3.2 实验方案设计

基于椭圆特征的相机位姿估计算法通过分析圆环靶标的针孔投影模型及其成像原理,使用弧线结构和 2-WD 损失改进的椭圆检测算法共同完成对成像区域内圆环靶标的检测,获得靶标边界,同时针对圆环靶标投影后圆心坐标不一致问题专门完成对圆环圆心坐标校正,以求获得准确圆心坐标,并依靠先验知识如内窥镜内参、圆环靶标尺寸共同完成对圆环靶标相应位姿参数估计任务。

因此为了评估本文提出方法的有效性与鲁棒性,本研究首先对算法中椭圆检测、圆环圆心校正及内窥镜内参标定这三个关键中间步骤进行实验验证:(1) 基于第三章和第四章提出的两种椭圆检测算法,对图像中的圆环椭圆边界进行了检测,并使用精确率、召回率和 F 值等评价指标对检测结果进行了对比分析;(2) 针对投影变换后导致圆环靶标内圆心偏移问题,提出了一种有效的圆环圆心校正方法,并通过一系列仿真实验验证了该方法的有效性;(3) 为了提高后续位姿估计方法的计算精度并避免误差累积,使用 Matlab 的相机标定工具对高精度的硬质棋盘格标定板进行了标定,获取了内窥镜的相机内参,计算重投影误差进行比较。在对这些模块进行单独验证的基础上,进一步通过设计实验综合评估了所提出方法的整体性能。

口腔咽喉场景下的目标位姿参数真值难以获取是该任务的难点之一,同时受到实验条件的限制,无法获得该时刻相机与目标之间的相对位置,也因此无法获得精确的精度评估。

针对此问题,本文使用 SWEBO 千分尺微动云台解决获取对当前环境的目标位

姿估计实验方案：在室内环境中，通过人工设置微动云台控制下的目标运动路径和距离，充分利用微动云台的双轴运动功能。具体来说，云台可以在千分尺旋钮的精确调节下，沿其导轨在 X 轴和 Z 轴两个方向上实现平滑的水平位移，将圆环靶标固定于云台通过读取千分尺的精细刻度，精确捕捉到目标在移动过程中的位姿变化，即可准确获得目标相对于相机的位姿参数的真实变化值。固定医用内窥镜位置，采集目标运动前后的关键数据，使用本节所提出的方法对目标运动前后的位姿参数求解，比较求出的位姿参数与实际运动的位姿变化量，用来评估位姿估计参数的精度，具体使用公式 5-18 衡量位姿参数中平移向量的平均误差，其中 $\|\cdot\|_2$ 表示 L2 范数， t_i^0 和 t_i^{end} 表示靶标移动前后的平移向量， dis_i 为经过千分尺微动云台测量获得的相对移动距离。

$$Error_t = \frac{1}{N} \sum_i \left| \|t_i^{end} - t_i^0\|_2 - dis_i \right| \quad (5-18)$$

考虑到双轴千分尺微动云台仅支持在两个水平方向上进行位移控制，为了全面评估目标姿态估计性能，本实验设计中特意将目标平面相对于相机成像面的倾斜角度进行了预设，确保测试覆盖不同的目标方向（与云台运动方向保持一致），通过这种方式在实验中考察目标旋转矩阵估计的准确性和稳定性。具体使用公式 5-19 衡量位姿参数中旋转矩阵的平均误差，其中 ω_i^0 ， ω_i^{end} 分别为圆环靶标运动前后其旋转矩阵在李代数空间的表示， $\hat{\omega}$ 为预设的圆环靶标平面与相机成像面之间倾斜角度。

$$Error_\omega = \frac{1}{2N} \sum_i (\|\omega_i^0, \hat{\omega}\|_2 + \|\omega_i^{end}, \hat{\omega}\|_2) \quad (5-19)$$

5.3.3 实验模块分析

(1) 椭圆检测算法

位姿参数的估计依赖于狭小空间内图像中富含的椭圆靶标特征提取效果，因此在第三、四章节实现的两种不同椭圆检测算法尽管已经通过大量的实验验证其算法的高效性、有效性，仍需在本章节的使用场景下对其进行相关印证。

正常室内环境下使微动云台携带定制圆环靶标，在千分尺旋钮的精确调节下，沿其导轨在 X 轴和 Z 轴两个方向上实现平滑的水平位移，同时在此运动过程中固定内窥镜位置并使用内窥镜采集图像，使用本文论述的基于弧线结构和 2-WD 损失改进的椭圆检测算法，对该运动过程中收集到的图像检测圆环靶标的效果。表 5.1 具体显示了对该过程中收集到的图片使用基于弧线结构和 2-WD 损失改进的椭圆检测算法后，对其检测效果的具体评价指标参数。

由该表可看出，在此次实验中基于弧线结构和 2-WD 损失改进的椭圆检测算法，

表 5.1 室内环境中使用两种椭圆检测算法检测性能评估

检测方法	评估指标			
	精确率	召回率	F 值	检测时间
弧线结构	0.8568	0.8704	0.8636	0.1438
2-WD	0.9286	0.9354	0.9320	0.2524

评估指标相对前两章节中使用的 TY 数据集均产生约 3% 的数值提升,这是因为在该室内场景中仅有单一目标靶标,没有口腔咽喉内部复杂的背景级纹理特征。竖向对比 2-WD 损失改进在检测时间上略微长于弧线结构的椭圆检测方法,但在精确率、召回率和 F 值上有更出色的表现,说明基于 2-WD 损失改进的检测算法对于圆环靶标检测的更为准确和有效,基于弧线结构的椭圆检测在时间上占据优势。因此使用这两种算法对后续位姿参数估计能提供非常可靠的椭圆特征,提高位姿参数估计的可靠性,避免误差累积现象。

(2) 圆环圆心矫正

为了验证所提出的圆环圆心校正方法的有效性和鲁棒性,进行了以下仿真:首先,生成半径和圆心位置已知的同心圆环,经过模拟摄像机投影变换后,它们成为两个大小不同且圆心不重合的椭圆。为了得到真实的仿真结果,在仿真图像平面的椭圆上加入随机噪声,如图 5.4所示。通过投影变换,得到理想的投影图像圆心;通过椭圆检测算法得到两个椭圆中心,然后使用所提出的校正算法对误差进行校正。最后,将校正中心与理想中心进行比较。




图 5.4 同心圆与加入噪声投影变换后图像

为了完成数值模拟,必须选择一定的几何参数。因此,假设仿真参数如下:设置同心圆圆心在世界坐标 (100,0,0) 上,较大圆的半径从 5mm 变为 40mm,较小圆的半径为较大圆的一半。摄像机分辨率为 1920×1280 ,焦距 c 为 12mm,拍摄角度为 45° ,摄像机坐标系原点与世界坐标系原点的距离为 800mm。在实际应用中,摄像机的信噪比大于 42dB,在仿真中,模拟图像中加入的最大噪声强度为 -50dB。(若信号强度为 1,则 -40dB 噪声为随机噪声,标准差为 0.0001)。

对每组不同噪声强度的模拟图像,重复实验 20 次,通过简单的统计分析,可以

得到较大和较小椭圆的偏心误差。校正后得到的误差是校正结果与理想投影中心的差值，仿真实验结果如下表所示。

表 5.2 圆心校正结果对比

噪声	大圆半径 (mm)	小圆半径 (mm)	校正前偏心误差 (pixel)		校正后误差
			大圆	小圆	
-40	5	2.5	0.1864	0.0452	0.0019
	10	5	0.7503	0.1859	0.0072
	20	10	3.0037	0.7508	0.0048
	40	20	6.7689	1.6897	0.0087
-45	5	2.5	0.1867	0.0465	0.0056
	10	5	0.7485	0.1818	0.0085
	20	10	3.0028	0.7496	0.0143
	40	20	6.7697	1.6904	0.0065

通过该模块的仿真分析实验证明了该方法的实用性和鲁棒性，能够切实解决投影变换后圆环靶标圆心偏移的问题，得到真实的投影图像中圆心坐标。

(3) 相机内参标定

基于椭圆特征的目标位姿估计方法依赖于焦距、畸变系数等内窥镜内在参数，因此为获得目标位姿估计的准确值，需要对实验中所使用的内窥镜设备进行标定。在本研究的实验部分采用了张正友的相机标定法^[58]，使用型号为 GT0080-5 的高精度光学玻璃标定板棋盘格标定板进行内窥镜参数标定，Matlab 和 OpenCV 中均有提供相机标定的相关工具箱。本文在标定内参算法测试中就采用了 Matlab 的 Camera Calibrator 相机标定工具箱，进行内窥镜内参数的估计。



图 5.5 多视角高精度棋盘格标定板

在标定过程中，内窥镜需要从多个不同角度对标定板进行拍摄，以此覆盖板上不

同位置和角度，从而增加求解标定方程的数量和独立性。同时，为了确保高精度的棋盘格特征提取，需要保障图像的质量，包括图像的清晰度和焦点的准确性，每次标定中都会选择 20 张标定图像，如图 5.5 展示了从部分视角拍摄的高精度标定板。

表格 5.3 是使用 matlab 的相机标定工具箱和高精度棋盘格标定板对医用单目内窥镜内参的具体参数：

表 5.3 内窥镜标定结果表

相机参数	医用单目内窥镜
焦距	[1268.3950, 1253.9988]
主点	[912.0612, 540.2622]
径向畸变系数	[-0.3620, 0.1770, -0.0644]
切向畸变系数	[-0.0010, -0.00015]

如图 5.6 所示为使用 Matlab 相机标定工具箱进行医用单目内窥镜相机标定的可视化结果，其中左图表示以相机位置为参考的高精度标定靶标姿态，右图为以标定靶标位置为参考的相机姿态。




图 5.6 医用单目内窥镜相机标定可视化

相机标定后获得内窥镜内参和畸变参数的计算结果之后，通过这些参数可以建立一个基于针孔摄像机模型的单目成像系统。此系统能够将空间中的三维点映射到成像平面上的二维像素点，在实验阶段，通过将这些理论上计算出的投影像素点坐标与从实际图像中提取的特征点像素坐标进行对比，计算出重投影误差，这个重投影误差能够用来评价以相机内参为基础构建的成像模型的准确性。

图 5.7 展示了利用 Matlab 相机标定工具箱完成一次标定所得到的重投影误差统




图 5.7 医用单目内窥镜内参标定误差

计直方图，其中 20 张标定图像的平均重投影误差为 0.57 像素，小于一般基准标定误差 0.7 像素，这说明实验中通过高精度棋盘格标定获取的相机内参数结果是成功的。

5.3.4 位姿参数精度评估

本研究旨在验证文中提出的基于椭圆检测的姿态估计方法的准确性与适用性，实验在室内环境中进行，主要采用精密的千分尺微调台和内窥镜相机作为实验工具。

首先将一个装有圆环靶标的刚体目标安装在千分尺微动云台上。接着，通过操作千分尺微动云台，使得圆环靶标沿着水平方向（ X_w 轴）和深度方向（ Z_w 轴）执行线性移动，创建两种独立的运动路径。由于千分尺的测量范围限制，设置目标的移动距离为 3mm、5mm、8mm、10mm 不同的长度，在目标移动期间，内窥镜相机固定不动，持续对目标进行拍摄。通过读取千分尺的刻度变化，可以准确获得目标在移动前后的位移量，即实际位移距离。同样通过设置靶标与内窥镜之间夹角（ 0° 、 30° 、 60° ），当作旋转的实际角度。然后应用本节所提出的位姿估计算法处理圆环靶标移动前后的图像，从而解算出位姿参数中位移向量和旋转矩阵的估计值。通过将估计的位移向量与实际位移距离、估计的旋转角度和实际旋转角度对比，可以评估该方法在估计位移向量上的性能。

(1) 位姿参数估计可视化

Pangolin 是一个轻量级的、便于使用的开源库，主要用于管理和显示 OpenGL 图形界面，其提供了一系列窗口管理、3D 导航、视频流处理和实时数据绘图功能等工具。图 5.8 和图 5.9 展示了利用 Pangolin 库，在微调千分尺云台的精确控制下，圆环靶标沿 x 轴的水平方向和 z 轴的景深方向分别移动 5mm 过程中，基于椭圆检测的目标位姿估计的可视化结果。以内窥镜当前的空间位置和姿态为参照，圆环靶标的成像平面由青色矩形框表示，而相机的 X 轴、 Y 轴、 Z 轴分别用红色、绿色和蓝色线段标

识。两幅图的左侧均展示了相机相对于靶标的姿态，右侧则显示了相机相对于靶标的整体运动轨迹，明显可见，在云台的精准稳定操控下，该运动轨迹形成了一条直线，验证了本文所提出的位姿估计方法的有效性。




图 5.8 基于 Pangolin 的靶标运动及轨迹可视化-x 轴




图 5.9 基于 Pangolin 的靶标运动及轨迹可视化-z 轴

为了进一步验证本文所提出的位姿估计方法的可行性与稳定性，我们在 3D 打印的狗头模型内进行了实验。首先，通过搭载本文设计的圆环靶标的末端执行器，模拟手术操作并采集视频数据。然后，使用本文提出的方法逐帧估计位姿参数，将结果作为参考值。接着，将连续帧目标位姿作为预设轨迹，令目标沿该轨迹运动。图 5.10 展示了 3D 打印狗头模型中圆环靶标沿导航路径运动的可视化结果。左图显示了 3D 点云可视化结果中的目标轨迹，右图为口腔咽喉部分的目标轨迹放大图。二维红色矩形框表示圆环靶标的实际运动轨迹。

(2) 位姿参数精度比较

为了衡量本节所提出的目标位姿参数估计方法的性能，本实验采用了四种标准评价指标：平均误差（ME）、均方根误差（RMSE）、标准差（SD）以及 95% 置信区间（95%CI），这些指标分别衡量了方法的准确性、精度、稳定性以及结果的可信




图 5.10 预设轨迹引导的位姿参数估计结果可视化

度。具体而言,平均误差表示实验中估计位姿与实际位姿间的平均偏差,均方根误差基于估计位姿与实际位姿差值的平方和的均值开方计算,而标准差描述了实验结果的波动程度,95% 置信区间则说明,在 95% 的置信水平上多次实验结果的真值落在该区间的可能性,从而反映了结果的可靠性。为了减少实验偶然性,采取对多次实验结果进行平均处理操作。此外,根据 5.3.2 节中介绍的指标 $Error_r$,对比目标物体运动前后的旋转矩阵估计值与实际值之间的平均差异,进一步评价了所提方法在旋转矩阵估计方面的相对稳定性。

本文使用不同椭圆检测算法(弧线结构和 2-WD 损失改进)进行圆环靶标检测后,获取到椭圆边界信息,同时为了评估圆环圆心校正模块对于整体目标位姿估计算法的影响,分别进行了多次对比实验,实验采用四种标准评价指标对其性能进行评估,如表 5.4 所示,其中平移向量 $\mathbf{T}$ 的评估指标单位为毫米(mm),旋转矩阵 $\mathbf{R}$ 的相关指标单位为角度($^{\circ}$)。

表 5.4 不同椭圆特征提取的目标位姿估计方法性能结果表

检测算法	有无圆心校正	平移向量			旋转向量		
		ME_T	$RMSE_T$	SD_T	ME_R	$RMSE_R$	SD_R
弧线结构	无	0.091	0.093	0.007	4.95	4.88	0.79
	有	0.069	0.068	0.005	4.12	4.05	0.38
2-WD	无	0.053	0.055	0.029	4.68	4.72	0.75
	有	0.045	0.048	0.021	3.95	3.97	0.31

从表 5.4 分析可知,该方法在正常室内环境中,对于位姿参数估计都有着较为优异的表现,平移向量的 ME 和 RMSE 均在 0.095mm 范围内,旋转矩阵的 ME 与 RMSE 均在 4.95° 内,因此该算法也具有较高的稳定性。首先对比两种检测算法所提取的椭圆特征对目标位姿参数估计的影响,使用 2-WD 损失改进的椭圆边界特征提取的算法

相对弧线结构特征的算法对应的目标位姿参数中平移向量的指标下降约 0.03mm，旋转矩阵的估计值也下降约 0.02°，这主要得益于 2-WD 算法对椭圆检测的高效性，能够准确提取到图像中目标的椭圆特征。同时分析圆环靶标圆心校正模块，不论是基于弧线结构的椭圆检测算法，还是基于 2-WD 损失改进的椭圆检测算法，经过投影圆心校正之后的平移向量相应评估指标基本下降 0.015mm，旋转矩阵的估计值也同样下降约 0.08°，这同样证明了圆环圆心校正模块对于目标位姿参数估计的重要性。

表 5.5 给出了不同位移距离对应各方法的平移距离估计的 95% 置信区间表。综合表 5.4 和表 5.5 来看，依据平移距离估计结果的 95% 置信区间也同样证明了该方法的可靠性。

表 5.5 不同位移距离对应各方法的平移距离估计 95% 置信区间表

指标	检测算法	圆心校正	平移距离			
			3mm	5mm	8mm	10mm
95%CI	弧线结构	无	2.952 ±0.002	4.947 ±0.006	7.978 ±0.001	9.948 ±0.006
		有	2.948 ±0.001	4.912 ±0.002	7.941 ±0.008	9.901 ±0.005
	2-WD	无	2.950 ±0.001	4.933 ±0.004	7.952 ±0.004	9.932 ±0.003
		有	2.945 ±0.004	4.907 ±0.001	7.938 ±0.003	9.899 ±0.005

5.4 本章小结

在本章节中，实现了狭小空间内基于椭圆检测的目标位姿估计方法。具体地说，通过本文第三章、第四章实现的基于弧线结构和 2-WD 损失改进的椭圆检测算法，提取出末端执行器所在图像内包含的圆环靶标的椭圆边界信息，在圆环的针孔投影模型下，依靠已知靶标尺寸与椭圆检测算法获得靶标边界特征，对投影后圆环靶标圆心坐标校正，根据相应几何约束关系计算出相机的姿态参数，包括平移向量与旋转向量。最后通过模块实验与综合实验结合的验证方法，均证明了所提出方法的有效性，具有较高的精度与鲁棒性，能够针对狭小空间内获取得到手术机器人末端执行器位姿参数，为引导末端机器人在该空间内精准运动提供有效算法支撑。

第六章 总结与展望

6.1 本文工作总结

近年来,手术机器人技术实现了突破性发展,有力推动了手术流程多个维度的大幅提升。在实施手术操作时,对手术机器人的动作精准度要求近乎苛刻,确保在切除病灶或修复损伤的同时,最大限度避免对周边正常组织和器官造成任何潜在伤害。通过运用位姿估计技术,手术机器人能实时且准确无误地掌握其末端执行器的具体三维位置和姿态信息,从而能够在进行诸如切割、缝合等复杂医疗操作时实现精确定向操控。

但鉴于在本文实际应用场景口腔咽喉这一狭小空间内,完成对末端执行器的检测及位姿估计面临诸多挑战,本研究从传统目标检测和深度学习的角度出发,分别实现了基于弧线结构的椭圆检测算法和采用 2-WD 损失改进的算法,用以获取椭圆边界特征,并依此进行位姿解算,并通过一系列实验,验证了所提算法的有效性。因此本研究的主要贡献总结如下:

(1) 本文专门设计了一种微型的高精度圆环靶标,适配外科手术的需求,并巧妙地集成到末端执行器中,以保证靶标动作与执行器同步。利用这些显著的靶标特征,能够间接而精确地对末端执行器进行检测。此外,利用这一特制的圆环靶标,本文创建了一个模拟真实口腔咽喉环境的狭小空间高精度圆环靶标数据集,该数据集包括了各种复杂条件下的图像,如变化的光照条件、组织遮挡和抖动模糊等,并对数据集中的图像进行了精确标注,为算法的性能评估提供了大量高质量的实验数据。因此,该方法主要解决了口腔咽喉空间内壁组织表面纹理特征极度匮乏并附着大量组织液,同时末端执行器种类繁多且几何形状复杂难以检测的问题。

(2) 本文第二个研究内容为针对检测自行设计的圆环靶标,实现了一种基于弧线结构的传统椭圆检测算法。该方法首先采用边缘检测算法来精确识别图像中存在的边缘弧线结构。紧接着,在满足特定角度范围和相邻弧线间角阈值的前提下,将连续的弧线段连接成弧线段组合。同时采用并行计算机制,结合局部细致搜索与全局优化策略,筛选出既遵循极性规律又适应所在区域边界,并满足动态内点条件的高质量弧线段对,初步构建起一系列可能的椭圆轮廓模型。随后,通过实施分层聚类方法,对各个椭圆的参数空间分析与整合,去除冗余和重复的椭圆拟合结果,进而提炼出一个包含多样但不重叠的候选椭圆集合。最后,对这个候选椭圆集进行全面而严格的验证与评估,确保整个算法不仅在执行效率上表现优异,而且在识别椭圆精度上达到高标准,从而保证了最终结果的可靠性和准确性。

(3) 本文第三个研究内容为针对检测所设计的圆环靶标, 实现的一种基于 2-WD 损失改进的深度学习椭圆检测算法。本方法在 Faster R-CNN 框架上实现了针对椭圆边界预测的 GPN, 具体来讲, GPN 通过将椭圆边界建模成图像平面上的二维高斯分布, 并最小化候选椭圆与真实椭圆之间的高斯分布差异, 来精准预测椭圆的位置。同时, GPN 架构中加入了 RoI 池化和回归分支, 进一步扩展功能。此外, 还引入了 2-WD 损失函数用于椭圆候选区域的精细化处理, 使得算法能够在复杂背景中准确地检测出圆环靶标。

(4) 本文第四个研究内容为基于椭圆检测的位姿估计模型。通过详细分析安装在末端执行器上的圆环靶标, 在经过针孔相机模型成像后形成的椭圆形状, 并采用了基于弧线结构与 2-WD 损失改进的椭圆检测算法来识别成像平面中的圆环靶标, 从而提取出椭圆边界的特征信息。通过运用这些检测到的椭圆边界特征, 并结合圆环靶标的已知尺寸信息, 对圆环投影的中心坐标进行了精确的校正。最后, 本文综合应用了内窥镜的已知内参、椭圆边界的特征信息以及校正后的圆心坐标真值, 以实现末端执行器在狭小空间内位姿参数的精确估计, 从而显著提高了位姿估计的精度和可靠性。

(5) 本文的第五部分专注于对提出算法的实验验证。第一部分为两种椭圆检测算法的实验分析, 通过在多个数据集上进行广泛的实验, 首先单独测试了基于弧线结构和 2-WD 损失改进的椭圆检测算法, 利用不同的参数配置和检测方法, 全面评估了各自的性能表现。随后, 将这两种方法进行直接比较, 特别是在本研究自主构建的狭小空间高精度圆环靶标数据集上, 基于弧线结构的算法在处理速度上显示出了明显的优势, 而采用 2-WD 损失改进的算法在精确度上实现了 86.31% 的显著成果。此外, 为进一步评估这两种椭圆检测算法的泛化性, 本研究也将其应用于覆盖中到大尺度目标特征的公开数据集, 均获得了良好的效果。第二部分为基于两种椭圆检测算法的位姿估计算法实验验证, 通过借助特殊仪器设备进行大量实验分析及验证, 本位姿估计方法展示了出色的性能, 其中平移分量的最佳平均误差为 0.045mm, 旋转矩阵的最佳平均误差达到 3.40°。这项工作为在复杂手术环境中执行精确的目标检测与位姿估计提供了有效的方法和技术支持, 有望显著提升微创手术的精度与安全性。

6.2 后续工作展望

本研究在口腔咽喉等小尺度场景下的目标检测及位姿参数估计方面取得了一定的进展, 但仍存在一些局限性。尽管微型靶标的设计是对特定场景下目标检测与位姿估计的折中解决方案, 但当前方法依赖于定制圆环靶标, 这可能限制了算法在没有这些靶标的环境中的应用。针对上述不足, 未来的研究还可以在以下方面进行探索:

(1) 丰富和多样化数据集: 现有的狭小空间场景数据集在物体种类和场景复杂度

方面相对简单。为了增强算法的鲁棒性和适用范围，未来需要构建包括更多物体种类和更复杂场景的数据集，这将有助于算法学习更多样的特征，以便更稳定可靠地应用于实际情境。

(2) 算法优化和泛化：虽然本研究已通过特定数据集验证了算法的有效性，但算法的优化和泛化能力仍有提升空间。未来研究可以探索更高效的优化策略，以及通过增强学习等技术进一步提高算法在未知或变化环境中的适应性和稳定性。

(3) 多模态数据集构建：考虑到狭小空间内的目标检测与位姿估计受多种因素影响，未来研究可以着手构建包含更多模态信息的数据集，如深度信息、纹理信息等，以丰富算法的训练基础，并探索多模态数据融合技术在此类任务中的应用潜力。

通过以上方向的持续探索和努力，未来的工作有望在手术机器人的目标检测和位姿估计技术方面实现更大的突破，为提高手术效率和患者安全做出更加重要的贡献。

参考文献

- [1] 桂圆圆, 翟俊萌. 工业机器人发展现状与发展趋势[J]. 科技风, 2020(21): 1.
- [2] DUDA R O, HART P E. Use of the Hough transformation to detect lines and curves in pictures[J]. Communications of the ACM, 1972, 15(1): 11-15.
- [3] XU L, OJA E, KULTANEN P. A new curve detection method: randomized Hough transform (RHT) [J]. Pattern recognition letters, 1990, 11(5): 331-338.
- [4] MCLAUGHLIN R A. Randomized Hough transform: improved ellipse detection with comparison [J]. Pattern Recognition Letters, 1998, 19(3-4): 299-305.
- [5] KÄLVIÄINEN H, HIRVONEN P, XU L, et al. Probabilistic and non-probabilistic Hough transforms: overview and comparisons[J]. Image and vision computing, 1995, 13(4): 239-252.
- [6] LU W, TAN J. Detection of incomplete ellipse in images with strong noise by iterative randomized Hough transform (IRHT)[J]. Pattern Recognition, 2008, 41(4): 1268-1279.
- [7] LUKAC R, PLATANOTIS K N. Color image processing: methods and applications[M]. CRC press, 2018.
- [8] KIM E, HASEYAMA M, KITAJIMA H. Fast and robust ellipse extraction from complicated images [C]//Proceedings of IEEE information technology and applications. 2002.
- [9] MAI F, HUNG Y, ZHONG H, et al. A hierarchical approach for fast and robust ellipse extraction [J]. Pattern Recognition, 2008, 41(8): 2512-2524.
- [10] CHIA A Y S, RAHARDJA S, RAJAN D, et al. A split and merge based ellipse detector with self-correcting capability[J]. IEEE Transactions on Image Processing, 2010, 20(7): 1991-2006.
- [11] PRASAD D K, LEUNG M K, CHO S Y. Edge curvature and convexity based ellipse detection method[J]. Pattern Recognition, 2012, 45(9): 3204-3221.
- [12] FORNACIARI M, PRATI A, CUCCHIARA R. A fast and effective ellipse detector for embedded vision applications[J]. Pattern Recognition, 2014, 47(11): 3693-3708.
- [13] JIA Q, FAN X, LUO Z, et al. A fast ellipse detector using projective invariant pruning[J]. IEEE Transactions on Image Processing, 2017, 26(8): 3665-3679.
- [14] PĂTRĂUCEAN V, GURDJOS P, von GIOI R G. Joint a contrario ellipse and line detection[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(4): 788-802.
- [15] VON GIOI R G, JAKUBOWICZ J, MOREL J M, et al. LSD: A fast line segment detector with a false detection control[J]. IEEE transactions on pattern analysis and machine intelligence, 2008, 32(4): 722-732.
- [16] LI Y. Detecting lesion bounding ellipses with gaussian proposal networks[C]//Machine Learning in

- Medical Imaging: 10th International Workshop, MLMI 2019, Held in Conjunction with MICCAI 2019, Shenzhen, China, October 13, 2019, Proceedings 10. 2019: 337-344.
- [17] LIU K, LU Y, BAI R, et al. Ellipse Detection with Applications of Convolutional Neural Network in Industrial Images[J]. Electronics, 2023, 12(16): 3431.
- [18] DONG W, ROY P, PENG C, et al. Ellipse R-CNN: Learning to infer elliptical object from clustering and occlusion[J]. IEEE Transactions on Image Processing, 2021, 30: 2193-2206.
- [19] HUANG Y P, WANG T H, BASANTA H. Using fuzzy mask R-CNN model to automatically identify tomato ripeness[J]. IEEE Access, 2020, 8: 207672-207682.
- [20] WANG T, LU C, SHAO M, et al. Eldet: An anchor-free general ellipse object detector[C]// Proceedings of the Asian Conference on Computer Vision. 2022: 2580-2595.
- [21] SINGHA A, THAKUR R S, PATEL T. Deep learning applications in medical image analysis[J]. Biomedical Data Mining for Information Retrieval: Methodologies, Techniques and Applications, 2021: 293-350.
- [22] NAM D, LAVANYA R, JAYAKRISHNAN R, et al. A deep learning approach for estimating traffic density using data obtained from connected and autonomous probes[J]. Sensors, 2020, 20(17): 4824.
- [23] LU B, XU D, HUANG B. Deep-learning-based anomaly detection for lace defect inspection employing videos in production line[J]. Advanced Engineering Informatics, 2022, 51: 101471.
- [24] DENG R, JIANG Y, TAO M, et al. Deep learning-based automatic detection of productive tillers in rice[J]. Computers and Electronics in Agriculture, 2020, 177: 105703.
- [25] 吴继春, 方海国, 阳广兴, 等. 基于最小尺寸点模型的 6D 位姿估计与机械臂抓取[J]. 计算机集成制造系统, 2022, 28(8): 2472.
- [26] 钟莹, 张蒙. 基于改进 ICP 算法的点云自动配准技术[J]. 控制工程, 2014, 21(1): 37-40.
- [27] ZHENG Y, KUANG Y, SUGIMOTO S, et al. Revisiting the pnp problem: A fast, general and optimal solution[C]//Proceedings of the IEEE International Conference on Computer Vision. 2013: 2344-2351.
- [28] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60: 91-110.
- [29] KENDALL A, GRIMES M, CIPOLLA R. PoseNet: A convolutional network for real-time 6-dof camera relocation[C]//Proceedings of the IEEE international conference on computer vision. 2015: 2938-2946.
- [30] HE Y, SUN W, HUANG H, et al. Pvn3d: A deep point-wise 3d keypoints voting network for 6dof pose estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11632-11641.
- [31] CHEN W, JIA X, CHANG H J, et al. G2l-net: Global to local network for real-time 6d pose esti-

- mation with embedding vector features[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 4233-4242.
- [32] LI H, LIN Z, SHEN X, et al. A convolutional neural network cascade for face detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 5325-5334.
- [33] YASMINA D, KARIMA R, OUAHIBA A. Traffic signs recognition with deep learning[C]//2018 International Conference on Applied Smart Systems (ICASS). 2018: 1-5.
- [34] MIRRAZAVI SALEHIAN S S, KHORAMSHAHI M, BILLARD A. A dynamical system approach for catching softly a flying object: Theory and experiment[J]. IEEE Transactions on Robotics, 2016, 32(2): 462-471.
- [35] GARCÉS Y, GUERRERO A, HIDALGO P, et al. Automatic detection and measurement of viral replication compartments by ellipse adjustment[J]. Scientific Reports, 2016, 6(1): 36505.
- [36] KIRYATI N, ELDAR Y, BRUCKSTEIN A M. A probabilistic Hough transform[J]. Pattern recognition, 1991, 24(4): 303-316.
- [37] YUEN H, ILLINGWORTH J, KITTLER J. Detecting partially occluded ellipses using the Hough transform[J]. Image and Vision Computing, 1989, 7(1): 31-37.
- [38] SHEN Z, ZHAO M, JIA X, et al. Combining convex hull and directed graph for fast and accurate ellipse detection[J]. Graphical Models, 2021, 116: 101110.
- [39] FITZGIBBON A, PILU M, FISHER R B. Direct least square fitting of ellipses[J]. IEEE Transactions on pattern analysis and machine intelligence, 1999, 21(5): 476-480.
- [40] MENKE W. Review of the generalized least squares method[J]. Surveys in Geophysics, 2015, 36: 1-25.
- [41] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. 2016: 21-37.
- [42] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [43] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [44] REN S, HE K, GIRSHICK R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [45] MASCARENHAS S, AGARWAL M. A comparison between VGG16, VGG19 and ResNet50 architecture frameworks for Image Classification[C]//2021 International conference on disruptive technologies for multi-disciplinary research and applications (CENTCON): vol. 1. 2021: 96-99.

- [46] BODLA N, SINGH B, CHELLAPPA R, et al. Soft-NMS—improving object detection with one line of code[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5561-5569.
- [47] DUTTA A, ZISSERMAN A. The VIA annotation software for images, audio and video[C]//Proceedings of the 27th ACM international conference on multimedia. 2019: 2276-2279.
- [48] ROSIN P L. Ellipse fitting using orthogonal hyperbolae and Stirling's oval[J]. Graphical Models and Image Processing, 1998, 60(3): 209-213.
- [49] CHENG Y. Mean shift, mode seeking, and clustering[J]. IEEE transactions on pattern analysis and machine intelligence, 1995, 17(8): 790-799.
- [50] ZHANG L, HUANG X, FENG W, et al. Consistency-based ellipse detection method for complicated images[J]. Optical Engineering, 2016, 55(5): 053105-053105.
- [51] LU C, XIA S, HUANG W, et al. Circle detection by arc-support line segments[C]//2017 IEEE International Conference on Image Processing (ICIP). 2017: 76-80.
- [52] ZHANG S, ZHU X, LEI Z, et al. S3fd: Single shot scale-invariant face detector[C]//Proceedings of the IEEE international conference on computer vision. 2017: 192-201.
- [53] LIU L, PAN Z, LEI B. Learning a rotation invariant detector with rotatable bounding box[J]. arXiv preprint arXiv:1711.09405, 2017.
- [54] ARJOVSKY M, CHINTALA S, BOTTOU L. Wasserstein generative adversarial networks[C]//International conference on machine learning. 2017: 214-223.
- [55] OLKIN I, PUKELSHEIM F. The distance between two random vectors with given dispersion matrices[J]. Linear Algebra and its Applications, 1982, 48: 257-263.
- [56] KAREN S. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv: 1409.1556, 2014.
- [57] HE D, LIU X, YIN Y, et al. Correction of circular center deviation in perspective projection[C]//Applications of Digital Image Processing XXXV: vol. 8499. 2012: 625-631.
- [58] ZHANG Z. Flexible camera calibration by viewing a plane from unknown orientations[C]//Proceedings of the seventh IEEE international conference on computer vision: vol. 1. 1999: 666-673.