

第二章

基础知识

机器学习概论



基于实例的系统 (Case-Based Systems, CBS)

实际情况中可能对问题的了解非常少，或基本上没有有关求解的知识

- 给定一组输入和结果


$\{(i_1, o_1), (i_2, o_2), \dots, (i_n, o_n)\}$

- 是一个问题的**实例**，则有一个简单的求解程序：

(x 是输入)

```
if x is  $i_1$  then  $o_1$ 
elif x is  $i_2$  then  $o_2$ 
...
elif x is  $i_n$  then  $o_n$ 
else "I can't handle it"
```


- 这里的实例 $\rightarrow$ 所有可能实例的一部分
- 为了更好“归纳”出规律，需要计算机进行自动推广
- 也就是“**机器学习**”



机器学习概论


- 机器学习原理与概念
- 机器学习分类
- 机器学习关键思想
- 机器学习与人工智能

➤ 语音识别 $f(\cdot)$ $=$ “你好”



什么是机器学习?


- 机器学习：通过算法使得机器能从大量数据中学习规律从而对新的样本做决策。
- 规律：决策（预测）函数




挑西瓜为例

常见的机器学习问题



回归



分类




聚类



- 给西瓜打分



- 看西瓜好坏



- 让相似西瓜抱团儿

机器学习基本概念


名词解释



- **特征**(Feature): 西瓜的颜色, 大小, 形状, 产地, 品牌等
我们通常用一个 D 维向量 $x = [x_1, x_2, \dots, x_D]^T$ 表示一个西瓜的所有特征构成的向量, 称为**特征向量**(Feature Vector), 其中每一维表示一个特征
- **标签**(Label): 连续值, 西瓜的甜度、水分、成熟度的综合打分; 离散值, 西瓜的“好”“坏”标签
标签通常用标量 y 来表示
- 我们可以将一个标记好特征以及标签的西瓜看作一个**样本**(Sample), 也经常称为**示例**(Instance)
- **数据集**(Data Set): 一组样本构成的集合。一般将数据集分为两部分:
 - **训练集**(Training Set): 用来训练模型的样本 (训练样本) 的集合
 - **测试集**(Test Set): 用来检验模型好坏的样本 (测试样本) 的集合

机器学习基本概念

我们希望让计算机从一个函数集合 $F = \{f_1(\mathbf{x}), f_2(\mathbf{x}), \dots\}$ 中自动寻找一个“最优”的函数 $f^*(\mathbf{x})$ 来近似每个样本的特征向量 $\mathbf{x}$ 和标签 y 之间的真实映射关系



寻找最优函数 $f^*(\mathbf{x})$ 是机器学习的关键任务：通过学习算法 (Learning Algorithm) $\mathcal{A}$ 来完成这个寻找过程通常称为 **学习** (Learning) 或 **训练** (Training)

机器学习的三要素

- 模型
- 线性方法

$$f(\mathbf{x}, \theta) = \mathbf{w}^T \mathbf{x} + b$$

- 广义线性方法

$$f(\mathbf{x}, \theta) = \mathbf{w}^T \phi(\mathbf{x}) + b$$

- 解决学什么

- 学习准则


- 期望风险

$$\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)} [\mathcal{L}(f(\mathbf{x}, y))]$$

- 解决学成什么样

- 优化算法

- 梯度下降



- 解决怎么学


机器学习的三要素—模型

- 输入空间 $\mathcal{X}$ 和输出空间 $\mathcal{Y}$ 构成了一个样本空间
- 样本空间中的样本 $(x, y) \in \mathcal{X} \times \mathcal{Y}$, x 和 y 之间的关系可以描述为:
 - 未知的**真实映射函数** $y = g(x)$, 或
 - **真实条件概率分布** $p_r(y|x)$
- **模型**是 $g(x)$ 或 $p_r(y|x)$ 的近似
- 我们不知道 $g(x)$ 或 $p_r(y|x)$ 的具体形式, 因而只能根据经验来假设一个函数集合 $\mathcal{F}$, 称为**假设空间**(Hypothesis Space)

- 假设空间 $\mathcal{F}$ 通常为一个参数化的函数族 $\mathcal{F} = \{f(x; \theta) | \theta \in \mathbb{R}^D\}$

其中 $f(x; \theta)$ 是参数为 θ 的函数, 也称为**模型**(Model), D 为参数的数量

- 选择一个理想的**假设**(Hypothesis) $f^* \in \mathcal{F}$



- 以**线性回归**(Linear Regression)为例
模型: $f(x, \theta) = w^T x + b$

机器学习的三要素—学习准则

- 训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$ 应当由 N 个独立同分布 (Independent and Identically Distributed, I.I.D) 的样本组成
 - 样本分布 $p_r(\mathbf{x}, y)$ 必须固定 (可以未知)
 - 如果 $p_r(\mathbf{x}, y)$ 本身可变, 无法通过这些数据学习

- 一个好的模型 $f(\mathbf{x}, \theta^*)$ 应该在所有 $(\mathbf{x}, y)$ 的可能取值上都与真实映射函数 $y = g(\mathbf{x})$ 一致
 - 衡量 $f(\mathbf{x}, \theta^*)$ 与 y 分布相似性的常用方法: KL散度或交叉熵

- 模型 $f(\mathbf{x}, \theta^*)$ 的好坏可以通过期望风险(Expected Risk) $\mathcal{R}(\theta)$ 来衡量
 $\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)} [\mathcal{L}(f(\mathbf{x}, y))]$

- $\mathcal{L}(f(\mathbf{x}), y)$ 表示损失函数, 用来量化两个变量间的差异

例:

$$\mathcal{L}(y, f(\mathbf{x}; \theta)) = \begin{cases} 0 & \text{if } y = f(\mathbf{x}; \theta) \\ 1 & \text{if } y \neq f(\mathbf{x}; \theta) \end{cases}$$

$$= I(y \neq f(\mathbf{x}; \theta)),$$

$$\mathcal{L}(y, f(\mathbf{x}; \theta)) = \frac{1}{2} (y - f(\mathbf{x}; \theta))^2.$$

机器学习的三要素—学习准则

- 风险最小化准则

- 期望风险未知，通过经验风险近似
- 给定一个训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$ ，我们可以计算的是经验风险 (Empirical Risk)，即在训练集上的平均损失：

$$\mathcal{R}_{\mathcal{D}}^{\text{emp}}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \theta)).$$

- 实践：寻找一个参数 θ^* ，使得经验风险函数最小化

$$\theta^* = \arg \min_{\theta} \mathcal{R}_{\mathcal{D}}^{\text{emp}}(\theta),$$

- 称为经验风险最小化 (Empirical Risk Minimization, ERM) 准则

经验风险最小化原则很容易导致模型在训练集上错误率很低，但是在未知数据上错误率很高，造成所谓的过拟合 (Overfitting)


机器学习的三要素—学习准则

• 过拟合与欠拟合

- 和过拟合相反的一个概念是**欠拟合**(Underfitting)
 - 模型不能很好拟合训练数据，训练集上错误率高
 - 模型能力不足造成

• 欠拟合和过拟合示例




定义 2.1 – 过拟合： 给定一个假设空间 $\mathcal{F}$ ，一个假设 f 属于 $\mathcal{F}$ ，如果存在其他的假设 f' 也属于 $\mathcal{F}$ ，使得在训练集上 f 的损失比 f' 的损失小，但在整个样本空间上 f' 的损失比 f 的损失小，那么就说假设 f 过度拟合训练数据 [Mitchell, 1997].



机器学习的三要素—优化算法

- 机器学习问题转化成为一个**最优化**问题
 - 寻找参数 θ^* 使经验风险最小化

$$\theta^* = \arg \min_{\theta} \mathcal{R}_D^{emp}(\theta),$$



- 梯度下降法
- 随机梯度下降法

- 机器学习中的优化又可以分为参数优化和超参数优化
 - 参数：模型 $f(x; \theta)$ 中的参数 θ
 - 超参数**(Hyper-Parameter)：用来定义模型结构或优化策略的参数

机器学习 $\neq$ 优化!
例：最优化不考虑
过拟合问题

机器学习概论

- 机器学习原理与概念
- 机器学习分类
- 机器学习关键思想
- 机器学习与人工智能

常见的机器学习类型

	监督学习	无监督学习	强化学习
训练样本	训练集 $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$	训练集 $\{\mathbf{x}^n\}_{n=1}^N$	智能体和环境交互的 轨迹 τ 和累积奖励 G_τ
优化目标	$y = f(\mathbf{x})$ 或 $p(y \mathbf{x})$	$p(\mathbf{x})$ 或带隐变量 $\mathbf{z}$ 的 $p(\mathbf{x} \mathbf{z})$	期望总回报 $\mathbb{E}_\tau[G_\tau]$
学习准则	期望风险最小化 最大似然估计	最大似然估计 最小重构错误	策略评估 策略改进


监督学习 (Supervised Learning)

- 已知输入和输出的情况下训练出一个模型，将输入映射到输出 $g: \mathcal{X} \rightarrow \mathcal{Y}$
- 通过学习**标记的训练样本**来构建预测模型，并依此模型推测新的实例
- 输出可以是一个连续的值（称为回归分析），或是预测一个分类标签（称作分类）


• 典型**监督学习**算法

- 朴素贝叶斯
- 决策树
- 支持向量机
- 线性回归
- 神经网络
-


Housing price prediction.



Housing price prediction.




回归




分类

无监督学习 (Unsupervised Learning)

- **不**给定事先标记过的训练示例，自动对输入的数据进行分析
- 不需要数据标注，对大数据分析很重要，但在实际应用中性能受限
- 包括聚类、降维等



聚类




降维

• 典型无监督学习算法

- 聚类: K-均值
- 降维: PCA
- 自编码器
-

强化学习 (Reinforcement Learning)

- 强化学习问题可以描述为一个智能体从与环境的交互(试错, Trial-and-Error)中不断学习以完成**特定目标**(比如取得最大奖励值)
- 强化学习就是智能体不断与环境进行交互, 并**根据经验**调整其策略来最大化其长远的所有奖励的累积值



典型**强化学习**算法

- 基于值函数
 - Q学习
 - 深度Q网络
- 基于策略:
 - 策略梯度
 - 近端策略优化
-

弱监督学习 (Weakly Supervised Learning)

监督学习 → 数据标注成本太高;

无监督学习 → 学习过程困难、发展缓慢




弱监督学习

数据标签允许是不完全的、不确切、不精确的

- 不完全监督 (Incomplete supervision)
- 不确切监督 (Inexact supervision)
- 不精确监督 (Inaccurate supervision)


Weakly supervised learning is an umbrella term covering a variety of studies that attempt to construct predictive models by learning with weak supervision.



迁移学习

(Transfer Learning)

- 迁移学习(Transfer Learning): 将已经学习过的知识迁移应用到新的问题中
- 在数据独立同分布不成立的条件下



机器学习概论

- 机器学习原理与概念
- 机器学习分类
- 机器学习关键思想
- 机器学习与人工智能

常用的定理

- **没有免费午餐定理**(No Free Lunch Theorem, NFL): 对于基于迭代的最优化算法, 不存在某种算法对所有问题 (有限的搜索空间内) 都有效。如果一个算法对某些问题有效, 那么它一定在另外一些问题上比纯随机搜索算法更差



常用的定理

- **丑小鸭定理**(Ugly Duckling Theorem): 丑小鸭与白天鹅之间的区别和两只白天鹅之间的区别一样大



常用的定理

- 奥卡姆剃刀原理(Occam's Razor): “如无必要, 勿增实体”



归纳偏置 (Inductive Bias)

很多学习算法经常会对学习的问题做一些假设，这些假设就称为**归纳偏置**

- 在最近邻分类器中，我们会假设在特征空间中，一个小的局部区域中的大部分样本都同属一类。
- 在朴素贝叶斯分类器中，我们会假设每个特征的条件概率是互相独立的。

e.g. 深度神经网络就认为**层次化处理信息**会有好的效果；卷积神经网络则认为**信息具有空间局部性**，可以用**滑动卷积共享权重**的方法降低参数空间；循环神经网络则将**时序信息**考虑进来，**强调顺序**的重要性；图网络则认为**中心节点于邻居节点的相似性**会更好引导信息流。

归纳偏置在贝叶斯学习中也经常称为**先验** (Prior)。

机器学习概论

- 机器学习原理与概念
- 机器学习分类
- 机器学习关键思想
- 机器学习与人工智能

机器学习与人工智能

- 机器学习
- 模式识别
- 人工智能
- 深度学习
- 数据挖掘
-



机器学习与人工智能

- **模式识别**：自己建立模型刻画已有的特征，样本是用于估计模型中的参数。
模式识别的落脚点是感知
- **机器学习**：根据样本训练模型，如训练好的神经网络是一个针对特定分类问题的模型；重点在于“学习”，训练模型的过程就是学习；机器学习的落脚点是思考，是一种实现人工智能的方法
- **深度学习**：深度学习本来并不是一种独立的学习方法，其本身也会用到有监督和无监督的学习方法来训练深度神经网络，是一种实现**机器学习的**技术。

机器学习是人工智能的基础

