



第四章

连接学派

Connectionism



第四章 连接学派

Connectionism

连接学派简介

神经网络基本概念与近代史

神经网络基本思想与结构

从浅层学习到深度学习


现代神经网络重要思想与结构

人工智能 — 连结主义

Introduction to Connectionism

- 回顾：
 - 符号主义(symbolicism), 认为人工智能源于数理逻辑
- 连接主义(connectionism), 又称为仿生学派或生理学派, 其主要原理为神经网络及神经网络间的连接机制与学习算法
- 源于仿生学, 认为高级的智能行为是从大量神经网络的连接中自发出现的
- 20世纪60-70年代, 连接主义出现过热潮(感知机), 70-80年代初落入低潮。直到1982-1984年Hopfield教授提出用硬件模拟神经网络以后, 连接主义才又重新抬头。1986年Rumelhart等人提出多层网络中的反向传播(BP)算法, 使连接主义势头大振。

符号和连接主义的发展历程



華中科技大學
HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY



第四章 连接学派

Connectionism

连接学派简介

神经网络基本概念与近代史

神经网络基本思想与结构


从浅层学习到深度学习

现代神经网络重要思想与结构

神经网络基本概念与近代史

Neural Networks Basics and Early History


- 神经网络的生物学启发
- MP模型
- 感知器模型
- ADALINE模型
- BP神经网络模型



生物神经元

- 人脑由一千多亿 (10^{11} 亿 - 10^{14} 亿) 个神经细胞 (神经元) 交织在一起的网状结构组成, 其中大脑皮层约140亿个神经元, 小脑皮层约1000亿个神经元。
- 神经元约有1000种类型, 每个神经元大约与 $10^3 - 10^4$ 个其他神经元相连接, 形成极为错综复杂而又灵活多变的神经网络。
- 人的智能行为就是由如此高度复杂的组织产生的。浩瀚的宇宙中, 也许只有包含数千亿颗星球的银河系的复杂性能够与大脑相比。


生物神经元结构



生物神经元结构

- 神经元的两种工作状态：
 - 兴奋状态：细胞膜电位 $>$ 动作电位的阈值 $\rightarrow$ 神经冲动
 - 抑制状态：细胞膜电位 $<$ 动作电位的阈值
- 学习与遗忘：由于神经元结构的可塑性，突触的传递作用可**增强**和**减弱**。


Biological neurons: An overly simplified illustration



Not real.


Source: <https://towardsdatascience.com/mcculloch-pitts-model-5fdf65ac5dd1>

Biological neurons: A little closer to the reality



Still not real but closer.

Biological neurons: Division of work




Division of work.

Biological neurons: The hierarchy



Layer 1: detect edges & corners

Each layer has its own role and responsibility.



Layer 2: form feature groups

To detect a face, the brain could be relying on the entire network and not on a single layer.



Layer 3: detect high level objects, faces, etc.

Many credible alternatives with experimental support are proposed by the scientists.

Biological neurons: Example


假设我要预测我是否会看一场球赛 (0-不看, 1-看)

x_1 我喜欢的球队在比赛

x_2 我不喜欢的球队在比赛

x_3 我有空, 可以看比赛

x_4 我超级喜欢的球队/员在比赛




$$g(x_1, x_2, x_3, \dots, x_n) = g(\mathbf{x}) = \sum_{i=1} x_i$$

有些输入是**抑制性**输入, 有些是**激励性**的输入。抑制性输入只要成立就输出为0, 激励性输入的累积效应决定是否输出为1.

$$y = f(g(\mathbf{x})) = \begin{cases} 1 & \text{if } g(\mathbf{x}) \geq \theta \\ 0 & \text{if } g(\mathbf{x}) < \theta \end{cases}$$


神经网络近代史



Brief history of neural network


McCulloch – Pitts 网络

- 1943年，麦克洛奇和皮兹提出M - P模型（被认为是最早的神经元模型）



$$\bar{\mathbf{x}} = (x_1, x_2, \dots, x_n)$$

$$g(\bar{\mathbf{x}}) = x_1 + x_2 + \dots + x_n$$




$$y = 1 \quad g(\bar{\mathbf{x}}) \geq \theta$$

$$y = 0 \quad g(\bar{\mathbf{x}}) < \theta$$


输入和输出均为布尔值（0或1）

M-P模型实现“与”“或”门

- “与”门：阈值 $\theta=2$




- “或”门：阈值 $\theta=1$




M-P模型的几何解释

• “与”门：阈值 $\theta=2$





• “或”门：阈值 $\theta=1$




M-P模型的特点

- 验证型模型（验证神经元模型可以计算）
- 布尔输入和输出
- 阶跃响应函数
- 模型没有可学习的权重

$$g(\bar{x}) = x_1 + x_2 + \dots + x_n$$




神经网络近代史




Brief history of neural network

感知器模型

- 神经网络发展的第二个阶段，心理学家Frank Rosenblatt于上世纪五六十年代提出的感知器（Perceptron）模型



$$g(\bar{x}, \bar{w}) = \bar{x} \cdot \bar{w} = x_1 * w_1 + x_2 * w_2 + \dots + x_n * w_n$$




$$y = 1 \quad g(\bar{x}, \bar{w}) \geq \theta$$

$$y = 0 \quad g(\bar{x}, \bar{w}) < \theta$$

$$\hat{y} = \text{sgn}(\mathbf{w}^T \mathbf{x})$$

输入和输出可以是实值


感知器的几何解释



$$\begin{aligned} \bar{\mathbf{x}} \cdot \bar{\mathbf{w}} &= \theta \\ \downarrow \\ x_1 * w_1 + x_2 * w_2 &= \theta \\ \downarrow \\ x_2 &= -\frac{w_1}{w_2} * x_1 + \frac{\theta}{w_2} \end{aligned}$$

- 感知器将输入空间通过一个（超）平面划分为两个半空间

感知器解决模式分类问题






感知器的特点

- 实值的输入和输出
- 阶跃响应函数
- 模型的权重可学习（权重如何学习在《模式识别》课程上讲解）

$$\begin{aligned}w_i &\leftarrow w_i + \Delta w_i \\b &\leftarrow b + \Delta b\end{aligned}$$

$$\begin{aligned}\Delta w_i &= \eta(t - y)x_i \\ \Delta b &= \eta(t - y)\end{aligned}$$


感知器的限制



- 属于线性模型，无法解决线性不可分的问题

ADALINE模型

- ADALINE (ADaptive Linear NEuron) 由Bernard Widrow 和他的研究生Ted Hoff 在1960年发明于斯坦福大学
- 它借鉴了很多MP模型和感知器模型的思想
- 被广泛应用于现在的信号处理过程中
- 是多层网络中BP算法的先驱




Bernard Widrow




Ted Hoff

Perceptron和ADALINE的对比



Perceptron




ADALINE

Perceptron和ADALINE的对比


- 激活函数由阶跃函数变为连续函数
- 增加了Quantizer用于类别预测
- 定义了代价函数的概念（均方误差）

$$E = (o - y)^2$$




- 使用梯度下降优化权重（详细算法在专业课讲授）

A Short Summary of AI in the 1960s



神经网络近代史



Brief history of neural network

XOR问题

- Marvin Minsky和Seymour Papert在 Perceptrons [1969] 一书中提到，一个2层（输入层和输出层）的感知器无法解决简单的XOR问题，直接导致了研究兴趣从神经网络的转移，贡献了所谓的“AI寒冬”。

感知器


Perceptrons

闵斯基和帕佩特合著

神经网络黑暗的十年，感知器和



连接主义算法都停滞了

1969



XOR问题



Input 1	Input 2	Output
0	0	0
0	1	1
1	1	0
1	0	1



- 异或问题不是线性可分的
- 无法用单一感知器找到XOR问题的分类面


XOR问题

- 但其实，可以用三层感知器来解决XOR问题





We can model XOR using a hidden layer.

神经网络近代史



AI寒冬




(Lighthill Report, 1973)



AI寒冬

- 1950s到1960早期，机器翻译进展的熄火 (The quiet decade of machine translation)
- *Perceptrons* 对于感知器模型的批判 (Fall of Connectionism)
- *The Lighthill report* [1973] 把AI贬的一无是处 (*in no part of the field have discoveries made so far produced the major impact that was then promised*)
- 第一次AI寒冬在1973年左右开始了，很多AI的基础研究很难得到资助


神经网络近代史




BP神经网络

- BP神经网络 (也被称为多层感知器, Multi-Layered Perceptron, MLP) 的提出让神经网络的发展迎来了第二春

Perceptron一书中其实提到可以用三层感知器来解决类似XOR的非线性分类问题



We can model XOR using a hidden layer.



BP神经网络

- 然而，当时并没有合适的学习算法可以用来训练多层感知器，直到17年后Backpropagation算法的提出才解决这个问题，这也是BP名字的由来。（实际上，BP算法被提出不久后，大家才发现这个算法之前就有，甚至早于Perception一书的发表）

Published: 09 October 1986

Learning representations by back-propagating errors

David E. Rumelhart, Geoffrey E. Hinton & Ronald J. Williams

Nature 323, 533–536 (1986) | [Cite this article](#)

76k Accesses | 11068 Citations | 235 Altmetric | [Metrics](#)



虽然BP算法不是我第一个提出，但我把它发表在Nature上了！



Paul Werbos
1974年在其博士论文中首次论证

BP神经网络



Geoffrey Hinton

 FOLLOWING


Emeritus Prof. Comp Sci, U.Toronto & Engineering Fellow, Google
 Verified email at cs.toronto.edu - [Homepage](#)

[machine learning](#) [psychology](#) [artificial intelligence](#) [cognitive science](#) [computer science](#)

TITLE	CITED BY	YEAR
Imagenet classification with deep convolutional neural networks A Krizhevsky, I Sutskever, GE Hinton Advances in neural information processing systems 25, 1097-1105	101956	2012
Deep learning Y LeCun, Y Bengio, G Hinton Nature 521 (7553), 436-44	47014	2015
Dropout: a simple way to prevent neural networks from overfitting N Srivastava, G Hinton, A Krizhevsky, I Sutskever, R Salakhutdinov The journal of machine learning research 15 (1), 1929-1958	33339	2014
Learning internal representations by error-propagation DE Rumelhart, GE Hinton, RJ Williams Parallel Distributed Processing: Explorations in the Microstructure of ...	29779	1986
Learning representations by back-propagating errors DE Rumelhart, GE Hinton, RJ Williams Nature 323 (6088), 533-536	27212	1986

Cited by [VIEW ALL](#)

	All	Since 2017
Citations	538503	366087
h-index	166	120
i10-index	391	289



Public access [VIEW ALL](#)

0 articles	8 articles
not available	available

Based on funding mandates

第四章 连接学派

Connectionism

连接学派简介

神经网络基本概念与近代史

神经网络基本思想与结构




从浅层学习到深度学习

现代神经网络重要思想与结构

神经网络基本思想与结构

Neural Networks Basic Ideas and Architectures

- 前馈神经网络 (近似函数)
- 循环神经网络 (近似动力学系统)
- Hopfield网络 (解决优化问题)





前馈神经网络的基本概念

- 前馈神经网络 (feedforward neural networks) , 也叫多层感知器 (multilayer perception) , 通常用于**监督式机器学习**或模式识别任务。
- 前馈神经网络的主要目标是去逼近某个函数 f^* , 它通过定义一个映射 $y = f(x; \theta)$, 并调整参数 θ 去尝试获得一个最好的 f^* 的逼近。
- 相比二层的感知器模型, 前馈神经网络最大的特点是增加了非线性的激活单元, 使得网络拥有**非线性建模能力**。


前馈神经网络的结构

- 前馈神经网络主要由三种类型的网络层构成：输入层、输出层、和隐含层



前馈神经网络的结构

- 隐含层由多个神经元组成，隐含层的个数可以是任意的，神经元的个数也可以是任意的，在实践中通常作为超参数
- 相邻两层之间的神经元两两连接，是一个全连接的结构，故有时候也叫做全连接层
- 同层神经元之间没有连接
- 输入层和隐含层通常会额外增加一个偏置单元




思考：隐含层越多越好吗？隐含层神经元个数越多越好吗？

非线性激活函数

- 标准前馈神经网络使用“S”型的非线性激活函数，通常有两种选择：Logistic函数和Tanh函数，Tanh函数是零中心化的，而sigmoid (logistic)函数的输出恒大于0
- 非线性激活函数的存在是使网络拥有非线性建模能力的关键


$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

$$\tanh(x) = \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)}$$




前馈神经网络的前向传播


- 前馈神经网络的计算分为前向计算和反向计算两种，也叫**前向传播**和反向传播
- 前向传播的方向由输入层传向输出层




前馈神经网络的前向传播



$$a_1^{(2)} = f(2 \times 0.1 + 0.5 \times 0.5 + -1 \times 0.2 + 1 \times 0.8)$$



$$a_2^{(2)} = f(2 \times 0.3 + 0.5 \times 0.4 + -1 \times 0.5 + 1 \times 0.6)$$



$$a_3^{(2)} = f(2 \times 0.05 + 0.5 \times 0.9 + -1 \times 0.1 + 1 \times 0.25)$$


前馈神经网络的前向传播

2

0.5

-1

+1



输出层一般不加
非线性激活函数

$$h_{w,b}(x) = a_1^{(2)} \times 0.2 + a_2^{(2)} \times 0.1 + a_3^{(2)} \times 0.4$$

通用近似定理

- 在人工神经网络的数学理论中，通用近似定理（或称万能近似定理）指出人工神经网络具有近似任意函数的能力

根据通用近似定理，对于具有线性输出层和至少一个使用“挤压”性质的激活函数的隐藏层组成的前馈神经网络，只要其隐藏层神经元的数量足够，它可以任意的精度来近似任何从一个定义在实数空间中的有界闭集函数。

定理 4.1 – 通用近似定理 (Universal Approximation Theorem)

[Cybenko, 1989, Hornik et al., 1989]: 令 $\varphi(\cdot)$ 是一个非常数、有界、单调递增的连续函数， $\mathcal{I}_d$ 是一个 d 维的单位超立方体 $[0, 1]^d$ ， $C(\mathcal{I}_d)$ 是定义在 $\mathcal{I}_d$ 上的连续函数集合。对于任何一个函数 $f \in C(\mathcal{I}_d)$ ，存在一个整数 m ，和一组实数 $v_i, b_i \in \mathbb{R}$ 以及实数向量 $\mathbf{w}_i \in \mathbb{R}^d$ ， $i = 1, \dots, m$ ，以至于我们可以定义函数

$$F(\mathbf{x}) = \sum_{i=1}^m v_i \varphi(\mathbf{w}_i^T \mathbf{x} + b_i), \quad (4.33)$$


作为函数 f 的近似实现，即

$$|F(\mathbf{x}) - f(\mathbf{x})| < \epsilon, \forall \mathbf{x} \in \mathcal{I}_d. \quad (4.34)$$

其中 $\epsilon > 0$ 是一个很小的正数。

前

- 后
- 网
- 学定
- 学到
- 后
- (




公众号·程序员学长

前馈神经网络的特点


- 前馈神经网络：多层前向网络（输入层、隐层、输出层）
- 连接权值：通过学习算法进行修正
- 神经元激活函数：S形函数
- 学习算法：正向传播、反向传播
- 层与层的连接是单向的，信息的传播是双向的

前馈神经网络的特点

- + 强大的逼近特性
- + 较强的通用能力，可以作为一个“万能”的函数 拟合器
- + 具有较好的容错性
- - 收敛速度慢（原因会在专业课深入介绍）
- - 局部极值
- - 没有选择隐层数和隐层结点数的通用准则



前馈神经网络的输入输出独立性



- 前馈网络的输出只依赖于当前的输入，那么如何处理有顺序依赖的序列数据？


什么是序列数据？

- 若以图像为代表的网格化数据能够看作数据元素的二维规则排布，那么序列是一种数据元素一维规则排布的网格化数据




Audio data
(Speech, noise)

Stock data



Natural
language
data



序列化数据

- 序列是被排成一行的元素，可以被表示为 $[a_1, a_2, \dots, a_n]$
- 序列中的元素通常是顺序依赖的（元素的排列具有**序列特性**），即序列中的元素排列符合时间顺序、逻辑顺序或其他顺序。



一个典型的序列问题：预测下一个单词

“This morning I took the dog for a walk.”


given these words

*predict what
comes next?*

一个典型的序列建模问题：预测下一个单词

“This morning I took the dog **for a** walk.”

*given these 2
words, predict
the next word*



问题难点：上下文依赖

“In **France**, I had a great time and I learnt some of the _____
language.”

需要过去和未来的信息来准确猜测正确的词

一种解决方案：使用整个序列

This morning I took the dog for a

[0 1 0 0 1 0 0 ... 0 0 1 1 0 0 0 1]

"bag of words"

prediction

统计句子中词出现的频率

又出现新的问题：频率对顺序不敏感

“The food was good, not bad at all.”

VS

“The food was bad, not good at all.”

新的解决方案：使用一个特别大的编码窗口

“This morning I took the dog for a walk.”

*given these 7
words, predict
the next word*

[1 0 0 0 0 0 0 0 0 0 0 0 1 0 0 0 0 0 1 0 0 0 0 0 1 0 0 0 0 0 0 0 0 0 1 0 0 0 ...]

morning

I

took

the

dog

...



prediction

又双出现新的问题：没有参数共享

this morning
[1 0 0 0 0 0 0 0 0 0 0 1 0 0 0 0 0 1 0 0 0 0 0 0 0 0 0 0 1 0 0 0 ...]

each of these inputs has a *separate parameter*

this morning
[0 0 0 1 0 0 0 0 1 0 0 0 0 0 0 0 0 0 1 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0 1 0 0 ...]

此外，当特征出现顺序改变时，从之前序列中学到的知识**没有良好的迁移性**，比如“This morning”出现的顺序不同，会有两组不同的权重

对于序列建模

- 需要处理变长的序列
- 需要能保留序列的顺序
- 需要能建模上下文依赖
- 需要在整个序列中共享模型参数

循环神经网络应运而生

- 循环神经网络 (Recurrent Neural Network, RNN) 的概念, 在 1994 年首次被提出 (《Neural Networks: a Comprehensive Foundation》)
- 循环神经网络在2010 年首次被《Recurrent Neural Network Based Language Model》用于语言模型

循环神经网络的辉煌

- 在2009年至2012年，由Schmidhuber 研究组提出的RNN 及其变式在八次模式识别与机器学习的国际竞赛获得了奖项。如其提出的Multi-dimensional LSTM 在没有任何先验知识的情况下，于2009年的ICDAR 手写体识别竞赛中赢得了三个语言赛道的冠军。

Table 1. Recognition rate (%) on task WR1.

System	GT		System	normalized GT	
	<i>top</i> ₁	<i>top</i> ₁₀		<i>top</i> ₁	<i>top</i> ₁₀
TUM	98.43	99.92	TUM	98.46	99.92
UPV	96.45	99.60	ParisTech(1)	97.17	99.76
SIEMENS	95.30	99.71	UPV	96.49	99.60
LITIS	92.40	99.26	SIEMENS	95.39	99.71
IRISA	91.24	96.33	LITIS	92.46	99.28
ParisTech(1)	86.37	88.79	ParisTech(2)	92.46	99.16
ParisTech(2)	82.05	88.25	IRISA	91.29	96.41
ParisTech(3)	79.90	87.98	ParisTech(3)	90.13	98.85
ITESOFT	74.57	85.28	ITESOFT	84.74	96.14

Table 2. Recognition rate (%) on task WR2

System	GT		System	normalized GT	
	<i>top</i> ₁	<i>top</i> ₁₀		<i>top</i> ₁	<i>top</i> ₁₀
TUM	93.17	98.95	TUM	93.37	98.95
UPV	86.11	97.95	ParisTech(1)	90.53	98.83
SIEMENS	81.30	96.37	UPV	86.44	98
ParisTech(1)	80.20	87.94	ParisTech(2)	81.71	96.03
IRISA	79.56	92.78	SIEMENS	81.66	96.38
LITIS	74.10	94.88	IRISA	80	93.34
ParisTech(2)	72.36	85.44	LITIS	74.57	94.94
ParisTech(3)	63.80	80.05	ParisTech(3)	72.70	90.37
ITESOFT	59.39	76.71	ITESOFT	68.07	86.91

Table 3. Recognition rate (%) on task WR3


System	GT		System	normalized GT	
	<i>top</i> ₁	<i>top</i> ₁₀		<i>top</i> ₁	<i>top</i> ₁₀
TUM	91.02	98.34	TUM	91.39	98.35
UPV	83.17	96.84	ParisTech(1)	86.08	97.68
ParisTech(1)	76.34	86.86	UPV	83.76	96.86
IRISA	74.69	90.29	ParisTech(2)	76.67	93.93
SIEMENS	73.24	93.39	IRISA	75.71	91.45
ParisTech(2)	67.99	83.57	SIEMENS	74.36	93.45
LITIS	66.65	91.61	LITIS	67.42	91.68
ParisTech(3)	58.70	77.21	ParisTech(3)	66.76	87.23
LSIS	52.37	54.86	ITESOFT	57.60	82.57
ITESOFT	50.44	72.94	LSIS	57.33	60.36

循环神经网络简史

Year	First Author	Contribution
1990	Elman	Popularized simple RNNs (Elman network)
1993	Doya	Teacher forcing for gradient descent (GD)
1994	Bengio	Difficulty in learning long term dependencies with gradient descend
1997	Hochreiter	LSTM: long-short term memory for vanishing gradients problem
1997	Schuster	BRNN: Bidirectional recurrent neural networks
1998	LeCun	Hessian matrix approach for vanishing gradients problem
2000	Gers	Extended LSTM with forget gates
2001	Goodman	Classes for fast Maximum entropy training
2005	Morin	A hierarchical softmax function for language modeling using RNNs
2005	Graves	BLSTM: Bidirectional LSTM
2007	Jaeger	Leaky integration neurons
2007	Graves	MDRNN: Multi-dimensional RNNs
2009	Graves	LSTM for hand-writing recognition
2010	Mikolov	RNN based language model
2010	Neir	Rectified linear unit (ReLU) for vanishing gradient problem
2011	Martens	Learning RNN with Hessian-free optimization
2011	Mikolov	RNN by back-propagation through time (BPTT) for statistical language modeling
2011	Sutskever	Hessian-free optimization with structural damping
2011	Duchi	Adaptive learning rates for each weight
2012	Gutmann	Noise-contrastive estimation (NCE)
2012	Mnih	NCE for training neural probabilistic language models (NPLMs)
2012	Pascanu	Avoiding exploding gradient problem by gradient clipping
2013	Mikolov	Negative sampling instead of hierarchical softmax
2013	Sutskever	Stochastic gradient descent (SGD) with momentum
2013	Graves	Deep LSTM RNNs (Stacked LSTM)
2014	Cho	Gated recurrent units
2015	Zaremba	Dropout for reducing Overfitting
2015	Mikolov	Structurally constrained recurrent network (SCRN) to enhance learning longer memory for vanishing gradient problem
2015	Visin	ReNet: A RNN-based alternative to convolutional neural networks
2015	Gregor	DRAW: Deep recurrent attentive writer
2015	Kalchbrenner	Grid long-short term memory
2015	Srivastava	Highway network
2017	Jing	Gated orthogonal recurrent units

循环神经网络基本结构

- 循环神经网络，以下简称RNN，是一种为了适应序列化数据的序列特性而设计的神经网络。它具有短期记忆能力并能够在序列化数据上进行端到端的学习和计算。
- RNN的两种计算图表示方法：折叠表示和展开表示
- RNN同样包含输入层、隐含层和输出层三种类型的网络层



展开RNN的计算


- 由于序列的序列特性，特征 $\mathbf{s}_t$ 不仅仅取决于当前输入 $\mathbf{x}_t$ ，还取决于 $\mathbf{s}_{t-1}$ 。把RNN的结构按照序列展开，每一个时间点的隐藏层函数（Hidden Layer Function） f 为：

$$\mathbf{s}_t = f(\mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{s}_{t-1})$$

即RNN可表示为：

$$\mathbf{o}_t = g(\mathbf{V}\mathbf{s}_t)$$

$$\mathbf{s}_t = f(\mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{s}_{t-1})$$



RNN与非线性动力系统的关系

- 事实上，RNN可以理解为一个通用的非线性系统

$$\mathbf{h}_t = f(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b}),$$

$$\mathbf{y}_t = \mathbf{V}\mathbf{h}_t,$$

非线性系统方程

$$\mathbf{s}_t = f(\mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{s}_{t-1})$$

$$\mathbf{o}_t = g(\mathbf{V}\mathbf{s}_t)$$

RNN计算方程

RNN的通用近似定理

- 一个完全连接的循环网络是任何非线性动力系统的近似器

定理 6.1 – 循环神经网络的通用近似定理 [Haykin, 2009]: 如果一个完全连接的循环神经网络有足够数量的 sigmoid 型隐藏神经元, 它可以以任意的准确率去近似任何一个非线性动力系统


$$\mathbf{s}_t = g(\mathbf{s}_{t-1}, \mathbf{x}_t), \quad (6.10)$$

$$\mathbf{y}_t = o(\mathbf{s}_t), \quad (6.11)$$

其中 $\mathbf{s}_t$ 为每个时刻的隐状态, $\mathbf{x}_t$ 是外部输入, $g(\cdot)$ 是可测的状态转换函数, $o(\cdot)$ 是连续输出函数, 并且对状态空间的紧致性没有限制.

But, RNN又双叒出现其他问题

- 长序列的**记忆丢失**（**梯度消失**）
- 关系建模**单向性**的局限




长序列梯度爆炸与消失的原因

- 循环网络要在很长时间序列的各个时刻**重复应用相同操作**
- 假设某个计算图中包含一条反复与矩阵 W 相乘的路径。那么 t 步后，相当于乘以 W^t 。假设 W 有特征值分解

$$W = V \text{diag}(\lambda) V^{-1}$$

- 在这种简单的情况下，容易看出

$$W^t = (V \text{diag}(\lambda) V^{-1})^t = V \text{diag}(\lambda)^t V^{-1}$$




- 当特征值 λ_i 不在1附近时，若在量级上大于1则会爆炸（很少）；若小于1时则会消失（大部分情况）。

改善梯度消失的途径

- 改进RNN的结构 (LSTM、GRU等, 如何做的?)
- 使用合适的激活函数 (如使用tanh, 为什么不使用sigmoid? 根据下图回答)
- 还有哪些途径?

Weight initialization
Network architecture



RNN参数的更新


- RNN的模型参数更新同样需要用到反向传播 (BP) 算法, 但使用的BP算法是标准BP算法的推广, 叫做**随时间反向传播** (BPTT, BP Through Time)
- 详细内容在专业课中学习

RNN典型应用之自然语言处理

• 情感分类（序列到类别）

sentiment classification

辨识词语的情感极性，自动从文本中识别观点并将其标记为“正面”、“负面”、以及“中性”




RNN典型应用之自然语言处理

• 中文分词（同步序列到序列）

Chinese Tokenization

将一个连续的汉字序列切分成一个个单独的词，或者说将汉字序列按照一定的规范重新组合成词序列的过程。

“今天天气真好” $\rightarrow$ “今天天气”，“真”，“好”



状态值集合为(B, M, E, S): {

B: begin,
M: middle,
E: end,
S: single

}

B代表该字是词语中的起始字，M代表是词语中的中间字，E代表是词语中的结束字，S则代表是单字成词。


RNN典型应用之自然语言处理

• 信息抽取（同步序列到序列）

Information Extraction

从自然语言文本中抽取指定类型的实体、关系、事件等事实信息，并形成结构化数据输出的文本处理技术

小米创始人雷军表示，该公司2015年营收达到780亿元人民币，较2014年的743亿元人民币增长了5%。



B 代表 begining, NE 开始的位置, I 代表 continue, 承接上一个 NE, 不是 NE 就标为 O(other)



Type	Tag	Sample Categories
People	PER	people, characters
Organization	ORG	companies, sports teams
Location	LOC	regions, mountains, seas
Geo-Political	GPE	countries, states, provinces
Entity		
Facility	FAC	bridges, buildings, airports
Vehicles	VEH	planes, trains, automobiles

RNN典型应用之自然语言处理

• 机器翻译（异步序列到序列）

Machine Translation

利用计算机将一种自然语言(源语言)转换为另一种自然语言(目标语言)的过程。





RNN典型应用之计算机视觉


• 看图说话

Image Caption

用一段话描述一张图像中的内容



Recurrent Neural Network





Convolutional Neural Network

RNN典型应用之计算机视觉

• 手写体识别

Handwriting Recognition



Touch points




Bézier curve approximation



Bézier curves

QRNN recognizer



Decoder matrix

CTC decoder

"go"


Text output

RNN的特点

- + 可处理任意长度序列
- + 参数共享：在每次时间迭代中，循环节点使用相同的权重系数处理所有的时间步
- + 通用计算能力：按任意精度逼近任意非线性系统
- 建模的单向性：输出仅和 t 时刻之前的输入有关
- 长序列的记忆丢失（梯度消失）

Hopfield网络的历史


- 1982年, John Hopfield提出, AI寒冬后的复兴
- 1987年贝尔实验室在其基础上研制出了神经网络芯片
- 开拓了神经网络用于联想记忆和神经优化的新途径
- 提供了一种理解人类记忆的模型



约翰·霍普菲尔德 (John Hopfield)

Hopfield网络基本概念

- Hopfield网络是单层、全连接、固定参数的反馈型神经网络
- 输出到输入均有反馈连接
- 每个神经元既是输入也是输出，神经元的输入结合其他所有神经元的输出以及自身输入
- 引入能量函数的概念，判断网络运行的稳定性
- 有离散型和连续性两种
 - 离散型适用于联想记忆（自联想，互联想）
 - 连续性适合处理优化问题



离散Hopfield神经网络

- 离散Hopfield网络 (DHNN) 为二值神经网络
 - ✓ 神经元的输入、输出只取 $\{0, 1\}$ 或者 $\{-1, 1\}$ ，分别代表抑制和激活状态
- 单层网络，每个神经元输出均接受其他神经元的输入，各节点没有自反馈
 - ✓ 每个节点处于一种可能的状态，由所受刺激和其阈值决定
- 两种工作方式：异步（串行）和同步（并行）
 - ✓ 在 t 时刻，只有某一个神经元状态变化，其他都不变；或是在任一时刻 t ，所有神经元状态都变化
 - ✓ 同步：一次更新所有的神经元的值
 - ✓ 异步：一次更新一个神经元的值

离散Hopfield神经网络

- DHNN是一个多输入多输出带阈值的二态非线性动力学系统
- DHNN中神经元相互作用，不断演化，如果从某一时刻开始，其中所有神经元的状态不再改变，则DHNN是稳定的
- Hopfield网络最重要的贡献之一就是**将能量函数引入到神经网络理论**，用来描述网络当前的状态
- 动态系统中，平衡稳定状态可以理解为系统某种形式的能量函数，在系统运行过程中，能量不断减少，最后处于最小值
- DHNN能量函数定义为：


$$E = -\frac{1}{2} \sum_{i=1}^N \sum_{\substack{j=1 \\ j \neq i}}^N w_{ij} v_i v_j + \sum_{i=1}^N \theta_i v_i$$

离散Hopfield神经网络的应用

- W 是对角元为0的对称矩阵，网络具有串行稳定性
- 非负定矩阵，网络具有并行稳定性
- 联想记忆：




联想记忆功能可以被抽象为下图神经动力学



离散Hopfield神经网络的应用

- 离散Hopfield网络的串扰问题：



- 由于“4”中包含了“1”中的全部竖线，Hopfield网络错把带有“横线”噪音的测试样本“1”识别为“4”，这种情况即串扰

Hopfield网络的串扰

连续Hopfield神经网络

- 连续Hopfield网络 (CHNN) 和DHNN拓扑结构一致, 比DHNN更接近生物神经元的特性
- 神经元状态可以取0-1之间的连续值
- 激活函数不是阶跃而是S型的连续函数
- 时间连续, 各个神经元是同步工作的
- 当CHNN的神经元传递函数是连续且有界, 且权值系数矩阵对称, 则CHNN是稳定的

Hopfield神经网络与优化


- 1985年，Hopfield和Tank将HNN网络用于求解经典的旅行商问题（TSP）。自此，HNN在优化中开始被广泛使用
- CHNN求解优化问题的动机很直接：如果一个优化问题的代价函数能被写为Hopfield能量函数的形式，那么Hopfield网络平衡态处于的点可以代表优化问题的解

连续Hopfield神经网络的应用

• CHNN解决组合优化问题

- 将走过的每一条路径构造成换位矩阵，作为TSP问题的约束条件。
- 将上述问题映射为HNN：
 - 换位矩阵集合与 $N \times N$ 个神经元组成的阵列相对应；
 - 每一条路径所对应的矩阵各元素与神经元的稳态输出相对应
- 找出一个反映TSP约束优化问题的能量函数 E
- 求使 E 取极小值时，网络稳态输出就是TSP问题的局部最优解。

在计算机上用离散HNN更快，用连续HNN可获得质量更好甚至全局最优解。



TSP问题

例如某一条路径的访问顺序是0123，
 $S = d_{01} + d_{12} + d_{23} + d_{30}$ ，
 相应换位矩阵为：

	1	2	3	4
0	1	0	0	0
1	0	1	0	0
2	0	0	1	0
3	0	0	0	1

其他早期的神经网络模型

- Boltzmann Machine (1983-1985) – by Hinton & Sejnowski et al.
 - RBM (1986)
 - DBM, DBN (2006)
- Self-Organizing Map (SOM) (1980s) - by Kohonen
- RBF (Radial Basis Function) 神经网络 (1980s) – by Moody & Darken

扩展阅读

- <https://cs.stanford.edu/people/eroberts/courses/soco/projects/neural-networks/History/history1.html>

温故而知新，了解智能学科的发展历史有助于我们成为更好的研究者！