

第四章 连接学派

Connectionism

连接学派简介

神经网络基本概念与近代史

神经网络基本思想与结构

从浅层学习到深度学习

现代神经网络重要思想与结构

概述

连接学派简介

神经网络基本概念与近代史

神经网络基本思想与结构


从浅层学习到深度学习

现代神经网络重要思想与结构

浅层学习：机器学习的第一次浪潮

- 20世纪80年代末期，人工神经网络的反向传播（BP）算法的发明给机器学习带来了希望，掀起了**基于统计模型**的机器学习热潮。这个热潮一直持续到今天。
- 20世纪90年代，各种各样的浅层机器学习模型相继被提出，例如支撑向量机（Support Vector Machine, SVM）、最大熵模型、逻辑回归、集成学习Boosting（如Adaboost、GBDT）等

这个时期的研究成果诞生了像 “**Pattern Recognition and Machine Learning**” 这样被称为 “机器学习圣经” 的书籍



机器视觉感知的流程

- 经典视觉感知流程中的若干关键步骤均依赖人手工设计




- 视觉系统中的关键步骤
- 识别准确率的关键
- 计算代价最大的地方
- 在传统视觉中通过手工设计

传统视觉描述子

- 视觉中经典描述子的特征编码过程过于抽象，难以理解
- 不同视觉任务下，描述子表现不一，通用性不足
- 对于新的任务，需要通过试错的方式选择描述子，甚至需要重新发明新的描述子

SIFT


尺度不变特征变换（
Scale-Invariant Feature
Transform, SIFT）




特征提取
特征描述

HoG

梯度方向直方图（
Histogram of Oriented
Gradients, HOG）



Textons



自然图像中基本的
微观结构，是
视觉感知初始阶
段的基元

基于词袋模型和空间金字塔的图像分类

- 分别为x方向梯度图，y方向梯度图，梯度幅值图，梯度方向图：




在每个像素处，梯度有一个大小和一个方向。x方向梯度图会强化垂直边缘特征，y方向梯度图会强化水平边缘特征。这就使得有用的特征（轮廓）得到保留，无关不重要的信息被去除。


基于词袋模型和空间金字塔的图像分类

- 深度学习流行之前，主流图像分类均基于词袋模型（Bag-of-Words Model）

第一步：利用SIFT算法，提取视觉词汇并集合于一处




第二步：利用K-Means算法进行视觉词汇分类合并，生成码本（单词表）




基于词袋模型和空间金字塔的图像分类

- 深度学习流行之前，主流图像分类均基于词袋模型（Bag-of-Words Model）




词袋模型是一种特征编码方法，本质上是对底层描述子的再次抽象，不同的特征编码途径都在尝试解答一个基础问题：**应该如何提取特征？**

特征提取难！
(图像、语音...)



深度学习的目标




特征学习:

怎么做?

与其设计特征, 不如设计特征学习器

深度学习的生物学启发


- 从认知神经科学、生物学等学科寻找启发（手艺不能丢）
- 1981年的诺贝尔医学/生理学奖颁发给了David Hubel和 Torsten Wiesel以及 Roger Sperry。前两位的主要贡献为“发现了视觉系统的信息处理机制”，发现**可视皮层是分级的**。




深度学习的生物学证据

David Hubble and Torsten Wiesel, 1958

- 视觉皮层的许多神经元具有一个很小的**局部感受野** (Local receptive field), 只会对视野里的有限区域做出反应;
- 方向选择性细胞**, 方向线条相比其它诸如圆圈, 光晕或条纹类的表示响应更强
- 视觉系统的信息处理是分级的。一些神经元具有较大的感受野, 只会对由低级模式组合成的高级模式做出反应。





Hubel-Wiesel 层级结构




深度学习的生物学证据

- 从视网膜（Retina）出发，经过低级的V1区提取边缘特征，到V2区的基本形状或目标的局部，再到高层V4的整个目标，再到更高层的PFC（前额叶皮层）进行分类判断等。
- 也就是说高层的特征是低层特征的组合，从低层到高层的特征表达越来越抽象和概念化。




深度学习的层级思想

- 科学家们相信，可以通过堆叠神经网络的层来模拟人视觉的层级表达过程



深度学习的模块化思想

- 科学家认为：可能在人脑中的许多区域中使用了相同的学习算法，这些作为基础模块被用来编码声音、触觉、语言以及其他感官类的输入。
- 分层，模块化处理
- 每层学到一定抽象程度的内容
- 特征提取→神经网络模块设计和架构设计




数据通过非线性被映射到特征空间

深度学习的挑战

然而，深度学习在早期遇到过很多瓶颈：

- 1989年，Yann LeCun等人开始将1974年提出的标准反向传播算法应用于深度神经网络，这一网络被用于手写邮政编码识别。尽管算法可以成功执行，但计算代价非常巨大，神经网络路的训练时间达到了3天，难以投入实际使用（**算力的限制**）
- 许多因素导致了这一缓慢的训练过程，其中一种是由Jürgen Schmidhuber的学生赛普·霍克赖特于1991年提出的梯度消失问题（**算法的限制**）

深度学习的标志性事件



Brief history of neural network

自2006年开始深度学习的回归

Reducing the Dimensionality of Data with Neural Networks

G. E. Hinton* and R. R. Salakhutdinov

High-dimensional data can be converted to low-dimensional codes by training a multilayer neural network with a small central layer to reconstruct high-dimensional input vectors. Gradient descent can be used for fine-tuning the weights in such “autoencoder” networks, but this works well only if the initial weights are close to a good solution. We describe an effective way of initializing the weights that allows deep autoencoder networks to learn low-dimensional codes that work much better than principal components analysis as a tool to reduce the dimensionality of data.

Dimensionality reduction facilitates the classification, visualization, communication, and storage of high-dimensional data. A simple and widely used method is principal components analysis (PCA), which

finds the directions of greatest variance in the data set and represents each data point by its coordinates along each of these directions. We describe a nonlinear generalization of PCA that uses an adaptive, multilayer “encoder” network

论文提出了一种在前馈神经网络中进行有效训练的算法。

这一算法将网络中的每一层视为无监督的受限玻尔兹曼机，再使用有监督的反向传播算法进行调优。

7 2006 VOL 313 SCIENCE www.sciencemag.org

深度学习回来了！
这次是Science:)



深度学习：机器学习的第二次浪潮

- Hinton在《Science》发表的这篇论文开启了深度学习在学术界和工业界的广泛研究和应用
- 论文的两个主要贡献：
 - 展现了神经网络具有**特征学习能力**
 - 降低了深度神经网络的**训练难度**
- 区别于传统的浅层学习，深度学习的不同在于：
 - 1)强调**模型结构的深度**，通常至少有5层、6层，甚至10多层的隐层节点；
 - 2)明确突出**特征学习的重要性**

深度学习在2012年ImageNet比赛大放异彩

- ImageNet是Fei-Fei Li牵头构建的一个百万级的大规模图像分类数据库
- 2012年9月30日，一个叫做AlexNet的深度卷积神经网络以15.3%的Top-5误差率，以超越第二名10.8%的强大优势在ImageNet 2012比赛上夺冠。
- According to [*The Economist*](#), "Suddenly people started to pay attention, not just within the AI community but across the technology industry as a whole."

深度学习的成功

- 深度学习在ImageNet上的巨大成功得益于成熟的算法（卷积神经网络）、强大算力的使用（GPUs）、以及之前被忽略的——大规模的数据集
- 天时（算法）、地利（算力）、人和（数据）共同造就了深度学习的成功


大数据



计算力



算法



深度学习的成功

2018年，ACM（国际计算机学会）决定将计算机领域的最高奖项图灵奖颁给 Yoshua Bengio、Yann LeCun 和 Geoffrey Hinton，以表彰他们在计算机深度学习领域的贡献。



常用深度学习框架

- 简易和快速的原型设计
- 自动梯度计算
- 无缝CPU和GPU切换
- 分布式训练

 PaddlePaddle

 Chainer

 Microsoft
CNTK

 TensorFlow

 PYTORCH

 APACHE
mxnet

 Keras

 theano

 Caffe2

 MegEngine

深度学习小结

- 从数据中学习数据间的统计特性以及相关性
- 学习的表达可以作为特征用于不同的任务中
- 深度学习也被称为: 特征学习、表达学习等等
- 深度学习的研究目标是通过发现有效的学习算法, 学习层次化的特征分布与表达, 通常更高层应表达更加抽象的特征。

Bengio Y. Deep learning of representations: Looking forward[M]. Statistical Language and Speech Processing. Springer Berlin Heidelberg, 2013: 1-37.

概述

连接学派简介

神经网络基本概念与近代史

神经网络基本思想与结构


从浅层学习到深度学习

现代神经网络重要思想与结构


现代神经网络重要思想与结构

- 深度卷积网络
- 生成与对抗
- 注意力机制
- 图上的深度学习



Deep Convolutional Network (DCN)



Generative Adversarial Network (GAN)




Attention Network (AN)




现代神经网络重要思想与结构



- 深度卷积网络
- 生成与对抗
- 注意力机制
- 图上的深度学习



Generative Adversarial Network (GAN)




Attention Network (AN)



深度卷积网络

Deep Convolutional Networks


- 动机和由来
- 基本构成与性质
- 典型架构
- 存在的问题



深度卷积网络



Deep Convolutional Networks

- 动机和由来
- 基本构成与性质
- 典型架构
- 存在的问题





来自神经科学与生理学的启发

- **整体结构: 简单细胞+复杂细胞**
 - **简单细胞**检测局部特征
 - **复杂细胞**聚合简单细胞周围视网膜附近的输出
- **局部感受野 (局部性)**
- **在视场中的自适应感受野 (权值共享)**
- **视觉皮层中的下采样率 (2到3)**



受生物学启发的HMAX模型



最早的卷积神经网络


- 1980年，福岛邦彦在论文《Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position》提出了一个包含卷积层、池化层的神经网络结构。
- 1998年，Yann Lecun在论文《Gradient-Based Learning Applied to Document Recognition》中提出了LeNet-5，将BP算法应用到这个神经网络结构的训练上。



福岛邦彦




Lecun



深度卷积网络

Deep Convolutional Networks

- 动机和由来
- 基本构成与性质
- 典型架构
- 存在的问题



网络层的概念

- 在现代深度学习的框架中，网络是以“层（Layer）”作为基本单元搭建的（每个层可以类比乐高中的积木）
- 不同层按功能不同可以分类许多的大类别，如卷积层、池化层
- 不同的大类层下，又可以细分为许多的子类层（不用记，需要用时查找即可）

Convolution Layers

`nn.Conv1d`

Applies a 1D convolution over an input signal composed of several input planes.

`nn.Conv2d`

Applies a 2D convolution over an input signal composed of several input planes.

`nn.Conv3d`

Applies a 3D convolution over an input signal composed of several input planes.

`nn.ConvTranspose1d`

Applies a 1D transposed convolution operator over an input image composed of several input planes.

`nn.ConvTranspose2d`

Applies a 2D transposed convolution operator over an input image composed of several input planes.

`nn.ConvTranspose3d`

Applies a 3D transposed convolution operator over an input image composed of several input planes.

`nn.LazyConv1d`

A `torch.nn.Conv1d` module with lazy initialization of the `in_channels` argument of the `Conv1d` that is inferred from the `input.size(1)`.

`nn.LazyConv2d`

A `torch.nn.Conv2d` module with lazy initialization of the `in_channels` argument of the `Conv2d` that is inferred from the `input.size(1)`.

`nn.LazyConv3d`

A `torch.nn.Conv3d` module with lazy initialization of the `in_channels` argument of the `Conv3d` that is inferred from the `input.size(1)`.

`torch.nn`

+ Containers

Convolution Layers

Pooling layers

Padding Layers

Non-linear Activations (weighted sum, nonlinearity)

Non-linear Activations (other)

Normalization Layers

Recurrent Layers

Transformer Layers

Linear Layers

Dropout Layers

Sparse Layers

Distance Functions

Loss Functions

Vision Layers

Shuffle Layers


DataParallel Layers (multi-GPU, distributed)

+ Utilities

Quantized Functions

Lazy Modules Initialization

深度卷积网络的基本构成



- 卷积 (Convolution Layer)
- 池化层 (Pooling Layer)
- 非线性激活单元 (Nonlinear Activation Units)
- 归一化层 (Normalization Layer)
- 全连接层 (Fully-connected Layer) 与分类器 (Classifier)

图像卷积

- 固定模板的卷积
 - 按卷积核对图像局部像素进行加权求和

例：边缘检测
Sobel算子

$$\begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$



卷积算子的定义



- 数学上，给定输入 x 以及一个滤波器 w ，卷积输出特征 y ：

$$y = x * W$$

其中 $*$ 表示卷积操作。 W 在 x 上卷积运算被定义为计算每个滤波器的值与输入之间的点积。相比Sobel预定义卷积参数， W 在卷积网络中是学习得到的。

- 卷积核的超参数：
 1. 卷积核的大小 (Kernel Size) 定义了卷积核的视场大小
 2. 步长 (Stride) 定义了 w 在 x 上滑动的步进
 3. 填充 (Padding) 定义了 x 四周的边缘如何处理

单通道2D卷积



单通道的卷积运算, kernel size=3, stride=1, padding=1

一个简单的例子

- 3x3的滤波器作用于5x5的输入
- 思考：
 - 当padding和kernel size满足什么关系时，卷积前后的输入的尺寸不变？
 - 试计算C、D和E的卷积结果

5x5

1	2	3	4	5
6	7	8	9	10
11	12	13	14	15
16	17	18	19	20
21	22	23	24	25

3x3

1	1	0
0	1	0
0	0	1

kernel size = 3

stride = 1

padding = 1 填充0

$$\begin{aligned}
 A &= 0 \times 1 + 0 \times 1 + 0 \times 0 + \\
 &\quad 0 \times 0 + 1 \times 1 + 2 \times 0 + \\
 &\quad 0 \times 0 + 6 \times 0 + 7 \times 1 \\
 &= 8
 \end{aligned}$$


A				E?
	C?			
				B
		D?		

$$\begin{aligned}
 B &= 14 \times 1 + 15 \times 1 + 0 \times 0 + \\
 &\quad 19 \times 0 + 20 \times 1 + 0 \times 0 + \\
 &\quad 24 \times 0 + 25 \times 0 + 0 \times 1 \\
 &= 49
 \end{aligned}$$

0	0	0				
0	1	2	3	4	5	
0	6	7	8	9	10	
	11	12	13	14	15	0
	16	17	18	19	20	0
	21	22	23	24	25	0

$o = \text{floor}[(i - k + 2p)/s] + 1$ where o : output i : input p : padding s : stride


多通道2D卷积



多通道的卷积运算, kernel size=3, stride=1, padding=0

Output depth=no. of filters

多通道输入生成多通道输出



卷积的作用

- 局部算子
- 平移同变性
- 特征增强
- 降噪



Input

Operation	Filter	Convolved Image
Identity	$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	
Edge detection	$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$	
	$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$	
	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$	
Sharpen	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	
Box blur (normalized)	$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$	
Gaussian blur (approximation)	$\frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$	






华中科技大学

HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY

池化算子

池化 (Pooling)

- 又称下采样 (Subsampling) 或降采样 (Down sampling)，常用于降低特征图的空间分辨率
- 常用方法：最大池化 (Max Pooling)、平均池化、...
- 经过池化运算通道数不变
- 池化层一般不训练学习参数
- 池化步长 (步幅)




$$o = \text{floor}[(i - k + 2p)/s] + 1 \text{ where } o: \text{output } i: \text{input } p: \text{padding } [0] \text{ } s: \text{stride}$$

The depth dimension remains unchanged.

池化的作用

- 局部变化的不变性（增加特征的鲁棒性）
- 增大感受野
- 降维（降低卷积层输出的特征维度）
- 防止过拟合




平移不变性和平移同变性

- 卷积算子具有平移同变性
- 池化算子具有局部的平移不变性

平移不变性


Invariance



不管输入如何平移的，系统产生完全相同的响应（输出）。



平移同变性

Equivariance




系统在不同位置的工作原理相同，但它的响应随着目标位置的变化而变化。

Quiz



https://www.zhihu.com/question/45509222/answer/105509222


多通道卷积1



每一个卷积核的通道数量，必须要求与输入通道数量一致，因为要对每一个通道的像素值要进行卷积运算，所以每一个卷积核的通道数量必须要与输入通道数量保持一致


Quiz

多通道卷积1



Quiz


多通道卷积1



- 1: 输入通道个数 等于 卷积核通道个数
- 2: 卷积核个数 等于 输出通道个数

Quiz

假设输入数据是一个 5×5 的二维矩阵，卷积核是一个 3×3 的矩阵。在进行卷积时，卷积核从输入数据的左上角开始，依次与对应的 3×3 区域的元素进行对应位置相乘，然后将乘积结果相加，得到输出特征图中对应位置的一个值。如上图，卷积核与输入数据左上角 3×3 区域的计算过程为： $(1 \times 1 + 2 \times 0 + 3 \times 1 + 0 \times 0 + 1 \times 1 + 2 \times 0 + 1 \times 1 + 2 \times 0 + 3 \times 1) = 10$ ，这个 10 就是输出特征图左上角的值。接着，卷积核按照设定的步长（这里假设步长为 1）向右滑动一个位置，重复上述计算过程，直到遍历完整个输入数据，从而得到完整的输出特征图。如果将这个制作成动画，会更清晰地看到卷积核是如何在输入数据上滑动并计算的，就像一个探测器在图像上扫描，寻找特定的模式和特征。在实际的图像卷积中，输入数据通常是三维的（包含通道维度），卷积核也相应地是三维的，但基本原理与上述二维示例一致，只是在计算时需要对每个通道分别进行卷积操作，然后将结果进行叠加。



Quiz



224×224×3的图片

32个5×5×3的卷积核

? 32张Feature Map

? 32张Feature Map

64个5×5×32的卷积核



? 64张Feature Map





華中科技大學

HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY


非线性激活单元



Rectified Linear Unit (ReLU)



Leaky ReLU activation function



线性整流单元

Rectified Linear Units (ReLUs)



归一化层

在机器学习领域中，不同评价指标（即特征向量中的不同特征就是所述的不同评价指标）往往具有不同的量纲和量纲单位，这样的情况会影响到数据分析的结果，为了消除指标之间的量纲影响，需要进行数据标准化处理，以解决数据指标之间的可比性。原始数据经过数据标准化处理后，各指标处于同一数量级，适合进行综合对比评价。其中，最典型的的就是数据的归一化处理。



<u>x1</u>	x2	x3	x4	x5	x6
2.0	1.8	2.1	1.9	2.2	45.5
1.0	1.2	0.9	0.8	1.5	10.5

奇异样本数据的存在会引起训练时间增大，同时也可能导致无法收敛，因此，当存在奇异样本数据时，在进行训练之前需要对预处理数据进行归一化。

归一化层

归一化的对比

如果不进行归一化，那么由于特征向量中不同特征的取值相差较大，会导致目标函数变“扁”。这样在进行梯度下降的时候，梯度的方向就会偏离最小值的方向，走很多弯路，即训练时间过长。




如果进行归一化以后，目标函数会呈现比较“圆”，这样训练速度大大加快，少走很多弯路


归一化层

- The “Internal covariate shift” problem

$$y = \frac{x - E[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$




```
def conv_bn(inp, oup, k=3, s=1, BatchNorm2d=SynchronizedBatchNorm2d):
    return nn.Sequential(
        nn.Conv2d(inp, oup, k, s, padding=k//2, bias=False),
        BatchNorm2d(oup),
        nn.ReLU6(inplace=True)
    )
```



卷积网络的优势


- 局部连接与权值共享



每个神经元仅和部分输入连接

$$1000 \times 1000 \times 1000000 = 10^{12}$$

Local connectivity: 10×10
 $10 \times 10 \times 1000000 = 10^8$



滤波器在图像不同位置的参数共享


每个滤波器100个参数, 100个滤波器, 仅 $100 \times 100 = 10K$ 个参数

局部连接 (Local connectivity)
 → 参数减少
 权值共享 (Parameter sharing)
 → 参数再减少

深度卷积网络


Deep Convolutional Networks

- 动机和由来
- 基本构成与性质
- **典型架构**
- 存在的问题



CNN典型架构之LeNet


LeNet-5 Document Recognition System



- 平均池化
- Sigmoid or tanh 非线性激活单元
- 全连接层用于分类
- 在60,000个训练样本的MNIST手写体识别数据集上训练

ImageNet图像分类比赛

IMAGENET



- 互联网图像数据
- Amazon MTurk人工标注
- 1200,000训练图像, 1000个类别

ImageNet背后的曲折故事

- 随父母移民，从洗衣妹到获得普林斯顿大学全额奖学金
- 拒绝华尔街offer，西藏之行研究藏药，看重小众科研项目在更大领域范围内的研究意义
- 在斯坦福tenure track期间决心建立ImageNet，被认为拿自己前途在赌博




ImageNet背后的曲折故事

- 为ImageNet筹集funding，决定重开洗衣店
- 许多意义重大的研究一开始很可能都隐藏在小角落的poster中
- 对很多人，论文的发表意味着一个工作的结束，对有些人，也许只是刚刚开始




ImageNet: A Large-Scale Hierarchical Image Database

Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li and Li Fei-Fei
Dept. of Computer Science, Princeton University, USA
{jiadeng, wdong, rsocher, jial, li, feifeili}@cs.princeton.edu




ImageNet历年来Top-5误差率



CNN典型架构之AlexNet

2012 ImageNet 比赛冠军!



与LeNet结构相似, 但:

- 更大的模型 (8 层)
- 采用ReLU激活函数
- 更多的数据 (10^6 vs 10^3 images)
- 更好的正则化 (DropOut)

- GPU实现 (超过CPU 50倍的加速)
- 7个隐含层, 650,000 神经元, 60,000,000 参数
- 在2块 GPUs 上训练一周

我又来了!



CNN典型架构之VGGNet

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64	conv3-64	conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128	conv3-128	conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Table 2: Number of parameters (in millions).


Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

2014 ImageNet 比赛亚军!


- 朴素的实现
- 更深的模型 (16 层 or 19 层)
- 由连续3x3卷积取得的更大的感受野 (对于C通道的特征图, 7x7的卷积核需要 $49C^2$ 个参数, 但通过三个连续3x3核的卷积层等价实现, 仅需 $27C^2$ 个参数)

CNN典型架构之GoogLeNet


2014 ImageNet 比赛冠军!



- Inception模块 (1x1, 3x3, 5x5的不同感受野分支用于捕获)
- 在昂贵的卷积计算前使用1x1卷积降低特征通道维数




CNN典型架构之ResNet



2015 ImageNet 比赛冠军!

- 152层
- 主要解决深度网络变深后难以优化的问题
- 以跳连 (Skip Connection) 为核心的残差网络
- 在所有学科领域中引用最高的论文



Kaiming He

Research Scientist, Facebook AI Research (FAIR)
Verified email at fb.com - [Homepage](#)
Computer Vision Machine Learning

FOLLOWING

TITLE

CITED BY


YEAR

Deep Residual Learning for Image Recognition
K He, X Zhang, S Ren, J Sun
Computer Vision and Pattern Recognition (CVPR), 2016

83014

2016


一位图形学教授曾评价Kaiming He:
Whatever this guy touches,
it becomes gold.



深度卷积网络

Deep Convolutional Networks

- 动机和由来
- 基本构成与性质
- 典型架构
- 存在的问题



CNN还有哪些问题?

Dataset $\neq$ Reality !!!

ImageNet

Chairs



ObjectNet


Chairs by rotation





Chairs by background




Chairs by viewpoint




Teapots



T-shirts




CNN还有哪些问题？



CNN对诸如平移旋转等几何变换的鲁棒性其实没有想象中那么好！！！！

CNN还有哪些问题?




论猪如何上天? —— CNN的对抗攻击

CNN还有哪些问题?



Class Activation Map



CNN通过局部判断目标类别，CNN内部没有关于整体与局部的显式表达，因而难以理解它们的关系

Reading List

- Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, Gradient-based learning applied to document recognition, Proc. IEEE 86(11): 2278–2324, 1998.
- A. Krizhevsky, I. Sutskever, and G. Hinton, ImageNet Classification with Deep Convolutional Neural Networks, NIPS 2012
- M. Zeiler and R. Fergus, Visualizing and Understanding Convolutional Networks, ECCV 2014
- K. Simonyan and A. Zisserman, Very Deep Convolutional Networks for Large-Scale Image Recognition, ICLR 2015
- M. Lin, Q. Chen, and S. Yan, Network in network, ICLR 2014
- C. Szegedy et al., Going deeper with convolutions, CVPR 2015
- C. Szegedy et al., Rethinking the inception architecture for computer vision, CVPR 2016
- K. He, X. Zhang, S. Ren, and J. Sun, Deep Residual Learning for Image Recognition, CVPR 2016

本周作业1

- 请判断以下关于CNN说法的正误，并解释原因：
 - 全连接层通常只出现在CNN的最后几层
 - 只有池化层能起到下采样的作用
 - 残差网络采用跳跃连接计算一个非线性函数使得输入能传递到更深的层

本周作业2

- 假设输入是一张 128×128 的RGB彩色图像，如果网络第一个卷积层的卷积核为 3×3 的大小，步长为1，共有64个卷积核，后接一个步长为2的 2×2 平均池化层，随后再接两层核大小为 5×5 ，卷积核个数为128的卷积层以及一层步长为2的 2×2 的平均池化层，最后接含有128个神经元的全连接层和一个含有10个神经元的输出层，试计算该网络的参数量和感受野并回答网络的参数量主要由哪部分贡献（ 3×3 卷积的padding为1， 5×5 卷积的padding为2，2层 5×5 的卷积层的stride需要讨论）。





本周作业3

请在网上查阅以下网络，每种网络用两到三句话概括其主要思想以及核心技术贡献：

- DenseNet
- ResNeXt
- MobileNets/MobileNet V2/MobileNet V3
- EfficientNets

现代神经网络重要思想与结构


- 深度卷积网络
- 生成与对抗
- 注意力机制
- 图上的深度学习



生成与对抗

An Introduction to Generative Adversarial Networks


- 背景与应用
- 主要思想
- 发展历程



生成与对抗

An Introduction to Generative Adversarial Networks

- 背景与应用
- 主要思想
- 发展历程



生成对抗网络的提出

- Ian Goodfellow 在 *Generative Adversarial Networks* 中首次提出了生成对抗网络(GAN), 他也因此被誉为“GANs之父”



Ian Goodfellow

Unknown affiliation

Verified email at cs.stanford.edu - [Homepage](#)


[Deep Learning](#)

[FOLLOW](#)

TITLE	CITED BY	YEAR
Generative adversarial networks IJ Goodfellow, J Pouget-Abadie, M Mirza, B Xu, D Warde-Farley, S Ozair, ... arXiv preprint arXiv:1406.2661	29329	2014
Deep learning I Goodfellow, Y Bengio, A Courville, Y Bengio MIT press 1 (2)	26673	2016

Cited by

	All	Since 2016
Citations	135513	132294
h-index	70	69
i10-index	110	107



酒后脑洞

- 2014年的一个晚上，Ian Goodfellow在酒吧给师兄庆祝博士毕业。一群工程师聚在一起探讨如何让自动生成照片。
- Goodfellow的朋友们提出：对构成照片的像素进行统计分析，使机器自己生成图像。
- Goodfellow一听觉得这个想法行不通，马上否决了它，然后边喝酒边思考。
- 突然他灵光一现：如果让两个神经网络互相对抗呢？（一个负责生成，一个负责判断生成的到底像不像）
- Goodfellow连夜写代码实现并测试，他本人都没想到，第一次就测试成功了，生成了质量不错的照片。那晚发明的东西就叫做GAN。

GAN能做什么?

- 自然图像生成



请问上面四幅图像哪些是真实拍摄的照片？ 哪些是模型生成的假图？


GAN能做什么?

- 动漫头像生成



GAN能做什么?

- 图像风格迁移



GAN能做什么?

• 文字转图像

A family standing in front of a sign while wearing skis and holding ski poles.



A train being operated on a train track.



Three boys playing a soccer game on a green soccer field.



Two people in a speed boat on a body of water.



A bird with a brown and black wings, red crown and throat and the bill is short and pointed.



This is a white and grey bird with black wings and a black stripe by its eyes.



This bird has a yellow throat, belly, abdomen and sides with lots of brown streaks on them.




This bird has a white belly and breast, with a blue crown and nape.



GAN能做什么?

- 图像编辑 (<https://www.artbreeder.com>)



GAN能做什么?


- 图像复原



生成与对抗

An Introduction to Generative Adversarial Networks

- 背景与应用
- 主要思想
- 发展历程



生成对抗？ 零和博弈？




生成对抗？ 零和博弈？



GAN的框架

- 生成网络接收一个随机的噪声，并生成“假数据”；判别网络接收“真数据”和生成的“假数据”，并预测不同数据的真实性概率。



GAN的学习目标

- 假设 G 为生成器， D 为判别器，真实数据 x 服从 $p_{data}(x)$ 分布，噪声 z 服从 $p_z(z)$ 分布，目标函数 $V(D,G)$ 的优化可表示为：

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

- $D(\cdot)$ 计算数据的真实性概率（1为真，0为假）。
- 生成器的目标是生成尽可能真实的“假数据”，即 $D(G(z)) \rightarrow 1$ ；
- 判别器的目标是尽可能判断出数据的真假，即 $D(x) \rightarrow 1, D(G(z)) \rightarrow 0$ 。

目标函数可看作真实数据和生成数据的交叉熵之和。

GAN的学习目标

实际操作分两步：

- 训练判别器 D 时，固定生成器 G 参数不变：

$$\max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{Z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

- 训练生成器 G 时，固定判别器 D 参数不变：

$$\min_G V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{Z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

- 循环优化，直至收敛。


GAN的优缺点

• 优点

1. 并未局限网络结构的具体形式，理论上，只要是可微分函数都可以用于构建生成器和判别器；
2. 生成器的参数更新不是直接来自数据样本，而是使用来自判别器的反向传播，因此网络设计更加灵活，降低了损失函数设计的困难。

• 缺点


1. 可解释性差，生成模型的分布没有显式的表达；
2. 比较难训练，生成器与判别器之间需要很好的同步，例如判别器更新 k 次而生成器只更新1次。



生成与对抗


An Introduction to Generative Adversarial Networks

- 背景与应用
- 主要思想
- 发展历程



DCGAN

- Deep Convolutional GAN, 将深度卷积神经网络CNN与生成对抗网络GAN结合，设计了一种通用的图像生成网络结构。



DCGAN

- DCGAN的改进包含以下几个方面：

- (1) 在生成器中使用转置卷积进行上采样，判别器中使用步长卷积代替池化层
- (2) 在生成器和判别器中都添加了批量归一化操作 (batch normalization)
- (3) 判别器中去掉了全连接层，使用全局池化层替代，使网络变为全卷积网络
- (4) 生成器中使用ReLU作为激活函数，最后输出层使用Tanh激活函数
- (5) 判别器中使用LeakyReLU激活函数

DCGAN



局限性： DCGAN依靠实验，找到了一组比较好的网络架构设置，但治标不治本，网络的训练仍然存在以下问题：

- 生成器和判别器的损失函数无法指导训练进程
- 生成样本缺乏多样性，容易出现模式崩塌（mode collapse）



WGAN

- Wasserstein GAN (Wasserstein 是一种经典的距离度量方式，也叫做推土机距离) 解释了GAN训练不稳定的原因，并给出了理论证明和解决方法。



WGAN


WGAN 的具体改进如下：

- 判别器最后一层去掉sigmoid
- 生成器和判别器的损失函数不取log（Wasserstein 距离）
- 每次更新判别器的参数后，把参数截断在某个范围内
- 不使用基于动量的优化算法如momentum和Adam，推荐使用RMSProp，SGD也行

CGAN

- Conditional GAN, 在生成器和判别器中同时加入条件约束来引导数据的生成过程, 实现控制图像的生成类别。

$$\begin{aligned} \min_G \max_D V(D, G) \\ = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x}|\mathbf{y})] + \\ \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{Z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z}|\mathbf{y})))] \end{aligned}$$




CGAN

- 在MNIST数据集上训练好的CGAN能够自由控制生成数字的类别。




Pix2Pix

- 传统GAN输入随机噪声，输出随机图像。但有时候用户希望输出图像和输入是对应的、有关联的。



Pix2Pix

- Pix2Pix是将CGAN应用于有监督的图像到图像翻译任务，有监督表示Pix2Pix使用成对的数据进行训练。



$$\mathcal{L}(G, D) = \mathcal{L}_{CGAN}(G, D) + \mathcal{L}_{\ell_1}(G)$$

$$\mathcal{L}_{\ell_1}(G) = \mathbb{E}_{\mathbf{x}, \mathbf{y}, \mathbf{z}} [\|\mathbf{y} - G(\mathbf{x}, \mathbf{z})\|_1]$$


Pix2Pix



Cityscapes labels $\rightarrow$ photo



facades labels $\rightarrow$ photo



day $\rightarrow$ night



edges $\rightarrow$ handbags




華中科技大學

HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY

CycleGAN


- CycleGAN在Pix2Pix的基础上更进一步，使用不成对的数据即可训练网络，大大降低了数据收集的难度。




CycleGAN

$$\begin{aligned} & \mathcal{L}(G_{A2B}, G_{B2A}, D_A, D_B) \\ &= \mathcal{L}_{GAN}(G_{A2B}, D_B) + \mathcal{L}_{GAN}(G_{B2A}, D_A) \\ &+ \lambda \mathcal{L}_{cyc}(G_{A2B}, G_{B2A}) \end{aligned}$$


$$\begin{aligned} & \mathcal{L}_{cyc}(G_{A2B}, G_{B2A}) \\ &= \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\|G_{A2B}(G_{B2A}(\mathbf{x})) - \mathbf{x}\|_1] \\ &+ \mathbb{E}_{\mathbf{y} \sim p_{data}(\mathbf{y})} [\|G_{B2A}(G_{A2B}(\mathbf{y})) - \mathbf{y}\|_1] \end{aligned}$$



CycleGAN




CycleGAN




PGGAN

- 用GAN直接训练生成高分辨率图像时不稳定情况会加剧，Progressive GAN对此提出了一种渐进训练方式。



PGGAN

- PGGAN递增分辨率过程：增加新的网络层时利用 α 进行平滑过渡



PGGAN

- PGGAN在人脸与自然场景下生成的高分辨率图像

直接生成结果



Progressive生成结果



参考文献

1. Goodfellow I J, Pouget-Abadie J, Mirza M, et al. "Generative Adversarial Nets." NIPS. 2014.
2. Radford, A., Metz, L., Chintala, S. "Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks." CoRR. 2016.
3. Arjovsky, M., Chintala, S., Bottou, L. "Wasserstein GAN." ICML. 2017.
4. Mirza, M., Osindero, S. "Conditional generative adversarial nets." arXiv preprint arXiv:1411.1784. 2014.
5. Isola P, Zhu J Y, Zhou T, et al. "Image-to-image translation with conditional adversarial networks." CVPR. 2017.
6. Zhu J Y, Park T, Isola P, et al. "Unpaired image-to-image translation using cycle-consistent adversarial networks." CVPR. 2017.

参考文献

7. Karras T, et al. “Progressive Growing of GANs for Improved Quality, Stability, and Variation.” ICLR. 2018.
8. Huang X, Belongie S. “Arbitrary Style Transfer in Real-time with Adaptive Instance Normalization.” ICCV. 2017.
9. Karras T, S. Laine, et al. “A Style-Based Generator Architecture for Generative Adversarial Networks.” CVPR. 2019.
10. Karras T, et al. “Analyzing and Improving the Image Quality of StyleGAN.” CVPR. 2020.


作业

请梳理一下GAN发展至今的若干代表性工作，绘制发展路径图，每个工作用一句话总结其核心贡献。（不限于本课程内的各种GAN变体）


现代神经网络重要思想与结构

- 深度卷积网络
- 生成与对抗
- 注意力机制
- 图上的深度学习


Deep Convolutional Network (DCN)




Generative Adversarial Network (GAN)



Attention Network (AN)




Graph Neural Network



注意力机制

Attention Mechanism


- 动机与由来
- 点积注意力简介
- 自注意力简介
- 典型应用



注意力机制

Attention Mechanism

- 动机与由来
- 点积注意力简介
- 自注意力简介
- 典型应用



人为什么会觉得“烧脑”？

- 信息量过大（悬疑电影、考前复习）
- 人脑的信息处理能力有限（怎么办？）


shāo nǎo 烧 脑

进行大量思考，从而充分“燃烧”
脑细胞的行为。

jìn xíng dà liàng sī kǎo, cóng ér chōng
fèn “ rán shāo ” nǎo xì bāo de xíng wéi 。

人眼的视觉注意力

- 注意力 (Attention) 是一个常见但又会被忽略的事实。比如天空飞过一只鸟儿，人的注意力会追随着鸟儿，那么天空在人的视觉系统中自然成为了一个背景。这种现象也被称为人的认知注意力 (Cognitive Attention)。




人眼的视觉注意力

- 注意力发生在突触水平上，作用是提高对输入信号的敏感性，并锐化这些信号的精确度，同时选择性地提高吸引注意力信息的传输，降低噪音水平或减弱干扰注意力信息的传输。
- 注意力通过选择性改变突触的“权重”，强化所有包括噪音在内感觉输入的感官特征，从而重塑神经感觉。
- 注意力是一个用来分配有限信息处理能力的选择机制。
 - 抑制某个区域的input/output以阻止干扰信息的进入
 - 加强某个区域的signal以促进该信息的处理

人眼的视觉注意力

- **自下而上**：“见山是山，见水是水”，即大脑内呈现的信息是通过视觉通路传递的外界刺激原始的物理特征，包括颜色、强度、方向等等。这是**外部环境信息驱动的注意力**。
- **自上而下**：指的是大脑的（高级）联合皮层，包括前额叶皮层（PFC）和后顶叶皮层（PPC）根据**当前任务的目标和以往的知识**对视觉通路中的信息进行的调控。这是**大脑内部信息驱动的注意力**。



人眼的视觉注意力

- 眼睛接受像素信息，根据具体的像素信息成像。这个过程属于 **bottom-up** 过程，即人眼根据某一个像素及其周围的像素信息形成图像区域并进一步抽象为某一个物体形状。
- 眼睛扫描整个场景元素，并且寻找感兴趣的影像区域。这个过程属于 **top-down** 过程，即获得第一步物体形状之后，人眼会快速扫描整个视野场景，然后快速定位到感兴趣的地方。
- 眼睛聚焦感兴趣的区域，仔细观察获得外部信息。


人眼的视觉注意力

- 人类在看到一副图像时是如何高效分配有限的注意力资源的：
 - 其中红色区域表明视觉系统更关注的目标，很明显对于如图所示的场景，人们会把注意力更多投入到人的脸部，文本的标题以及文章首句等位置。



为什么需要注意力?

- 以计算机视觉系统为例，注意力可以帮助系统忽略无关信息、关注重点信息。



图像识别（识别两幅图片中的鸟是否为一种类别时，注意力机制将关注的重点放在了鸟的头部）



图像分类（汽车分类中，网络关注的是汽车的车标以及车尾）



A group of people sitting on a boat in the water.


图像翻译（在图像翻译中，“people”这个词在图中关注的位置正是船上的人）

注意力的定义

- 在神经网络中，注意力机制（Attention Mechanism）表示一类**模拟人类认知注意力**的技术。
- 它主要通过引入**乘法交互**使输入的**重要部分得到加强**，同时**弱化剩余输入**——网络应将算力关注到某些虽小但重要的区域。

DL中注意力机制的首次出现

- 在2014年，Google DeepMind团队在RNN 模型上引入了attention机制用于图像分类。这是在深度学习流行后，大家普遍认为的Attention机制最早出现的地方。



V. Mnih, N. Heess, A. Graves, K. Kavukcuoglu, Recurrent Models of Visual Attention, arXiv:1406.6247, 2014.

NLP中注意力机制的发展


- 还是2014年，Bahdanau和Bengio等人使用类似attention的机制在机器翻译任务上实现翻译和文本对齐。这可以认为第一个将attention机制应用到NLP领域中的工作。



D. Bahdanau, K. Cho, Y. Bengio, Neural Machine Translation by Jointly Learning to Align and Translate, arXiv:1409.0473, 2014

NLP中注意力机制的发展

- 接着attention机制被广泛应用在基于RNN/CNN 等神经网络模型的各种NLP任务中，例如，K. Xu et al. 等人首先将注意力机制引入计算机视觉领域



K. Xu et al., Show, attend and tell: Neural image caption generation with visual attention, arXiv preprint arXiv:1502.03044, 2015


NLP中注意力机制的发展

- 2017年，Google机器翻译团队发表了著名的论文《Attention is all you need》，提出了自注意力机制学习文本表示。



Vaswani A, Shazeer N, Parmar N, et al., Attention is all you need, Advances in Neural Information Processing Systems, pp. 5998-6008, 2017.

CV中注意力的发展



注意力机制的分类

- 点积注意力
 - 强注意力 (Hard-attention) : $\{0, 1\}$ 二值分布问题
 - 软注意力 (Soft-attention) : $[0, 1]$ 连续分布问题
- 自注意力 (Self-attention) : 特征间的自主学习

强注意力

- 强注意力机制，是0/1二值分类问题，0表示区域不被关注，1表示区域受到关注。




软注意力

- 软注意力机制，是 $[0, 1]$ 连续分布问题，每个区域被关注的程度高低，用0~1的得分表示。下图中越高亮的位置表示关注度越大。



A woman is throwing a frisbee in a park.



A dog is standing on a hardwood floor.




A stop sign is on a road with a mountain in the background.



自注意力

- 自注意力是强/软注意力的改进，其减少了对外部信息的依赖，**更擅长捕捉数据或特征的内部相关性。**
- 自注意力机制可通过**捕捉全局信息**获得**更大的感受野和上下文信息。**

考虑一个单词it的特征，它的特征将根据别的单词的特征加权得到。
比如：可能the animal跟it的关系比较近（因为it指代the animal），所以它们的权值很高。




不同注意力机制的特点

- **强注意力**：强注意力关注点。图像中每个点都有可能延伸出注意力；同时强注意力是一个不可微的过程，训练过程往往通过强化学习实现。
- **软注意力**：软注意力关注区域或者特征通道，同时软注意力是可微的，因此可以通过神经网络计算出梯度并且通过前向传播和后向反馈来学习得到注意力的权重。
- **自注意力**：自注意力关注全局信息，有显式的表达式。由于每一个点都要捕捉全局上下文信息，导致自注意力机制模块计算复杂度和内存占用较大。

注意力机制

Attention Mechanism


- 动机与由来
- 点积注意力简介
- 自注意力简介
- 典型应用



点积注意力

- 点积注意力是神经网络中最常规的实现方式，根据作用对象不同可以分为：

- 空间注意力
- 通道注意力
- 混合注意力
- 时间注意力



空间注意力


- 空间注意力，顾名思义是让神经网络学习看哪里。对于一张图片或者一句话，其中关键信息往往仅有一小部分。因此，我们希望通过注意力机制让网络自主地关注这些关键位置。

I eat a nutritious breakfast in the hotel.



通道注意力


- 通道注意力的代表性成果为SENet，它提出的SE Block 将通道注意力分成三个部分：挤压（Squeeze），激励（Excitation），以及缩放（Scale）



SENet网络的创新点在于关注 **channel之间的关系**，希望模型可以自动学习到不同 **channel特征的重要程度**

空间通道注意力


- 空间通道注意力是一种混合注意力，顾名思义即将空间注意力和通道注意力结合。
- CBAM 是一个直观的混合注意力机制模型，它在通道域和空间域同时加入了注意力机制。空间注意力引导网络关注“where”；通道注意力引导网络关注“what”。



这样不不仅能够**节约参数和计算力**，并且保证了其能够做为即插即用的模块集成到现有的网络架构中去。


空间时间注意力

- 输入图像用 x 表示，特征提取网络用 ϕ ，则 $\phi(x)$ 代表卷积操作提取特征图。
- 注意力模型的locations随着时间一直变化，每一时刻的定位组成了 $\{l_1, l_2, l_3, \dots, l_T\}$ ，其中 $l_t \sim \pi(l_t | \phi(x))$ ， π 代表一个选择标准（选择峰值响应区域）。




空间时间注意力

- 如果是一个图像序列，每一时间的空间注意力结果都不一样。
- 对某一时刻的一帧图像提取到的特征图，按照一定的方式选择其响应够大的区域，就代表这一帧图像中在空间上应该着重关注/优先处理的区域。




时间注意力

- 对于时间域的注意力机制，应用最早的当属**自然语言处理（Natural Language Processing, NLP）**领域。斯坦福大学的一篇Effective Approaches to Attention-based Neural Machine Translation提出了一种软时间注意力机制。




无注意力




注意力

时间注意力




无注意力




注意力

- (1) 采用Encoder-Decoder框架进行翻译：Encoder对输入句子Source进行编码，转化为中间语义表示 c ；对于解码器Decoder来说，其任务是根据中间语义表示 c 和之前已经生成的历史信息 $y_1, y_2, \dots, y_{(i-1)}$ 来预测 y_i
- (2) 不采用注意力时，在生成目标句子的单词时，不论生成哪个单词，它们使用的输入句子Source的语义编码 c 都是一样的，没有任何区别。似于人类看到眼前的画面，但是眼中却没有注意焦点一样。
- (3) 没有引入注意力的模型在输入句子比较短的时候问题不大，但是如果输入句子比较长，此时所有语义完全通过一个中间语义向量来表示，单词自身的信息已经消失，可想而知会丢失很多细节信息，这也是为何要引入注意力模型的重要原因。

时间注意力



无注意力



注意力


(1) 如果引入Attention模型的话，注意力分配模型分配给不同英文单词的注意力大小，即图中的 c_1, c_2, c_3 ，这对于正确翻译目标语单词肯定是有帮助的，因为引入了新的信息。

(2) 目标句子中的每个单词都应该学会其对应的源句子中单词的注意力分配概率信息。这意味着在生成每个单词 y_i 的时候，原先都是相同的中间语义表示 c 会被替换成根据当前生成单词而不断变化的 c_i 。理解Attention模型的关键就是这里，即由**固定的中间语义表示 c 换成了根据当前输出单词来调整成加入注意力模型的变化的 c_i** 。

注意力机制

Attention Mechanism


- 动机与由来
- 点积注意力简介
- 自注意力简介
- 典型应用



自注意力

- *Attention is all you need* 是第一篇提出在序列模型中利用自注意力 (Self-attention) 机制取代循环神经网络的工作，取得了很大的成功。
- 其中一个重要的模块是**缩放点积注意力模块** (scaled dot-product attention)。
- 文中提出 (**key, query, value**) 三元组捕捉长距离依赖的建模方式: key和query通过点乘的方式获得相应的注意力权重，最后把得到的权重和value做点乘得到最终的输出。

Scaled Dot-Product Attention



自注意力

- 自注意力机制通过 (Query, Key, Value) 的三元组提供了一种有效的捕捉全局上下文信息的建模方式:

$$Attention(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}$$

- $\mathbf{Q}$ 表示query, $\mathbf{K}$ 表示key, $\mathbf{V}$ 表示value, d_k 表示k的维度。

形象化理解: 【搜索领域】在bilibili找视频, key就是bilibili数据库中的关键字序列, query就是你输入的关键字序列, value就是你找到的视频序列。

【推荐系统】在淘宝买东西, key就是淘宝数据库中所有的商品信息, query就是你最近关注到的商品信息, value就是推送给你的商品信息。

自注意力模块

Self-attention

<https://arxiv.org/abs/1706.03762>



q : query (to match others)


$$q^i = W^q a^i$$

k : key (to be matched)

$$k^i = W^k a^i$$

v : information to be extracted

$$v^i = W^v a^i$$




自注意力模块

Self-attention

拿每个q去对每个k做attention

Scaled Dot-Product Attention: $\alpha_{1,i} = \underbrace{q^1 \cdot k^i}_{\text{dot product}} / \sqrt{d}$


d is the dim of q and k



自注意力模块

Self-attention

$$\hat{\alpha}_{1,i} = \exp(\alpha_{1,i}) / \sum_j \exp(\alpha_{1,j})$$




自注意力模块

Self-attention


Considering the whole sequence

$$b^1 = \sum_i \hat{\alpha}_{1,i} v^i$$





多头注意力

- 多头自注意力机制（Multi-head self-attention mechanism），将模型分为多个头，形成多个子空间，可以让模型去关注不同方面的信息。



多头注意力

Multi-head Attention



卷积和自注意力计算复杂度的对比

Convolution复杂度

- 为了保证输入和输出在第一个维度都相同，故需要对输入进行padding操作，因为这里kernel size为 k (实际kernel的形状为 $k \times k \times d$)。
- 大小为 $k \times k$ 的卷积核一次运算复杂度为 $O(k^2 d)$ ，一共做了 $H \times W$ 次，故复杂度为 $O(HWk^2 d)$ 。
- 为了保证第三个维度相等，故需要 d 个卷积核，所以卷积操作的时间复杂度为 $O(HWK^2 d^2)$ 。


Self-Attention复杂度^Q

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- Q, K, V 的计算复杂度为 $n \times d$ 。
- 相似度计算 QK^T ： $n \times d$ 与 $d \times n$ 运算，得到 $n \times n$ 矩阵，复杂度为 $O(n^2 d)$ 。
- softmax 计算：对每行做 softmax ，复杂度为 $O(n)$ ，则 n 行的复杂度为 $O(n^2)$ 。
- 加权和： $n \times n$ 与 $n \times d$ 运算，得到 $n \times d$ 矩阵，复杂度为 $O(n^2 d)$ 。
- 故最后self-attention的时间复杂度为 $O(n^2 d)$ 。


图像中的自注意力

- Non-local Neural Networks是CV领域中的自注意力机制的核心文章，基于图片滤波领域的非局部均值滤波操作思想，提出了一种全局的自注意力机制。



注意力网络的典型应用：文本翻译


- Attention-based模型：在每次生成目标词时，对源语句隐藏状态计算相似度。



注意力机制


Attention Mechanism

- 动机与由来
- 点积注意力简介
- 自注意力简介
- 典型应用



注意力网络的典型应用：图像分类


- An Image is Worth 16x16 Words 就是把一幅图变成16×16的图元（视觉单词），然后输入Transformer进行编码，最后再用简单的小网络进行分类任务的学习。



Dosovitskiy, A. and Beyer, L. and Kolesnikov, A. and Weissenborn, D. and Houlsby, N.:
An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (2020)

注意力网络的典型应用：目标检测

- Facebook提出的模型DETR (detection transformer) 把 transformer用于目标检测的任务。




注意力网络的典型应用：语义分割

- SETR将语义分割视为序列到序列的预测任务。
- SETR使用一个纯transformer（即不进行卷积和分辨率降低）将图像编码为一系列patch。通过在transformer的每一层中建模全局上下文，此编码器可以与简单的解码器组合以提供功能强大的分割模型。(左列：FCN，右列：SETR)



注意力网络的典型应用：点云分类与分割

- Point Cloud Transformer将Transformer的encoder结构用来提取特征，在点云分类和分割任务中获得了不错的效果。



注意力网络的典型应用：行为识别

- MLAD提出了一种基于注意力的多标签动作相关性架构，该架构建模了视频中的动作关系。
- 可以区分在相同时间步长发生的动作与在不同时间步长发生的动作（即彼此先后的动作）之间的关系，将这些不同的关系定义为动作依赖项。

Actions	I3D	Our Model	Actions	I3D	Our Model	Actions	I3D	Our Model
Basketball Dribble	0.89	0.98	Basketball Dribble	0.88	0.98	Basketball Dribble	0.87	0.97
Run	0.59	0.91	Run	0.58	0.88	Run	0.60	0.81
								
Actions	I3D	Our Model	Actions	I3D	Our Model	Actions	I3D	Our Model
Pole Vault	0.43	0.86	Pole Vault	0.94	0.98	Pole Vault	0.48	0.98
Run	0.96	0.99	Jump	0.69	0.98	Fall	0.42	0.97
								

小结：浅谈Transformer中的归纳偏置

- 归纳偏置是什么？

- 归纳偏置在机器学习中是一种很微妙的概念：在机器学习中，很多学习算法经常会对学习的问题做一些假设，这些假设就称为归纳偏置（Inductive Bias）。

- CNN和RNN的归纳偏置

- 在CNN中，假设特征具有局部性(Locality)的特点，即把相邻的一些特征融合到一起，会更容易得到“解”；在RNN中，假设每一时刻的计算依赖于历史计算结果；即使attention机制，也是从生物学启发、人的直觉、生活经验等归纳得到的规则。

- Transformer**避免了CNN的局部性归纳偏置问题**



$$Attention(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}$$

扩展阅读

1. [RNN模型与NLP的应用](#)
2. [Transformer模型](#)
3. [注意力机制概述](#)
4. [Attention in Neural Networks](#)
5. [Transformer Neural Networks](#)
6. [注意力机制的九重理解](#)
7. [Attention Mechanisms in Computer Vision: A Survey](#)

作业

- 以下两个图分别表示什么类型的注意力机制？




- 自注意力机制定义了哪三个关键元素？如何理解它们之间的关系？主要起什么作用？


现代神经网络重要思想与结构

- 深度卷积网络
- 生成与对抗
- 注意力机制
- 图上的深度学习



Deep Convolutional Network (DCN)



Generative Adversarial Network (GAN)



Attention Network (AN)



图上的深度学习

Deep Learning over Graph

- 基本概念
- 图神经网络
- 图卷积网络
- 典型应用



图上的深度学习

Deep Learning over Graph

- 基本概念
- 图神经网络
- 图卷积网络
- 典型应用



网格化数据

- 常见图像、语音、以及自然语言均为**规则的网格化**数据

IMAGENET




Speech data




Natural language processing (NLP)

...




Grid games




图结构数据

- 现实世界中的许多数据并非建立在**网格**之上

Social networks
Citation networks
Communication networks
Multi-agent systems




Knowledge graphs



Molecules

Protein interaction networks




Road maps




现实世界中的图数据



a) 社交网络



b) 电子购物




c) 化学分子



d) 交通网络



e) 场景图



f) 电路设计图

非结构化（图）数据的难点


- 图的大小任意，拓扑结构复杂，没有像图像一样的空间规律性
- 图没有固定的节点顺序，或者说没有参考节点
- 图通常是动态的，可能包含多模态的特征

什么是图?

- 图 (graph) 是一种数据结构, 它可直观表示和可视化不同变量间的相互关系


$$\mathcal{G} = \{\mathcal{V}, \mathcal{E}\}$$

- $\mathcal{V}$ 是节点 (nodes) 或顶点 (vertices) 的集合
- $\mathcal{E}$ 是边 (edges) 的集合





属性图

- 节点和边都可以具有属性（特征）
- 在一个图结构中，每一个节点由它自身的特征以及与其相连的节点特征来定义该节点



图的两种类型

- **有向图**: 表示不同变量间的因果关系
- **无向图**: 表示不同变量间的相关性



关于图的研究


针对图的研究可以分为三类：

- **经典图算法**：生成树算法，最短路径算法，二分图匹配，费用流问题等等（《算法导论》）
- **概率图模型**：研究图结构的概率表示，典型的有条件随机场、马尔科夫随机场等（《概率图模型》）
- **图神经网络**：研究图结构数据挖掘的问题，典型的有图嵌入（graph embedding），图卷积网络（graph convolutional networks）等（《机器学习》，《深度学习》）


图相关任务

- 图分类
- 节点分类
- 连接预测
- 群体检测 (图聚类)
- 图嵌入/节点嵌入
- 图生成


Graph Classification



Node Classification




Link Prediction




Community Detection



Graph Embedding



Graph Generation



图上的深度学习

Deep Learning over Graph

- 基本概念
- 图神经网络
- 图卷积网络
- 典型应用



图神经网络的提出

- 图神经网络的概念首次在2005年被提出，其理论基础在论文《The Graph Neural Network Model》中被正式定义



Franco Scarselli

[University of Siena](#)

Verified email at [ing.unisi.it](#) - [Homepage](#)

[Artificial intelligence](#) [machine learning](#) [artificial neural networks](#) [graph neural networks](#)
[deep learning](#)


[FOLLOW](#)

TITLE	CITED BY	YEAR
The graph neural network model F Scarselli, M Gori, AC Tsoi, M Hagenbuchner, G Monfardini IEEE transactions on neural networks 20 (1), 61-80	2041	2008
A new model for learning in graph domains M Gori, G Monfardini, F Scarselli Proceedings. 2005 IEEE International Joint Conference on Neural Networks ...	643	2005

Cited by


[VIEW ALL](#)

	All	Since 2016
Citations	5548	3607
h-index	22	12
i10-index	49	18




图神经网络元年

- graph neural network在2019年到2020年之间力压deep learning、GAN等，成为各大顶会的增长热词
- 2019 年被称为图神经网络元年




何为图神经网络?

- 图神经网络 (GNN), 简而言之就是将图数据和神经网络进行结合, 在图数据上进行端对端的学习和计算。



图神经网络简史




初代GNN

- 给定一张图 G , 每个节点 v 的特征用 x_v 表示, 连接节点 v 和节点 u 的边的特征用 $x_{(u,v)}$ 表示。GNN的学习目标是: 获得每个节点 v 的隐藏状态 h_v 。


注意:

对于每个节点, 它的隐藏状态由自身节点的特征、相邻节点的特征和隐藏状态以及与自身节点相连的边的特征共同决定。




$$h_5 = f(x_5, x_{(3,5)}, x_{(5,6)}, h_3, h_6, x_3, x_6)$$

GNN的信息传递



GNN的信息传递




注意:
不同时刻间信息的传递与图的拓扑结构一致。


GNN与RNN的区别

- GNN在不同时刻的输入相同，RNN在不同时刻的输入不同
- GNN可以是结构化的输出（多个任务），RNN是单输出

**Graph
Neural
Network**



**Recurrent
Neural
Network**



图上的深度学习

Deep Learning over Graph

- 基本概念
- 图神经网络
- 图卷积网络
- 典型应用



图卷积网络

- 图卷积网络 (Graph Convolutional Networks, 以下简称GCN) 是GNN的主要变体之一
- CNN有能力去抽取多尺度局部空间信息, 并将其融合起来构建特征表示, 但只能应用于常规的欧几里得数据上
- GNN和CNN的共同点:
 - ① 局部连接
 - ② 权值共享
 - ③ 多层网络





Fig. 1. Left: image in Euclidean space. Right: graph in non-Euclidean space



常规卷积和图卷积

• 常规卷积

- 1) 定义在欧式空间
- 2) 节点的邻域数量固定
- 3) 卷积核大小固定

• 图卷积

- 1) 定义在非欧空间
- 2) 节点的邻域不固定
- 3) 卷积核大小不固定



邻居结点数量不固定




- 把非欧空间的图转换成欧式空间
- 可处理变长邻居结点的卷积核在图上抽取特征

图卷积的本质是想找到适用于图的可学习卷积核

图卷积网络框架


• 图卷积网络特点

- 局部特性
- 一阶特性
- 参数共享



GCN的输入

- 图卷积神经网络的目标是在图 $G = (V, E)$ 上学习一个信号/特征的函数，输入包括：
- 节点特征**：节点 i 的特征 x_i ，表示为一个 $N \times D$ 的特征矩阵 X ， N 表示节点数， D 表示特征维数。
- 图结构特征**：图结构的信息通常表示为**邻接矩阵** A 。

Labeled graph	Adjacency matrix
	$\begin{pmatrix} 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$

不同数据的邻接矩阵












Image Pixels



Adjacency Matrix




Graph



GCN的输出

GCN的输出包括:

- **节点级别输出:** 节点级别输出 z 是一个 $N \times F$ 大小的特征矩阵, F 是输出特征维数;
- **图级别输出:** 图级别输出可通过引入某种形式的池化算子



GCN的层级传播规则 f

- GCN的每一层可以写作一个非线性函数

$$\mathbf{H}^{(l+1)} = f(\mathbf{H}^{(l)}, \mathbf{A})$$

- 其中, $\mathbf{H}^{(0)} = \mathbf{X}$, $\mathbf{H}^{(L)} = \mathbf{Z}$, L 是GCN 的层数。

- 不同模型的主要差别在于 $f(\cdot, \cdot)$ 如何选择。
- 一个简单的示例:

$$f(H^{(l)}, A) = \sigma(AH^{(l)}W^{(l)})$$

GNN与GCN

联系

初代GNN 和GCN 都属于图表示学习的范畴，也叫图嵌入（Graph Embedding）。通常有两个层次的含义：

- 将图中的节点表示成低维、实值、稠密的向量形式；
- 将整个图表示成低维、实值、稠密的向量形式。

区别

- 初代GNN 通过循环迭代更新节点的特征，而GCN 通过堆叠层更新节点特征。



图上的深度学习

Deep Learning over Graph

- 基本概念
- 图神经网络
- 图卷积网络
- 典型应用

图神经网络的典型应用

• 计算机视觉—图像生成场景图生成 (scene graph generation)




Input: fully connected graph, unlabeled edges

Output: labels for edges

- 场景中的每个类别都被抽象为图中的一个节点
- 场景图生成的目标是生成一个图以及图中两两节点之间的关系能尽可能描述图像的内容



图神经网络的典型应用

• 计算机视觉—场景图生成图像




图神经网络的典型应用


- 计算机视觉—点云分类 (point cloud classification)



- GNN特别适合处理点云这类本身就不规则的数据





Airplane; 1000 points; PointNet Input



Graph Constructed based on Points; GNN Input


图神经网络的典型应用

- 计算机视觉—姿态估计 (pose estimation)
- 姿态的关节点天然适合作为图的节点




图神经网络的典型应用

- 计算机视觉—图像匹配 (image matching)





图神经网络的典型应用

- 自然语言处理—文本分类 (text classification)





图神经网络的典型应用

• 网络应用：推荐系统 (recommendation systems)




图神经网络的典型应用

- 智能交通：车联网 (internet of vehicles)



图神经网络的典型应用

- 生物：分子分类



扩展阅读

1. A Gentle Introduction to Graph Neural Networks (Basics, DeepWalk, and GraphSage)
2. Structured deep models: Deep learning on graphs and beyond
3. Representation Learning on Networks
4. Graph neural networks: Variations and applications
5. <http://snap.stanford.edu/proj/embeddings-www/>
6. Graph Neural Networks: A Review of Methods and Applications
7. <https://math.stackexchange.com/questions/3035968/interpretationof-symmetric-normalised-graph-adjacency-matrix>
8. <https://distill.pub/2021/gnn-intro/>

作业

1. 请问GCN中主要靠____矩阵的作用使得卷积能够方便的在不规则的图数据结构上运算。
2. 请问常规卷积和图卷积有哪些相同点和不同点？试各回答三点。
3. 请网上查询一个基于图神经网络/图卷积网络的应用，简要介绍该应用，并回答为何该问题适合使用图神经网络/图卷积网络进行建模。