

第五章 行为学派

智能优化简介



第五章 行为学派

Connectionism

行为学派简介

智能优化的产生与发展

智能优化典型思想与方法

强化学习基本概念与发展历史

经典强化学习基本思想与算法

深度强化学习简介

人工智能-行为主义

- 回顾：
 - 符号主义(Symbolicism): 人工智能源于数理逻辑
 - 连接主义(Connectionism): 人工智能源于仿生学, 主要是神经网络及连接机制
- 1991年, MIT的Rodney Brooks教授发表论文“Intelligence without representation”, 抨击符号主义和连接主义

*Artificial intelligence research has foundered on the issue of **representation**. When intelligence is approached in an incremental manner, with strict reliance on interfacing to the real world through **perception and action**, reliance on representation disappears.*



Rodney Allen Brooks

**MIT计算机科学与
人工智能实验室主任**

<https://people.csail.mit.edu/brooks/>

人工智能-行为主义

Intelligence without representation

[RA Brooks](#) - Artificial intelligence, 1991 - Elsevier

Artificial intelligence research has foundered on the issue of representation. When intelligence is approached in an incremental manner, with strict reliance on interfacing to the real world through perception and action, reliance on representation disappears. In this ...

☆ Save ↀ Cite Cited by 7466 Related articles All 102 versions

Brooks 假想有一台时光穿越机，将飞机发明之前的工程师送到当代喷气式客机上体验一次飞行，且工程师们只被允许参观客舱和驾驶舱。飞行结束后，他们被立即送回100年前，开始他们的飞机仿造计划。

- 部分工程师着手设计真皮座椅、安全带、可调节的靠背和柔软的腰枕，以及驾驶舱里飞行员的护目镜和眼花缭乱的各種不停闪烁的按钮。显然，他们制造的“飞行器”永远无法起飞。→ 对应人工智能界的**符号主义学派**。
- 另一批工程师透过舱壁的舷窗瞥到了机翼上轰鸣的发动机。于是他们开始建造巨大的风扇和管道。→ 对应人工智能界的**连接主义学派**。

人工智能-行为主义

- 行为主义(Actionism): 又称进化主义(Evolutionism)或控制论学派(Cyberneticsism)
 - 其原理为控制论(Cybernetics)及感知-动作型控制系统。
 - 行为主义认为人工智能源于**控制论**, 其研究重点是模拟人在控制过程中的智能行为和作用, 如对自寻优、自适应、自学习等控制论行为系统的研究。

《控制论—关于在动物和机器中控制和通讯的科学》, 诺伯特·维纳 (Norbert Wiener), 1948年
- Lawrence Fogel (进化规划的提出者): *model the process of evolution itself rather than model the end product of evolution.*

人工智能-行为主义

- 行为主义认为智能取决于感知和行动，提出智能行为的“感知-动作”模式。
- 行为主义认为人工智能的研究方法应**采用行为模拟方法**
 - **功能、结构和智能行为**是不可分的，
 - 不同行为表现出不同功能和不同控制结构。



- 对行为主义的批评：**最多只能达到昆虫的智能，无法创造出人的复杂智能行为。**


⚡ 反击：符号智能对于机器人行为并不够用

傳統的邏輯程序在機器人的導航方面顯得非常緩慢和笨拙

人工智能-行为主义

- 行为主义研究的内涵相对复杂
 - ① 早期的研究重点是模拟人在控制过程中的智能行为和作用
 - 对自寻优、自适应、自镇定、自组织和自学习等控制论系统的研究，并进行“控制论动物”的研制
 - ② 20世纪60~70年代，上述这些控制论系统的研究取得一定进展，播下智能控制和智能机器人的种子
 - ③ 20世纪80年代诞生了智能控制和智能机器人系统
 - 代表人物Rodney Brooks
- 核心是智能机器人研究，也涉及各种智能控制[专业课]方法
 - 本章介绍：智能优化，强化学习

Recall: 计算机求解问题的方法



- 将这些方法用于解决行为学派的问题

五十多年前, 美籍华人傅京孙教授 (见图1) 在IEEE自动控制汇刊上发表长文[1], 全面深入地综述并展望了学习控制的现状与未来. 之后, 他意犹未尽, 于1971年初又补充了一篇短文[2] “学习控制系统与智能控制系统: 人工智能与自动控制的交叉”, 进一步讨论人工智能方法与技术 in 控制和自动化中深入且系统化的应用之途径.



K. S. Fu (1930 ~ 1985) G. N. Saridis (1931 ~ 2006)

智能控制之父傅京孙与萨里迪斯

第五章 行为学派

Connectionism

行为学派简介

智能优化的产生与发展

智能优化典型思想与方法

强化学习基本概念与发展历史

经典强化学习基本思想与算法

深度强化学习简介

最优化理论的发展

1. 极值理论;
2. 运筹学的兴起(Operation Research);
3. 数学规划方法:

线性规划(LP); 非线性规划(NLP); 动态规划(DP); 马尔科夫决策过程(MDP); 排队论; 存储论; 博弈论。

最优化理论对现代科学与工程起到重要作用

⚡ 实际场景中的优化问题, 涉及各种决策变量、复杂的结构化目标和约束, 经典或传统的优化技术在以其原始形式求解现实优化问题时都会遇到困难。


智能优化

- 受自然界和生物界规律的启迪，人们根据其原理模仿设计了许多求解问题的算法，包括遗传算法、DNA计算、模拟退火算法、禁忌搜索算法、免疫算法、膜计算、量子计算、粒子群优化算法、蚁群算法、人工蜂群算法、人工鱼群算法以及细菌群体优化算法等
 - 可统称为智能优化(Intelligent Optimization)方法
- 智能优化包括**进化计算**和**群智能**等两大类方法，是一种典型的元启发式随机优化方法
 - **Search** Inspired by Mother Nature

传统优化方法基本步骤

1. 选一个初始解


- LP: 单纯形法构造初始解，顶点之一
- NLP: 任意点或一个内点



传统优化方法基本步骤

2. 停止判据——停止规则最优性检验


- LP: 检验数
 - 基于检验数的最优性判据
- NLP: $\nabla f(x) = 0$
 - 有约束问题, KKT条件



传统优化方法基本步骤

3. 向改进方向移动——改进解

- LP: 移动到相邻顶点
 - 基变换保证改善
- NLP: 向负梯度方向移动
 - (共轭梯度方向、牛顿方向)



传统优化的局限性


1. 对问题中目标函数、约束函数有很高的要求——有显式表达，线性、连续、可微，且高阶可微；
2. 只从一个初始点出发，难以进行并行、网络计算，难以提高计算效率；
Lack of Parallelization
3. 最优性达到的条件太苛刻——问题的函数为凸，可行域为凸；
4. 在非凸条件下，没有跳出局部最优解的能力。
 - 目标函数和约束集凸集

实际问题中对最优化方法的要求

1. 对问题的描述要宽松(目标和约束函数)——
 - 可以用一段程序来描述(程序中带判断、循环), 函数可以非连续、非凸、非可微、非显式;
2. 并不苛求最优解——通常满意解、理想解就可以了;
3. 计算快速、高效, 可随时终止(根据时间定解的质量);
4. 能够处理数据、信息的不确定性(如数据的模糊性, 事件的随机性)。

智能优化的发展历史

- 1975年Holland提出遗传算法 (Genetic Algorithm)
- 1977年Glover提出禁忌搜索算法 (Tabu Search)
- 1982年Kirkpatrick提出模拟退火算法 (Simulated Annealing)
- 1995年Dorigo提出蚁群算法 (Ant Colony Optimization)
- 1995年Kennedy & Eberhart提出粒子群优化 (Particle Swarm Optimization)
- 其它
 - 文化算法(Cultural Algorithm)
 - 人工生命算法(Artificial-Life Algorithm)



- 66. Holland J (1975) **Adaptation in natural and artificial systems**. The University of Michigan Press
- 67. Glover F (1989) Tabu search. ORSA J Comput 1(3):190–206
- 68. Kirkpatrick S, Gelatt CD, Vechi MP (1983) Optimization by simulated annealing. Science 220(4598):671–680
- 69. Farmer JD, Packard NH, Perelson AS (1986) The immune system, adaptation, and machine learning. Physica D 22(1–3):187–204
- 70. Dorigo M (1992) Optimization, learning and natural algorithms. Ph.D. Thesis, Politecnico di Milano
- 71. Adleman LM (1994) Molecular computation of solutions to combinatorial problem. Science 266(5187):1021–1024
- 72. Reynolds RG (1994) An introduction to cultural algorithms. In: The 3rd annual conference on evolution programming
- 73. **Kennedy J, Eberhart RC (1995) Particle swarm optimization**. In: IEEE international conference on neural networks
- 74. Linhares A (1998) State-space search strategies gleaned from animal behavior: a traveling salesman experiment. Biol Cybern 87(3):167–173
- 75. Li XL (2003) A new intelligent optimization algorithm—artificial fish school algorithm. Ph.D. Thesis, Zhejiang University, China
- 76. Yang XS (2010) A new metaheuristic bat-inspired algorithm. Nature inspired cooperative strategies for optimization (NICSO 2010), Springer, Berlin, p 65–74
- 47. Geem ZW, Kim JH, Loganathan GV (2001) A new heuristic optimization algorithm: harmony search. Simulation
- 48. Karaboga D, Basturk B (2007) A powerful and efficient algorithm for numerical function optimization: artificial bee colony (ABC) algorithm. J Global Optim 39(3):459–471
- 50. Lam AYS, Li VOK (2010) Chemical-reaction-inspired metaheuristic for optimization. IEEE Trans Evol Comput 14(3):381–399

第五章 行为学派

Connectionism

行为学派简介

智能优化的产生与发展

智能优化典型思想与方法

强化学习基本概念与发展历史

经典强化学习基本思想与算法

深度强化学习简介

智能优化能做什么？

- 智能优化经典应用——函数优化问题：

$$\max \leftrightarrow \min f(x), x = (x_1, \dots, x_D) \in S = \prod_{i=1}^D [L_i, U_i]$$

- 对比梯度下降方法 (以遗传算法为例)：

最大最小化模型 (Maximin Model) 是一种优化方法，旨在**最大化最坏情况下的收益**（最大风险的最低限度）或**最小化最坏情况下的损失**。




图 5.15 基于梯度的优化方法的主要缺陷






图 5.16 进化算法的主要原理

多点出发，同步搜索
(随机方向，适者生存)

智能优化能做什么？



Genetic Algorithm Evolution Flow

智能优化能做什么？

- 粒子群求解Rosenbrock（香蕉）函数：


$$f = \sum_{i=1}^{n-1} \left(100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right)$$

$$-2 \leq x_i \leq 2, \min(f) = 0, x_{\min} = [1, 1, \dots, 1]$$

便于展示，考察2维情形：


$$f(x_1, x_2) = 100(x_1^2 - x_2)^2 + (1 - x_1)^2$$

$$-2 \leq x_i \leq 2, \min(f) = 0, x_{\min} = [1, 1]$$




智能优化能做什么？


- 粒子群算法求解，采用20个个体（种群数量20）



第0代：
初始化，随机分布




第10代：
向极值点靠拢



第20代：
基本收敛到极值附近

第40代：
误差足够小，可以
认为收敛到极值点
 $\min f = 6.6553e - 004$



智能优化能做什么？

- 求解NP难的组合优化问题：背包问题
- 精确解法时间复杂度指数级





VS.



背包问题描述为：给定一组物品，每件物品有重量（或体积）和价值，在背包容量有限的情况下，选择若干物品放入背包，使总价值最大化。它属于NP完全问题，暴力穷举复杂度为 $O(2^N)$ ，不可行，但动态规划可将复杂度降至为多项式 $O(NW)$ 。


智能优化能做什么？

- 遗传算法绘制蒙娜丽莎 (复现?)




迭代次数: 1 适应度: 0.73012

迭代次数: 100 适应度: 0.82749



迭代次数: 550 适应度: 0.90041

迭代次数: 1350 适应度: 0.92339



迭代次数: 7300 适应度: 0.94006



迭代次数: 30150 适应度: 0.95535

Ref

科学与艺术的融合：遗传算法绘制蒙娜丽莎, <https://zhuanlan.zhihu.com/p/149710617>
<https://blog.amnuts.com/2019/04/22/genetic-algorithms-and-the-mona-lisa/>

智能优化能做什么？

- 遗传算法控制机器人运动



第五章 行为学派

Connectionism

行为学派简介

智能优化的产生与发展

智能优化典型思想与方法

- 进化算法

- 群智能算法

强化学习…


进化算法

- 20世纪50年代中期开始的仿生学研究：生物→人造系统
- 基于语言智能和逻辑-数学智能的传统人工智能 vs. 基于自然进化的思想
 - 1960s, Holland, Bremermann等, 遗传算法(genetic algorithm)
 - 1960s, Rechenberg, Schwefel等, 进化策略(evolution strategy)
 - 1960s, Fogel, Owens, Walsh等, 进化规划(evolutionary programming)
- 三种算法独立发展, 逐步走向统一：进化计算
 - 1990s, Koza, 遗传编程/基因规划(genetic programming)
- 进化算法四大经典：GA, ES, EP和GP

- four major evolutionary algorithm paradigms

进化的生物学思想

- 适者生存：最适合自然环境的群体往往产生了更大的后代群体。
 - 自然界的生物体在**选择**、**遗传**和**变异**等一系列作用下，优胜劣汰，不断地由低级向高级进化和发展。




生物进化与遗传算法

- 遗传算法的大量术语来自生物学：

$v_1 =$

2	1	8	4	3	2	6	4	7	6	8
---	---	---	---	---	---	---	---	---	---	---

$v_1 = [100110110100101101000000010111001]$



生物学	遗传算法
染色体(chromosome) ：生物的遗传物质的主要载体。	字符串 ，遗传算法的运算基础
基因(gene) ：染色体的DNA片段	字符串中的每个 字符 都有特定的含义，反映所求解问题的某个特征
基因座(locus) ：遗传基因在染色体中所占据的位置。	字符在字符串中的 位置
等位基因(alleles) ：同一基因座可能有的全部基因称为等位基因。	特定位置的字符 所有可能取值 最简单情况，0和1两个整数

生物进化与遗传算法

$$v_1 = \begin{bmatrix} 2 & 1 & 8 & 4 & 3 & 2 & 6 & 4 & 7 & 6 & 8 \end{bmatrix}$$

$$v_1 = [100110110100101101000000010111001]$$

术语	生物学	遗传算法
基因型 (genotype)	反映表现型的基因组成	基因型就是字符串的结构
表现型 (phenotype)	生物个体所表现出来的性状	表现型就相当于所求解问题的特征，如参数、可行解等。
编码 (coding)	DNA中遗传信息在一个长链上按一定的模式排列，表现型到基因型的映射	将所求解问题表达成染色体的过程。
解码 (decoding)	基因型到表现型的映射	通过染色体计算得到适应度值的过程
个体 (individual)	指带有染色体特征的实体	每个个体代表所求问题的一个解
种群 (population)	个体的集合，该集合内个体数称为种群的大小	

更多生物学术语...

v1=[00000101010010100110111101111110]
v2=[001110101110011000000010101001000]
v3=[111000111000001000010101001000110]
v4=[100110110100101101000000010111001]
v5=[0000101111011000100011100011010000]
v6=[111110101011011000000010110011001]
v7=[110100010011111000100110011101101]
v8=[001011010100001100010110011001100]
v9=[111110001011101100011101000111101]
v10=[111101001110101010000010101101010]



v1'=[100110110100101101000000010111001]
v2'=[100110110100101101000000010111001]
v3'=[001011010100001100010110011001100]
v4'=[111111001011101100011101000111101]
v5'=[100110110100101101000000010111011]
v6'=[110100010011111000100110011101101]
v7'=[101110101110011000000010101001000]
v8'=[100110110100101101000000010111001]
v9'=[00000101010010100110111101111110]
v10'=[001110101110011000000010101001010]


• 种群层面的进化:

- **进化 (evolution)**: 种群逐渐适应生存环境, 品质不断得到改良。生物的进化是以种群的形式进行的。
- **适应度 (fitness)**: 度量某个物种对于生存环境的适应程度, 在遗传算法中就是对染色体解码后得到适应度函数值。
- **选择 (selection)**: 一定的概率从种群中选择若干个个体。一般, 选择过程是一种基于适应度的优胜劣汰的过程。
 - **遗传 (heredity)**: 子代和父代具有相同或相似的性状, 保证物种的稳定性;
 - **变异 (variation)**: 子代与父代, 子代不同个体之间总有差异, 是生命多样性的根源;


更多生物学术语...

• 基因层面的进化：

- **复制 (reproduction)**：细胞在分裂时，遗传物质DNA通过复制而转移到新产生的细胞中，新的细胞就继承了旧细胞的基因；
- **交叉 (crossover)**：在两个染色体的某一相同位置处DNA被切断，其前后两串分别交叉组合形成两个新的染色体。又称基因重组，俗称“杂交”；
- **变异 (mutation)**：在细胞进行复制时可能以很小的概率产生某些复制差错，从而使DNA发生某种变异，产生出新的染色体，这些新的染色体表现出新的性状；



遗传算法的基本思想



1. 根据问题的目标函数构造**适应度函数**(Fitness Function);
2. 产生一个初始种群(100-1000);
3. 根据适应度函数的好坏, 不断选择繁殖;
4. 若干代后得到适应度函数最好的个体即最优解

遗传算法的要素

- ① 种群(Population)
 - 种群大小(Pop-size)
- ② 基因表达法——**编码方法** (Encoding Scheme; Gene Representation)
- ③ **遗传算子**(Genetic Operator):
 - 交叉(Crossover)
 - 变异(Mutation)
- ④ **选择策略**: 一般为正比选择
- ⑤ 停止准则 (Stopping Rule/Criterion):
 - 一般是指定最大代数

- 学习内容:
 - 编码
 - 遗传算子
 - 选择策略
- 基于Holland的基本GA

基本GA算法框架





图1 遗传算法的运算流程


CSDN @talkAC



一个例子

- 求解下面的无约束优化问题：

$$\begin{aligned} \max f(x_1, x_2) &= 21.5 + x_1 \sin(4\pi x_1) + x_2 \sin(20\pi x_2) \\ &- 3.0 \leq x_1 \leq 12.1 \\ &4.1 \leq x_2 \leq 5.8 \end{aligned}$$



- 其三维图形

基因表达

位串编码：染色体编码法，将问题空间的参数编码为一维排列的染色体的方法。

- 通常采用**二进制**编码，将某个变量值代表的个体表示为一个二进制串，串长取决于求解的精度。
- 例如， x_j 的值域是 $[a_j, b_j]$ ，需求精度是小数点后4位
- 需要将 x_j 的值域分成至少 $(b_j - a_j) \times 10^4$ 份
- 设 x_j 所需要的字串长度为 m_j ，则有

$$2^{m_j-1} < (b_j - a_j) \times 10^4 \leq 2^{m_j} - 1$$

- 即可以用二进制串 $(b_{m_j-1}b_{m_j-2} \dots b_0)_2$ 表示 x_j

基因表达

1) 将一个二进制串 $(b_{m_j-1}b_{m_j-2} \dots b_0)_2$ 代表的二进制数化为十进制数;

$$(b_{m_j-1}b_{m_j-2} \dots b_0)_2 = \left(\sum_{i=0}^{m_j-1} b_i \cdot 2^i \right)_{10} = x'$$

2) x' 对应的区间 $[a_j, b_j]$ 内的实数:

$$x = a_j + x' \cdot \frac{b_j - a_j}{2^{m_j} - 1}$$

基因表达

• 假设 x_1 和 x_2 需要的精度都是小数点后4位，两个变量需要的总串长按下面计算：

• $(12.1 - (-3.0)) \times 10^4 = 151000$, $2^{17} < 151000 \leq 2^{18}$, 所以 $m_1=18$ 。


• $(5.8 - 4.1) \times 10^4 = 17000$, $2^{14} < 17000 \leq 2^{15}$, 所以 $m_2=15$ 。

$$-3.0 \leq x_1 \leq 12.1$$

$$4.1 \leq x_2 \leq 5.8$$

• 染色体的总长为18+15=33位，可表示如下：

变量 x_1 和 x_2 的值为



对应的十进制值为

	二进制码	十进制码
x_1	000001010100101001	5417
x_2	1011110111111110	24318

$$x_1 = -3.0 + 5417 \times (12.1 - (-3.0)) / (2^{18} - 1) = -2.687969$$

$$x_2 = 4.1 + 24318 \times (5.8 - 4.1) / (2^{15} - 1) = 5.361653$$

GA算法框架




图1 遗传算法的运算流程

CSDN @talkAC

种群初始化

- 随机产生初始种群如下

$v1=[000001010100101001101111011111110]$
 $v2=[001110101110011000000010101001000]$
 $v3=[111000111000001000010101001000110]$
 $v4=[100110110100101101000000010111001]$
 $v5=[0000101111011000100011100011010000]$
 $v6=[111110101011011000000010110011001]$
 $v7=[110100010011111000100110011101101]$
 $v8=[001011010100001100010110011001100]$
 $v9=[111110001011101100011101000111101]$
 $v10=[111101001110101010000010101101010]$

- 对应的十进制值为

$v1=[x1,x2]=[-2.687969,5.361653]$
 $v2=[x1,x2]=[0.474101,4.170144]$
 $v3=[x1,x2]=[10.419457,4.661461]$
 $v4=[x1,x2]=[6.159951,4.109598]$
 $v5=[x1,x2]=[-2.301286,4.455282]$
 $v6=[x1,x2]=[11.788.84,4.174346]$
 $v7=[x1,x2]=[9.342067,5.121702]$
 $v8=[x1,x2]=[-0.330256,4.694977]$
 $v9=[x1,x2]=[11.671267,4.873501]$
 $v10=[x1,x2]=[11.446273,4.171908]$

GA算法框架




图1 遗传算法的运算流程

CSDN @talkAC

适应度计算

- 计算染色体适应度值的过程由以下三步构成：

Step1: 将染色体的基因型转换为表现型，即将二进制串转换为十进制值： $x^k = (x_1^k, x_2^k)$, $k = 1, 2, \dots, M$ 。

Step2: 计算目标函数值 $f(x^k)$ 。

Step3: 将目标函数值转换为适应度值，对于最大化问题，可简单地取目标值为适应度值。

适应度计算

- 以上初始种群中染色体的适应度值为

$\text{eval}(v1)=f(-2.687969,5.361653)=19.805119$

$\text{eval}(v2)=f(0.474101,4.170144)=17.370896$

$\text{eval}(v3)=f(10.419457,4.661461)=9.590546$

$\text{eval}(v4)=f(6.159951,4.109598)=29.406122$

$\text{eval}(v5)=f(-2.301286,4.455282)=15.686091$

$\text{eval}(v6)=f([11.788.84,4.174346])=11.90541$

$\text{eval}(v7)=f(9.342067,5.121702)=17.958717$

$\text{eval}(v8)=f(-0.330256,4.694977)=19.763190$

$\text{eval}(v9)=f(11.671267,4.873501)=26.401669$

$\text{eval}(v10)=f(11.446273,4.171908)=10.252480$

$$\begin{aligned}\max f(x_1, x_2) &= 21.5 + x_1 \sin(4\pi x_1) + x_2 \sin(20\pi x_2) \\ &- 3.0 \leq x_1 \leq 12.1 \\ &4.1 \leq x_2 \leq 5.8\end{aligned}$$

- 显然，染色体v4是最好的，而染色体v3是最差的。

GA算法框架




图1 遗传算法的运算流程

CSDN @talkAC

选择

- 大多数情况下采用轮盘赌法作为选择方法，它是一种正比选择策略，能够根据与适应度值成正比的概率选择新的种群。
- 轮盘赌法由以下四步构成：
 - a) 对各个染色体 $\mathbf{v}_k$ 计算适应度值 $eval(\mathbf{v}_k)$

$$eval(\mathbf{v}_k) = f(\mathbf{x}), \quad k = 1, 2, \dots, M$$

- b) 计算种群中所有染色体的适应度之和

$$F = \sum_{k=1}^M eval(\mathbf{v}_k)$$


选择

c) 对各染色体 $\mathbf{v}_k$ ，计算选择概率 p_k

$$p_k = \frac{eval(\mathbf{v}_k)}{F}, k = 1, 2, \dots, M$$


d) 对各染色体 $\mathbf{v}_k$ ，计算累积概率 q_k

$$q_k = \sum_{i=1}^k p_j, \quad k = 1, 2, \dots, M$$



选择

- 选择过程就是旋转轮盘M次，每次按如下方式选出一个染色体来构造新的种群。
 - Step1: 在 $[0,1]$ 区间内产生一个均匀分布的伪随机数 r 。
 - Step2: 若 $r \leq q_1$ ，则选第一个染色体 v_1 ，否则，选择第 k 个染色体 v_k ($2 \leq k \leq M$)，使得 $q_{k-1} < r \leq q_k$ 成立。
- 案例中，种群的适应度值和F为178.135372。
- 各染色体 v_k ($k = 1, 2, \dots, 10$) 的选择概率 p_k 为



$p_1=0.111180$, $p_2=0.097515$, $p_3=0.053839$, $p_4=0.165077$, $p_5=0.088057$,
 $p_6=0.066806$, $p_7=0.100815$, $p_8=0.110945$, $p_9=0.148211$, $p_{10}=0.057554$

选择

- 由此得到如下的轮盘赌：
- 各染色体的累积概率 q_k 为：

$q_1=0.111180$, $q_2=0.208695$, $q_3=0.262534$, $q_4=0.427611$, $q_5=0.515668$,
 $q_6=0.582475$, $q_7=0.683290$, $q_8=0.794234$, $q_9=0.942446$, $q_{10}=1.000000$

染色体来构造新种群，设产生的
[0,1]区间内的10个随机数分别为：

0.301431, 0.322062, 0.766503, 0.881893, 0.350871,
0.583392, 0.177618, 0.3434242, 0.032685, 0.197577

- 根据随机数所在区间，选出如下的新种群

$v1'=[100110110100101101000000010111001]$ (v4)

$v2'=[100110110100101101000000010111001]$ (v4)

$v3'=[001011010100001100010110011001100]$ (v8)

$v4'=[111110001011101100011101000111101]$ (v9)

$v5'=[100110110100101101000000010111001]$ (v4)

$v6'=[110100010011111000100110011101101]$ (v7)

$v7'=[0011101011100110000000010101001000]$ (v2)

$v8'=[100110110100101101000000010111001]$ (v4)

$v9'=[00000101010010100110111101111110]$ (v1)

$v10'=[0011101011100110000000010101001000]$ (v2)

GA算法框架




图1 遗传算法的运算流程

CSDN @talkAC

交叉

- 这里先采用单点交叉。
- 该方法在染色体中随机选择一个断点，交换两个父代染色体上断点的右端，对于如下两个染色体，若随机断点选在第17个基因之后：

$v_1 = [10011011010010110100000010111001]$
 $v_2 = [001011010100001100010110011001100]$

单点交叉 (Single-point crossover)

- 交换父代染色体断点右端的部分将得到：

$v_1 = [100110110100101100010110011001100]$
 $v_2 = [00101101010000110100000010111001]$

parent1

1	2	3	4	5	6	7	8
---	---	---	---	---	---	---	---

 parent2

a	b	c	d	e	f	g	h
---	---	---	---	---	---	---	---

交叉

- 设交叉率 $p_c=0.25$ ，即平均有25%的染色体进行交叉，于是有：
交叉过程

```
1 begin
2     k←0;
3     while k≤10 do
4         rk←[0,1]均匀分布随机数;
5         if rk<0.25 then
6             选择vk作为交叉的父代之一;
7         end
8         k←k+1;
9     end
10 end
```

交叉

- 设随机数列如下：
0.625721, 0.266823, 0.288644, 0.295114, 0.163274
0.567461, 0.085940, 0.392865, 0.770714, 0.548656
- 于是染色体v5'和v7'被选择进行交叉，设断点在第一个基因之后，则交叉得到的子代染色体为：

$$v_5 = [10011011010010110100000010111001]$$

$$v_7 = [001110101110011000000010101001000]$$

↓

$$v_5 = [101110101110011000000010101001000]$$

$$v_7 = [00011011010010110100000010111001]$$

GA算法框架




图1 遗传算法的运算流程

CSDN @talkAC

变异

- 变异以变异率的概率改变一个或几个基因，假设 v_1 的第16个基因被选择进行变异，该基因为1，则变异后为0，于是变异后的染色体为：

$v_1 = [100110110100101101000000010111001]$



$v_1' = [100110110100101001000000010111001]$

变异

- 设变异率为 $p_m = 0.01$ ，即种群中平均有1%的基因会发生变异，种群中共有 $33 \times 10 = 330$ 个基因，假设如下基因发生变异：

染色体	基因位	随机数
4	6	0.009857
5	32	0.003113
7	1	0.000946
10	32	0.001282

变异

- 变异后的新种群如下：

$v1'=[100110110100101101000000010111001]$
 $v2'=[100110110100101101000000010111001]$
 $v3'=[001011010100001100010110011001100]$
 $v4'=[111111001011101100011101000111101]$
 $v5'=[100110110100101101000000010111011]$
 $v6'=[110100010011111000100110011101101]$
 $v7'=[1011101011100110000000010101001000]$
 $v8'=[100110110100101101000000010111001]$
 $v9'=[000001010100101001101111011111110]$
 $v10'=[0011101011100110000000010101001010]$

- 相应的十进制值和适应度值为：

$f(6.159951, 4.109598)=29.406122$
 $f(6.159951, 4.109598)=29.406122$
 $f(-0.330256, 4.694977)=19.763190$
 $f(11.907206, 4.873501)=5.702781$
 $f(8.024130, 4.170248)=19.91025$
 $f(9.342067, 5.121702)=17.958717$
 $f(6.159951, 4.109598)=29.406122$
 $f(6.159951, 4.109598)=29.406122$
 $f(-2.687969, 5.361653)=19.805119$
 $f(0.474101, 4.170248)=17.370896$

GA算法框架





图1 遗传算法的运算流程

CSDN @talkAC

迭代

- 至此完成了完整的一次迭代。
- 最终循环**1000代**，得到以下最优染色体：
 - ✓ $v^* = [111110000000111000111101001010110]$
 - ✓ $eval(v^*) = f(11.631407, 5.724824) = 38.818208$
 - ✓ $x_1^* = 11.631407, x_2^* = 5.724824,$
 - ✓ $f(x_1^*, x_2^*) = 38.818208$



第五章 行为学派

Connectionism

行为学派简介



智能优化的产生与发展

智能优化典型思想与方法

- 进化算法
- 群智能算法

强化学习…

群体智能(Swarm Intelligence)



- 生物学家研究表明：在这些群居生物中虽然每个个体的智能不高，行为简单，也不存在集中的指挥，但由这些单个个体组成的群体，似乎在某种内在规律的作用下，却表现出异常复杂而有序的群体行为。

群体智能

- 群(swarm)定义为某种交互作用的组织或agent的结构集合（**相互作用的相邻个体的集合**）。群集中个体行为简单，但群体行为相当复杂：
 - 群体的成员必须是活跃的、动态的和简单的（没有或几乎没有对周围环境的固有知识）；
 - 既有竞争又有协作；
 - 没有一个集中控制中心，分布式、自组织；
 - 个体间不仅能够交互信息，还能够处理信息，根据信息改变自身行为。
- 作为群体协同工作时，能够突现出非常复杂的行为特征，即智能。



群体智能

- **群体智能**：群集系统能够在没有外部指导和中心协调控制的情况下，完成动态变化环境中的复杂任务。

- 个体仅有简单行为
- 解决单一个体无法解决的复杂问题
- 具有群体鲁棒性，单一个体失败对全局影响不大
- 个体仅有局部信息，极小的存储能力，没有全局信息

基本原则




群智能算法


- 基于群体智能的协作行为，出现了一种**比随机搜索更好**的搜索策略，所得到的智能搜索策略一般称为群智能算法。
- 90年代提出两种具有代表性的群智能算法：
 - 1992年蚁群优化算法ACO
 - 1995年粒子群算法PSO
- 其后涌现出许多分支。
- 由于种群利用随机性和应用领域的相似性，群体智能方法起初被认为是一类**进化计算方法**。
- 然而，由于**群智能**和**进化计算**的基本理念存在着一些内在的差异：
 - 群智能试图模拟简单智能体的集体和协同行为；
 - 进化计算受到生物进化的启发。
- 群智能算法作为一类优化算法，总体来说**简单、有效**，在解决实际问题中得到了广泛的应用。

典型群体智能算法


- 粒子群优化算法 (Particle Swarm Optimization, PSO)
 - 模拟鸟群觅食的**社会行为**



- 蚁群优化算法 (Ant Colony Optimization, ACO)
 - 模拟蚁群觅食的**寻路机制**



群智能算法发展历史



群智能算法分支

- 人工蜂群优化(Artificial Bee Colony, ABC), 灵感来源于蜜蜂的**觅食行为**
- 细菌觅食优化(Bacterial Foraging Optimization, BFO), 灵感来自于大肠杆菌和黄原胶等细菌的**群体觅食**
- 萤火虫算法(Firefly Algorithm, FA), 灵感来自萤火虫的**闪烁行为**
- 而蜘蛛猴优化(Spider Monkey Optimization, SMO), 灵感来自蜘蛛猴的**觅食行为**。

- 群体智能之粒子群优化 (PSO)
- 群体智能之人工蜂群算法及其改进(ABC)
- 群体智能之蜘蛛猴优化算法(SMO)
- 群体智能优化算法之蚁群优化算法(ACO)
- 群体智能优化算法之布谷鸟搜索(CS)

- 群体智能优化算法之萤火虫群优化算法(Glowworm Swarm Optimization, GSO)
- 群体智能优化算法之萤火虫算法(Firefly Algorithm, FA)
- 智能优化算法天牛须搜索算法(Beetle Antennae Search Algorithm, BAS)
- 群体智能优化算法之蝙蝠算法(Bat Algorithm, BA)
- 群体智能优化算法之人工鱼群优化算法(Artificial Fish Swarm Algorithm, AFSA)
- 群体智能优化算法之蟑螂算法((Cockroach Swarm Optimization, CSO)
- 群体智能优化算法之猫群算法(Cat Swarm Optimization)
- 群体智能优化算法之细菌觅食优化算法(Bacterial Foraging Optimization Algorithm, BFOA)
- 群体智能优化算法之烟花算法(Fireworks Algorithm, FWA)

群智能算法共性

1. 都有多个粒子，代表每种智能体；
2. 每个个体通过一定的机制进行位置的变化或者移动，来对解的空间进行搜索；
3. 个体之间具有一定的独立性，利用局部信息和全局信息进行交互；
4. 群体在演变过程中都引入了随机数，以便进行充分地探索。

粒子群算法(Particle Swarm Optimization)

- 鸟群在森林中随机搜索食物，需要在森林里寻找食物最多的位置；
- 每只鸟沿着自己判定的方向进行搜索，并在搜索的过程中记录自己在沿途观察到的食物多少；
- 所有的鸟都共享自己的位置以及食物量的信息；
- 每只鸟都会根据自己记忆中食物最多的位置和当前鸟群记录的食物最多的位置调整自己接下来搜索的方向，直至找到有着最丰盛食物的最佳餐桌



粒子群算法(Particle Swarm Optimization)


- 基本思想：利用群体中的个体对信息的共享使整个群体的运动在问题求解空间中产生从无序到有序的演化过程，从而获得问题的可行解。
- 系统初始化为一组随机解，通过迭代搜寻最优值，粒子（潜在的解）在解空间追随最优的粒子进行搜索。

鸟群觅食	粒子群算法
鸟	粒子（无体积无质量）
森林	求解空间
每只鸟的位置	空间中的一个解（粒子位置）
当前位置的食物多少	目标函数值（适应度）
食物最多的位置	全局最优解


粒子群算法 (Particle Swarm Optimization)

每只鸟抽象为一个无质量，
无体积的“粒子”
每个粒子有一个适应度以
模拟每只鸟在当前位置观
察到的食物多少

每个粒子有一个速度决
定它们的飞行方向和距
离，初始值可随机确定



粒子群优化算法-流程图



蚁群优化算法-思想


- 蚁群优化算法 (Ant Colony Optimization)
 - 蚂蚁觅食
 - 1992年由意大利学者Dorigo提出
 - 模拟自然界中蚂蚁寻找从巢穴到食物的最佳路径的行为




Dorigo
多里戈

双桥实验


- 1989年戈斯等研究蚂蚁觅食行为所做的实验



(a)




(b)



4 分钟

(c)




8 分钟

(d)

信息素

- 蚂蚁通过**信息素(Pheromone)**实现间接通信
 - 蚂蚁在移动过程中分泌具有挥发性的**信息素**
 - 碰到未走过的路口，随机挑选一条路，释放与路径长度有关的信息素
 - 信息素浓度与路径长度成反比。后来的蚂蚁再次碰到该路口时，选择信息素浓度较高的路径
 - 最优路径上的信息素浓度越来越高（**信息正反馈**）
 - 最终蚁群找到最优觅食路径


蚂蚁行为



1. 两只蚂蚁以同样的概率随机选了一条路

2. 较短路径上的蚂蚁花费较短的时间找到食物，即，从巢穴到食物花费的时间较短


蚂蚁行为



3. 较短路径上的信息素浓度较高（一去一回两趟 vs. 去一趟）

4. 下一只蚂蚁选择了较短的路径，即信息素较高的路径

蚂蚁行为



5. 通过不断迭代，更多的蚂蚁选择信息素更高的路径，愈加强化了这条路径

6. 一段时间后，基本都选择了较短路径

蚁群优化算法-TSP例子


• 旅行商（TSP）问题

- 某旅行者寻求一条由起点出发，通过所有给定的需求点之后，最后再回到起点的最短路径。
- 若固定一个城市为终点，则需要 $(n-1)!$ 次枚举。
- 假设计算机1s可以完成24个城市所有路径枚举，则随城市数增加，寻找最优解的计算时间如下表所示：



城市数	24	25	26	27	28	29	30	31
计算时间	1s	24s	10min	4.3h	约4.9天	约135.5天	约10.8年	约323年

蚁群优化算法-TSP例子



路径构建

- 按随机概率规则选择下一个城市，随机概率受信息素强度和能见度（即两点路径的倒数）影响
- 不允许选择已走过的路（禁忌表）


信息素更新方式

- 信息素挥发**：所有路径上的信息素以一定的比率进行减少，模拟自然蚁群的信息素随时间挥发的过程；
- 信息素增强**：给评价值“好”（有蚂蚁走过）的边增加信息素。


蚁群优化算法-TSP例子

示例1:

- (1) 51个城市, 51只蚂蚁, 600次迭代。
- (2) 最优解与已知最优解偏差0.23%
- (3) 最优解路径长度=427



示例2: 31个城市, 50只蚂蚁, 200次迭代



第五章 行为学派

Connectionism

行为学派简介


智能优化的产生与发展

智能优化典型思想与方法

➤ 小结

强化学习…

群智能 vs. 进化算法



对智能优化方法的批评

- 对于一些复杂的优化问题，EC算法和SI算法是较好的选择，因为它们对目标的数学性质和约束条件(如凸性、连续性或显式定义)要求不高。这些方法使用随机方法，可以应用于更广泛的问题。
 - 但是，这种适用性伴随着代价，即全局最优的概率收敛性。
 - 此外，这些算法有时也无法在当前状态下在搜索空间的探索和利用之间取得适当的平衡。
 - 通常，指导搜索过程的参数的选择会变得很困难，结果可能在很大程度上取决于这些选择。
- 考虑到这些限制，EC和SI算法其实有很大的改进空间，使之更为高效、准确、可靠。