

近代人工智能发展简史

孕育阶段-逻辑推理

- 亚里士多德三段论——两个前提一个结论，间接推理。
- 培根：归纳法——特殊到一般。

孕育阶段-重要思想

- 布尔：布尔代数——真/假，与/或/非。
- 图灵：图灵机。

孕育阶段-先驱成果

- 第一个神经网络模型（M-P 模型）。

形成阶段 1956-1969

- 1956.8，达特茅斯会议：提出“人工智能”术语；人工智能元年。

发展阶段 1970-

- 1970-1988 知识应用时期。
- 1986 以后 集成发展时期。

发展阶段 2011-

- 大数据驱动发展期：算法、算力和算料（数据）；深度学习。
- 专用人工智能和通用人工智能：是否面向特定任务。
- 强人工智能与弱人工智能：是否模拟人类。

发展阶段-我国

- 1978 “智能模拟”。
- 1978 图像识别与人工智能研究所成立。
- 1981 长沙 中国人工智能学会。
- 1986 智能计算系统、智能机器人和智能信息处理等列入 863 计划。

人工智能的学派

- 符号主义

又称逻辑主义、心理学派或计算机学派。

原理：物理符号系统假设和有限合理性原理。

起源：数学逻辑。

认为人类认知和思维的基本单元是符号，而认知过程就是在符号表示上的一种运算。符号主义致力于用计算机的符号操作来模拟人的认知过程。

提出“人工智能”术语，后来又发展了启发式算法→专家系统→知识工程理论与技术。

- 连接主义

又称：仿生学派或生理学派。

原理：神经网络和神经网络间的连接机制和学习算法。

起源：仿生学和人脑模型的研究。

从神经生理学和认知科学的研究成果出发，强调智能活动是由大量简单的单元通过复杂的相互连接后得到的结果。

人工神经网络是其典型代表性技术。

- 行为主义

又称：进化主义或控制论学派。

原理：控制论及感知动作型控制系统。

起源：控制论。

控制论把神经系统的工作原理与信息理论、控制理论、逻辑以及计算机联系起来，模拟人在控制过程中的智能行为和作用，如对自寻优、自适应、自校正、自镇定、自组织和自学习等控制论系统的研究，并进行“控制论动物”的研制。

诞生了智能控制和智能机器人系统。

人工智能的主要研究与典型应用

搜索

组合优化问题

- **NP 完全问题**：用目前知道的最好的方法求解，问题求解需要花费的时间是随问题规模增大以指数关系增长。

时间复杂度： $O(1) < O(n) < O(n \log n) < O(n^2) < O(n^a) < O(a^n) < O(n!)$ 。

多项式级别 $\leftarrow$ $\rightarrow$ 非多项式级别

智能计算

- 受自然界和生物界启发，模仿设计的各种智能算法。
- 广泛应用于组合优化、模式识别、机器学习等领域。

进化计算：基于自然选择和遗传等生物进化机制的搜索算法；群智能：受动物群体智能启发的算法；遗传算法。

模式识别

- 研究对象描述和分类方法的学科。
- 模式：对一个物体或感兴趣实体定量或结构的描述。
- 统计方法、结构方法、神经网络方法等。
- 有监督/无监督。
- 应用：图像识别、文字识别、语音识别等。

数据挖掘与知识发现

人工神经网络与神经计算

- 用大量简单处理单元经广泛连接组成的人工网络，模拟大脑神经系统的结构和功能。
- 人工智能中极其重要的研究领域。
- 应用：模式识别、图像处理、自动控制等。

计算机视觉

- 通过对采集的图片或视频进行处理以获得相应的信息。
- 低层视觉：突出对象某些特征；高层视觉：理解对象。
- 目标：使计算机能象人那样通过视觉观察和理解世界。
- 机器学习三大热点方向：计算机视觉、自然语言处理、语音识别。

自然语言处理

- 自然语言理解：文本分类、命名实体识别、指代消歧；句法分析、机器阅读理解等。
- 自然语言生成：理解文本后生成自然文本。自动摘要、机器翻译、问答系统、对话机器人。
- 难点：语言的多样性、歧义性、语言的鲁棒性、知识依赖、上下文。
- 应用：机器翻译、自动摘要、文本分类、问题回答、文本语义对比、语音识别等。

分布式人工智能与多智能体

- 目标是创建一种描述自然系统和社会系统的模型。分布式问题求解：把一个具体的求解问题划分为多个相互合作和知识共享的模块或者结点；多智能体系统：研究各智能体之间行为的协调。
- 多智能体系统更能体现人类的社会智能。

- 应用：飞行器编队、传感器网络、数据融合、交通车辆控制等。

专家系统

• 具有特定领域内大量知识与经验的程序系统,应用人工智能技术模拟人类专家的思维过程来求解领域内的问题。

- 应用：医疗诊断、地质勘探、石油化工、数理问题。

博弈与游戏 AI

智能信息检索

- 能理解自然语言。
- 具有推理能力。
- 系统拥有一定的常识性知识。

机器人：第一代 程序控制机器人；第二代 自适应机器人；第三代 智能机器人。

脑机接口：脑与设备的信息交换。


智能+others

盲目式搜索与启发式搜索的概念

盲目搜索：在不具有对特定问题的任何有关信息的条件下，按固定的步骤（依次或随机调用操作算子）进行的搜索。


启发式搜索：考虑特定问题领域可应用的知识，动态地确定调用操作算子的步骤，优先选择较适合的操作算子，尽量减少不必要的搜索，以求尽快地到达结束状态。

状态空间的图描述



作业二：简单版修道士和野人问题

设有 2 个修道士和 2 个野人来到河边，打算乘一条索道从河的左岸渡到河的右岸。但索道只有一个轿箱，每次只能装载 1 人，在任何岸边野人的数目都不得超过修道士的人数，否则修道士就会被野人吃掉。野人和修道士都服从你的过河安排。请问如何规划过河计划才能把所有人都安全地渡过河去。请画出状态空间图，并给出深度优先的搜索求解过程。



宽度优先和深度优先搜索

宽度优先搜索（广度优先搜索）：以接近起始节点的程度（深度）为依据，进行逐层扩展的节点搜索方法。

特点：（1）每次选择深度最浅的节点首先扩展，搜索是逐层进行的。

（2）一种高价搜索，但若有解存在，则必能找到它。

宽度优先搜索中保存状态空间搜索轨迹用到的表：

- **Open**: 已经生成出来但其子状态未被搜索的状态（类 NPS 表），是一个队列（先进先出）。
- **Closed**: 记录了已被生成扩展过的状态（类 PS 表和 NSS 表的合并）。

深度优先搜索：首先扩展最新产生的节点，深度相等的节点按生成次序的盲目搜索。

特点：（1）扩展最深的节点使得搜索沿着状态空间某条单一的路径从起始节点向下进行。

（2）仅当搜索到达一个没有后裔的状态时，才考虑另一条替代的路径。

算法：防止搜索过程沿着无益的路径扩展下去，往往给出一个节点扩展的最大深度——深度界限；与宽度优先搜索算法最根本的不同：将扩展的后继节点放在 **OPEN** 表的前端；深度优先搜索算法的 **Open** 表是堆栈，先进后出。

在深度优先搜索中，当搜索到某一个状态时，它所有的子状态以及子状态的后裔状态都必须先于该状态的兄弟状态被搜索。为了保证找到解，应选择合适的深度限制值，或采取不断加大深度限制值的办法，反复搜索，直到找到解。深度优先搜索并不能保证第一次搜索到的某个状态时的路径是到这个状态的最短路径。

八数码问题

- 例：八数码问题的状态空间

2	3	1
5		8
4	6	7

初始状态


1	2	3
8		4
7	6	5

目标状态

- 将空格向上移Up
- 将空格向左移Left
- 将空格向下移Down
- 将空格向右移Right

状态集 S 所有摆法

操作算子



八数码状态空间图

启发式信息和启发式搜索

- 启发式信息：用来简化搜索过程有关具体问题领域的特性信息叫做启发信息。

按运用的方法分类：

- (1) 陈述性启发信息：用于更准确、更精炼地描述状态。
- (2) 过程性启发信息：用于构造操作算子。
- (3) 控制性启发信息：表示控制策略的知识。

按作用分类：

- (1) 用于扩展节点的选择，即用于决定应先扩展哪一个节点，以免盲目扩展。
 - (2) 用于生成节点的选择，即用于决定要生成哪些后继节点以免盲目生成过多无用的节点。
 - (3) 用于删除节点的选择，即用于决定删除哪些无用节点，以免造成进一步的时空浪费。
- 启发式搜索：利用启发信息的搜索过程。
 - 启发式图搜索策略的特点：重排 OPEN 表，选择最有希望的节点加以扩展。
 - 运用启发式策略的两种基本情况：
 - (1) 一个问题由于存在问题陈述和数据获取的模糊性，可能会使它没有一个确定的解；
 - (2) 虽然一个问题可能有确定解，但是其状态空间特别大，搜索中生成扩展的状态数会随着搜索的深度呈指数级增长。

A*算法

估价函数：估算节点“希望”程度的量度。估价函数值 $f(n)$ ：从初始节点经过 n 节点到达目标节点的路径的最小代价估计值，其一般形式是 $f(n)=g(n)+h(n)$ 。

$g(n)$ ：从初始节点 S_0 到节点 n 的实际代价；

$h(n)$ ：从节点 n 到目标节点 S_g 的最优路径的估计代价，称为启发函数。

$h(n)$ 比重大：降低搜索工作量，但可能导致找不到最优解； $h(n)$ 比重小：一般导致工作量加大，极限情况下变为盲目搜索，但可能可以找到最优解。

A 搜索算法：使用了估价函数 f 的最佳优先搜索。

寻找并设计启发函数 $h(n)$ ，然后以 $f(n)$ 的大小来排列 OPEN 表（保留所有已生成而未扩展的状态）中待扩展状态的次序，每次选择 $f(n)$ 值最小者进行扩展。

$g(n)$ ：状态 n 的实际代价，例如搜索的深度；

$h(n)$ ：对状态 n 与目标“接近程度”的某种启发式估计。

A*搜索算法（最佳图搜索算法）：定义 $h^*(n)$ 为状态 n 到目的状态的最优路径代价，当 A 搜索算法的启发函数 $h(n)$ 小于等于 $h^*(n)$ ，即对所有结点 n 满足 $h(n) \leq h^*(n)$ 时，被称为 A*搜索算法。如果某一问题有解，那么利用 A*搜索算法对该问题进行搜索则一定能搜索到解，并且一定能搜索到最优的解。

例：八数码问题中定义的 $h(n)$ 表示“不在位”的数码数，其 A 搜索树也是 A*搜索树，所得解路径为最优解路径。

答：如果规则允许随便移动（比如把某个数字扣下来直接按到正确位置），把数码各自归位最少要移动的步数就是不在位数字的数量。但实际上根据八数码游戏的规则是不能这么移动的，那移动的实际步数肯定要大于上面这个数量。这实际上就满足了 A*算法对于 $h(n)$ 的要求。

A*搜索的特性

- 可采纳性：当一个搜索算法在最短路径存在时能保证找到它，就称该算法是可采纳的。
A*搜索算法是可采纳的，宽度优先搜索算法是 A*搜索算法的特例（ $h(n)=0$ ， $f(n)=g(n)$ ）。
- 单调性：如果某一启发函数 $h(n)$ 满足“对所有状态 n_i 和 n_j ，其中 n_j 是 n_i 的后裔，满足 $h(n_i)-h(n_j) \leq \text{cost}(n_i, n_j)$ ，其中 $\text{cost}(n_i, n_j)$ 是从 n_i 到 n_j 的实际代价”，“目的状态的启发函数

值为 0”，则称 $h(n)$ 是单调的。如果对启发函数 $h(n)$ 加上单调性的限制，就可以总从祖先状态沿着最佳路径到达任一状态。A* 搜索算法中采用单调性启发函数，可以减少比较代价和调整路径的工作量，从而减少搜索代价。

- 信息性：在两个 A* 启发策略的 h_1 和 h_2 中，如果对搜索空间中的任一状态 n 都有 $h_1(n) \leq h_2(n)$ ，就称策略 h_2 比 h_1 具有更多的信息性；如果某一搜索策略的 $h(n)$ 越大，则 A* 算法搜索的信息性越多，所搜索的状态越少，但更多的信息性可能需要更多的计算时间，也有可能抵消减少搜索空间所带来的益处。

机器学习的分类

1. 按学习方式分类：监督学习，无监督学习，强化学习。
2. 按学习方法分类（温斯顿，1977）：机械式学习、指导式学习、示例学习、类比学习、解释学习等；符号学习、非符号学习（连接学习）。
3. 按推理方式分类：基于演绎的学习（解释学习）；基于归纳的学习（示例学习、发现学习等）。
4. 按综合属性分类：归纳学习、分析学习、连接学习、遗传式学习等。

监督学习、无监督学习、强化学习的概念

- 监督学习：从给定的训练数据集中学习出一个模型，当新的数据到来时，可以根据这个模型预测结果。监督学习的训练集要求是包括输入和预期输出，也可以说是特征和标签。训练集中的样本需要标注（有标签）。
- 无监督学习：训练集没有标签。
- 强化学习：机器为了达成目标，随着环境的变动，评估每一个行动之后所得到的反馈是正向的或负向的，从而逐步调整其行为。

个体词、谓词、量词、逻辑连接词（连词）

- 个体：独立存在的客体，具体事物，抽象事物（概念）。
- 个体词 $\sim$ 给个体起的名字，个体可以是常量、变元、函数（一般用小写字母指代确定个体）。
- 谓词：描述个体性质或关系的词。
- 谓词的一般形式： $P(x_1, x_2, \dots, x_n)$ 。个体 $x_1, x_2, \dots, x_n$ ：某个独立存在的事物或者某个抽象的概念；谓词名 P ：刻画个体的性质、状态或个体间的关系。若谓词 $P(x_1, x_2, \dots, x_n)$ 中 x_i 都是个体常量、变元或函数，则该谓词被称为一阶谓词。

例：“老张是一个教师”：“老张” $\rightarrow$ 个体词 z ，“是一个教师” $\rightarrow$ 谓词名 T 。 $T(z)$ 描述了个体老张是一个教师这种性质，是一个一元谓词，其中个体词是常量。

“老张的儿子作为一个教师为华科工作”： $Work(son(z), hust, teacher)$ ，是三元谓词，其中 $son(z)$ 这个个体是一个函数。

- 量词：刻画谓词与个体间的关系。

全称量词 $\forall x$ ：对个体域中的所有个体 x ； $(\forall x) A(x)$ ：对于所有的 x 来说，都有性质 A 。

存在量词 $\exists x$ ：在个体域中存在个体 x ； $(\exists x) A(x)$ ：存在个体 x ，其有性质 A 。

逻辑连接词（连词）

- 无论命题逻辑还是谓词逻辑，均可用连接词把简单命题连接起来构成复合命题，表示更复杂的含义。
- 连词表示某种运算过程，所以又叫作逻辑运算符。

- (1) $\neg$: “否定”或“非”。
- (2) $\vee$: “或”。
- (3) $\wedge$: “与”。
- (4) $\rightarrow$: “蕴含”或“条件”。
- (5) $\leftrightarrow$: “等价”或“双条件”。

自然语言表示成一阶谓词公式

谓词公式表示知识的步骤:

- (1) 定义谓词及个体;
- (2) 变元赋值;
- (3) 用连接词连接各个谓词, 形成谓词公式。

作业三: 将自然语言翻译为谓词逻辑语言。

1. 有些泳池要么就是不干净, 要么就是很拥挤。

参考答案: $(\exists x)(P(x) \wedge (\neg C(x) \vee C(x)))$ 。

存在一些 x , x 是泳池, 并且, x 或者是不干净的或者是拥挤的。

2. 玫瑰花和菊花都是花。

参考答案: $(\forall x)(M(x) \vee J(x) \rightarrow H(x))$ 。

对于所有的 x 来说, 如果 x 是玫瑰或者 x 是菊花, 那么 x 就是花。

3. 有一些老师会很高兴, 当且仅当有一些同学学习很好。

参考答案: $(\exists x)(T(x) \wedge H(x)) \leftrightarrow (\exists y)(S(y) \wedge G(y))$ 。

存在一些 x , x 是老师并且 x 很高兴, 当且仅当, 存在一些 y , y 是学生并且 y 学习好。

产生式系统

产生式: 通常用于表示事实、规则以及它们的不确定性度量, 适合于表示事实性知识和规则性知识。

产生式系统: 一组产生式放在一起, 互相配合, 一个产生式的结论可以供另一个作为事实使用, 以求得问题的解。

- 规则库: 用于描述相应领域内知识的产生式集合。
- 综合数据库(事实库、上下文、黑板等): 一个用于存放问题求解过程中各种当前信息的数据结构。
- 控制系统(推理机): 由一组程序组成, 负责整个产生式系统的运行, 实现对问题的求解。

产生式系统的特点

- 不断从规则库中选择可用规则与综合数据库中的已知事实进行匹配。
- 规则的每一次成功匹配都使综合数据库中增加新的内容, 朝着问题解决的方向前进, 称为推理, 是专家系统中的核心内容。

适合产生式表示的知识:

- 领域知识间关系不密切, 不存在结构关系, 如化学方面。
- 经验性及不确定性的知识, 且相关领域中对这些知识没有严格、统一的理论, 如医疗论断。
- 领域问题的求解过程可被表示为一系列相对独立的操作, 且每个操作可被表示为一条或多条产生式规则。

知识图谱的组成、特点、类别

知识图谱的组成：

- 实体：具有可区别性且独立存在的某种事物。
- 概念：具有同种特性的实体构成的集合。
- 值：对象指定属性的值。
- 关系：侧重实体之间的关系。
- 属性：描述一个物体的特性。

知识图谱的特点（优势）：尺度大，语义丰富，质量高，结构易于实现。


知识图谱的类别：

针对不同种类知识：概念图谱；常识图谱；词汇图谱；百科图谱；文本图谱……

针对领域特性：通用知识图谱；领域（行业）知识图谱；企业知识图谱……

推理的定义、分类、方向

推理的定义



推理的方式

- （1）演绎推理：一般→个别。
- （2）归纳推理：个别→一般。
- （3）默认推理（缺省推理）：知识不完全的情况下假设某些条件已经具备所进行的推理。

推理的分类

1. 确定性推理、不确定性推理。
2. 单调推理、非单调推理。
3. 启发式推理、非启发式推理。

推理的方向

- 正向推理：（事实驱动推理）：已知事实→结论。

从初始已知事实出发，在知识库中匹配知识进行推理，将推理出的新事实加入数据库作为下一步推理的已知事实，直到求解为止。简单，易实现，目的性不强，效率低。

- 逆向推理：（目标驱动推理）：以某个假设目标作为出发点。

选定一个假设目标->寻找支持该假设的证据->找到则假设成立/找不到则重新假设。目的性强，但起始目标的选择有盲目性。

- 混合推理（结合正向与逆向推理）。

先正向后逆向：先进行正向推理，帮助选择某个目标，即从已知事实演绎出部分结果，然后

再用逆向推理证实该目标或提高其可信度。

先逆向后正向：先假设一个目标进行逆向推理，然后再利用逆向推理中得到的信息进行正向推理，以推出更多的结论。

适用情况：已知事实不充分、正向推理得到的结论可信度不高、希望得到更多结论。

- 双向推理（同时进行正向与逆向推理）。

正向推理和逆向推理在中途碰头时结束推理。困难在于碰头的判断。

归结反演进行证明

定理：Q 为 $P_1, P_2, \dots, P_n$ 的逻辑结论，当且仅当 $(P_1 \wedge P_2 \wedge \dots \wedge P_n) \wedge \neg Q$ 是不可满足的。

- 应用归结原理证明定理的过程称为归结反演。

- 用归结反演证明的步骤是：

- (1) 将已知前提表示为谓词公式 P。

- (2) 将待证明的结论表示为谓词公式 Q，并否定得到 $\neg Q$ 。

- (3) 把谓词公式集 $\{P, \neg Q\}$ 化为子句集 S。

- (4) 应用归结原理对子句集 S 中的子句进行归结，并把每次归结得到的归结式都并入到 S 中。如此反复进行，若出现了空子句，则停止归结，此时就证明了 Q 为真。

- 例：某公司招聘工作人员，A, B, C 三人应试，经面试后公司表示如下想法：

- (1) 三人中至少录取一人。

- (2) 如果录取 A 而不录取 B，则一定录取 C。

- (3) 如果录取 B，则一定录取 C。

求证：公司一定录取 C。

连接词化规律（蕴含、等价等值式）： $P \rightarrow Q \leftrightarrow \neg P \vee Q$

德摩根定律：

$$\neg(P \vee Q) \leftrightarrow \neg P \wedge \neg Q$$
$$\neg(P \wedge Q) \leftrightarrow \neg P \vee \neg Q$$

子句集：	(1) $P(A) \vee P(B) \vee P(C)$	(5) $P(B) \vee P(C)$	由 (1) (2) 归结
	(2) $\neg P(A) \vee P(B) \vee P(C)$	(6) $P(C)$	由 (3) (5) 归结
	(3) $\neg P(B) \vee P(C)$	(7) 空	由 (4) (6) 归结
	(4) $\neg P(C)$		$\therefore$ 结论成立

可信度方法

2. 设有如下一组推理规则：

r1: IF E1 AND E2 THEN E3 (0.9)

r2: IF E3 OR E4 THEN E5 (0.8)

r3: IF E5 THEN H (0.7)

r4: IF E6 THEN H (0.9)

已知 $CF(E1) = 0.6$, $CF(E2) = 0.5$, $CF(E4) = 0.4$, $CF(E6) = 0.8$, 求 $CF(H)$ 。

参考答案：

根据题目所述，计算 $CF(H)$ 需要计算 E5 和 E6 对 H 的综合可信度，为此需要计算 E5 对 H 的可信度 $CF_1(H)$ 以及 E6 对 H 的可信度 $CF_2(H)$ ，即

$$CF_1(H) = CF(H, E5) \times \max\{0, CF(E5)\} \quad (1)$$
$$CF_2(H) = CF(H, E6) \times \max\{0, CF(E6)\} \quad (2)$$

其中，由 r3 和 r4 可知， $CF(H, E5) = 0.7$, $CF(H, E6) = 0.9$ ；又由已知条件可知， $CF(E6) = 0.8$ 。因此，只要求得 $CF(E5)$ 即可计算得出 $CF(H)$ 。

又由 r2 可知，

$$CF(E5) = CF(E5, E3 \vee E4) \times \max\{0, CF(E3 \vee E4)\} = CF(E5, E3 \vee E4) \times \max\{0, \max[CF(E3), CF(E4)]\} \quad (3)$$

其中， $CF(E3)$ 又为未知量，需要继续推理求得。

根据 $r1$,

$$CF(E3) = CF(E3, E1 \wedge E2) \times \max\{0, CF(E1 \wedge E2)\} = CF(E3, E1 \wedge E2) \times \max\{0, \min[CF(E1), CF(E2)]\} = 0.9 \times \max\{0, \min(0.6, 0.5)\} = 0.45 \quad (4)$$

将 $CF(E3) = 0.45$ 带入公式 (3) 可得, $CF(E5) = 0.8 \times 0.45 = 0.36$ 。

进一步, 再将 $CF(E5) = 0.36$ 带入公式 (1) 可得, $CF1(H) = 0.7 \times 0.32 = 0.252$,

而 $CF2(H) = 0.9 \times 0.8 = 0.72$ 。

因此, 由不确定合成算法可知,

$$CF(H) = CF1(H) + CF2(H) - CF1(H)CF2(H) = 0.252 + 0.72 - 0.252 \times 0.72 = 0.79056 \quad (5)$$

模糊推理方法

4. 设有模糊规则: 如果天气冷, 则调高空调温度。设室温的论域为 $\{0, 5, 10\}$, 单位摄氏度, 隶属度 $[1.0, 0.8, 0.5]$, 调高空调论域为 $\{1, 3, 5\}$, 单位摄氏度, 隶属度 $[0.2, 0.5, 1.0]$ 。已知事实 “天气冷” $= \{(0.1, 0), (0.6, 5), (0.2, 10)\}$, 试用模糊推理确定空调应该怎么调。

参考答案:

模糊关系:

$$R = \begin{bmatrix} 1.0 \\ 0.8 \\ 0.5 \end{bmatrix} \circ [0.2 \quad 0.5 \quad 1.0] = \begin{bmatrix} 1.0 \wedge 0.2 & 1.0 \wedge 0.5 & 1.0 \wedge 1.0 \\ 0.8 \wedge 0.2 & 0.8 \wedge 0.5 & 0.8 \wedge 1.0 \\ 0.5 \wedge 0.2 & 0.5 \wedge 0.5 & 0.5 \wedge 1.0 \end{bmatrix} = \begin{bmatrix} 0.2 & 0.5 & 1.0 \\ 0.2 & 0.5 & 0.8 \\ 0.2 & 0.5 & 0.5 \end{bmatrix}$$

模糊推理:

$$[0.1 \quad 0.6 \quad 0.2] \circ R = [0.1 \quad 0.6 \quad 0.2] \circ \begin{bmatrix} 0.2 & 0.5 & 1.0 \\ 0.2 & 0.5 & 0.8 \\ 0.2 & 0.5 & 0.5 \end{bmatrix} = [0.2 \quad 0.5 \quad 0.6]$$

决策:

按最大隶属度法: 调高 5°C

按加权平均法: $(1 \times 0.2 + 3 \times 0.5 + 5 \times 0.6) / (0.2 + 0.5 + 0.6) = 3.62^{\circ}\text{C}$,

调高 3°C

证据理论方法

3. 警方判定罪犯肯定是嫌疑人 A、B 中的一个, 但不知道是哪一个; 经过问询, 两个证人张三、李四对他们认为的罪犯给出如下不同的判断: 试使用 D-S 理论分析最有可能的罪犯。

假设	张三认为 m1	李四认为 m2
A 作案	0.8	0.6
B 作案	0.1	0.2
A 或 B 作案	0.1	0.2

参考答案：

求归一化常数：

$$\begin{aligned}
 K &= \sum_{X \cap Y \neq \emptyset} m_1(X) \cdot m_2(Y) \\
 &= m_1(A) \cdot m_2(A) + m_1(A) \cdot m_2(A \text{ or } B) + m_1(B) \cdot m_2(B) \\
 &\quad + m_1(B) \cdot m_2(A \text{ or } B) + m_1(A \text{ or } B) \cdot m_2(A) + m_1(A \text{ or } B) \cdot m_2(B) \\
 &\quad + m_1(A \text{ or } B) \cdot m_2(A \text{ or } B) \\
 &= 0.78
 \end{aligned}$$

基于合成规则，A 是罪犯的概率：

$$\begin{aligned}
 m_1 \oplus m_2(A) &= \frac{1}{K} \sum_{X \cap Y = A} m_1(X) \cdot m_2(Y) \\
 &= \frac{1}{K} (m_1(A) \cdot m_2(A) + m_1(A) \cdot m_2(A \text{ or } B) + m_1(A \text{ or } B) \cdot m_2(A) + m_1(A \text{ or } B) \cdot m_2(A \text{ or } B)) \\
 &= \frac{0.72}{0.78} = 0.9231
 \end{aligned}$$

同理，B 是罪犯的概率：

$$\begin{aligned}
 m_1 \oplus m_2(B) &= \frac{1}{K} \sum_{X \cap Y = B} m_1(X) \cdot m_2(Y) \\
 &= \frac{1}{K} (m_1(B) \cdot m_2(B) + m_1(B) \cdot m_2(A \text{ or } B) + m_1(A \text{ or } B) \cdot m_2(B) + m_1(A \text{ or } B) \cdot m_2(A \text{ or } B)) \\
 &= \frac{0.08}{0.78} = 0.1026
 \end{aligned}$$

因此 A 更有可能是罪犯。

人工神经网络发展简史

- 1943 年，M-P 模型。
- 上世纪五六十年代，感知器（Perceptron）模型。
- 1960 年 ADALINE。
- 1969 年 XOR 问题，“AI 寒冬”。
- 1986 年 BP 神经网络。
- 1995 年 SVM。

感知器模型的基本概念、限制

感知器将输入空间通过一个（超）平面划分为两个半空间。

感知器的特点：实值的输入和输出；阶跃响应函数；模型有可学习的权重。

感知器的限制

- 属于线性模型，只能解决线性可分的问题。
- 即使少量不可分样本都会导致学习的不收敛。


BP 神经网络的基本概念、结构、特点，前向和反向传播的概念

BP 神经网络的提出解决了类似 XOR 的非线性分类问题。

BP 神经网络主要由三种类型的网络层构成：输入层，输出层和隐含层。

BP 网络的特点

- BP 网络：多层前向网络（输入层、隐层、输出层）。
- 连接权值：通过学习算法进行修正。
- 神经元传输函数：S 形函数（Sigmoid）。
- 学习算法：正向传播、反向传播。
- 层与层的连接是单向的，信息的传播是双向的。



BP 网络的学习与后向传播

- BP 网络的学习由损失函数驱动，例如 ADALINE 中使用的均方损失函数。
- 学习的目的在于：调整 BP 神经网络的连接权重，使网络的输入与输出与给定的样本相同。
- 学习过程中需要求损失函数对网络中每个权重的偏导数，这个过程从输出端到输入端逐层传递，因此叫做后向（反向）传播。
- 后向传播的核心为链式法则。

深度学习的动机、概念、思想、特点

动机：设计局部特征。

概念：特征学习——与其设计特征，不如设计特征学习器。

核心思想：

- 从数据中学习数据间的统计特性以及相关性。
- 学习的表达可以作为特征用于不同的任务中。
- 深度学习也被称为：特征学习、表达学习等等。
- 深度学习的研究目标是通过发现有效的学习算法，学习层次化的特征分布与表达，通常更高层应表达更加抽象的特征。

特点：深度学习的模块化思想。科学家认为：人脑中的许多区域中可能使用了相同的学习算法，作为基础模块以编码声音、触觉、语言以及其他感官类的输入。

分层，模块化处理，每层学到一定抽象程度的内容。

卷积神经网络的基本组成，各模块（部分）的作用


基本组成：输入层，卷积层，池化层，全连接层，输出层。


卷积和池化的计算、特点

卷积：局部感知；平移同变性；特征增强/降噪。

池化：局部变化的不变性；增大感受野；降维。

卷积计算：对图像局部像素加权求和。池化计算：





典型的 CNN 模型及其特点

LeNet: 平均池化；非线性激活单元；全连接层用于分类；在 60,000 个训练样本的 MNIST 手写体识别数据集上训练。

AlexNet: 更大的模型(8 层)；更多的数据 (10^6 images)；GPU 实现 (超过 CPU 50 倍的加速)；更好的正则化。

VGGNet: 朴素的实现；更深的模型 (16 层 or 19 层)；由连续 3×3 卷积取得的更大的感受野（对于 C 通道的特征图， 7×7 的卷积核需要 $49C^2$ 个参数，但通过三个连续 3×3 核的卷积层等价实现，仅需 $27C^2$ 个参数）。

GoogLeNet: Inception 模块（ 1×1 , 3×3 , 5×5 的不同感受野分支用于捕获）；昂贵的卷积计算前使用 1×1 卷积降低特征通道维数。

ResNet: 152 层；主要解决深度网络变深后难以优化的问题；以 Skip Connection 为核心的残差网络；在所有学科领域中引用最高的论文。

作业五

1. 判断下列表述，并对你的判断简要陈述理由：

1) 随着 CNN 的层数变深，通常特征图的宽高减小、通道数增加。

一般是这样，也有少数网络不是。

2) 全连接层通常只出现在 CNN 的最后几层。

对。

3) 只有池化层能起到下采样的作用。

不对，步长不为 1 的卷积层也能。

4) 残差网络采用跳跃连接计算一个非线性函数使得输入能传递到更深的层。

不对，跳跃连接不是一个非线性函数。

3. 假设输入是一张 128×128 的 RGB 彩色图像，如果网络第一个卷积层的卷积核为 3×3 的大小，步长为 1，共有 64 个卷积核，后接一个步长为 2 的 2×2 平均池化层，随后再接两层核大小为 5×5 ，卷积核个数为 128 的卷积层以及一层步进为 2 的 2×2 的平均池化层，最后接含有 128 个神经元的全连接层和一个含有 10 个神经元的输出层，试计算该网络的参数量和感受野并回答网络的参数量主要由哪部分贡献（2 层 5×5 的卷积层的 stride 需要讨论）。

参数计算： 卷积层 1: $(3 \times 3 \times 3 + 1) \times 64 = 1792$

卷积层 2: $(5 \times 5 \times 64 + 1) \times 128 = 204928$

卷积层 3: $(5 \times 5 \times 128 + 1) \times 128 = 409728$

全连接层 1: $(F + 1) \times 128$

全连接层 2: $(128 + 1) \times 10 = 1290$

感受野计算：

卷积层 1: $1 + (3 - 1) \times 1 = 3$

池化层 1: $3 + (2 - 1) \times 1 \times 1 = 4$

卷积层 2: $5 + (5 - 1) \times 1 \times 1 \times 2 = 13$

卷积层 3: $13 + (5 - 1) \times 1 \times 1 \times 2 \times S_1 = 13 + 8S_1$

池化层 2: $13 + 8S_1 + (2 - 1) \times 1 \times 1 \times 2 \times S_1 \times S_2 = 13 + 8S_1 + 2S_1S_2$

RNN 的概念、结构和表示方式

RNN：循环神经网络，是一种为了适应序列化数据的序列特性而设计的神经网络。它能够在序列化数据上进行端到端的学习和计算。

展开的RNN结构




- 由于序列的序列特性，特征 s_t 不仅仅取决于当前输入 x_t ，还取决于 s_{t-1} 。把RNN的结构按照序列展开，每一个时间点的隐藏层函数（Hidden Layer Function） f 为：

$$\mathbf{s}_t = f(\mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{s}_{t-1})$$

即RNN可表示为：

$$\mathbf{o}_t = g(\mathbf{V}\mathbf{s}_t),$$

$$\mathbf{s}_t = f(\mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{s}_{t-1})$$




未展开的RNN结构



- 与神经网络的结构一样，输入 $X[x_1, x_2, \dots, x_n]$ （ n 表示序列长度）的特征用 $S[s_1, s_2, \dots, s_n]$ 表示，输出用 $O[o_1, o_2, \dots, o_n]$ 表示，神经网络的输出层参数用 V 表示。则当前的输出函数（Output Function） g 为：

$$\mathbf{O} = g(\mathbf{V}, \mathbf{S})$$



RNN 的两种计算图表示方法：折叠表示和展开表示。

RNN 存在的问题

- 长序列的记忆丢失（梯度消失）。

- 关系建模单向性的局限。

LSTM 的基本结构

- 综上，一个LSTM 单元可表示为：

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f)$$


$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o)$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c)$$

$$\mathbf{C}_t = \mathbf{f}_t \otimes \mathbf{C}_{t-1} + \mathbf{i}_t \otimes \tilde{\mathbf{C}}_t$$

$$\mathbf{y}_t = \mathbf{h}_t = \mathbf{o}_t \otimes \tanh(\mathbf{C}_t)$$



RNN 和 LSTM 的异同

同：和初代 RNN 相比，LSTM 同样采取了循环链式结构；

LSTM 和初代 RNN 都假设了元素之间的依赖关系是单向的。

异：LSTM 引入了大量的非线性单元，为不同状态引入丰富的非线性性；

增加了细胞状态 $\mathbf{C}_t$ 和门控单元用于有选择性地建模长期记忆。

作业五

4. 关于 RNN 与 LSTM，下面哪些说法是正确的，为什么？

- 两者均通过前向计算输出结果，反向计算更新模型参数。 对。
 - CNN 有参数共享，RNN 没有参数共享。 RNN 在不同时刻参数也是共享的。
 - RNN 可以用于描述时间上连续状态的输出，有记忆功能，而 CNN 用于静态输出。 对。
 - RNN 和 CNN 可以建立数据之间的长程依赖关系。 建立不了长程依赖关系。
5. 如果你面对以下任务“基于视觉内容判断视频是否是风景视频”，你将如何设计模型架构？绘制大致的框架图并简要说明其模块功能。

框图：先有一部分 CNN 的结构提取单帧图像特征，再接一部分 RNN 的结构建模视频（图像序列），最后接分类器判断是否是风景。大致是 CNN+RNN 的结构。

图的基本概念、类型

图：一种数据结构，它可直观表示和可视化不同变量间的相互关系。由节点或顶点的集合以及边的集合组成。

属性图

- 节点和边都可以具有属性（特征）。

- 在一个图结构中，每一个节点由它自身的特征以及与其相连的节点特征来定义该节点。

图的两种类型

- 有向图：表示不同变量间的因果关系。
- 无向图：表示不同变量间的相关性。

图相关任务


- 图分类 • 节点分类 • 连接预测 • 群体检测（图聚类） • 图嵌入 • 图生成

GNN 的基本结构

- 给定一张图 G ，每个节点 v 的特征用 x_v 表示，连接节点 v 和节点 u 的边的特征用 $x_{(u,v)}$ 表示。GNN 的学习目标是：获得每个节点 v 的隐藏状态 h_v 。

注意：

对于每个节点，它的隐藏状态由自身节点的特征、相邻节点的特征和隐藏状态以及与自身节点相连的边的特征共同决定。



$$h_5 = f(x_5, x_{(3,5)}, x_{(5,6)}, h_3, h_6, x_3, x_6)$$

GCN 的基本概念、难点、输出

GCN 的本质是想找到适用于图的可学习卷积核。

GCN 的难点：定义在非欧空间；节点的邻域不固定；卷积核大小不固定。

GCN 的输出

- 节点级别输出：节点级别输出 Z 是一个 $N \times F$ 大小的特征矩阵， F 是输出特征维数。
- 图级别输出：图级别输出可通过引入某种形式的池化算子。

GAN 的原理、组成、目标

原理和组成：



GAN 的学习目标

- 假设 G 为生成器， D 为判别器，真实数据 x ，噪声 z 。
- $D(\cdot)$ 计算数据的真实性概率（1 为真，0 为假）。
- 生成器的目标是生成尽可能真实的“假数据”，即 $D(G(z)) \rightarrow 1$ 。
- 判别器的目标是尽可能判断出数据的真假，即 $D(x) \rightarrow 1, D(G(z)) \rightarrow 0$ 。

基础 GAN 存在的问题

1. 可解释性差，生成模型的分布没有显式的表达；
2. 比较难训练，生成器与判别器之间需要很好的同步，例如判别器更新 k 次而生成器只更新 1 次。

注意力机制的意义、内含

注意力可以帮助系统忽略无关信息、关注重点信息。

在神经网络中，注意力机制表示一类模拟人类认知注意力的技术。它主要通过引入乘法交互使输入的重要部分得到加强，同时弱化剩余输入——关注小但重要。

注意力机制的分类，不同注意力机制的特点

- 点积注意力

强注意力： $\{0, 1\}$ 二值分布问题。0 表示区域不被关注，1 表示区域受到关注。

软注意力： $[0, 1]$ 连续分布问题。每个区域被关注的程度高低，用 $0 \sim 1$ 的得分表示。

- 自注意力：特征间的自主学习。减少对外部信息的依赖，更擅长捕捉内部相关性。

不同注意力机制的特点

- 强注意力：强注意力关注点。图像中每个点都有可能延伸出注意力；同时强注意力是一个不可微的过程，训练过程往往通过增强学习实现。
- 软注意力：软注意力关注区域或者特征通道，同时软注意力是可微的，因此可以通过神经网络计算出梯度并且通过前向传播和后向反馈来学习得到注意力的权重。
- 自注意力：自注意力关注全局信息，有显式的表达式。由于每一个点都要捕捉全局上下文信息，导致自注意力机制模块计算复杂度和内存占用较大。

点积注意力机制的类型、各类注意力机制的含义

- 空间注意力：让神经网络学习看哪里。
- 通道注意力：对不同通道的重要性加权，实现通道域的注意力机制。
- 混合注意力：将空间注意力和通道注意力结合。
- 时间注意力

自注意力机制的三元组、之间的关系、起到的作用

- 自注意力机制通过（Query, Key, Value）的三元组提供了一种有效的捕捉全局上下文信息的建模方式：

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

- Q 表示query， K 表示key， V 表示value， d_k 表示 k 的维度。

形象化理解：【搜索领域】在bilibili找视频，key就是bilibili数据库中的关键字序列，query就是你输入的关键字序列，value就是你找到的视频序列。

【推荐系统】在淘宝买东西，key就是淘宝数据库中所有的商品信息，query就是你最近关注的商品信息，value就是推送给你的商品信息。

注意力网络的典型应用

文本翻译；图像分类；目标检测；语义分割；点云分类和分割；行为识别。

计算智能的概念

计算智能系统：当一个系统只涉及数值（低层）数据，含有模式识别部分，不应用人工智能意义上的知识，而且能够呈现出计算适应性，计算容错性，接近人的速度，误差率与人相近，则该系统就是计算智能系统。

计算智能是一种智力方式的低层认知，它与人工智能的区别只是认知层次从中层下降至低层而已。中层系统含有知识，低层系统则没有。

进化算法的基本概念、术语

进化算法四大经典：GA（遗传算法），ES（进化策略），EP（进化规划）和 GP（基因规划）。

生物遗传概念	进化算法中的应用
适者生存	更符合需求的解被选择的可能性大
个体(Individual)	解
染色体(Chromosome)	解的编码（字符串，向量等）
基因(Gene)	解的编码中的每一个分量
适应性(Fitness)	适应度函数值（不等同于目标函数值）
群体(Population)	根据适应度值选定的一组解（解的个数为群体的规模）
重组(Reproduction)	染色体（编码）按照某种方式（交叉），相互交换部分基因，形成两个新的个体的过程
变异(Mutation)	编码的某一分量发生变化的过程


进化算法的作用、应用

- 函数优化问题
- 其他难以求解的优化问题：

NP 难优化问题：旅行商问题、背包问题；
没有目标函数的优化问题；
.....

遗传算法的流程

- (1) 编码
- (2) 产生初始种群
- (3) 计算适应度
- (4) 选择与遗传操作
 - (4.1) 复制、交叉、变异操作
 - (4.2) 生成子代
- (5) 重复 (3) - (4) 直至满足停止条件



群智能的概念、与进化算法的对比

群定义为某种交互作用的组织或 agent 的结构集合（相互作用的相邻个体的集合）。

群集中个体行为简单，但群体行为相当复杂，作为群体协同工作时，能够突现出非常复杂的行为特征—智能。

群智能：速度快，早熟；全局搜索能力强；社会交互更新状态生成新解；模拟生物群体决策。

进化算法：收敛速度偏慢；全局能力强；以染色体重组和变异生成新解；模拟生物进化。

粒子群算法的基本思路、特点

基本思想：源于对鸟群觅食过程中的迁徙和群居的模拟。系统初始化为一组随机解，通过迭代搜寻最优值，粒子（潜在的解）在解空间追随最优的粒子进行搜索。

特点：通过群体中个体之间的协作和信息共享来寻找最优解。

蚁群算法的信息素、基本思路、特点

信息素：会随着时间慢慢挥发，短路径上的信息素相对浓度高。

基本思路：

- 用蚂蚁的行走路径表示待优化问题的可行解，整个蚂蚁群体的所有路径构成待优化问题的解空间；
- 路径较短的蚂蚁释放的信息素量较多，随着时间的推进，较短的路径上累积的信息素浓度逐渐增高，选择该路径的蚂蚁个数也越来越多；
- 最终，整个蚂蚁会在正反馈的作用下集中到最佳的路径上，此时对应的便是待优化问题的最优解。

特点：通过个体之间的信息交流与相互协作最终找到从蚁穴到食物源的最短路径。

作业六

1. 与经典梯度下降法相比，进化算法更适用于哪些问题？简述理由。

参考答案：

进化算法更适用于（1）多峰优化问题；（2）存在平坦区域的优化问题；（3）NP 难优化问题；（4）没有目标函数的优化问题。

梯度下降方法是用一个点沿梯度下降方向进行搜索，本质上属于贪婪算法，全局搜索能力很差；进化算法同时用多个个体（即一个种群）协同对解空间进行搜索，具有较强的全局搜索能力和较高的搜索效率。所以进化算法不容易陷入局部最优（故适合问题 1），也能较好地搜索平坦区域（故适合问题 2）。也正因为此，对于 NP 难问题，进化算法能够在相对较短的时间，给出较满意的解，即接近最优解的解（故适合问题 3）。同时，进化算法是用 fitness 函数度量个体的好坏，这使得其即使在不存在目标函数的场景下，进化算法也能工作（故适合问题 4）。

3. 你认为粒子群算法和蚁群算法中最关键的分别是什么？两者的异同点体现在哪些地方？

参考答案：

粒子群算法最关键可以是：粒子的数量/更新的方式/加权的方式等等。

蚁群算法最关键的可以是：信息素的设计/蚂蚁的数量等等。

相同点：都是群智能算法，模拟了生物群体的智能行为，都有较强的全局寻优能力；


不同点：一个模拟鸟群或蜂群，通过群体中个体之间的协作和信息共享来寻找最优解；一个模拟蚁群，在信息素的指引下在正反馈的作用下集中到最佳的路径上……

强化学习和其他机器学习范式的区别

- 没有监督，只有奖励信号
- 延迟反馈，而非瞬时结果
- 时序的重要作用（使用序列训练数据，而非独立同分布数据）
- 智能体与环境的互动（动态特性）：机器的动作影响了它接下来获取的数据。

强化学习模型的基本模型、要素

• 基本模型：



• 要素：

- 环境
- 智能体
- 状态 s
- 动作 a
- 奖励 r



强化学习智能体的组成, 各自的含义、分类

- 基于值函数的
 - 在值函数空间中搜索
 - 策略隐式表达 (基于值函数选择动作)
- 基于策略的
 - 在策略空间中搜索
 - 没有值函数
- 混合型策略
 - 有策略显式表达 (动作网络)
 - 有值函数 (评价网络)
 - Actor Critic
- 无模型的
 - 基于策略和/或值函数
 - 没有模型
- 基于模型的
 - 基于策略和/或值函数
 - 有模型

Q 学习和深度 Q 学习的基本思路

Q 学习 (其中一种 Value-based RL 方法)

- 无模型的 (Model-free) $Q_{\pi}(s, a) = E_{\pi}[G_t | S_t = s, A_t = a]$
- 基于动作值函数 $Q(s, a)$
- 通过与环境交互直接训练 $Q(s, a)$, 找到 $Q^*(s, a)$ 和 $\pi^*(s)$
- 深度 Q 网络 (DQN) 属于深度强化学习 (DRL) 的一种, 它是深度学习与 Q 学习的结合体。
- Q 表的局限性: 当状态和行为的组合不可穷尽时, 无法通过查表的方式选取最优的 Action。
- DQN: 用(深度)神经网络拟合 Q 表: 转化为监督学习; 目标: Q 函数。