



数据结构与算法分析-8



人工智能与自动化学院

韩守东

shoudonghan@hust.edu.cn

13720301586



8. 查找

- ▶ 8.1 顺序查找
- ▶ 8.2 折半查找
- ▶ 8.3 分块查找
- ▶ 8.4 哈希查找



查找的定义

- ▶ 查找——也叫检索，是根据给定的某个值，在表中确定一个关键字等于给定值的记录或数据元素
- ▶ 关键字——是数据元素中某个数据项的值，它可以标识一个数据元素

- ▶ 查找方法评价

- ▶ 查找速度

- ▶ 占用存储空间多少

- ▶ 算法本身复杂程度

- ▶ 平均查找长度ASL(Average Search Length): 为确定记录在表中的位置，需和给定值进行比较的关键字的个数的期望值叫查找算法的~

对含有 n 个记录的表，
$$ASL = \sum_{i=1}^n p_i c_i$$


其中： p_i 为查找表中第 i 个元素的概率， $\sum_{i=1}^n p_i = 1$

c_i 为找到表中第 i 个元素所需比较次数



8.1 顺序查找

- 查找过程：从表的一端开始逐个进行记录的关键字和给定值的比较
- 算法描述



比较次数：

查找第 n 个元素：1

查找第 $n-1$ 个元素：2

.....

查找第1个元素： n

查找第 i 个元素： $n+1-i$

查找失败： $n+1$



顺序查找的ASL

对含有 n 个记录的表, $ASL = \sum_{i=1}^n p_i c_i$

设表中每个元素的查找概率相等 $p_i = \frac{1}{n}$

$$\text{则 } ASL = \sum_{i=1}^n p_i c_i = \frac{1}{n} \sum_{i=1}^n i = \frac{1}{n} \cdot \frac{n(n+1)}{2} = \frac{n+1}{2}$$



8.2 折半查找

- ▶ 查找过程：每次将待查记录所在区间缩小一半
- ▶ 适用条件：采用顺序存储结构的有序表
- ▶ 算法实现
 - ▶ 设表长为 n ， low 、 $high$ 和 mid 分别指向待查元素所在区间的上界、下界和中点, k 为给定值
 - ▶ 初始时，令 $low=1, high=n, mid=\lfloor (low+high)/2 \rfloor$
 - ▶ 让 k 与 mid 指向的记录比较
 - ▶ 若 $k==r[mid].key$ ，查找成功
 - ▶ 若 $k<r[mid].key$ ，则 $high=mid-1$
 - ▶ 若 $k>r[mid].key$ ，则 $low=mid+1$
 - ▶ 重复上述操作，直至 $low>high$ 时，查找失败



Diagram illustrating a binary search on a sorted array. The array contains 11 elements: 5, 13, 19, 21, 37, 56, 64, 75, 80, 88, 92. The search range is from low=1 to high=11. The middle element (mid) is 56. A callout bubble indicates the target value is 21.

1	2	3	4	5	6	7	8	9	10	11
5	13	19	21	37	56	64	75	80	88	92

low → mid → high

1	2	3	4	5	6	7	8	9	10	11
5	13	19	21	37	56	64	75	80	88	92

↑ low ↑ mid ↑ high


1	2	3	4	5	6	7	8	9	10	11
5	13	19	21	37	56	64	75	80	88	92

low mid high



找70

例





算法评价

- ✧ 判定树：描述查找过程的二叉树叫~
- ✧ 有 n 个结点的判定树的深度为 $\lfloor \log_2 n \rfloor + 1$
- ✧ 折半查找法在查找过程中进行的比较次数最多不超过其判定树的深度
- ✧ 折半查找的ASL

设表长 $n = 2^h - 1$, $h = \log_2(n + 1)$, 即判定树是深度为 h 的满二叉树


设表中每个记录的查找概率相等 $p_i = \frac{1}{n}$

$$\text{则: } ASL = \sum_{i=1}^n p_i c_i = \frac{1}{n} \sum_{i=1}^n c_i = \frac{1}{n} \sum_{j=1}^h j \cdot 2^{j-1} = \frac{n+1}{n} \log_2(n+1) - 1 \approx \log_2(n+1) - 1$$



8.3 分块查找

- ▶ 查找过程：将表分成几块，块内无序，块间有序；先确定待查记录所在块，再在块内查找
- ▶ 适用条件：分块有序表
- ▶ 算法实现
 - ▶ 用数组存放待查记录,每个数据元素至少含有关键字域
 - ▶ 建立索引表，每个索引表结点含有最大关键字域和指向本块第一个结点的指针
- ▶ 算法描述





分块查找方法评价

$$ASL_{bs} = L_b + L_w$$

其中： L_b —— 查找索引表确定所在块的平均查找长度

L_w —— 在块中查找元素的平均查找长度

若将表长为 n 的表平均分成 b 块，每块含 s 个记录，并设表中每个记录的查找概率相等，则：

(1) 用顺序查找确定所在块：
$$ASL_{bs} = \frac{1}{b} \sum_{j=1}^b j + \frac{1}{s} \sum_{i=1}^s i = \frac{b+1}{2} + \frac{s+1}{2} = \frac{1}{2} \left(\frac{n}{s} + s \right) + 1$$

(2) 用折半查找确定所在块：
$$ASL_{bs} \approx \log_2 \left(\frac{n}{s} + 1 \right) + \frac{s}{2}$$




查找方法比较

	顺序查找	折半查找	分块查找
ASL	最大	最小	两者之间
表结构	有序表、无序表	有序表	分块有序表
存储结构	顺序存储结构 线性链表	顺序存储结构	顺序存储结构 线性链表



8.4 哈希查找

- ▶ 基本思想：在记录的存储地址和它的关键字之间建立一个确定的对应关系；这样，不经过比较，一次存取就能得到所查元素的查找方法
- ▶ 定义
 - ▶ 哈希函数——在记录的关键字与记录的存储地址之间建立的一种对应关系叫~
 - ▶ 哈希函数是一种映象，是从关键字空间到存储地址空间的一种映象
 - ▶ 哈希函数可写成： $\text{addr}(a_i) = H(k_i)$
 - ▶ a_i 是表中的一个元素
 - ▶ $\text{addr}(a_i)$ 是 a_i 的存储地址
 - ▶ k_i 是 a_i 的关键字





- ▶ 哈希表——应用哈希函数，由记录的关键字确定记录在表中的地址，并将记录放入此地址，这样构成的表叫~
- ▶ 哈希查找——又叫散列查找，利用哈希函数进行查找的过程叫~

例 30个地区的各民族人口统计表

编号	地区别	总人口	汉族	回族.....
1	北京			
2	上海			
⋮	⋮			

以编号作关键字，
构造哈希函数： $H(\text{key})=\text{key}$
 $H(1)=1$
 $H(2)=2$

以地区别作关键字，取地区名称第一个拼音字母的序号作哈希函数： $H(\text{Beijing})=2$
 $H(\text{Shanghai})=19$
 $H(\text{Shenyang})=19$



从例子可见：

- ▶ 哈希函数只是一种映象，所以哈希函数的设定很灵活，只要使任何关键字的哈希函数值都落在表长允许的范围之内即可
- ▶ 冲突： $key1 \neq key2$ ，但 $H(key1) = H(key2)$ 的现象
- ▶ 同义词：具有相同函数值的两个关键字，叫该哈希函数的
- ▶ 哈希函数通常是一种压缩映象，所以冲突不可避免，只能尽量减少；同时，冲突发生后，应该有处理冲突的方法



哈希函数的构造方法

▶ 直接定址法

- ▶ 构造：取关键字或关键字的某个线性函数作哈希地址，即 $H(\text{key})=\text{key}$ 或 $H(\text{key})=a \cdot \text{key}+b$
- ▶ 特点
 - ▶ 直接定址法所得地址集合与关键字集合大小相等，不会发生冲突
 - ▶ 实际中能用这种哈希函数的情况很少



数字分析法

- ▶ 构造：对关键字进行分析，取关键字的若干位或其组合作哈希地址
- ▶ 适于关键字位数比哈希地址位数大，且可能出现的关键字事先知道的情况

例 有80个记录，关键字为8位十进制数，哈希地址为2位十进制数

①②③④⑤⑥⑦⑧

⋮
8 1 3 | 4 6 5 3 | 2
8 1 3 | 7 2 2 4 | 2
8 1 3 | 8 7 4 2 | 2
8 1 3 | 0 1 3 6 | 7
8 1 3 | 2 2 8 1 | 7
8 1 3 | 3 8 9 6 | 7
8 1 3 | 6 8 5 3 | 7
8 1 4 | 1 9 3 5 | 5
⋮

分析：①只取8

②只取1

③只取3、4

⑧只取2、7、5

④⑤⑥⑦数字分布近乎随机

所以：取④⑤⑥⑦任意两位或两位
与另两位的叠加作哈希地址



▶ 平方取中法

- ▶ 构造：取关键字平方后中间几位作哈希地址
- ▶ 适于不知道全部关键字情况

▶ 折叠法

- ▶ 构造：将关键字分割成位数相同的几部分，然后取这几部分的叠加和（舍去进位）做哈希地址
- ▶ 种类
 - 移位叠加：将分割后的几部分低位对齐相加
 - 间界叠加：从一端沿分割界来回折送，然后对齐相加
- ▶ 适于关键字位数很多，且每一位上数字分布大致均匀情况



例 关键字为：0442205864，哈希地址位数为4

$$\begin{array}{r} 5864 \\ 4220 \\ \hline 04 \\ \hline 0088 \end{array}$$

$H(\text{key})=0088$

移位叠加

$$\begin{array}{r} 5864 \\ 0224 \\ \hline 04 \\ \hline 6092 \end{array}$$

$H(\text{key})=6092$

间界叠加



▶ 除留余数法

▶ 构造：取关键字被某个不大于哈希表表长 m 的数 p 除后所得余数作哈希地址，即 $H(\text{key}) = \text{key} \text{ MOD } p$ ， $p \leq m$

▶ 特点

□ 简单、常用，可与上述几种方法结合使用

□ p 的选取很重要； p 选的不好，容易产生同义词

▶ 随机数法

▶ 构造：取关键字的随机函数值作哈希地址，即 $H(\text{key}) = \text{random}(\text{key})$

▶ 适于关键字长度不等的情况





选取哈希函数的因素：

- 计算哈希函数所需时间
- 关键字长度
- 哈希表长度（哈希地址范围）
- 关键字分布情况
- 记录的查找频率





表处理冲突的方法

► 开放定址法

□ 方法：当冲突发生时，形成一个探查序列；沿此序列逐个地址探查，直到找到一个空位置（开放的地址），将发生冲突的记录放到该地址中，即 $H_i = (H(\text{key}) + d_i) \text{MOD } m$,
 $i = 1, 2, \dots, k (k \leq m - 1)$

其中： $H(\text{key})$ ——哈希函数

m ——哈希表表长

d_i ——增量序列



散列方法

- 线性探测再散列： $d_i = 1, 2, 3, \dots, m-1$
- 二次探测再散列： $d_i = 1^2, -1^2, 2^2, -2^2, 3^2, \dots, \pm k^2 (k \leq m/2)$
- 伪随机探测再散列： $d_i = \text{伪随机数序列}$



例

表长为11的哈希表中已填有关键字为17, 60, 29的记录,
 $H(\text{key}) = \text{key} \bmod 11$, 现有第4个记录, 其关键字为38,
按三种处理冲突的方法, 将它填入表中

0	1	2	3	4	5	6	7	8	9	10
			38	38	60	17	29	38		

- (1) $H(38) = 38 \bmod 11 = 5$ 冲突
 $H_1 = (5+1) \bmod 11 = 6$ 冲突
 $H_2 = (5+2) \bmod 11 = 7$ 冲突
 $H_3 = (5+3) \bmod 11 = 8$ 不冲突

- (2) $H(38) = 38 \bmod 11 = 5$ 冲突
 $H_1 = (5+1^2) \bmod 11 = 6$ 冲突
 $H_2 = (5-1^2) \bmod 11 = 4$ 不冲突

- (3) $H(38) = 38 \bmod 11 = 5$ 冲突
设伪随机数序列为9, 则:
 $H_1 = (5+9) \bmod 11 = 3$ 不冲突



▶ 再哈希法

- 方法：构造若干个哈希函数，当发生冲突时，计算下一个哈希地址，即： $H_i = R_{hi}(\text{key})$
 $i = 1, 2, \dots, k$

其中： R_{hi} ——不同的哈希函数


- 特点：计算时间增加

▶ 链地址法

- 方法：将所有关键字为同义词的记录存储在一个单链表中，并用一维数组存放头指针




例 已知一组关键字(19,14,23,1,68,20,84,27,55,11,10,79)
哈希函数为: $H(\text{key}) = \text{key} \text{ MOD } 13$,
用链地址法处理冲突





哈希表查找过程及分析



▶ 哈希查找分析

- ▶ 哈希查找过程仍是一个给定值与关键字进行比较的过程
- ▶ 评价哈希查找效率仍要用 ASL
- ▶ 哈希查找过程与给定值进行比较的关键字的个数取决于：
 - 哈希函数
 - 处理冲突的方法
 - 哈希表的填满因子 $\alpha = \text{表中填入的记录数} / \text{哈希表长度}$



例 已知一组关键字(19,14,23,1,68,20,84,27,55,11,10,79)
哈希函数为: $H(\text{key}) = \text{key} \text{ MOD } 13$, 哈希表长为 $m=16$,
设每个记录的查找概率相等

(1) 用线性探测再散列处理冲突, 即 $H_i = (H(\text{key}) + d_i) \text{ MOD } m$

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
	14	1	68	27	55	19	20	84	79	23	11	10			

$$H(19)=6$$

$$H(11)=11$$

$$H(14)=1$$

$$H(10)=10 \text{ 冲突, } H_1=(10+1)\text{MOD}16=11$$

$$H(23)=10$$

$$\text{冲突, } H_2=(10+2)\text{MOD}16=12$$

$$H(1)=1 \text{ 冲突, } H_1=(1+1)\text{MOD}16=2$$

$$H(79)=1 \text{ 冲突, } H_1=(1+1)\text{MOD}16=2$$

$$H(68)=3$$

$$\text{冲突, } H_2=(1+2)\text{MOD}16=3$$

$$H(20)=7$$

$$\text{冲突, } H_3=(1+3)\text{MOD}16=4$$

$$H(84)=6 \text{ 冲突, } H_1=(6+1)\text{MOD}16=7$$

$$\text{冲突, } H_4=(1+4)\text{MOD}16=5$$

$$\text{冲突, } H_2=(6+2)\text{MOD}16=8$$

$$\text{冲突, } H_5=(1+5)\text{MOD}16=6$$

$$H(27)=1 \text{ 冲突, } H_1=(1+1)\text{MOD}16=2$$

$$\text{冲突, } H_6=(1+6)\text{MOD}16=7$$

$$\text{冲突, } H_2=(1+2)\text{MOD}16=3$$

$$\text{冲突, } H_7=(1+7)\text{MOD}16=8$$

$$\text{冲突, } H_3=(1+3)\text{MOD}16=4$$

$$\text{冲突, } H_8=(1+8)\text{MOD}16=9$$

$$H(55)=3 \text{ 冲突, } H_1=(3+1)\text{MOD}16=4$$


$$ASL = (1 \times 6 + 2 \times 3 + 3 \times 3 + 4 \times 9) / 12 = 2.5$$

$$\text{冲突, } H_2=(3+2)\text{MOD}16=5$$



关键字(19,14,23,1,68,20,84,27,55,11,10,79)

(2) 用链地址法处理冲突



$$ASL = (1 \times 6 + 2 \times 4 + 3 + 4) / 12 = 1.75$$



Take-home Message

- 顺序查找是最自然的一种查找方式，效率低
- 折半查找利用了有序信息，形成了查找树，效率高
- 分块查找结合了折半和顺序查找的优势
- 哈希查找算法利用了哈希函数建立数据的直接存储地址，效率更优，是大规模搜索的基础